

CS 153: Infrastructure at Scale

Lecture 06

国家级基础设施与数字化转型

沙特通信与信息技术部长 Abdullah Alswaha 访谈

课程	Stanford CS 153: Infrastructure at Scale
嘉宾	Abdullah Alswaha (沙特通信与信息技术部长)
形式	炉边对谈 + 学生问答
频道	Stanford CS 153
发布日期	2025-03-07
时长	52:17
视频链接	https://www.youtube.com/watch?v=LriOr64E8D8

目录

1 引言：从硅谷工程师到国家级技术领导者	3
1.1 本章小结	3
2 AI 时代与互联网时代的历史镜像	3
2.1 本章小结	4
3 计算架构的三大技术挑战	4
3.1 挑战一：Von Neumann 瓶颈与能效问题	4
3.2 挑战二：化合物半导体	5
3.3 挑战三：互连架构与光子计算	5
3.4 内存架构的三种范式	5
3.5 本章小结	6
4 数据中心建设：规模、成本与能效	6
4.1 沙特的数据中心建设规模	6
4.2 数据中心经济学	6
4.3 基础设施规划的时间尺度矛盾	7
4.4 本章小结	7
5 AI 应用的三大前沿用例	7
5.1 用例一：Generative AI — 药物研发加速	7
5.2 用例二：Agentic AI — 能源行业优化	8
5.3 用例三：Physical AI — 全机器人心脏移植	8
5.4 本章小结	8
6 开源模型与”无模型信仰”战略	8
6.1 从互联网协议之争到模型生态	8
6.2 Model Agnostic（模型无关）策略	9
6.3 本章小结	9
7 基础设施投资、数字鸿沟与公平性	9
7.1 基础设施投资是”无悔投资”	9
7.2 Training vs Inference 的比例演变	10
7.3 数字鸿沟的历史教训	10
7.4 数据大使馆与虚拟化	10
7.5 本章小结	11
8 太空产业与 NEOM 智慧城市	11
8.1 AI 与太空的交汇	11
8.2 NEOM：新市场颠覆者	11
8.3 本章小结	12

9 新兴计算范式与机器人技术	12
9.1 In-Memory Computing (存内计算)	12
9.2 机器人技术的三大方向	12
9.3 本章小结	13
10 Agentic AI 与政府数字化转型	13
10.1 沙特的数字化转型成就	13
10.2 Agentic AI 在政府中的应用	13
10.3 本章小结	14
11 总结与延伸	14
11.1 拓展阅读	15

1 引言：从硅谷工程师到国家级技术领导者

本讲是 Stanford CS 153 (Infrastructure at Scale) 课程的第六讲，邀请了沙特阿拉伯通信与信息技术部部长 Abdullah Alswaha 进行炉边对谈。Alswaha 的独特之处在于，他本质上是一位工程师而非典型的政府官僚——他的职业生涯始于硅谷，在 Cisco (San Jose, Building 10) 编写 IOS (Internetwork Operating System) 代码。

CS 153 课程背景

Stanford CS 153: Infrastructure at Scale 是一门关注大规模基础设施系统的课程，涵盖从硬件到软件的完整技术栈。课程邀请业界领袖分享在数据中心、计算架构、能源系统等领域的实践经验与战略思考。

Alswaha 将自己的人生旅程概括为三个阶段：**Learn** (学习与知识获取)、**Earn** (积累专业经验并证明自己)、**Return** (回馈社会与国家)。他在 Cisco 工作期间，正值该公司市值接近 5000 亿美元（按通胀调整约为今天的 1 万亿美元），是当时全球最有价值的公司。

信噪比 (Signal-to-Noise Ratio) 思维

Alswaha 强调，作为工程师出身，他非常推崇 **Signal-to-Noise Ratio** (信噪比) 的思维方式：只要你作为个人和领导者的核心信号足够清晰、足够强大，就能超越周围的噪声。历史告诉我们，变化和不确定性始终伴随着我们，关键是提取正确的信号。

他指出，历史上的基础设施建设高峰期，往往由具有工程或私营部门背景的领导者推动——从早期新加坡到美国建国时期莫不如此。纯粹的行政官僚主导基础设施建设是相对晚近的现象。

1.1 本章小结

Alswaha 是一位罕见的“技术官僚” (Technocrat)，他将硅谷的工程思维带入了国家治理。他的核心理念是：在充满噪声的时代，领导者必须具备从纷繁信息中提取关键信号的能力。

2 AI 时代与互联网时代的历史镜像

Alswaha 提出的第一个核心信号是：当前 AI 时代的发展轨迹与互联网时代高度相似。

互联网时代的教训

在互联网时代的早期，Cisco 大量向客户推销路由器和交换机，但并没有真正理解应用层面的价值。只有当出现创新触发点——远程医疗 (Telemedicine)、在线教育 (Tele-education)、政务科技 (GovTech)、从“红色胶带”到“红毯服务”的官僚改革——网络技术才真正改变了人们工作、生活、娱乐和学习的方式。

当前的 AI 领域正在重演同样的模式：

1. **硬件炒作阶段**：大量资金涌入 GPU、数据中心等硬件基础设施
2. **价值转移**：在互联网时代，每 1 美元的硬件投入最终催生了 10-20 美元的软件和服务收入

3. **GenAI 的 SaaS 时刻**：当前的 GenAI 热潮正在镜像当年的 B2B SaaS 浪潮，真正的价值将来自技术在各行业和垂直领域的扩散

从 Benchmark 到生产力的鸿沟

Alswaha 直言，许多硅谷初创公司能够以 500–600 万美元的成本刷出漂亮的 Benchmark 数据，但他更关心的是：**这对 GDP 意味着什么？对生产力意味着什么？**如果你无法用简单的语言向决策者解释你的技术突破如何创造就业、提升 GDP、改善效率，那你对决策者来说就不具有相关性。

Alswaha 指出，过去两年 AI 领域的变化速度甚至超过了他在 Cisco 二十年所经历的变化总和。他用《丁丁历险记》中的一个梗来形容这种节奏——Haddock 船长说“天哪，真是漫长的一周”，而丁丁回答“船长，今天才周一”。

2.1 本章小结

AI 时代正在重复互联网时代的演进模式：先是硬件狂热，然后是应用层的爆发式增长。但关键的区别在于变化速度更快，这要求决策者和创业者必须更加敏捷。真正的价值不在于跑分，而在于技术对实体经济的影响。

3 计算架构的三大技术挑战

Alswaha 以技术专家的视角，系统性地阐述了当前计算架构面临的三大核心挑战，并将每一项都视为价值数百亿美元的创业机会。

3.1 挑战一：Von Neumann 瓶颈与能效问题

Von Neumann 架构的根本性低效

当前的计算架构（无论 CPU 还是 GPU）遵循 Von Neumann 架构：执行单元与存储（数据和指令集）分离。每次从内存取数据都要消耗能量：

- 访问内存 (DRAM)：~1 瓦特
- 访问固态存储 (SSD)：~10 瓦特
- 通过互连 (Interconnect) 传输：更多瓦特

当这些操作乘以数十亿次访问时，累积的能耗极为可观。

Stanford 此前发表的 **Memory Wall** 论文清晰地揭示了这一问题：过去 20 年，按照摩尔定律，TFLOPS（晶体管数量）增长了约 60,000 倍，但内存带宽和互连速度仅以每 2 年翻倍的速率增长（约 1.4–1.7 倍），形成了巨大的剪刀差。

Memory Wall (内存墙)

Memory Wall 是指处理器计算速度与内存访问速度之间日益扩大的差距。随着 AI 模型规模爆炸式增长，这一瓶颈变得更加严峻——当前 GPU 和 NPU 的成本中，约 40% 来自高带宽内存 (HBM)。

3.2 挑战二：化合物半导体

Alswaha 指出，传统硅基架构已经“过时”。硅的带隙 (Band Gap) 约为 1.1 eV，限制了开关速度和能效。他呼吁业界向**化合物半导体** (Compound Semiconductors) 过渡，例如**氮化镓** (Gallium Nitride, GaN)，因为其更宽的带隙允许更快的开关速度和更低的漏电流。

不要对特定架构产生“技术信仰”

Alswaha 警告，过去某些公司因为对特定架构（如 x86、CISC/RISC）的过度依恋而陷入困境。他主张“No Technology Religion” (无技术信仰)，这一原则同样适用于当前的 AI 模型选择——不应该对任何特定模型产生依赖。

3.3 挑战三：互连架构与光子计算

Alswaha 在 1990 年代就参与了 InfiniBand 的工作，他指出光电转换 (Optical-to-Electrical Conversion) 中的损耗是当前互连架构的主要瓶颈。每次从光信号转换为电信号都会产生泄漏和损耗，**AI 光子互连** (Photonic AI Architectures) 的突破早已过期。

三大百亿美元级创业机会

Alswaha 向 Stanford 学生明确指出三个“下一个百亿美元市场”的机会方向：

1. **化合物半导体**：从硅过渡到 GaN 等宽带隙材料
2. **新型内存架构**：突破 Von Neumann 架构的分离式设计
3. **光子互连**：消除光电转换损耗，实现全光通信

沙特方面表示愿意为这些方向的初创公司提供数十亿美元的投资支持。

3.4 内存架构的三种范式

Alswaha 详细介绍了当前三种主要的内存访问架构：

表 1: 三种内存架构范式对比

架构类型	内存位置	代表厂商/技术	特点
Memory-on-Chip	芯片上 (SRAM)	Groq (LPU)	极快但仅适合文本
Memory-next-to-Chip	芯片旁 (DRAM)	Qualcomm (NPU)	平衡速度与容量
Memory-on-the-side	芯片侧 (HBM/SSD)	NVIDIA, AMD	大容量多模态

沙特与以上所有类型的厂商都有合作。Groq 的 LPU 利用 SRAM 实现了极快的推理速度，但

局限于文本处理；Qualcomm 的 NPU 使用 DRAM 提供更灵活的方案；NVIDIA 和 AMD 则依赖 HBM 架构支持大规模多模态工作负载。

3.5 本章小结

计算架构正面临三重瓶颈：Von Neumann 分离式架构导致的能效低下、硅基半导体性能天花板、以及光电转换损耗。这三个方向各自对应着百亿美元级的市场机遇，而 In-Memory Computing (存内计算) 被 Alswaha 视为最有前景的突破方向之一。

4 数据中心建设：规模、成本与能效

4.1 沙特的数据中心建设规模

沙特目前正在建设 **1.5–2 GW** 的计算容量。Alswaha 提到，沙特在 NEOM 项目中与 DataVault Investments 合作，正在建设一个 **1.5 GW 的 Shell Data Center** (外壳数据中心)，用于托管超大规模客户 (Hyperscalers)。

数据中心的”能源税”

Alswaha 指出，当前数据中心的一个核心痛点是 **50% 的能源税**——每建设 1 GW 的数据中心，实际到达 GPU 的功率只有约一半：

- **电压转换**：高压到低压的 step-down 约消耗 100 MW/GW
- **冷却**：液冷 (Liquid Cooling)、浸没式冷却 (Immersion Cooling)
- **网络与存储**：交换机、存储阵列等辅助设备

他呼吁下一代计算架构应确保尽可能多的电力直接送达 GPU。

4.2 数据中心经济学

表 2: 数据中心建设成本概览

项目	成本 (每 MW)
Shell Data Center (不含计算设备)	\$8–12M
含计算设备 (GPU/NPU/LPU)	\$20–30M

成本取决于合作伙伴的选择——Groq、SambaNova、NVIDIA、AMD 等不同厂商的定价差异显著。沙特利用其 SambaNova 合作伙伴关系，帮助 Aramco 实现了 AI 在工业领域的落地。

4.3 基础设施规划的时间尺度矛盾

GPU 迭代速度 vs 数据中心建设周期

数据中心建设面临严重的时间尺度矛盾：

- GDP 层面的规划周期：数十年
- 数据中心从选址到上线：18–36 个月
- GPU 架构迭代周期：18–24 个月

例如，Blackwell 相比 H100 仅在 24 个月内就实现了 2.5 倍性能提升。数据中心在建成时可能已经面临设备过时的风险。沙特的应对方式是以 4 个月的极限速度完成了 Groq 节点的部署（被戏称为“Founder Mode”）。

Alswaha 的解决思路是：不要试图预测计算架构的走向，而是从用例和工作负载倒推（Work Backwards from Use Cases）。只要关键用例能够被满足，就能在架构迭代中保持韧性。

市场塑造者 vs 市场响应者

Alswaha 区分了两类参与者：Market Shapers（市场塑造者）和 Market Responders（市场响应者）。在 AI 时代，最成功的策略是两者兼顾——既要有远见地布局基础设施，又要敏捷地响应技术变革。不能仅仅“建好了等客来”，也不能完全被动等待用例成熟。

4.4 本章小结

沙特正在建设 GW 级别的数据中心集群，但面临着 50% 能源税和 GPU 快速迭代的双重挑战。其策略是采用 Shell Data Center 模式（先建外壳，灵活填充计算设备），并以用例驱动的方式进行基础设施投资决策。

5 AI 应用的三大前沿用例

Alswaha 详细介绍了沙特在三个 AI 方向上的标志性用例，这些用例被世界经济论坛评选为全球最具代表性的 AI 实际应用之一。

5.1 用例一：Generative AI — 药物研发加速

NanoPal：AI 驱动的镰状细胞病药物研发

沙特国家实验室孵化的初创公司 NanoPal，利用 Generative AI 将镰状细胞病（Sickle Cell Disease）的药物配方研发周期从 10 年缩短至 2–3 年。具体做法是：

1. 利用 GenAI 分析不同排列组合的药物特性和属性
2. 设计搭载 CRISPR 基因编辑技术的纳米机器人
3. 精准剪切导致镰状细胞的致病基因

镰状细胞病影响中东和非洲地区约 2000 万人，导致截肢甚至死亡。

AI 加速 ≠ 跳过治理

Alswaha 强调了一个重要教训：虽然 GenAI 能大幅缩短药物配方阶段的时间，但**临床试验的治理流程不能跳过**。仍然需要经历：

- 第一阶段：毒性和副作用评估
- 第二阶段：有效性验证 (Efficacy)
- 第三阶段：完整审批

这体现了 AI 治理的核心原则：**基于风险评估的行业特异性监管** (Risk-Based Assessment per Industry)，在促进创新与确保安全之间寻找平衡。

5.2 用例二：Agentic AI — 能源行业优化

沙特与 SambaNova 合作，为 **Aramco**（全球最大的能源公司之一）部署了 Agentic AI 系统：

- 分析油井的**孔隙率** (Porosity)，优化钻井运行次数
- 管理管道**腐蚀** (Corrosion)，进行预测性维护
- 将专家智慧”民主化” (Democratize)，使 CEO 和工程团队能够直观理解节约方案

成果：为 Aramco 节省了约 10 亿美元。

5.3 用例三：Physical AI — 全机器人心脏移植

全球首例全机器人心脏移植手术

沙特完成了世界首例**全机器人辅助心脏移植手术**，利用 AI 驱动的手术机器人：

- 传统手术：切口 20–30 cm，ICU 住院 6–8 周
- 机器人手术：切口仅 **2–3 cm**，手术不到 4 小时，患者 **48 小时内出院**

这一突破为远程手术 (Remote Surgery)、缓解心脏外科医生短缺等问题开辟了全新可能。

5.4 本章小结

沙特的三大 AI 用例分别覆盖了 Generative AI (药物研发)、Agentic AI (工业优化) 和 Physical AI (手术机器人)，均以解决实际问题为导向。核心理念是：AI 的价值不在于跑分，而在于创造就业、提升 GDP、拯救生命。

6 开源模型与”无模型信仰”战略

6.1 从互联网协议之争到模型生态

Alswaha 用互联网历史类比当前的模型竞争格局：

IP 协议的胜出之路

在互联网早期，多种网络协议并存竞争。最终，IP 协议通过标准化（NIST 标准、DoD 认证等）胜出，虽然部分专有系统仍然存在。Alswaha 预测 AI 模型领域将走类似道路：闭源和开源模型将长期共存，最终行业会形成某种标准化方法。

6.2 Model Agnostic（模型无关）策略

Alswaha 明确表示沙特采取**模型无关**立场：“无论哪个模型能帮我拯救生命、提升效率、创造 GDP 和生产力，我们就用它。”这一策略的具体体现：

- 投资 **Mistral**，看重其在 Mission-Critical 领域的解决方案能力
- 与 Groq 合作，部署全球最具成本效益的推理基础设施
- 在 Groq 平台上上线所有主流模型：Llama、DeepSeek、Mistral、Cohere 等
- **Saba**（Mistral 为沙特训练的阿拉伯语模型）周一发布，周五就在 Groq 上线

不要对特定模型产生”信仰”

Alswaha 将 Cisco 时代的”No Technology Religion”原则延伸为”**No Model Religion**”。他指出：

- 模型之间可以**相互借鉴**——DeepSeek 就借鉴了 Mistral 的 Mixture of Experts (MoE) 实现
- 世界将收敛到一个**多模型生态**：闭源/开源、大/小模型并存
- 对特定方法的过度依赖在快速变化的市场中是危险的

6.3 本章小结

沙特采取模型无关的务实策略，不押注单一模型或技术路线。通过与 Groq、Mistral 等公司的合作，沙特致力于成为全球最具成本效益的 AI 推理服务提供者，同时保持技术生态的开放性。

7 基础设施投资、数字鸿沟与公平性

7.1 基础设施投资是”无悔投资”

Alswaha 提出了国家级 AI 基础设施投资的决策框架。他引用 ITU（国际电信联盟）的研究指出：**宽带渗透率每提高 10 个百分点，2–4 年内 GDP 增长 1–2%**。他认为 AI 基础设施将扮演类似角色。

AI 基础设施投资的三大前提条件

Alswaha 认为，对于满足以下条件的国家，AI 基础设施投资是“无悔决策”（No-Regret Investment）：

1. **能源优势**：沙特正在上线 20 GW 的可再生能源，拥有全球最低的太阳能和风能发电成本（以“美分/千瓦时”计）
2. **人口规模**（Captive Market）：约 3000 万人口的市场门槛——与 SaaS 时代、互联网企业和 AI 的市场启动规模一致
3. **资本充裕**：有能力进行长周期的基础设施投资

7.2 Training vs Inference 的比例演变

Alswaha 指出当前的计算负载分布为 **70% Training / 30% Inference**，但随着技术扩散和用例成熟，这一比例将**翻转**。问题是“何时翻转”而非“是否翻转”。

7.3 数字鸿沟的历史教训

数字时代的失败承诺

Alswaha 尖锐地指出数字时代的一大失败：

- **承诺**：互联网将成为最大的社会均衡器（Social Equalizer）和经济乘数器（Economic Multiplier）
- **现实**：全球南方每赚 1 美元，全球北方赚 3.5–4 美元
- **AI 时代的风险**：到 2030 年，乐观估计只有 7–20 亿人进入智能时代，**留下约 70 亿人**

这意味着每 10 个人中有 8 个将被排除在 AI 红利之外——这不是一项通用技术应有的表现。

Alswaha 引用 Sam Altman 的观点：如果全球经济持续以 2–3% 的速度增长，即使是创新者和企业家也无法真正繁荣。因此，AI 基础设施的公平分配不仅是道德问题，也是商业利益的要求。

沙特的桥梁角色

沙特将自身定位为连接“全球北方”技术与“全球南方”需求的桥梁。在中东和非洲地区的 15 家独角兽中，有 7 家受到了沙特的投资支持。沙特利用自身的能源优势、资本和市场规模，致力于让 AI 技术惠及更广泛的人群。

7.4 数据大使馆与虚拟化

Alswaha 介绍了**数据大使馆**（Data Embassies）的概念，这是一种解决跨境 AI 工作负载治理问题的创新机制：

- 类比物流领域的**过境免检**（Safe Harbor）条款
- 美国初创公司可以在沙特数据中心运行工作负载，但该工作负载遵守美国法律

- 类似于微服务架构中的分布式部署——X (Twitter) 的通知引擎可能在阿姆斯特丹，分析系统可能在美国
- 如果某项内容在沙特合规但由欧洲的工作负载提供服务，则不受沙特管辖

7.5 本章小结

沙特视 AI 基础设施为“无悔投资”，但同时警惕数字鸿沟的加剧。通过数据大使馆机制和低成本推理服务，沙特试图构建一个对全球开发者友好的基础设施生态，同时维护各国的数据主权。

8 太空产业与 NEOM 智慧城市

8.1 AI 与太空的交汇

Alswaha 将太空产业比作 AI 技术栈的另一个维度：

太空经济的上下游结构

- **上游 (Upstream)**：太空探索——月球任务、火星计划
- **下游 (Downstream)**：商业应用
 - 太空通信：LEO (低轨道)、MEO (中轨道)、GEO (地球同步轨道)
 - 地球观测 (Earth Observation)：气候监测、环境保护
 - 导航：影响欧盟 11% 的 GDP，沙特自身 6-7% 的 GDP

太空产业要实现 2 万亿美元的目标，必须与 AI 深度融合。

AI + 太空在沙特已经产生了实际成果：利用**地理空间数据**和**卷积网络** (Convolutional Networks)，沙特解决了**随机耕种**问题——此前，随机耕种导致地下水浪费量达到实际需求的 3 倍，并加剧了 75% 的荒漠化效应。通过 AI 优化，水资源浪费减少了 **66%**。

沙特正在与 SpaceX、Lockheed Martin 等多方合作，并认为 LEO/MEO/GEO 的融合（而非单一依赖某一轨道）才是下一代通信的正确方向。

8.2 NEOM：新市场颠覆者

NEOM 的战略定位

NEOM 不仅是一个智慧城市项目，更是沙特的**创新试验田** (Test Bed) 和**北极星** (True North)。在克里斯坦森的创新理论框架中，NEOM 充当的是**新市场颠覆者** (New Market Disruptor)，推动社会突破创新边界。

NEOM 的核心创新方向：

- **绿色氢能**：4 GW 的绿色氢能设施，利用红海的电解水技术将氢气和氧气分离，以氢气作为清洁能源，帮助沙特从热能过渡到“绿色光子、电子和氢气”的完整能源周期
- **数据中心**：1.5 GW Shell Data Center，由绿色氢能供电
- **城市设计革命**：打造“5 分钟城市”——在 5 分钟步行范围内完成工作、生活、娱乐和学习

为人设计的城市，而非为车设计的城市

Alswaha 指出，自工业革命（约 300 年前）以来，城市一直是为汽车设计的，而非为人设计的。NEOM 的目标是彻底颠覆这一范式，创建以人为中心的城市空间。这是一个跨越 20-30 年的长期挑战。

8.3 本章小结

太空产业与 AI 的深度融合正在沙特产生实际价值（精准农业、水资源管理）。NEOM 作为国家级创新试验田，不仅在探索绿色能源和数据中心的新范式，更在重新思考城市设计的根本逻辑。

9 新兴计算范式与机器人技术

9.1 In-Memory Computing（存内计算）

Alswaha 个人最看好的新兴计算范式是 In-Memory Computing(存内计算)和 Near-Memory Computing（近存计算）。

存内计算的能效优势

存内计算通过将执行、数据和指令集**统一在内存中**，从根本上消除了 Von Neumann 架构的数据搬运开销。以 H100 为例：

- 当前功耗：根据精度配置不同，约 600W 以上
- 存内计算方案：完成相同 TFLOPS 的计算，能耗**至少降低 50%**

目前学术界已有大量相关论文，多家初创公司也开始出现在资本市场上（通过论文发表 → 原型验证 → 财报电话会议的路径可以追踪趋势）。

Alswaha 同时关注的其他新兴范式包括：

- **AI 光子学**（AI Photonics）：全光计算，消除光电转换损耗
- **化合物半导体**：GaN 等宽带隙材料
- **类脑计算**（Brain-Inspired Computing）：学生提问中提及的方向

Von Neumann 架构的历史惯性

Von Neumann 架构诞生于 **1945 年**，至今已有 80 年历史。CISC、RISC、x86 等指令集架构虽然在此基础上做了大量优化，但根本性的计算与存储分离问题从未真正解决。Alswaha 警告，某些公司因过度依赖特定指令集架构而付出了巨大代价。

9.2 机器人技术的三大方向

1. **医疗机器人**：如前述全机器人心脏移植手术，远程手术的实现将根本性地改变医疗资源分配
2. **Robotaxi**（自动驾驶出租车）：沙特正与多家 Stanford 系初创公司合作，将重复性驾驶任务自动化，释放人力到更高价值的经济活动中

3. **太空机器人**：与 Intuitive Machines 合作，开发用于月球**水资源提取**的 Rover（月球车），目标是将极端环境下的技术方案转化为解决地球水资源稀缺问题的工具

9.3 本章小结

存内计算是突破 Von Neumann 瓶颈最有前景的方向，有望将 AI 计算能效提升一倍。在机器人技术方面，医疗、交通和太空探索是沙特最看好的三大应用领域，每个方向都与解决实际社会问题紧密关联。

10 Agentic AI 与政府数字化转型

10.1 沙特的数字化转型成就

在王储 Mohammed bin Salman 2016 年首次硅谷之行后，Alswaha 从 Cisco 转入沙特政府服务。在他的领导下，沙特实现了：

表 3: 沙特数字化转型关键指标

指标	初始值	当前值
数字经济规模	—	\$1350 亿
数字经济增长率（7 年）	—	60%
技术人才规模	15 万	38.1 万
LEAP 科技大会参与者	—	20 万 +
LEAP 投资公告总额	—	\$130–140 亿

LEAP 科技大会

LEAP 是沙特举办的大型科技盛会，每年 2 月在利雅得举行。2025 年吸引了超过 20 万参与者和 2000 家初创公司，投资公告总额达 130–140 亿美元。Alswaha 向 Stanford 学生发出了公开邀请，参加 2026 年 2 月的下一届 LEAP。

10.2 Agentic AI 在政府中的应用

Alswaha 透露了一个公开的 Agentic AI 项目：为沙特政府公务员**增强和提升生产力**，预计可创造**数十亿美元**的生产力收益。

在扫描市场后，他将 Agentic AI 的参与者分为两类：

AI-Enhanced vs AI-Native 的关键区别

1. **AI-Enhanced** (AI 增强型)：传统 B2B SaaS 公司，在医疗、HR、财务等垂直领域拥有专有数据和 Fortune 500 客户的供应链集成。它们尝试将数据喂给 AI 模型以构建 Agentic AI——在**任务级别** (Task Level) 取得了一些成功，但在**工作流级别** (Workflow Level) 和**多 Agent 级别**尚未看到显著成果。
2. **AI-Native** (AI 原生型)：从一开始就以 AI 为核心设计的公司，专注于解决**数据层** (Data Layer) 和**人在环路中** (Human-in-the-Loop) 的问题。它们在数据创建和数据清洗方面具有独特优势。

Agentic AI 的真正瓶颈

Alswaha 指出，很多人认为 Agentic AI 的挑战在于**模型**，但实际上瓶颈在于**数据**和**商业模式**。AI-Native 公司之所以更有潜力，是因为它们更擅长处理数据质量和人机交互的核心问题。

10.3 本章小结

沙特在 7 年内实现了数字经济 60% 的增长和技术人才规模的翻倍。在 Agentic AI 领域, Alswaha 更看好 AI-Native 公司而非传统 SaaS 公司的 AI 改造，因为核心挑战在于数据和商业模式创新，而非模型本身。

11 总结与延伸

本讲通过沙特通信与信息技术部部长 Abdullah Alswaha 的视角，呈现了国家级 AI 基础设施建设的全景图。核心要点总结如下：

1. **历史镜像**：AI 时代正在重复互联网时代的发展轨迹，硬件热潮之后必然迎来应用层爆发，每 1 美元硬件投入将催生 10-20 美元的软件和服务价值
2. **三大技术瓶颈**：化合物半导体、新型内存架构、光子互连——各自对应百亿美元级创业机会
3. **数据中心经济学**：50% 能源税是核心痛点，Shell Data Center + 用例驱动是应对 GPU 快速迭代的策略
4. **用例优先**：从 Benchmark 到生产力的转化是关键——药物研发、工业优化、手术机器人是三个标杆
5. **无模型信仰**：Model Agnostic 策略，开源与闭源并行，以实际效用为唯一标准
6. **公平性**：数字时代留下了巨大的南北鸿沟，AI 时代不能重蹈覆辙——数据大使馆和低成本推理是解决方案
7. **新兴范式**：In-Memory Computing 有望将计算能效提升一倍，突破 80 年历史的 Von Neumann 瓶颈
8. **Agentic AI 的本质**：瓶颈在数据和商业模式，不在模型

Alswaha 的人生哲学: Learn / Earn / Return

Alswaha 将人生总结为三个阶段: 学习获取知识、积累经验证明自己、回馈社会与国家。他引用了一句阿拉伯谚语: ”人生之旅会停滞, 除非你做三件事——获取并传播知识、培养下一代、回馈社会。”这不仅是他个人的座右铭, 也是他鼓励 Stanford 学生思考的职业框架。

11.1 拓展阅读

- **Stanford Memory Wall 论文**: 探讨处理器与内存速度差距的经典研究
- **ITU Broadband-GDP 研究**: 宽带渗透率与 GDP 增长的量化关系
- **Groq LPU 架构白皮书**: 了解 SRAM-based Language Processing Unit 的设计理念
- **SambaNova RDU 架构**: Reconfigurable Dataflow Unit 的设计与 Aramco 案例
- **NEOM 官方文档**: <https://www.neom.com/> — 了解沙特智慧城市和绿色氢能计划
- **LEAP 科技大会**: <https://oneleap.com/> — 沙特年度旗舰科技活动
- **In-Memory Computing 综述**: IEEE/ACM 近年关于存内计算和近存计算的学术综述
- **GaN 化合物半导体**: 了解宽带隙材料在功率电子和 AI 芯片中的应用前景