

课程笔记

CS224R Lecture 1: 深度强化学习导论

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-04

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 课程定位：什么是深度强化学习	2
1.1 与监督学习的核心区别	2
1.2 课程范围与目标	2
1.3 本章小结	2
2 为什么学习深度强化学习	3
2.1 超越监督学习	3
2.2 广泛应用于高性能 AI 系统	3
2.3 学习的本质	5
2.4 本章小结	5
3 建模行为与强化学习基础	5
3.1 经验的数据表示	5
3.2 状态与观察的区别	5
3.3 用神经网络表示行为	5
3.4 强化学习的目标	6
3.5 随机策略的意义	6
3.6 价值函数与 Q 函数	6
3.7 算法类型概览	6
3.8 本章小结	6
4 总结与延伸	7
4.1 拓展阅读	7

1 课程定位：什么是深度强化学习

CS224R 的第一讲从最根本的问题出发：什么是深度强化学习 (Deep Reinforcement Learning)，它与传统的机器学习有什么不同，以及为什么值得学习。

深度强化学习的定义

深度强化学习研究的是**序贯决策问题** (Sequential Decision-Making Problems)：系统需要基于信息流不断地“观察——行动——观察——行动”。课程同时研究这类问题的**解法**，包括 imitation learning、online/offline RL、model-free/model-based RL、multi-task/meta RL 以及 RL for LLMs 和 RL for robots。所有方法都强调能扩展到深度神经网络。

1.1 与监督学习的核心区别

在监督学习中，我们拥有标注数据 $\{(x_i, y_i)\}$ ，目标是学习一个函数 $f(x) \approx y$ 。数据点之间是独立同分布 (i.i.d.) 的，并且我们被**直接告知**正确的输出。

在强化学习中，情况完全不同：

- **目标**：学习行为策略 $\pi(a | s)$ ，将状态映射到动作。
- **反馈**：不是直接告诉答案，而是通过**间接反馈**（如奖励信号）从经验中学习。
- **数据非 i.i.d.**：智能体的动作 a 会影响未来的观察 s' ，因此数据分布取决于当前策略。

行为的多种形态

深度强化学习中的“行为”可以包括：机器人的运动控制、聊天机器人的对话、游戏的策略、自动驾驶的决策、Web agent 的操作等。这些场景的共同特点是：模型的输出（动作）会对环境产生后果，进而影响未来的输入。

1.2 课程范围与目标

Chelsea Finn 明确指出，这门课不可能覆盖深度强化学习的所有内容。课程聚焦于：

- 深度 RL 方法背后的**核心概念**，以便学生能理解更高级的方法。
- 算法的**实现**，使学生能够自己编程实现。
- 以**机器人控制和语言模型**为主要示例，但技术具有更广泛的适用性。

1.3 本章小结

深度强化学习是关于序贯决策的学科。与监督学习相比，RL 面临的独特挑战包括：反馈是间接的、数据是非 i.i.d. 的、动作有后果。课程的核心目标是让学生能够理解和实现现有和新兴的深度 RL 方法。

2 为什么学习深度强化学习

2.1 超越监督学习

许多真实世界的 AI 应用不只是简单的输入输出映射。讲者给出几个关键场景：

1. **决策有后果**：如 Spotify 推荐歌曲后，下一次推荐应该避免重复同一首歌，且应保持风格连续性。
2. **直接监督不可得**：如编码助手（Cursor、Copilot），用户只能给出”好”或”不好”的反馈，而非直接提供正确输出。
3. **目标不可微**：很多实际目标（如用户满意度）无法通过梯度直接优化。

Why study deep reinforcement learning?

Beyond supervised learning from (x, y) examples

Decision-making problems are everywhere!

- a. Any sort of AI agent: robots, autonomous vehicles, web assistants
- b. What if you want your AI system to interact with people? chatbots, recommenders
- c. What if deploying your system affects future outcomes & observations?
- d. What if don't have labels or your objective isn't just accuracy? "feedback loops"
(and isn't differentiable!)

18

图 1：课程用“部署会改变未来观测”这一视角解释为什么序贯决策问题不能退化为普通监督学习 (Slide 18)。

2.2 广泛应用于高性能 AI 系统

讲者展示了大量深度 RL 的实际应用：

- **机器人**：Unitree 的四足机器人行走、Physical Intelligence 的 π_0 操作、Google Gemini Robotics。
- **游戏**：AlphaGo 的 Move 37 展示了 RL 发现人类未曾想到的新策略的能力。
- **大语言模型**：几乎所有现代 LLM 都使用某种形式的 RL 进行 post-training，尤其是在高级推理方面。
- **其他**：交通控制、生成式图像模型的 prompt 遵循、芯片设计（Google TPU）。

Why study deep reinforcement learning?

Widely used for performant AI systems

Learning complex physical tasks: legged robots



19

图 2: 深度 RL 已经成为复杂机器人系统的重要训练范式, 尤其适合需要闭环控制和在线适应的物理任务 (Slide 19)。

RL 的发现能力


强化学习不只是模仿数据中已有的行为, 它还能通过”试错”发现全新的解决方案。AlphaGo 的 Move 37 就是一个经典案例——它走出了人类棋手从未下过的棋步。

Why study deep reinforcement learning?

Widely used for performant AI systems

Not just robots and games!

Nearly all modern language models use some form of RL for post-training.



especially for more advanced reasoning.

22

图 3: 课程也明确把 LLM post-training 放进深度 RL 的应用版图中, 说明 RL 已经从机器人和游戏扩展到语言模型系统 (Slide 22)。

2.3 学习的本质

从哲学角度看，从经验中学习似乎是智能的基本组成部分。能够自主实践并改进的算法，是构建真正智能系统的关键。

2.4 本章小结

学习深度 RL 的理由包括：(1) 很多问题超出了监督学习的范畴；(2) 高性能 AI 系统广泛使用 RL；(3) 从经验中学习是智能的基本能力；(4) 领域中仍有大量开放研究问题。

3 建模行为与强化学习基础

3.1 经验的数据表示

核心术语

- **状态** s_t : 时刻 t 的世界状态。
- **观察** o_t : 智能体在时刻 t 观察到的信息（当存在信息缺失时使用）。
- **动作** a_t : 时刻 t 的决策。
- **轨迹** $\tau = (s_1, a_1, s_2, a_2, \dots, s_T, a_T)$: 一个完整的状态-动作序列。
- **奖励函数** $r(s, a)$: 衡量状态-动作对的好坏。

3.2 状态与观察的区别

一个关键性质是**马尔可夫性** (Markov Property): 下一个状态仅取决于当前状态和动作，与更早的历史无关：

$$p(s_{t+1} | s_t, a_t) \text{ 独立于 } s_{t-1}$$

但在很多实际场景中（如聊天机器人），智能体只能看到**观察**而非完整状态，此时需要给策略加入记忆： $\pi_\theta(a_t | o_{t-m}, \dots, o_t)$ 。

3.3 用神经网络表示行为

策略 $\pi_\theta(a | s)$ 是将状态映射到动作分布的函数。智能体的运行过程如下：

1. 观察状态 s_t
2. 从策略中采样动作 $a_t \sim \pi_\theta(\cdot | s_t)$
3. 观察下一个状态 $s_{t+1} \sim p(\cdot | s_t, a_t)$

这样产生的完整序列称为策略 rollout 或 episode。

3.4 强化学习的目标

强化学习的目标是最大化期望累计奖励：

$$\max_{\theta} \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \left[\sum_t r(s_t, a_t) \right]$$

其中轨迹分布为：

$$p_{\theta}(\tau) = p(s_1) \prod_{t=1}^T \pi_{\theta}(a_t | s_t) p(s_{t+1} | s_t, a_t)$$

为什么要用期望

累计奖励不是一个确定量，它有两个随机性来源：(1) 环境本身是随机的；(2) 策略可能是随机的。因此我们优化的是期望累计奖励。

3.5 随机策略的意义

为什么使用随机策略而不是确定性策略？两个原因：

1. **探索**：要从自己的经验中学习，必须尝试不同的事情。
2. **建模随机行为**：现有数据往往展示多样化的行为，可以利用生成模型的工具。

3.6 价值函数与 Q 函数

衡量策略好坏的两个核心量：

- **价值函数** $V^{\pi}(s)$ ：从状态 s 出发，遵循策略 π 的未来期望奖励。
- **Q 函数** $Q^{\pi}(s, a)$ ：从状态 s 采取动作 a ，然后遵循策略 π 的未来期望奖励。

3.7 算法类型概览

1. **Imitation Learning**：模仿能获得高奖励的策略。
2. **Policy Gradients**：直接对目标函数求梯度。
3. **Actor-Critic**：估计当前策略的价值，并用它来改进策略。
4. **Value-based**：估计最优策略的价值。
5. **Model-based**：学习环境动力学模型，用于规划或策略改进。

不同算法做了不同的权衡，适用于不同的假设条件（数据收集成本、监督形式、稳定性、动作空间特性等）。

3.8 本章小结

强化学习的基本要素包括状态、动作、轨迹、奖励和策略。目标是最大化期望累计奖励。价值函数和 Q 函数是评估策略好坏的核心工具。不同类型的算法各有侧重，适用于不同场景。

4 总结与延伸

本讲建立了深度强化学习的整体框架。核心要点包括：

1. 深度 RL 研究序贯决策问题及其解法，与监督学习有本质区别。
2. RL 的应用已经非常广泛：从机器人到游戏到 LLM 的 post-training。
3. 基本建模框架：状态、动作、策略、奖励、轨迹。
4. 目标是最大化期望累计奖励 $\mathbb{E}_{\tau \sim p_{\theta}(\tau)} [\sum_t r(s_t, a_t)]$ 。
5. 后续课程将依次介绍 imitation learning、policy gradients、actor-critic、Q-learning、offline RL、reward learning 和 RLHF。

4.1 拓展阅读

- Sutton & Barto, *Reinforcement Learning: An Introduction* (2nd edition): 经典 RL 教材。
- CS234 (Stanford): 更偏理论的 RL 课程，与 CS224R 互补。
- Sergey Levine, *CS285 (Berkeley)*: 另一门优秀的深度 RL 课程。