

课程笔记

CS224R Lecture 1: 深度强化学习导论

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-04

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1 课程定位：什么是深度强化学习	2
1.1 与监督学习的核心区别	2
1.2 课程范围与目标	2
1.3 本章小结	2
2 为什么学习深度强化学习	3
2.1 超越监督学习	3
2.2 广泛应用于高性能 AI 系统	3
2.3 学习的本质	3
2.4 本章小结	3
3 建模行为与强化学习基础	4
3.1 经验的数据表示	4
3.2 状态与观察的区别	4
3.3 用神经网络表示行为	4
3.4 强化学习的目标	4
3.5 随机策略的意义	5
3.6 价值函数与 Q 函数	5
3.7 算法类型概览	5
3.8 本章小结	5
4 总结与延伸	5
4.1 拓展阅读	6

1 课程定位：什么是深度强化学习

CS224R 的第一讲从最根本的问题出发：什么是深度强化学习 (Deep Reinforcement Learning)，它与传统的机器学习有什么不同，以及为什么值得学习。

深度强化学习的定义

深度强化学习研究的是**序贯决策问题** (Sequential Decision-Making Problems)：系统需要基于信息流不断地“观察——行动——观察——行动”。课程同时研究这类问题的**解法**，包括 imitation learning、online/offline RL、model-free/model-based RL、multi-task/meta RL 以及 RL for LLMs 和 RL for robots。所有方法都强调能扩展到深度神经网络。

1.1 与监督学习的核心区别

在监督学习中，我们拥有标注数据 $\{(x_i, y_i)\}$ ，目标是学习一个函数 $f(x) \approx y$ 。数据点之间是独立同分布 (i.i.d.) 的，并且我们被**直接告知**正确的输出。

在强化学习中，情况完全不同：

- **目标**：学习行为策略 $\pi(a | s)$ ，将状态映射到动作。
- **反馈**：不是直接告诉答案，而是通过**间接反馈**（如奖励信号）从经验中学习。
- **数据非 i.i.d.**：智能体的动作 a 会影响未来的观察 s' ，因此数据分布取决于当前策略。

行为的多种形态

深度强化学习中的“行为”可以包括：机器人的运动控制、聊天机器人的对话、游戏的策略、自动驾驶的决策、Web agent 的操作等。这些场景的共同特点是：模型的输出（动作）会对环境产生后果，进而影响未来的输入。

1.2 课程范围与目标

Chelsea Finn 明确指出，这门课不可能覆盖深度强化学习的所有内容。课程聚焦于：

- 深度 RL 方法背后的**核心概念**，以便学生能理解更高级的方法。
- 算法的**实现**，使学生能够自己编程实现。
- 以**机器人控制和语言模型**为主要示例，但技术具有更广泛的适用性。

1.3 本章小结

深度强化学习是关于序贯决策的学科。与监督学习相比，RL 面临的独特挑战包括：反馈是间接的、数据是非 i.i.d. 的、动作有后果。课程的核心目标是让学生能够理解和实现现有和新兴的深度 RL 方法。

2 为什么学习深度强化学习

2.1 超越监督学习

许多真实世界的 AI 应用不只是简单的输入输出映射。讲者给出几个关键场景：

1. **决策有后果**：如 Spotify 推荐歌曲后，下一次推荐应该避免重复同一首歌，且应保持风格连续性。
2. **直接监督不可得**：如编码助手（Cursor、Copilot），用户只能给出”好”或”不好”的反馈，而非直接提供正确输出。
3. **目标不可微**：很多实际目标（如用户满意度）无法通过梯度直接优化。

2.2 广泛应用于高性能 AI 系统

讲者展示了大量深度 RL 的实际应用：

- **机器人**：Unitree 的四足机器人行走、Physical Intelligence 的 π_0 操作、Google Gemini Robotics。
- **游戏**：AlphaGo 的 Move 37 展示了 RL 发现人类未曾想到的新策略的能力。
- **大语言模型**：几乎所有现代 LLM 都使用某种形式的 RL 进行 post-training，尤其是在高级推理方面。
- **其他**：交通控制、生成式图像模型的 prompt 遵循、芯片设计（Google TPU）。

RL 的发现能力

强化学习不只是模仿数据中已有的行为，它还能通过”试错”发现全新的解决方案。AlphaGo 的 Move 37 就是一个经典案例——它走出了人类棋手从未下过的棋步。

2.3 学习的本质

从哲学角度看，从经验中学习似乎是智能的基本组成部分。能够自主实践并改进的算法，是构建真正智能系统的关键。

2.4 本章小结

学习深度 RL 的理由包括：(1) 很多问题超出了监督学习的范畴；(2) 高性能 AI 系统广泛使用 RL；(3) 从经验中学习是智能的基本能力；(4) 领域中仍有大量开放研究问题。

3 建模行为与强化学习基础

3.1 经验的数据表示

核心术语

- **状态** s_t : 时刻 t 的世界状态。
- **观察** o_t : 智能体在时刻 t 观察到的信息（当存在信息缺失时使用）。
- **动作** a_t : 时刻 t 的决策。
- **轨迹** $\tau = (s_1, a_1, s_2, a_2, \dots, s_T, a_T)$: 一个完整的状态-动作序列。
- **奖励函数** $r(s, a)$: 衡量状态-动作对的好坏。

3.2 状态与观察的区别

一个关键性质是**马尔可夫性** (Markov Property): 下一个状态仅取决于当前状态和动作, 与更早的历史无关:

$$p(s_{t+1} | s_t, a_t) \text{ 独立于 } s_{t-1}$$

但在很多实际场景中 (如聊天机器人), 智能体只能看到**观察**而非完整状态, 此时需要给策略加入记忆: $\pi_\theta(a_t | o_{t-m}, \dots, o_t)$ 。

3.3 用神经网络表示行为

策略 $\pi_\theta(a | s)$ 是将状态映射到动作分布的函数。智能体的运行过程如下:

1. 观察状态 s_t
2. 从策略中采样动作 $a_t \sim \pi_\theta(\cdot | s_t)$
3. 观察下一个状态 $s_{t+1} \sim p(\cdot | s_t, a_t)$

这样产生的完整序列称为策略 rollout 或 episode。

3.4 强化学习的目标

强化学习的目标是**最大化期望累计奖励**:

$$\max_{\theta} \mathbb{E}_{\tau \sim p_{\theta}(\tau)} \left[\sum_t r(s_t, a_t) \right]$$

其中轨迹分布为:

$$p_{\theta}(\tau) = p(s_1) \prod_{t=1}^T \pi_{\theta}(a_t | s_t) p(s_{t+1} | s_t, a_t)$$

为什么要用期望

累计奖励不是一个确定量, 它有两个随机性来源: (1) 环境本身是随机的; (2) 策略可能是随机的。因此我们优化的是**期望**累计奖励。

3.5 随机策略的意义

为什么使用随机策略而不是确定性策略？两个原因：

1. **探索**：要从自己的经验中学习，必须尝试不同的事情。
2. **建模随机行为**：现有数据往往展示多样化的行为，可以利用生成模型的工具。

3.6 价值函数与 Q 函数

衡量策略好坏的两个核心量：

- **价值函数** $V^\pi(s)$ ：从状态 s 出发，遵循策略 π 的未来期望奖励。
- **Q 函数** $Q^\pi(s, a)$ ：从状态 s 采取动作 a ，然后遵循策略 π 的未来期望奖励。

3.7 算法类型概览

1. **Imitation Learning**：模仿能获得高奖励的策略。
2. **Policy Gradients**：直接对目标函数求梯度。
3. **Actor-Critic**：估计当前策略的价值，并用它来改进策略。
4. **Value-based**：估计最优策略的价值。
5. **Model-based**：学习环境动力学模型，用于规划或策略改进。

不同算法做了不同的权衡，适用于不同的假设条件（数据收集成本、监督形式、稳定性、动作空间特性等）。

3.8 本章小结

强化学习的基本要素包括状态、动作、轨迹、奖励和策略。目标是最大化期望累计奖励。价值函数和 Q 函数是评估策略好坏的核心工具。不同类型的算法各有侧重，适用于不同场景。

4 总结与延伸

本讲建立了深度强化学习的整体框架。核心要点包括：

1. 深度 RL 研究序贯决策问题及其解法，与监督学习有本质区别。
2. RL 的应用已经非常广泛：从机器人到游戏到 LLM 的 post-training。
3. 基本建模框架：状态、动作、策略、奖励、轨迹。
4. 目标是最大化期望累计奖励 $\mathbb{E}_{\tau \sim p_\theta(\tau)} [\sum_t r(s_t, a_t)]$ 。
5. 后续课程将依次介绍 imitation learning、policy gradients、actor-critic、Q-learning、offline RL、reward learning 和 RLHF。

4.1 拓展阅读

- Sutton & Barto, *Reinforcement Learning: An Introduction* (2nd edition): 经典 RL 教材。
- CS234 (Stanford): 更偏理论的 RL 课程, 与 CS224R 互补。
- Sergey Levine, *CS285 (Berkeley)*: 另一门优秀的深度 RL 课程。