


课程笔记

CS224R Lecture 2: 模仿学习

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-04

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 模仿学习的基本思想	2
1.1 Version 0: 确定性策略回归	2
1.2 本章小结	2
2 学习表达性策略分布	2
2.1 用神经网络表示分布	2
2.2 生成模型作为策略	2
2.3 Version 1: 表达性策略的模仿学习	3
2.4 实际应用	3
2.5 本章小结	3
3 累积误差与在线修正	3
3.1 Compounding Errors 问题	3
3.2 DAgger: 数据集聚合	3
3.3 Human-Gated DAgger: 干预式修正	4
3.4 本章小结	4
4 演示数据的收集	4
4.1 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	5

1 模仿学习的基本思想

模仿学习 (Imitation Learning) 是深度 RL 中最直接的方法：给定专家的演示数据，让策略学会模仿专家的行为。

模仿学习的目标

给定由专家策略 π_{expert} 采集的演示轨迹数据集 $\mathcal{D} = \{(s_1, a_1, \dots, s_T)\}$ ，目标是学习一个策略 π_θ ，使其表现达到专家水平。

1.1 Version 0: 确定性策略回归

最简单的方法是将模仿学习视为监督回归问题：

$$\min_{\theta} \frac{1}{|\mathcal{D}|} \sum_{(s,a) \in \mathcal{D}} \|\hat{a} - a\|^2, \quad \text{其中 } \hat{a} = \pi_\theta(s)$$

均值问题

当数据由多个演示者收集时， ℓ_2 回归会趋向数据的**均值**。例如在驾驶场景中，如果有人向左打方向盘、有人向右打，回归结果可能是直行——这在实际中非常危险。这种情况在实践中非常常见。

1.2 本章小结

模仿学习的最简单版本是行为克隆 (Behavior Cloning)，但确定性回归在多模态数据上会产生均值问题。

2 学习表达性策略分布

2.1 用神经网络表示分布

对于**离散动作**，神经网络可以输出各动作的概率，构成 categorical 分布——这是最大化表达力的。

对于**连续动作**，简单地输出 μ, σ 构成高斯分布**表达力不足**——它只能表示单峰分布。

关键洞察：网络表达力 $\neq$ 分布表达力

神经网络本身很”大”并不意味着它输出的分布很丰富。一个很大的网络输出单个高斯分布，仍然只能表示单峰行为。真正需要的是**分布层面**的表达力。

2.2 生成模型作为策略

核心想法：借助生成模型的工具来学习策略分布 $p(a | s)$ 。三种主要方法：

1. **Mixture of Gaussians (MoG)**：输出多个高斯分量的参数 (μ_i, σ_i, w_i) 。
2. **Discretize + Autoregressive**：将连续动作离散化，自回归地预测每个维度。
3. **Diffusion Policy**：迭代去噪，从噪声中生成动作。

2.3 Version 1: 表达性策略的模仿学习

使用表达性分布后，优化目标变为最大化演示动作的对数似然：

$$\min_{\theta} -\mathbb{E}_{(s,a) \sim \mathcal{D}} [\log \pi_{\theta}(a \mid s)]$$

实验证明，diffusion policy 和 GMM 在多人数据集上远优于 ℓ_2 回归，尤其是在机器人操作任务中。

2.4 实际应用

表达性策略 + 模仿学习的范式已经被广泛采用：

- Physical Intelligence π_0 ：使用 diffusion policy。
- NVIDIA Gr00t N1：使用 diffusion policy。
- OpenVLA：使用 discretize + autoregressive。
- Waymo EMMA、Wayve LINGO-2：自动驾驶中的 autoregressive prediction。

2.5 本章小结

表达性策略是模仿学习成功的关键。生成模型（diffusion、GMM、autoregressive）为策略提供了丰富的分布表达力，使其能够捕捉数据中的多模态行为。

3 累积误差与在线修正

3.1 Compounding Errors 问题

模仿学习与标准监督学习的关键区别：在监督学习中，输入 x 独立于预测 $\hat{y}$ ；但在行为学习中，预测的动作 $\hat{a}$ 会影响下一个状态 s' 。

一旦学习到的策略犯了小错误，它就会漂移到训练数据分布之外。在这些未见过的状态上，策略可能犯更大的错误，导致**误差累积**（compounding errors）。

分布偏移

核心问题是 $p_{\text{expert}}(s) \neq p_{\pi}(s)$ ：专家访问的状态分布与学习策略访问的状态分布不同。这就是 covariate shift。

3.2 DAgger：数据集聚合

解决思路：让学习到的策略运行，然后在它访问的状态上查询专家的动作，将修正数据加入训练集。

1. 用学习策略 π_{θ} rollout: $s'_1, \hat{a}_1, \dots, s'_T$
2. 在访问的状态上查询专家动作 $a^* \sim \pi_{\text{expert}}(\cdot \mid s')$
3. 将修正数据加入数据集 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(s', a^*)\}$
4. 重新训练策略

3.3 Human-Gated DAgger: 干预式修正

更实用的变体：人类在策略运行时监控，在策略犯错时接管控制权，提供部分演示，然后将这些修正数据加入训练集。

Offline vs. Online 模仿学习

- **Offline (行为克隆)**：仅使用现有数据，不需要运行学习到的策略。简单安全，但可能需要大量数据。
- **Online (DAgger/HG-DAgger)**：涉及运行策略并收集修正数据。数据效率更高，但需要交互接口。

3.4 本章小结

Compounding errors 是模仿学习的核心挑战。DAgger 和 HG-DAgger 通过收集修正数据来缓解分布偏移问题。许多成功的方法会结合模仿学习和强化学习。

4 演示数据的收集

在某些领域（如驾驶、文本输入），演示数据可以从人类日常活动中自然收集。在机器人领域，常见方法包括：

- **Kinesthetic Teaching**：直接用手引导机器人，界面简单但人手可能出现在画面中。
- **Remote Controllers**：远程控制，可能有延迟。
- **Puppeteering**：用镜像硬件操控，界面直观但需要双倍硬件。

能否直接使用人类/动物的视频？存在 **embodiment gap**（外观差异、自由度差异），直接模仿困难，但可以用来引导探索。

4.1 本章小结

演示数据的收集方式取决于应用领域。机器人领域有多种方法，各有优劣。跨 embodiment 的模仿仍是开放问题。

5 总结与延伸

本讲的核心要点：

1. **行为克隆**：将模仿学习视为监督学习，简单但存在均值问题。
2. **表达性策略**：使用生成模型（diffusion、GMM、autoregressive）作为策略类，是实践中成功的关键。
3. **Compounding errors**：模仿学习的核心挑战，由分布偏移引起。
4. **DAgger/HG-DAgger**：通过在线修正来缓解。
5. 模仿学习是完全 offline 的（不需要奖励函数），但无法超越演示者，也没有自我改进的框架。

5.1 拓展阅读

- Chi et al., *Diffusion Policy*: 将 diffusion model 用于机器人策略的开创性工作。
- Ross et al., *A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning* (DAgger 原文)。
- Brohan et al., *RT-2: Vision-Language-Action Models*, 展示了大规模模仿学习的效果。