


课程笔记

CS224R Lecture 4: Actor-Critic 方法

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-04

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1 回顾：策略梯度的不足	2
2 核心对象回顾	2
2.1 本章小结	2
3 Actor-Critic 框架	2
3.1 用优势函数改进策略梯度	2
3.2 如何估计价值函数	2
3.3 价值函数的拟合方法	3
3.4 Actor-Critic 完整流程	3
3.5 本章小结	3
4 Off-Policy Actor-Critic 简介	3
4.1 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 回顾：策略梯度的不足

策略梯度使用采样的 reward-to-go 来估计每个动作的好坏，但这种估计方差很大。

策略梯度的两个核心问题

1. **数据利用不充分**：稀疏奖励下，大部分轨迹的奖励为零，梯度信息很少。
2. **高方差**：采样 reward-to-go 是单次采样估计，噪声大。

核心改进思路：能否学习什么是好的、什么是坏的，而不是仅依赖采样估计？

2 核心对象回顾

价值函数、Q 函数与优势函数

- **价值函数** $V^\pi(s)$ ：从状态 s 出发遵循 π 的期望未来奖励。
- **Q 函数** $Q^\pi(s, a)$ ：从 s 执行 a 后遵循 π 的期望未来奖励。
- **优势函数** $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ ：动作 a 相对于策略 π 的平均表现好多少。

关键关系： $V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)} [Q^\pi(s, a)]$

2.1 本章小结

V 、 Q 、 A 三个函数从不同角度描述策略的好坏。优势函数 A 特别有用，因为它直接衡量某个动作相对于策略平均水平的好坏。

3 Actor-Critic 框架

3.1 用优势函数改进策略梯度

用 A^π 替代 reward-to-go：

$$\nabla_\theta J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \sum_{t=1}^T \nabla_\theta \log \pi_\theta(a_{i,t} | s_{i,t}) \cdot \hat{A}^\pi(s_{i,t}, a_{i,t})$$

更好的 $\hat{A}$ 估计 $\Rightarrow$ 更低噪声的梯度。

3.2 如何估计价值函数

只需拟合 $\hat{V}^\pi$ 即可，因为：

$$\hat{A}^\pi(s_t, a_t) = r(s_t, a_t) + \gamma \hat{V}^\pi(s_{t+1}) - \hat{V}^\pi(s_t)$$

这里利用了采样得到的 s_{t+1} 来近似期望。

3.3 价值函数的拟合方法

方法 1: Monte Carlo 回归

$$\min_{\phi} \sum_{s_t \in \mathcal{D}} \left\| \hat{V}_{\phi}^{\pi}(s_t) - \sum_{t'=t}^T r(s_{t'}, a_{t'}) \right\|^2$$

直接用采样的累计奖励作为 target。无偏但高方差。

方法 2: Bootstrapped / TD 更新

$$\min_{\phi} \sum_{(s,a,s') \in \mathcal{D}} \left\| \hat{V}_{\phi}^{\pi}(s) - \left(r(s,a) + \gamma \hat{V}_{\phi}^{\pi}(s') \right) \right\|^2$$

用自身的估计作为 target (bootstrap)。低方差但有偏。

方法 3: n-step 回报

结合上述两者, 使用 n 步实际奖励 + bootstrap:

$$y_{i,t} = \sum_{t'=t}^{t+n-1} r(s_{i,t'}, a_{i,t'}) + \gamma^n \hat{V}^{\pi}(s_{i,t+n})$$

Bias-Variance Tradeoff

- Monte Carlo: 无偏, 高方差。
- TD (1-step bootstrap): 有偏 (因为 $\hat{V}$ 不精确), 低方差。
- n-step: 在两者之间提供可调的平衡。

3.4 Actor-Critic 完整流程

1. 运行策略收集数据
2. 拟合价值函数 $\hat{V}^{\pi}$
3. 估计优势 $\hat{A}^{\pi}$
4. 用策略梯度更新策略 π_{θ}
5. 重复

3.5 本章小结

Actor-Critic 通过学习价值函数来估计优势, 替代了策略梯度中噪声很大的采样 reward-to-go, 显著降低了梯度方差。

4 Off-Policy Actor-Critic 简介

当结合 importance weights 时, Actor-Critic 可以复用旧数据进行多步梯度更新。

$$\nabla_{\theta'} J(\theta') \approx \sum_{t,i} \frac{\pi_{\theta'}(a_{i,t} | s_{i,t})}{\pi_{\theta}(a_{i,t} | s_{i,t})} \nabla_{\theta'} \log \pi_{\theta'}(a_{i,t} | s_{i,t}) \hat{A}^{\pi_{\theta}}(s_{i,t}, a_{i,t})$$

但 importance weights 在新旧策略差异大时不稳定。下一讲将介绍如何用 KL 约束和 clipping 来解决这个问题。

4.1 本章小结

Off-policy actor-critic 通过 importance sampling 复用旧数据，但需要限制策略更新的步幅以保持稳定性。

5 总结与延伸

1. Actor-Critic 方法通过学习价值函数来估计优势，降低了策略梯度的方差。
2. 价值函数可以用 Monte Carlo、TD、或 n-step 方法拟合，各有 bias-variance 权衡。
3. Off-policy 版本通过 importance weights 复用旧数据，提高数据效率。
4. Actor-Critic 是 PPO、SAC 等现代 RL 算法的基础。

5.1 拓展阅读

- Mnih et al., *Asynchronous Methods for Deep Reinforcement Learning* (A3C)。
- Schulman et al., *High-Dimensional Continuous Control Using Generalized Advantage Estimation* (GAE)。