


课程笔记

CS224R Lecture 6: Q-Learning

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-04

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 从 Actor-Critic 到纯 Value-Based 方法	2
1.1 本章小结	2
2 Q-Learning 基础	2
2.1 最优 Q 函数	2
2.2 DQN 算法	2
2.3 本章小结	2
3 连续动作空间的挑战	3
3.1 本章小结	3
4 Double Q-Learning 与过估计问题	3
4.1 过估计偏差	3
4.2 Double DQN	3
4.3 本章小结	3
5 总结与延伸	4
5.1 拓展阅读	4

1 从 Actor-Critic 到纯 Value-Based 方法

前几讲介绍了 actor-critic 方法：同时维护策略（actor）和价值函数（critic）。Q-Learning 走得更远——完全去掉显式策略，只学习 Q 函数，然后从 Q 函数隐式地派生策略。

Value-Based vs. Actor-Critic

- **Actor-Critic**: 同时学习策略 π_θ 和价值函数 $\hat{V}$ 或 $\hat{Q}$ 。
- **Value-Based (Q-Learning)**: 只学习最优 Q 函数 Q^* ，策略隐式为 $\pi(s) = \arg \max_a Q^*(s, a)$ 。

1.1 本章小结

Q-Learning 是一种纯 value-based 方法，不需要显式的策略网络。

2 Q-Learning 基础

2.1 最优 Q 函数

Bellman 最优方程

最优 Q 函数 Q^* 满足：

$$Q^*(s, a) = r(s, a) + \gamma \max_{a'} Q^*(s', a')$$

关键性质： Q^* 对应的策略 $\pi^*(s) = \arg \max_a Q^*(s, a)$ 是所有策略中最优的。

与 actor-critic 中拟合 Q^π （当前策略的 Q 函数）不同，Q-Learning 直接拟合 Q^* （最优策略的 Q 函数），使用 $\max$ 而不是 $\mathbb{E}_{a' \sim \pi}$ 。

2.2 DQN 算法

Deep Q-Network (DQN) 使用深度神经网络来参数化 $Q_\phi(s, a)$ ：

$$\min_{\phi} \sum_{(s, a, r, s') \in \mathcal{B}} \left\| Q_\phi(s, a) - \left(r + \gamma \max_{a'} Q_{\phi'}(s', a') \right) \right\|^2$$

DQN 的关键技巧

- **Replay Buffer**: 存储所有历史转移，随机采样来打破数据相关性。
- **Target Network**: 使用延迟更新的 $Q_{\phi'}$ 计算 TD target，避免”自己追自己”的不稳定。
- **ϵ -Greedy 探索**: 以概率 ϵ 随机选择动作，否则选 $\arg \max_a Q(s, a)$ 。

2.3 本章小结

Q-Learning 通过拟合最优 Q 函数来间接获得最优策略。DQN 将 Q-Learning 扩展到高维状态空间，replay buffer 和 target network 是关键的稳定化技巧。

3 连续动作空间的挑战

DQN 原始形式只适用于**离散**动作空间（网络输出每个动作的 Q 值，然后取 $\arg\max$ ）。对于连续动作空间， $\max_a Q(s, a)$ 本身就是一个优化问题。

解决方案包括：

1. **离散化**：将连续空间离散化，但维度诅咒严重。
2. **采样**：随机采样多个动作，取 Q 值最大的。
3. **学习一个 actor**：回到 actor-critic 框架（如 SAC）。
4. **DDPG**：训练一个确定性策略网络 $\mu_\theta(s) = \arg\max_a Q(s, a)$ 。

Q-Learning 在连续空间的困难

纯 Q-Learning 在连续动作空间中需要解决内层优化问题 $\max_a Q(s, a)$ ，这在高维空间中计算代价很大。这也是为什么连续控制任务中 actor-critic 方法（如 SAC）通常比纯 Q-learning 更受欢迎。

3.1 本章小结

Q-Learning 在离散动作空间中自然高效，但在连续动作空间中需要额外的技巧或回归到 actor-critic 方法。

4 Double Q-Learning 与过估计问题

4.1 过估计偏差

$$\max_{a'} Q_\phi(s', a') \geq Q^*(s', \pi^*(s'))$$

取 $\max$ 操作会系统性地高估 Q 值，因为它选择的是**噪声最大的方向**。

4.2 Double DQN

使用当前网络选择动作，但用 target 网络评估：

$$y = r + \gamma Q_{\phi'}\left(s', \arg\max_{a'} Q_\phi(s', a')\right)$$

这在一定程度上缓解了过估计问题。

4.3 本章小结

Q-Learning 有系统性的过估计偏差。Double Q-Learning 通过分离动作选择和动作评估来缓解这一问题。

5 总结与延伸

1. Q-Learning 是一种纯 value-based 方法，直接学习最优 Q 函数。
2. DQN 使用 replay buffer + target network + ϵ -greedy 探索，是深度 Q-Learning 的里程碑。
3. Q-Learning 天然适合离散动作空间；连续空间需要额外处理。
4. 过估计是 Q-Learning 的固有问题，Double DQN 等方法可以缓解。
5. Q-Learning 是完全 off-policy 的，数据效率高。

5.1 拓展阅读

- Mnih et al., *Playing Atari with Deep Reinforcement Learning* (DQN, 2013)。
- Van Hasselt et al., *Deep Reinforcement Learning with Double Q-learning* (Double DQN, 2016)。
- Lillicrap et al., *Continuous Control with Deep Reinforcement Learning* (DDPG, 2016)。