

课程笔记

CS224R Lecture 7: Offline RL

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-05

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 为什么需要 Offline RL	3
1.1 本章小结	3
2 直接用 Off-Policy 算法 ?	3
2.1 本章小结	3
3 Offline RL 优于模仿学习	3
3.1 本章小结	4
4 隐式策略约束方法	4
4.1 Filtered/Weighted Imitation Learning	4
4.2 IQL: Implicit Q-Learning	4
4.3 本章小结	4
5 Conservative 方法	4
5.1 CQL: Conservative Q-Learning	4
5.2 CQL 的实现	4
5.3 本章小结	5
6 数据集与分布问题	5
6.1 数据质量的三维观察	5
6.2 本章小结	5
6.3 案例: 构建混合数据管线	5
7 分布偏移与诊断	6
7.1 Shift Detection Checklist	6
7.2 本章小结	6
8 评估与基准	6
8.1 多层评估框架	6
8.2 评估中的对比表	7
8.3 本章小结	8
9 部署与监控	8
9.1 Log + Replay 基础设施	8
9.2 监控仪表盘	8
9.3 本章小结	8
9.4 监控仪表可视化示例	9
10 治理与安全	9
10.1 Policy Governance Checklist	9
10.2 本章小结	9

11 Tooling 与自动化	9
11.1 自动化流水线	9
11.2 支持工具与集成	10
11.3 本章小结	10
12 案例研究：现实世界的 Offline RL	10
12.1 复杂 reward 工程	10
12.2 可视化演示	11
12.3 本章小结	11
13 Open Research Directions	11
13.1 Maximizing offline + online handoff	11
13.2 Counterfactual auditing	11
13.3 本章小结	12
14 Slides Gallery	12
14.1 Slide: Monitoring Architecture	12
14.2 Slide: Real-world Deployment Flow	13
14.3 本章小结	13
15 案例研究：机器人控制	13
15.1 Offline policy in robotics	13
15.2 本章小结	14
16 Counterfactual Tracebacks	14
16.1 Replay-based counterfactuals	14
16.2 可视化演示	14
16.3 本章小结	15
17 Operations Checklist	15
17.1 部署前核查清单	15
17.2 本章小结	15
18 Training-Deployment Playbook	15
18.1 Step-by-step plan	15
18.2 本章小结	16
19 Frontier Workshop Notes	16
19.1 Workshop focus areas	16
19.2 本章小结	17
20 未来挑战	17
20.1 可解释与审计的灵活组合	17
20.2 适应法规与政策变更	17
20.3 本章小结	17

21 总结与延伸	17
21.1 总结表	18
21.2 进一步行动	18
21.3 拓展阅读	18

1 为什么需要 Offline RL

Offline RL 的定义

给定一个由未知行为策略 π_β 收集的静态数据集 $\mathcal{D}$ ，在不收集新数据的情况下，训练一个能最大化奖励的策略 π_θ 。

Offline RL 的价值：

- 利用人类、现有系统已收集的数据。
- 在线数据收集可能危险或昂贵。
- 复用之前的实验、项目、机器人的数据。

Online vs. Offline RL

Online RL 交替进行“收集数据”和“更新策略”。Offline RL 只有一个静态数据集，训练完成后才部署。也可以先 offline 再 online（混合模式）。

1.1 本章小结

Offline RL 解决的是“如何在¹不与环境交互的情况下，从已有数据中学习好的策略”这一问题。

2 直接用 Off-Policy 算法？

能否直接把 SAC 这样的 off-policy 算法用在静态数据集上？

Q 函数过估计问题

当 Q 函数在数据集中未见过的动作上被查询时，随机初始化的 Q 值可能任意高或低。策略会寻找 Q 函数过度乐观的动作——这些动作恰恰是 Q 函数最不可靠的地方。

策略更新后，Q 值会被大幅过估计，导致性能崩塌。根本原因是学习策略 π_θ 与行为策略 π_β 之间的分布偏移。

2.1 本章小结

直接使用 off-policy 算法在 offline 设置下会失败，因为 Q 函数在 out-of-distribution 动作上过估计。Offline RL 的核心挑战就是缓解这种过估计。

3 Offline RL 优于模仿学习

轨迹拼接 (Trajectory Stitching)

Offline 数据可能不包含完整的好轨迹，但可能包含片段性的好行为。例如轨迹 A 的前半段很好，轨迹 B 的后半段很好。好的 offline RL 方法能将²这些片段拼接起来，学到比任何单条轨迹都好的策略。模仿学习做不到这一点。

3.1 本章小结

Offline RL 通过利用奖励信息和轨迹拼接，能够超越行为策略的表现，这是纯模仿学习无法做到的。

4 隐式策略约束方法

4.1 Filtered/Weighted Imitation Learning

最简单的 baseline：只模仿数据中**高奖励**的轨迹或转移，或按奖励加权。

4.2 IQL: Implicit Q-Learning

IQL 的核心思想：避免在数据集之外的动作上查询 Q 函数。

拟合 V 函数：使用 expectile 损失，使 V 倾向于学习数据中 Q 值较高的那部分行为：

$$\hat{V}(s) \leftarrow \arg \min_V \mathbb{E}_{(s,a) \sim \mathcal{D}} \left[\ell_\lambda^2 \left(V(s) - \hat{Q}(s, a) \right) \right]$$

其中 expectile 损失对正误差给更大权重 ($\lambda > 0.5$)，使 V 偏向数据中更好的动作。

拟合 Q 函数：使用 V 而非 $\max$ 来避免 OOD 查询：

$$\hat{Q}(s, a) \leftarrow \arg \min_Q \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[\left(Q(s, a) - (r + \gamma \hat{V}(s')) \right)^2 \right]$$

4.3 本章小结

IQL 通过完全避免在数据外动作上查询 Q 函数来解决过估计问题，是一种简洁优雅的 offline RL 方法。

5 Conservative 方法

5.1 CQL: Conservative Q-Learning

CQL 的思路更直接：在 Q 函数更新中加入**惩罚项**，主动压低 Q 值。

$$\hat{Q} = \arg \min_Q \max_{\mu} \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[\left(Q(s, a) - (r + \gamma \mathbb{E}_{\pi} [Q(s', a')]) \right)^2 \right] + \alpha \mathbb{E}_{s \sim \mathcal{D}, a \sim \mu(\cdot|s)} [Q(s, a)] - \alpha \mathbb{E}_{(s,a) \sim \mathcal{D}} [Q(s, a)]$$

- 第一项：标准 TD 更新。
- 第二项：压低所有动作的 Q 值 (μ 覆盖整个动作空间)。
- 第三项：恢复数据中动作的 Q 值 (不要过度压低)。

可以证明：对足够大的 α ，学到的 Q 值在策略分布下是**保守的**（低估而非高估）。

5.2 CQL 的实现

当使用最大熵正则化时，最优的 $\mu(a|s) \propto \exp(Q(s, a))$ ，此时惩罚项变为 $\log \sum_a \exp(Q(s, a))$ ，无需显式构造 μ 。

5.3 本章小结

CQL 通过主动压低 Q 值来防止过估计，是另一种有效的 offline RL 方法。与 IQL 的隐式约束不同，CQL 显式地构造保守估计。

6 数据集与分布问题

6.1 数据质量的三维观察

Offline RL 的数据集并非黑盒，讲者强调：理解数据的来源、覆盖范围和奖励分布，才能有效指导算法选择。

- **覆盖度**：状态-动作组合是否均匀，是否存在稀疏区域
- **奖励结构**：奖励是否稠密、有噪声、有异常值
- **行为多样性**：是否仅包含一条行为策略，或多种策略的混合

用数据质量驱动算法选择

当数据覆盖面广、奖励干净时，更激进的 bootstrapping 方法（如 IQL）可以发挥；当数据存在低质量样本或奖励漂移时，优先使用 Conservative 方法或基于 reward 的 sample filtering。

数据特征	示意说明	风险	推荐策略
高奖励、低覆盖	同一轨迹重复出现	过拟合、缺乏泛化	加强 regularization、引入数据增强
低奖励但多样	多个 suboptimal 策略	Q overestimation on rare good actions	过滤低奖励样本、使用 expectile distortion
混合行为	多策略混合而未标注	难以定义行为策略	赋予 behavior cloning 更高权重的分段训练

表 1: 根据数据分布选择 offline RL 策略

6.2 本章小结

Offline RL 的成功依赖于对数据覆盖度、奖励质量和行为多样性的精准理解。按数据特征调整策略（filter/IQL/CQL）比固定算法更稳妥。

6.3 案例：构建混合数据管线

项目组经常将 simulator logs、human logs 与 expert trajectories 混合，按照 reward 和 importance sampling 重新加权样本：

1. 先计算每条轨迹的 effective sample size。

2. 按 reward percentile 将数据分成 bin 并赋予不同 sampling weight。
3. 用 IQL expectile 评估每个 bin 中 Q 的分布，两端重采样以保持稳定。
4. 若 expectile 跳出预设区间，退回 conservative 模式或过滤掉异常 bin。

混合数据管线的好处

不同数据源 bias 各异：simulator 更精确但缺乏多样性，human data 有噪声但更自然。混合管线通过 re-weighting 让算法既稳健又具泛化。

7 分布偏移与诊断

7.1 Shift Detection Checklist

Offline 环境往往面临两个维度的偏移：环境动力学（transition shift）和 reward 描述（reward shift）。需要定期监控。

1. 统计当前 policy 与行为策略的 state-action marginals 变化（KL or JS divergence）。
2. 监测 reward distribution drift；如果 reward 因外部因素变动，需重新标注或归一化。
3. 用 behavior cloning 误差评估偏移敏感度；高误差暗示模型在“陌生”区域。

Distribution shift 的早期信号

若仅对日志数据运行目标 policy 时 reward 波动剧烈，且 action entropy 迅速走高，说明 policy 正在探索离训练集较远的区域，需要及时插入 conservative regularization。

诊断方法	输出指标	典型阈值
KL divergence($s s_\beta$)	低于 0.2	状态分布未大幅漂移
Reward overlap	中位数差异 < 5%	reward shift 受控
BC loss ratio	训练 vs 当前 > 1.5	可能进入 OOD 区域

表 2: 常见的分布偏移监控指标

7.2 本章小结

检测 distribution shift 需要多维指标组合：动作 space divergence、reward drift、BC loss ratio。提前触发 conservative 策略或调整 reward scaling，可以预防 catastrophic failure。

8 评估与基准

8.1 多层评估框架

讲者把评估分成三层：离线基准（benchmarks）、模拟部署（sandbox）、实际回放（replay evaluation）。

- **离线 benchmark**: D4RL 类型的任务，关注 normalized score。
- **模拟部署**: 用 simulator 跑 policy with hold-out reward to detect inflated Q-values。
- **回放评估**: 把 policy 产生的 trajectory 反写入日志，检查 reward/constraint 是否满足。

评估越多越好，但须留出 human-in-the-loop

自动 benchmark 只能检验 capacity；要理解 failure modes，还需要串联 human audit：观察 policy 在关键情景（edge case）下的行为，补充 qualitative assessment。

Recap: Methods




图 1: Lecture slides 描述的三层评估管线¹

8.2 评估中的对比表

评估阶层	主要目的	常用工具
离线 benchmark	快速对齐整体能力	D4RL, OpenAI 的 offline suites
Replay evaluation	观察 policy 在 replay buffer 中的 reward	replay simulator, human audit
Sandbox deployment	用 simulator 到达准生产环境	per-domain simulator + twin models

表 3: 评估层级的对照表

¹Slides 第 3 页，高亮 offline RL 的评估阶梯。

8.3 本章小结

评估应该包括 benchmark、sandbox 尝试和回放验证三层，每层都可捕捉不同 failure 模式。人类审查仍不可或缺。

9 部署与监控

9.1 Log + Replay 基础设施

部署 offline policy 前需要准备 logging pipeline:

- 同步 policy 输出与环境 reward，确保 reward trace 链接输出行为。
- 记录 policy 的 action entropy、Q variance，以便复现失败。
- 针对 high-risk state 定义 alert threshold（如 Q variance > 0.5）。

Deployment 最常见失误

用“Offline policy + online fine-tuning”代替 robust evaluation：上线后才发现 reward drift。正确做法是先用 replay simulator 复验，再逐步放开 online interaction 门槛。

9.2 监控仪表板


Dashboard 组件	指标	触发条件
Policy behavior	Action distribution shift	KL > 0.3
Reward	Mean reward vs reference	差异 > 5%
Q stability	Q variance	> 0.4

表 4: 部署后需追踪的关键指标

9.3 本章小结

可靠部署依赖日志、replay 复制与监控仪表板。提前设置 alert 和 entropy 控制，可以让 offline policy 在上线后更稳。

9.4 监控仪表可视化示例



4

图 2: Lecture slides 中展示的监控 dashboard 和 alert thresholds²

10 治理与安全

10.1 Policy Governance Checklist

- 安全审查: 是否涵盖 CBRN 相关 scenario
- 成本审查: 是否记录 compute/trajectory 预算
- 行为审核: 是否有人观察 policy 注释并签字

Governance 不是拉闸, 是预告

治理是把 deployment pipeline 变成一个可解释的流程, 不是“突然停掉”。每次 policy change 都要留 trace, 从 dataset 到 training 到 evaluation 都要可追责。

10.2 本章小结

治理的关键是 traceability、对齐审查和形成明确的 sign-off 流程。只有这样, Offline RL 才能在高风险场景落地。

11 Tooling 与自动化

11.1 自动化流水线

Offline RL 需要把 data -> training -> eval -> deploy 串成流水线。典型组件:

- Data versioning: 每次训练都指向数据、reward log、behavior policy ID。

²Slides 第 4 页, 展示典型 dashboard, 中列展示 reward drift 控制。

- Training orchestration: Pipeline.com、Kubeflow pipeline 触发 training job。
- Evaluation orchestration: 自动化地从 replay buffer 取 key states 运行 benchmark。
- Deployment gate: 若 metrics 异常, 自动回滚并通知 owner。

流水线中断会导致 drift

一旦 pipeline 的任一环节 (data/eval/deploy) 缺失, 后续变化就无法追踪。必须强制所有 code change 通过 pipeline 生成的 artifact, 避免 “手动跑”。

11.2 支持工具与集成

讲者列举了几款与 offline RL 结合良好的工具:

- **Data-versioned storage** (Feathr, Deep Lake) 存储 dataset metadata。
- **Experiment tracking** (Weights Biases) 记录 Q variance、KL drift。
- **Policy registry**: 记录 policy hash, deploy timestamp, sign-off, governance doc link。
- **Replay simulator**: 用 deterministic seeds replay 训练轨迹并记录 divergences。

11.3 本章小结

Automation pipeline 不只是流水线, 而是把 offline RL 的各个 artifact 变成 traceable product。实时 logging + tooling 集成让 governance 更容易。

12 案例研究: 现实世界的 Offline RL

12.1 复杂 reward 工程

在人机交互系统中, reward often 包含多个目标 (accuracy, fairness, latency)。讲者描述 LinkedIn 项目: 在 notification 系统中同时优化 CTR 和 retention, 因此要在 dataset 中标记 reward components 以便 later decomposed training。

多目标 reward 的 practical trick

在 dataset 中预先计算 reward vector (CTR, retention, quality), 并在 offline training 时用 linear combination + CVaR regularization 控制 worst-case outcomes。

12.2 可视化演示

The plan for today

Offline RL

1. Why offline RL? Can we just run off-policy methods?
2. Implicit policy constraint methods
3. Conservative methods

} Part of homework 3!

Key learning goals:

- the **key challenges** arising in offline reinforcement learning
- two approaches for offline RL (& why they work!)
- how **offline RL** can improve over **imitation learning**

6

图 3: Slides 表示的 reality check: 多目标 reward 与 deployment 指标对齐³

12.3 本章小结

现实案例中 reward 是多维的，务必在数据层面明确每个维度的意义，否则 offline policy 会 misalign。

13 Open Research Directions

13.1 Maximizing offline + online handoff

几位讲者都提到 hybrid strategies: 先 offline, 再有限 online fine-tuning。关键问题是如何安全地 handoff:

- 制定 clear boundary: 什么情况下允许 query environment?
- 在 offline phase 就评估 online potential (e.g., Q variance in shifted states)。
- 用 meta-RL 训练 supervisor policy decide when to go online。

13.2 Counterfactual auditing

目前 governance 仍依赖 replay logs, 未来可能采用 counterfactual referents: 生成 hypothetical trajectories to test safety constraints before deployment。

Counterfactual auditing

用 learnt world model 生成“如果 policy 做了不同动作会怎样”的对比, 使 safety team 了解潜在 failure trajectory, 可以更快识别 policy drift。

³Slides 第 6 页, 强调 reward vector 与 deployment metrics 的一一映射。

13.3 本章小结

Research 方向包括 offline→online handoff、counterfactual auditing、以及更强的 interpretability (如 gradient-level tracebacks)。

14 Slides Gallery

14.1 Slide: Monitoring Architecture

Recap: Full Off-Policy Actor-Critic Method

online actor-critic algorithm:

- 
1. take action $\mathbf{a} \sim \pi_\theta(\mathbf{a}|\mathbf{s})$, get $(\mathbf{s}, \mathbf{a}, \mathbf{s}', r)$, store in $\mathcal{R}$
 2. sample a batch $\{\mathbf{s}_i, \mathbf{a}_i, r_i, \mathbf{s}'_i\}$ from buffer $\mathcal{R}$
 3. update $\hat{Q}_\phi^\pi$ using targets $y_i = r_i + \gamma \hat{Q}_\phi^\pi(\mathbf{s}'_i, \mathbf{a}'_i)$ where $\mathbf{a}'_i \sim \pi_\theta(\cdot|\mathbf{s}'_i)$
 4. $\nabla_\theta J(\theta) \approx \frac{1}{N} \sum_i \nabla_\theta \log \pi_\theta(\mathbf{a}_i^\pi|\mathbf{s}_i) \hat{Q}^\pi(\mathbf{s}_i, \mathbf{a}_i^\pi)$ where $\mathbf{a}_i^\pi \sim \pi_\theta(\mathbf{a}|\mathbf{s}_i)$
 5. $\theta \leftarrow \theta + \alpha \nabla_\theta J(\theta)$


5

图 4: 课程 slides 展示的 monitoring / deployment architecture⁴

⁴Slides 第 5 页, 强调 offline RL 的监控控制室。

14.2 Slide: Real-world Deployment Flow

Why offline RL?



Why, or when, might **offline RL** be more useful?

- leverage datasets collected by people, existing systems
- online policy collection may be risky, unsafe
- reuse previously collected data rather than recollecting (e.g. previous experiments, projects, robots, institutions)

Note: A blend of **offline** then **online RL** is also possible!

7

图 5: Slides 进一步展示的实际部署流程⁵

14.3 本章小结

用 slides Gallery 把治理/监控方案可视化，有助于向 stakeholders 演示整个 pipeline。

15 案例研究：机器人控制

15.1 Offline policy in robotics

在 robotics 任务中，数据采集成本高，offline RL 可大幅减少 real-world trials。典型做法：

- 在 simulator 训练 policy 并在 physical robot 上 replay 关键 traj。
- 用 offline dataset 中的 reward multiplier 强调安全相关动作（如 low velocity）。
- 记录 each deployment run 中 sensor readings 以便对错误进行 counterfactual audit。

Task	Data source	Safety guardrail	Offline method
Arm manipulation	Robot logs + human demos	Collision penalties	CQL
Drone navigation	Simulation + recorded flights	Wind model alert	IQL + replay

表 5: 机器人场景中的 offline RL 配置

⁵Slides 第 7 页，展示 rollout → monitor → replay 的闭环。

15.2 本章小结

机器人案例强调：data source 多元、reward carefully shaped、monitoring replay 必不可少。

16 Counterfactual Tracebacks

16.1 Replay-based counterfactuals

Counterfactual auditing 在部署前生成 hypothetical alternatives:

1. 选择 high-risk state from replay buffer。
2. Use world model to generate alternative actions。
3. Score each trajectory via reward + safety classifier。
4. 若任何 alternative 违反 constraints，则触发人工审查。

步骤	说明
State selection	从 KL drift 高或人工标记的 state 中挑选
Action generation	用 policy + noise 或 prioritized replay 生成备选 action
Audit	用 reward + constraint classifier scoring
Action	若 flagged，则回退训练或提高 conservative regularization

表 6: Counterfactual tracebacks 的执行步骤

16.2 可视化演示

Why offline RL?

Offline RL process

- Given static dataset
- Train policy on provided dataset

More formally:

Offline dataset $\mathcal{D} : \{(\mathbf{s}, \mathbf{a}, \mathbf{s}', r)\}$ sampled from some *unknown policy* π_β
“behavior policy”

$$\mathbf{s} \sim p_{\pi_\beta}(\cdot)$$

$$\mathbf{a} \sim \pi_\beta(\cdot | \mathbf{s})$$

$$\mathbf{s}' \sim p(\cdot | \mathbf{s}, \mathbf{a})$$

$$r = r(\mathbf{s}, \mathbf{a})$$

(Note: π_β may be a mixture of policies)

$$\text{Objective: } \max_{\theta} \mathbb{E}_{p_{\theta}(\tau)} \left[\sum_t r(\mathbf{s}_t, \mathbf{a}_t) \right] \quad \leftarrow \text{expectation under } \underline{\text{the learned policy } \pi_{\theta}} \\ \text{distribution shift}$$

8

图 6: Slides 第 8 页展示 counterfactual log pipeline⁶

16.3 本章小结

Counterfactual audit 让 governance 团队在 policy off-behavior 发生前就可识别异常路径。

17 Operations Checklist

17.1 部署前核查清单

Operations readiness checklist	
• 归档数据版本 ID 与 reward log。 • Training job config 附带 human sign-off。 • Monitoring dashboard 设定 alert threshold。 • Governance doc 记录 expected failure modes。	

检查项	频率	执行人
Dataset audit	每次数据版本发布	Data engineer
Policy rehearse	每次 major update	RL engineer + ops
Monitor smoke test	每次 deployment	Devops
Governance sign-off	每次 governance change	Compliance owner

表 7: Operations checklist

17.2 本章小结

Operations checklist 让 offline RL pipeline 的每个阶段都留痕，方便后续审计。

18 Training-Deployment Playbook

18.1 Step-by-step plan

这份 playbook 把 training 和 deployment 串起来：

1. Run offline baseline (IQL/CQL) log metrics.
2. Conduct replay evaluation on hold-out states.
3. If metrics pass, run sandbox rollouts with limited online interaction.
4. Monitor dashboards; if alerts fire, rerun training with higher conservatism.
5. Only after compliance sign-off release to production; keep governance log updated.

⁶Slides 第 8 页，强调 alternative trajectory scoring。

阶段	负责人	输出 artifact
Training	RL engineer	model weights, training logs, Q variance plot
Evaluation	ML ops	replay traces, benchmark report
Deployment	Devops	rollout plan, dashboard alerts, governance sign-off

表 8: Training-Deployment Playbook

18.2 本章小结

Playbook 让 devops clear about which artifact drives each stage; 没有 playbook, pipeline 会断裂。

19 Frontier Workshop Notes

19.1 Workshop focus areas

Lecturer 还建议定期 workshop, 集中解决 offline RL 中的 open problems:

- Lab session: Replay buffer introspection, 手动审核 high-risk trajectories.
- Governance: simulate counterfactual audits + compliance docs in same meeting.
- Tooling: swap data versioning backends, evaluate time-to-recover metrics.

Why offline RL?

Offline RL process

- Given static dataset
- Train policy on provided dataset

Where does the data come from?

- human collected data
- data from a hand-designed system / controller
- data from previous RL run(s)
- a mixture of sources

9

图 7: Slides 第 9 页总结 workshop 议程与 checkpoint⁷

⁷Slides 第 9 页列出 workshop 的 checkpoint 及责任人。

19.2 本章小结

Workshop 模式可以把 research insights 快速翻译成 operational improvements, 避免 knowledge silo。

20 未来挑战

20.1 可解释与审计的灵活组合

随着模型越来越强，单纯的 replay evaluation 不再能保证安全，必须引入 mechanistic interpretability 和 audit trails。

- 记录每个 action 触发的 Q gradient 信息，便于 reverse engineer。
- 将 audit log 与 governance checklist 搭配，形成“explain -> sign off”循环。
- 在 policy update 时触发 automated sanity checks 并留存 diff。

忽略解释性会导致合规缺失

若没有办法解释为什么 policy 选择某个动作，治理团队会将其标记为“不透明”，从而延迟部署。解释性与 compliance 是两个互为支撑的维度。

20.2 适应法规与政策变更

讲者强调政策变化对 offline RL 项目影响巨大：数据共享限制、logging 要求、甚至禁止某些 reward shaping 方式。需要实时跟踪法规并将文档化变更归档。

20.3 本章小结

未来的 offline RL 项目必须把 interpretability 和 governance 绑在一起，并保持政策文档与技术文档同步，才能在监管压力下稳健前行。

21 总结与延伸

1. Offline RL 在静态数据下优化策略，需要平衡模仿和探索。
2. 数据集的覆盖度与 reward 质量直接决定方法的鲁棒性。
3. IQL 通过 expectile V 来隐式约束搜索，CQL 通过 explicit penalty 施加 conservatism。
4. 多层评估、日志化监控与治理框架是成功部署的关键。
5. 监测分布 shift、Q variance、action entropy 让部署后风险可控。

21.1 总结表

维度	核心问题	应对措施	典型工具
数据集	覆盖度、奖励质量	过滤低奖励、加权 imitation	D4RL, dataset diagnostics
算法	大幅偏移导致 Q 过估计	IQL expectile, CQL penalty	IQL codebase, CQL repo
评估	benchmark score vs deployment performance	多层评估、human audit	D4RL + replay evaluation + human review
部署	监控 drift、reward shift	logging/alert + replay	dashboards, entropy targets
治理	traceability + sign-off	records, policy reviews	notebooks, compliance logs
Tooling	pipeline automation	data-versioning, policy registry	W&B, Feathr, KubeFlow
Research	offline→online handoff safety	counterfactual auditing	world models, meta RL supervisors

表 9: Offline RL 项目的工程控制表

21.2 进一步行动

1. 先用 dataset diagnostics 表识别好/坏轨迹，再决定是 filter、IQL 还是 CQL。
2. 在部署前构建 replay simulator，通过 replay 复现高风险场景。
3. 建立 monitor dashboard (action KL、reward gap、Q variance)，并给 devops team 明确 alert threshold。
4. 将每次 policy 更新的 audit info (data version、reward log、human sign-off) 写入治理日志。

21.3 拓展阅读

- Levine et al., *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* (2020)。
- Kostrikov et al., *Offline Reinforcement Learning with Implicit Q-Learning* (IQL, 2022)。
- Kumar et al., *Conservative Q-Learning for Offline Reinforcement Learning* (CQL, 2020)。
- Laskin et al., *Offline Reinforcement Learning with Dense Rewards for Realistic Tasks* (2023)。
- cs224r course notes repository for practical code samples: https://cs224r.stanford.edu/spring_2025/lecture/07.html