

课程笔记

CS224R Lecture 7: Offline RL

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-05

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1	为什么需要 Offline RL	2
1.1	本章小结	2
2	直接用 Off-Policy 算法？	2
2.1	本章小结	2
3	Offline RL 优于模仿学习	2
3.1	本章小结	3
4	隐式策略约束方法	3
4.1	Filtered/Weighted Imitation Learning	3
4.2	IQL: Implicit Q-Learning	3
4.3	本章小结	3
5	Conservative 方法	3
5.1	CQL: Conservative Q-Learning	3
5.2	CQL 的实现	3
5.3	本章小结	4
6	总结与延伸	4
6.1	拓展阅读	4

1 为什么需要 Offline RL

Offline RL 的定义

给定一个由未知行为策略 π_β 收集的静态数据集 $\mathcal{D}$ ，在不收集新数据的情况下，训练一个能最大化奖励的策略 π_θ 。

Offline RL 的价值：

- 利用人类、现有系统已收集的数据。
- 在线数据收集可能危险或昂贵。
- 复用之前的实验、项目、机器人的数据。

Online vs. Offline RL

Online RL 交替进行“收集数据”和“更新策略”。Offline RL 只有一个静态数据集，训练完成后才部署。也可以先 offline 再 online（混合模式）。

1.1 本章小结

Offline RL 解决的是“如何在¹不与环境交互的情况下，从已有数据中学习好的策略”这一问题。

2 直接用 Off-Policy 算法？

能否直接把 SAC 这样的 off-policy 算法用在静态数据集上？

Q 函数过估计问题

当 Q 函数在数据集中未见过的动作上被查询时，随机初始化的 Q 值可能任意高或低。策略会寻找 Q 函数过度乐观的动作——这些动作恰恰是 Q 函数最不可靠的地方。

策略更新后，Q 值会被大幅过估计，导致性能崩塌。根本原因是学习策略 π_θ 与行为策略 π_β 之间的分布偏移。

2.1 本章小结

直接使用 off-policy 算法在 offline 设置下会失败，因为 Q 函数在 out-of-distribution 动作上过估计。Offline RL 的核心挑战就是缓解这种过估计。

3 Offline RL 优于模仿学习

轨迹拼接 (Trajectory Stitching)

Offline 数据可能不包含完整的好轨迹，但可能包含片段性的好行为。例如轨迹 A 的前半段很好，轨迹 B 的后半段很好。好的 offline RL 方法能将²这些片段拼接起来，学到比任何单条轨迹都好的策略。模仿学习做不到这一点。

3.1 本章小结

Offline RL 通过利用奖励信息和轨迹拼接，能够超越行为策略的表现，这是纯模仿学习无法做到的。

4 隐式策略约束方法

4.1 Filtered/Weighted Imitation Learning

最简单的 baseline：只模仿数据中**高奖励**的轨迹或转移，或按奖励加权。

4.2 IQL: Implicit Q-Learning

IQL 的核心思想：避免在数据集之外的动作上查询 Q 函数。

拟合 V 函数：使用 expectile 损失，使 V 倾向于学习数据中 Q 值较高的那部分行为：

$$\hat{V}(s) \leftarrow \arg \min_V \mathbb{E}_{(s,a) \sim \mathcal{D}} \left[\ell_\lambda^2 \left(V(s) - \hat{Q}(s, a) \right) \right]$$

其中 expectile 损失对正误差给更大权重 ($\lambda > 0.5$)，使 V 偏向数据中更好的动作。

拟合 Q 函数：使用 V 而非 max 来避免 OOD 查询：

$$\hat{Q}(s, a) \leftarrow \arg \min_Q \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[\left(Q(s, a) - (r + \gamma \hat{V}(s')) \right)^2 \right]$$

4.3 本章小结

IQL 通过完全避免在数据外动作上查询 Q 函数来解决过估计问题，是一种简洁优雅的 offline RL 方法。

5 Conservative 方法

5.1 CQL: Conservative Q-Learning

CQL 的思路更直接：在 Q 函数更新中加入**惩罚项**，主动压低 Q 值。

$$\hat{Q} = \arg \min_Q \max_{\mu} \mathbb{E}_{(s,a,s') \sim \mathcal{D}} \left[\left(Q(s, a) - (r + \gamma \mathbb{E}_{\pi} [Q(s', a')]) \right)^2 \right] + \alpha \mathbb{E}_{s \sim \mathcal{D}, a \sim \mu(\cdot|s)} [Q(s, a)] - \alpha \mathbb{E}_{(s,a) \sim \mathcal{D}} [Q(s, a)]$$

- 第一项：标准 TD 更新。
- 第二项：压低所有动作的 Q 值 (μ 覆盖整个动作空间)。
- 第三项：恢复数据中动作的 Q 值 (不要过度压低)。

可以证明：对足够大的 α ，学到的 Q 值在策略分布下是**保守的**（低估而非高估）。

5.2 CQL 的实现

当使用最大熵正则化时，最优的 $\mu(a|s) \propto \exp(Q(s, a))$ ，此时惩罚项变为 $\log \sum_a \exp(Q(s, a))$ ，无需显式构造 μ 。

5.3 本章小结

CQL 通过主动压低 Q 值来防止过估计，是另一种有效的 offline RL 方法。与 IQL 的隐式约束不同，CQL 显式地构造保守估计。

6 总结与延伸

1. Offline RL 从静态数据中学习策略，无需在线交互。
2. 核心挑战： Q 函数在 OOD 动作上的过估计。
3. 三类方法：(1) 过滤/加权模仿学习；(2) 隐式策略约束 (IQL)；(3) 保守 Q 学习 (CQL)。
4. 轨迹拼接使 offline RL 能超越行为策略，这是模仿学习做不到的。
5. Offline RL 在产业中有广泛应用（如 LinkedIn 的通知优化）。

6.1 拓展阅读

- Levine et al., *Offline Reinforcement Learning: Tutorial, Review, and Perspectives on Open Problems* (综述)。
- Kostrikov et al., *Offline Reinforcement Learning with Implicit Q-Learning* (IQL, 2022)。
- Kumar et al., *Conservative Q-Learning for Offline Reinforcement Learning* (CQL, 2020)。