


课程笔记

CS224R Lecture 8: Reward Learning

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-05

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 奖励从哪里来	2
1.1 本章小结	2
2 Goal Classifiers: 从目标示例学习奖励	2
2.1 基本思想	2
2.2 对抗训练解决 Reward Hacking	2
2.3 本章小结	3
3 Inverse RL: 从行为推断奖励	3
3.1 基本思想	3
3.2 MaxEntIRL	3
3.3 本章小结	3
4 从人类偏好学习奖励	3
4.1 偏好比较	3
4.2 RLHF Pipeline	4
4.3 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 奖励从哪里来

在之前的讲次中，我们假设奖励函数 $r(s, a)$ 是给定的。但在现实中，定义奖励函数本身就是一个难题。

不同领域的奖励情况

- **电子游戏**：分数天然就是奖励，直接可用。
- **机器人**：什么是“好的抓取”？什么是“整洁的折叠”？需要人工定义，往往使用代理指标。
- **对话系统**：什么是“好的回答”？高度主观，难以用简单函数衡量。
- **自动驾驶**：涉及安全、舒适、效率等多个维度的权衡。

除了直接定义奖励外，我们已经见过一种替代方案：**模仿学习**——直接模仿专家动作，无需奖励。但模仿学习不推理结果和动力学，且专家可能有不同的 embodiment。

1.1 本章小结

奖励设计是 RL 应用的关键瓶颈。本讲介绍三种从人类监督中学习奖励的方法。

2 Goal Classifiers: 从目标示例学习奖励

2.1 基本思想

收集成功状态（正例）和失败状态（负例），训练一个二分类器，用其输出作为奖励信号。

1. 收集成功状态集 D^+ 和失败状态集 D^-
2. 训练二分类器：输入 s_i ，标签 $\mathbf{1}(s_i \in G)$
3. 用分类器输出作为 RL 的奖励

Reward Hacking

RL 算法会积极寻找使分类器输出高分的状态。它可能找到分类器**从未训练过的**状态——即利用分类器的弱点，而不是真正完成任务。

2.2 对抗训练解决 Reward Hacking

解决思路：将 RL 访问的状态加入负例集合，迫使分类器不断更新以避免被利用。

1. 初始化 D^+ （成功状态）和 D^- （失败状态）
2. 用 D^+ 和 D^- 训练分类器（平衡数据集）
3. 用策略 π 收集经验 $s_t, a_t, \dots$
4. 用分类器奖励更新策略

5. 将访问的状态加入负例: $D^- \leftarrow D^- \cup \{s_t\}$

6. 重复

为什么这个方法能工作

分类器不再能被利用。关键问题: 如果策略真的成功了怎么办? 只要保持 D^+ 和 D^- 的平衡采样, 分类器对真正的成功状态仍会输出 $p \geq 0.5$ 。

实验表明, 在机器人任务中, 基于 50 个演示训练的 goal classifier + RL 达到了 62% 的成功率, 远高于直接模仿学习的 26%。

2.3 本章小结

Goal classifier 是一种简单有效的奖励学习方法。对抗训练是防止 reward hacking 的关键。

3 Inverse RL: 从行为推断奖励

3.1 基本思想

给定专家的演示轨迹, 推断专家优化的是什么奖励函数。

$$\max_{\psi} \mathbb{E}_{\tau \sim \pi_{\text{expert}}} \left[\sum_t r_{\psi}(s_t, a_t) \right] - \mathbb{E}_{\tau \sim \pi} \left[\sum_t r_{\psi}(s_t, a_t) \right]$$

直觉: 学到的奖励应该使专家的行为比其他策略的行为获得更高的奖励。

3.2 MaxEntIRL

加入最大熵正则化后, IRL 与 GAN 有深层联系: 奖励函数类似判别器, 策略类似生成器。

3.3 本章小结

Inverse RL 从专家行为中推断奖励函数, 比直接模仿学习更灵活 (可以处理不同 embodiment), 但需要交替优化奖励和策略。

4 从人类偏好学习奖励

4.1 偏好比较

直接让人类给绝对评分困难且噪声大。更好的方式: 展示两个选项, 让人类选择哪个更好。

$$p(y_1 \succ y_2 \mid x) = \sigma(R_{\phi}(x, y_1) - R_{\phi}(x, y_2))$$

Bradley-Terry 模型

给定人类偏好数据 (y_w, y_l) (y_w 被偏好), 训练奖励模型 R_ϕ 最大化:

$$\mathcal{L}(\phi) = \mathbb{E} [\log \sigma (R_\phi(x, y_w) - R_\phi(x, y_l))]$$

这就是 RLHF 中**奖励模型训练**的核心公式。

4.2 RLHF Pipeline

1. 收集人类偏好比较数据
2. 训练奖励模型 R_ϕ
3. 用 RL (如 PPO) 优化策略以最大化 R_ϕ 的输出

奖励模型也会被利用

与 goal classifier 类似, 如果 RL 优化过度, 策略可能找到奖励模型的漏洞而不是真正满足人类偏好。因此通常加入 KL 约束, 限制策略不能偏离初始策略太远。

4.3 本章小结

从偏好比较中学习奖励模型是 RLHF 的基础。Bradley-Terry 模型将偏好比较转化为奖励差的 sigmoid, 训练简单高效。

5 总结与延伸

1. 奖励设计是 RL 应用的瓶颈, reward learning 提供了自动化的解决方案。
2. **Goal Classifiers**: 从成功/失败示例学习, 简单直接。对抗训练防止 reward hacking。
3. **Inverse RL**: 从专家行为推断奖励函数, 比模仿学习更灵活。
4. **偏好学习**: 从人类偏好比较中训练奖励模型, 是 RLHF 的核心。
5. 所有 reward learning 方法都面临 reward hacking 的风险, 需要正则化和约束。

5.1 拓展阅读

- Christiano et al., *Deep Reinforcement Learning from Human Preferences* (2017)。
- Ziegler et al., *Fine-Tuning Language Models from Human Preferences* (2019)。
- Sharma et al., *Self-Improving Robots: End-to-End Autonomous Visuomotor Reinforcement Learning* (2023)。