

课程笔记

CS224R Lecture 9: RLHF 与偏好优化

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025-05

视频时长: 约 80 分钟

讲者: Archit Sharma (Guest Lecture)

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	从语言模型到助手	2
1.1	预训练语言模型的局限	2
1.2	本章小结	2
2	Instruction Finetuning	2
2.1	基本方法	2
2.2	Instruction Finetuning 的局限	2
2.3	本章小结	2
3	RLHF: 从人类偏好中强化学习	2
3.1	核心框架	2
3.2	奖励模型训练	3
3.3	Policy Gradient 用于 LLM	3
3.4	本章小结	3
4	DPO: Direct Preference Optimization	4
4.1	绕过奖励模型	4
4.2	DPO 的直觉	4
4.3	本章小结	4
5	RL for LLM Reasoning	5
5.1	超越偏好: 可验证奖励	5
5.2	本章小结	5
6	总结与延伸	5
6.1	拓展阅读	5

1 从语言模型到助手

1.1 预训练语言模型的局限

预训练语言模型学会了**补全文本**，但这不等于**帮助用户**。语言建模目标与”满足人类偏好”之间存在根本性的不对齐。

预训练学到了什么

预训练通过大量文本学到了丰富的知识：事实、语法、共指消解、情感分析、基本推理、数学、编程等。但它学到的是”下一个最可能的 token”，而不是”用户最想要的回答”。

1.2 本章小结

预训练 LM 具有丰富的知识和能力，但需要额外的对齐步骤才能成为有用的助手。

2 Instruction Finetuning

2.1 基本方法

收集 (instruction, output) 对，在预训练模型上继续做监督微调。

Instruction Finetuning 的效果

FLAN-T5 在 1800+ 任务上进行 instruction finetuning 后，在未见过的任务上表现显著提升。更大的模型从 finetuning 中获益更多。

2.2 Instruction Finetuning 的局限

1. **开放式生成没有标准答案**：创意写作等任务无法用唯一正确输出来监督。
2. **Token 级别的惩罚不区分错误严重程度**：语言建模损失对所有 token 错误一视同仁。
3. **人类生成的答案本身不完美**：标注数据有噪声。

2.3 本章小结

Instruction finetuning 是从 LM 到助手的第一步，但仍存在目标不对齐的问题。需要更直接地优化人类偏好。

3 RLHF：从人类偏好中强化学习

3.1 核心框架

1. **Instruction Finetuning**：作为初始化。
2. **训练奖励模型**：从人类偏好比较中学习 $R_\phi(x, y)$ 。
3. **RL 优化**：用 PPO 等算法最大化奖励模型的输出。

3.2 奖励模型训练

人类比较两个回答并选择更好的那个。使用 Bradley-Terry 模型：

$$p(y_w \succ y_l \mid x) = \sigma(R_\phi(x, y_w) - R_\phi(x, y_l))$$

损失函数：

$$\mathcal{L}(\phi) = -\mathbb{E}_{(x, y_w, y_l)} [\log \sigma(R_\phi(x, y_w) - R_\phi(x, y_l))]$$

为什么用比较而不是评分

人类给绝对评分时噪声大且校准不一致。成对比较更简单、更可靠：只需判断“A 比 B 好”而不需要“A 是 7.3 分”。

3.3 Policy Gradient 用于 LLM

将 LLM 生成视为 RL 问题：

$$\max_{\theta} \mathbb{E}_{y \sim p_{\theta}(y|x)} [R_{\phi}(x, y)]$$

使用 REINFORCE / policy gradient：

$$\theta_{t+1} := \theta_t + \alpha \frac{1}{m} \sum_{i=1}^m R(s_i) \nabla_{\theta_t} \log p_{\theta_t}(s_i)$$

直觉：高奖励的生成增加概率，低奖励的生成降低概率。

KL 正则化的必要性

不加约束地优化奖励模型，策略会 exploit 奖励模型的弱点（reward hacking）。标准做法是加入 KL 惩罚：

$$\max_{\theta} \mathbb{E}_{y \sim p_{\theta}} [R_{\phi}(x, y)] - \beta D_{\text{KL}}(p_{\theta} \| p_{\text{ref}})$$

其中 p_{ref} 是 SFT 模型。 β 控制策略偏离初始模型的程度。

3.4 本章小结

RLHF 的完整 pipeline：instruction finetuning → 奖励模型训练 → PPO 优化。KL 正则化是防止 reward hacking 的关键。

4 DPO: Direct Preference Optimization

4.1 绕过奖励模型

DPO 的核心洞察

RLHF 中带 KL 约束的 RL 问题有闭式解：

$$\pi^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp \left(\frac{1}{\beta} r(x, y) \right)$$

反过来可以将奖励表示为策略的函数：

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x)$$

将此代入 Bradley-Terry 模型， $Z(x)$ 项相消，得到 DPO 损失：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right]$$

DPO 的优势：

- 不需要训练单独的奖励模型。
- 不需要 RL 训练（无需 PPO）。
- 只需要标准的监督训练循环。
- 训练更稳定、更简单。

4.2 DPO 的直觉

DPO 损失隐式地做了两件事：

1. 增加被偏好回答 y_w 的概率。
2. 降低不被偏好回答 y_l 的概率。

权重由 σ 函数内部的”隐式奖励差”自动调节。

DPO vs. RLHF

- **RLHF**：训练奖励模型 $\rightarrow$ RL 优化。两阶段，需要 RL 基础设施。
- **DPO**：直接在偏好数据上优化策略。单阶段，只需 SFT 代码。
- 理论上 DPO 与 RLHF 优化的是同一个目标。
- 实践中 DPO 更简单但可能在某些场景下不如 RLHF 灵活。

4.3 本章小结

DPO 通过将 RL 目标的闭式解代入 Bradley-Terry 模型，将偏好优化简化为纯监督学习问题。它是目前 LLM 对齐中最流行的方法之一。

5 RL for LLM Reasoning

5.1 超越偏好：可验证奖励

在数学、编程等领域，答案是否正确可以**自动验证**。此时不需要人类偏好，可以直接用正确性作为奖励进行 RL 训练。

RL for Reasoning 的兴起

DeepSeek-R1 等模型展示了 RL 训练能让 LLM 学会推理中的自我纠错和思维链等能力。这是 RL 在 LLM 中除对齐之外的另一个重要应用方向。

5.2 本章小结

RL 在 LLM 中不仅用于对齐 (RLHF/DPO)，还可以用于提升推理能力。可验证奖励（如数学答案正确性）为 RL 训练提供了免费且准确的信号。

6 总结与延伸

1. 从预训练 LM 到助手需要三步：instruction finetuning、奖励建模、策略优化。
2. **RLHF**：训练奖励模型 + PPO 优化，是 ChatGPT 等模型的核心技术。
3. **DPO**：将偏好优化简化为监督学习，无需 RL 基础设施。
4. KL 正则化防止 reward hacking，是偏好优化的关键组件。
5. RL 在 LLM 推理（数学、编程）中展现出巨大潜力。
6. 偏好比较比绝对评分更可靠，Bradley-Terry 模型是标准框架。

6.1 拓展阅读

- Ouyang et al., *Training Language Models to Follow Instructions with Human Feedback* (InstructGPT, 2022)。
- Rafailov et al., *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* (DPO, 2023)。
- DeepSeek-AI, *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* (2025)。
- Chung et al., *Scaling Instruction-Finetuned Language Models* (FLAN-T5, 2022)。