

课程笔记

CS224R Lecture 9: RLHF 与偏好优化

基于 Stanford CS224R 公开课程整理

2025 年 5 月 12 日



视频作者/频道: Stanford Online

发布日期: 2025-05-07

视频时长: 约 80 分钟

讲者: Archit Sharma (Guest Lecture)

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	从语言模型到助手	3
1.1	预训练语言模型的局限	3
1.2	人类偏好的多样性	3
1.3	本章小结	3
2	Instruction Finetuning	3
2.1	基本方法	3
2.2	数据策略与对齐	4
2.3	Instruction Finetuning 的局限	4
2.4	本章小结	4
3	RLHF: 从人类偏好中强化学习	4
3.1	核心框架	4
3.2	奖励模型训练	5
3.3	Policy Gradient 用于 LLM	5
3.4	奖励数据质量控制	5
3.5	策略正则化与采样策略	6
3.6	本章小结	6
4	DPO: Direct Preference Optimization	6
4.1	绕过奖励模型	6
4.2	DPO 的直觉	7
4.3	实践与参数选择	7
4.4	本章小结	8
5	RL for LLM Reasoning	8
5.1	超越偏好: 可验证奖励	8
5.2	可验证奖励的设计	8
5.3	实验与评估	8
5.4	本章小结	9
6	评估与证据	9
6.1	Benchmark Stack	9
6.2	Evidence Matrix	9
6.3	Calibration 与 Robustness	10
6.4	部署指标与 evidence ranking	10
6.5	本章小结	10
7	工程与监控	10
7.1	RLHF Pipeline Timeline	10
7.2	Operational Monitoring	11
7.3	Governance Checklist	12
7.4	Drift Detection 架构	12

7.5	本章小结	12
7.6	Ops Playbook	12
7.7	本章小结	13
8	部署与信任	13
8.1	部署复盘与回滚	13
8.2	多角色治理与信任	14
8.3	本章小结	14
9	案例与研究方向	14
9.1	Visual Agent Evidence	14
9.2	Slides 与实践映射	15
9.3	Research Directions	15
9.4	本章小结	16
10	行动清单与下一步	16
10.1	部署前准备	16
10.2	上线后反馈	16
10.3	本章小结	16
11	总结与延伸	16
11.1	总结表	17
11.2	拓展阅读	17

1 从语言模型到助手

1.1 预训练语言模型的局限

预训练语言模型学会了**补全文本**，但这不等于**帮助用户**。语言建模目标与”满足人类偏好”之间存在根本性的不对齐。

预训练学到了什么

预训练通过大量文本学到了丰富的知识：事实、语法、共指消解、情感分析、基本推理、数学、编程等。但它学到的是”下一个最可能的 token”，而不是”用户最想要的回答”。

1.2 人类偏好的多样性

真实用户偏好并不是单一的奖赏函数，而是由多个维度组成：任务完成度、创造性、礼貌、可解释性、甚至审美。Archit 在讲座中称“偏好是一个多模态的向量空间，而非单一标量”，并强调在构建信号时一定要分层采集。

我们可以按来源将偏好分为：

- **人类比较**：用户或标注者给出回答队列，挑选最优者。
- **可验证指标**：数学题目、编程任务、事实一致性等可以自动打分。
- **行为数据**：点击率、重写率、跳出率等隐含用户满意度。
- **治理约束**：安全、合规要求需要额外的 guardrail 信号。

偏好矩阵建模的洞察

把多个偏好信号组合成 *hierarchical preference matrix*，能够明确每种信号的作用范围，并在优化时以加权方式对齐不同目标。

多信号偏好可解释化

把 signal 分成 *primary preference* (核心满意度) 和 *secondary constraint* (安全、bias) 两类，分别用 reward model 和 guardrail filter 处理，能减少 reward hacking 并提升治理透明度。

1.3 本章小结

预训练 LM 具有丰富的知识，但要变成助手必须从指令微调、偏好信号拆分、治理信号嵌入等多个维度对齐，才能避免单一 reward 走偏。

2 Instruction Finetuning

2.1 基本方法

收集 (instruction, output) 对，在预训练模型上继续做监督微调。

Instruction Finetuning 的效果

FLAN-T5 在 1800+ 任务上进行 instruction finetuning 后, 在未见过的任务上表现显著提升。更大的模型从 finetuning 中获益更多。

2.2 数据策略与对齐

- 在数据层面, 先做 prompt rewriting 和 canonicalization, 减少语义重复, 再标注最佳回答与备选回答。
- 用多轮对话模拟, 增加上下文依赖; 对负样本加入多样化错误类型, 提升 robustness。
- 采集指令时, 同时保留 user intent metadata (任务类型、复杂度、偏好) 以便后续 reward model 进行分层建模。

Instruction 数据的可解释化

把每条 instruction 附上 metadata, 使得训练时可以根据意图 (如 *creative vs. factual*) 动态选用 reward signal, 减少因单一 loss 导致的泛化误差。

数据质量胜过模型大小

虽然更大的模型具备更强的底层能力, 但 instruction 微调的数据质量决定了最终助手的可靠性。对抗性字段、多样化指令和人工审查是基本保障。

2.3 Instruction Finetuning 的局限

1. 开放式生成没有标准答案: 创意写作等任务无法用唯一正确输出来监督。
2. Token 级别的惩罚不区分错误严重程度: 语言建模损失对所有 token 错误一视同仁。
3. 人类生成的答案本身不完美: 标注数据有噪声。

2.4 本章小结

Instruction finetuning 是从 LM 到助手的第一步, 必须配合数据策略与偏好拆分, 才能为 RLHF 或 DPO 提供稳定的初始策略。

3 RLHF: 从人类偏好中强化学习

3.1 核心框架

1. Instruction Finetuning: 作为初始化。
2. 训练奖励模型: 从人类偏好比较中学习 $R_\phi(x, y)$ 。
3. RL 优化: 用 PPO 等算法最大化奖励模型的输出。

3.2 奖励模型训练

人类比较两个回答并选择更好的那个。使用 Bradley-Terry 模型：

$$p(y_w \succ y_l \mid x) = \sigma(R_\phi(x, y_w) - R_\phi(x, y_l))$$

损失函数：

$$\mathcal{L}(\phi) = -\mathbb{E}_{(x, y_w, y_l)} [\log \sigma(R_\phi(x, y_w) - R_\phi(x, y_l))]$$

为什么用比较而不是评分

人类给绝对评分时噪声大且校准不一致。成对比较更简单、更可靠：只需判断“A 比 B 好”而不需要“A 是 7.3 分”。

3.3 Policy Gradient 用于 LLM

将 LLM 生成视为 RL 问题：

$$\max_{\theta} \mathbb{E}_{y \sim p_{\theta}(y|x)} [R_{\phi}(x, y)]$$

使用 REINFORCE / policy gradient：

$$\theta_{t+1} := \theta_t + \alpha \frac{1}{m} \sum_{i=1}^m R(s_i) \nabla_{\theta_t} \log p_{\theta_t}(s_i)$$

直觉：高奖励的生成增加概率，低奖励的生成降低概率。

KL 正则化的必要性

不加约束地优化奖励模型，策略会 exploit 奖励模型的弱点（reward hacking）。标准做法是加入 KL 惩罚：

$$\max_{\theta} \mathbb{E}_{y \sim p_{\theta}} [R_{\phi}(x, y)] - \beta D_{\text{KL}}(p_{\theta} \| p_{\text{ref}})$$

其中 p_{ref} 是 SFT 模型。 β 控制策略偏离初始模型的程度。

3.4 奖励数据质量控制

偏好数据的质量直接决定 reward model 的泛化能力。常见的质量维度有：比较一致性、标注员经验、context diversity 以及 hard negative 比例。

维度	实施做法
一致性	多轮盲审，计算 Cohen's kappa；不一致条目发送给高级审查
多样性	故意补充 creative、factual、multi-turn prompt，避免 reward 只对某类指令上调
硬负样本	采集 near-miss 回答，让 reward model 区分 subtle flaws
元数据	记录 intent、topic、difficulty，以便在训练时按人类意图分层采样

表 1: 偏好数据质量控制要素

质量胜于模型大小

Reward model 归因链上最薄弱的一环通常是 label quality, 而不是参数尺寸。构建 audit trail 并把 inconsistency 反馈给 labeler, 是提升对齐稳定性的捷径。

3.5 策略正则化与采样策略

KL 不只是 regularizer, 也是在 sampling 过程中维持多样性的手段:

- 在 PPO 中用 KL constraint 监控策略 drift, 如果某次 rollout 的 KL 超阈值立即恢复到 reference。
- 加入 entropy bonus 让策略不会 collapse 到 deterministic 解。
- 通过 temperature sweep 和 rejection sampling 评估 reward model 的 risk surface, 并记录在 rollout ledger。

KL 作为审核机制

Archit 强调: “KL 让模型在走得太远之前先听到参考政策的自我批评”, 这让 reward model 与 reference policy 之间保持健康对话。

3.6 本章小结

RLHF 的完整 pipeline: instruction finetuning → 奖励模型训练 → PPO 优化。数据质量控制、KL 正则化与采样策略共同保障 reward model 不走偏, 才能把 LM 变成可靠的助手。

4 DPO: Direct Preference Optimization

4.1 绕过奖励模型

DPO 的核心洞察

RLHF 中带 KL 约束的 RL 问题有闭式解:

$$\pi^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

反过来可以将奖励表示为策略的函数:

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x)$$

将此代入 Bradley-Terry 模型, $Z(x)$ 项相消, 得到 DPO 损失:

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right]$$

DPO 的优势:

- 不需要训练单独的奖励模型。

- 不需要 RL 训练（无需 PPO）。
- 只需要标准的监督训练循环。
- 训练更稳定、更简单。

4.2 DPO 的直觉

DPO 损失隐式地做了两件事：

1. **增加**被偏好回答 y_w 的概率。
2. **降低**不被偏好回答 y_l 的概率。

权重由 σ 函数内部的”隐式奖励差”自动调节。

DPO vs. RLHF

- **RLHF**：训练奖励模型 $\rightarrow$ RL 优化。两阶段，需要 RL 基础设施。
- **DPO**：直接在偏好数据上优化策略。单阶段，只需 SFT 代码。
- 理论上 DPO 与 RLHF 优化的是**同一个目标**。
- 实践中 DPO 更简单但可能在某些场景下不如 RLHF 灵活。

4.3 实践与参数选择

DPO 训练过程中几个关键要素：

- 选取稳定的 reference policy，通常用 instruction finetuned checkpoint。
- 调整 β 以控制偏好程度： β 越小，策略越接近 reference；越大，则更容易强化偏好。
- 采样权重需要兼顾头部和尾部，避免 reward model 只偏好高概率回答。

超参	推荐设置
β	0.1-1.0，按照偏好强度进行 sweep，观察 KL 与 accuracy trade-off
Reference policy	SFT checkpoint + small RL finetuning for stability
Batch composition	保留 balanced ratio 的 winning/losing pair，避免 collapse

表 2: DPO 调参与训练实践

DPO Training Insight

DPO 把 reward scoring 转换成 logits 差值，因此观察 $\log \pi_\theta / \pi_{\text{ref}}$ shift 就可以直观判断偏好强化程度。

4.4 本章小结

DPO 通过将 RL 目标的闭式解代入 Bradley-Terry 模型，将偏好优化简化为纯监督学习问题。结合 β sweep 与参考策略选择可以在精度与稳定性之间取得平衡。

5 RL for LLM Reasoning

5.1 超越偏好：可验证奖励

在数学、编程等领域，答案是否正确可以**自动验证**。此时不需要人类偏好，可以直接用正确性作为奖励进行 RL 训练。

RL for Reasoning 的兴起

DeepSeek-R1 等模型展示了 RL 训练能让 LLM 学会推理中的自我纠错和思维链等能力。这是 RL 在 LLM 中除对齐之外的另一个重要应用方向。

5.2 可验证奖励的设计

可验证任务常见信号包括：

- **逻辑一致性**：自动判别数学解答是否满足步骤逻辑。
- **合成推理**：用 symbolic executor 检查推理链条，reward 直接反馈到 token。
- **生成式验证**：用 verifier LM 对 candidate 回答打分，作为 auxiliary reward。

任务类别	可验证信号	典型指标
数学推理	steps correctness	chain-of-thought accuracy、full solution correctness
编程	unit test pass rate	pass@k、runtime exceptions
知识问答	factuality consistency	TruthfulQA、F1 against evidence

表 3: 可验证奖励覆盖的任务与指标

自监督 verifier 的作用

当人工比较不可行时，引入自监督 verifier（如 program executor 或 verifier LM）可以生成 reward signal，保障 reasoning RL 的闭环。

5.3 实验与评估

DeepSeek-R1 等工作常用 baseline：Instruction tuned LM + RLHF contrast、DPO、RL for reasoning pipeline。验证方法包括 LM 生成、多轮提示和 external verifier 检查。

Reasoning RL 的洞察

“RL 为模型提供了自我纠错的机制，而不是仅仅加强模仿”——这种反馈让 model 在面对长链推理或 multi-hop question 时更愿意 traverse deeper reasoning tree。

评估时也要考虑 inference latency，因为 reasoning RL 常常需要 rollouts 和 verifier，部署时需要权衡 real-time 体验。

5.4 本章小结

RL 在 LLM 中不仅用于对齐 (RLHF/DPO)，也服务于 reasoning：通过可验证奖励与 verifier pipeline，模型得到自我纠错的监督；实验中需要同时考量 correctness 与 latency trade-off。

6 评估与证据

6.1 Benchmark Stack

偏好优化的目标是让模型在多种 benchmark 上展现一致进步。常见的评估层次：

层次	示例指标	说明
自动化 benchmark	HumanEval、MMLU、TruthfulQA	量化能力与 reasoning
偏好一致性	Pairwise Preference Accuracy	奖励模型能否预测人类偏好
对齐检查	Red Team、Safety Gym	模型在安全边界内的表现
部署指标	Rejection Rate、Hallucination Rate	实际使用中体验质量

表 4: RLHF/DPO 评估栈

6.2 Evidence Matrix

部署前需要整理 evidence matrix，搭建对齐与验证的证据链：

Evidence		Source	Metric	Decision Use
Pairwise ranking	human	crowdsourced label studio	Accuracy	Reward model calibration
Automated guardrails		prompt test suite	Reject rate	Safety filter tuning
Long-context consistency	con-	multi-turn benchmark	Drift score	Deployment guardrail
Deployment logs		tooling + telemetry	Incident count	Postmortem loop

表 5: Evidence matrix 用于跨阶段验证

6.3 Calibration 与 Robustness

不仅需要对齐 evaluation，还要在不同语义注入、上下文长度、token budget 变动时保持稳定。常见措施有：

- 对 reward model 输出做 temperature calibration 到 0-1 区间
- 建立 multi-context benchmark，检测 evidence drift
- 用 counterfactual prompt (e.g. ‘change numeric context’) 验证 reward 变化趋势一致
- 记录 rejection case IDs 以便 drill-down

偏好模型 drift 误判的风险

即便 reward model 在训练集表现良好，也可能在实际 prompt 中 drift。如果没有 calibration 和 drift detection，就无法保证 alignment 在部署后仍然成立。

6.4 部署指标与 evidence ranking

当模型进入灰度或全量部署后，evaluation stack 需要稳健对接监控层：

- **Rejection/deferral rate**：判断 guardrail 是否过于宽松或严格。
- **Hallucination trend**：按 topic 分组，查看 hallucination rate 是否在特定方向聚集。
- **Latency drift**：策略更新后 latency 是否突破 SLO。
- **Evidence score**：把 benchmark、human eval、deployment logs 建立分层排序，为 decision board 提供实时依据。

Evidence ranking 的价值

把不同阶段的 evidence 赋予不同权重（例如：部署 logs > benchmark），可以在不牺牲安全的前提下快速推进版本迭代。

评价仪表盘需要实时可视化

Archit 提醒：“*Evidence matrix* 不是写在文档里的表格，而是在 *dashboard* 上不断更新的热力图”，只有实时可视化才能发现 drift 盲点。

6.5 本章小结

评估与证据体系需要从 benchmark 到部署层层覆盖，Evidence Matrix 是把不同信号拼接成可执行结论的枢纽，deploy metrics 则把 evaluation stack 延伸到 production。

7 工程与监控

7.1 RLHF Pipeline Timeline

把 RLHF pipeline 拆成阶段，便于团队协作：

- 数据构建周: instruction + comparison data 采集
- 奖励建模周: 重复训练 + calibration + validation
- 策略优化周: PPO 或 DPO 迭代 + KL/entropy tuning
- 质量检查周: benchmark + red team + human eval
- 监控与 rollout: gradual deployment + drift monitoring

Action Timeline

每个阶段都定义清晰的 deliverable: 数据构建结果、奖励模型 blueprints、PPO checkpoint、审查报告、部署决策。这样团队才知道什么时候可以推进下一步。

7.2 Operational Monitoring

部署后必须持续监控 hallucination、rejection、latency。




图 1: Slide 1 把 RLHF pipeline 与监控指标同时展示，强调 latency 与 rejection 的追踪。

观察盘的指标设计

推荐同时展示: Reward score drift、human rejection rate、token latency、deploy coverage。不同指标组合可以帮助团队快速判断是 model drift 还是 data drift。

指标	说明
Reward score drift	用 rolling window 比较 current vs baseline reward distribution
Reject ratio	审查反馈的拒绝率，用于评估 guardrail 灵敏度
Latency P99	保障 transformer + verifier pipeline 不超出 SLO
Human override count	人工干预次数，用来 calibrate automation trust

表 6: 部署后观察盘核心指标

7.3 Governance Checklist

控制点	核心问答	输出
Reward model approval	是否经过 blind eval validation?	Approval checklist
Policy guardrails	是否有 automatic rejection for forbidden topics?	Guardrail rules
Deployment gating	是否逐步扩容、扣留异常?	Rollout policy

表 7: RLHF 的治理检查表

7.4 Drift Detection 架构

一旦模型上线，需要检测两类 drift: prompt drift (用户输入变化) 与 distribution drift (输出行为变化)。

- 在 logging pipeline 中捕获 prompt signature (hash + metadata)
- 用 rolling window 统计 reward score distribution
- 提供 alert, 当 KL divergence vs zscore 超阈值时触发 human review
- 建立 ‘drift ticket’, 包含 snapshot prompt, reward score, output diff

Drift detection 不只是 anomaly detection

它需要 context-aware thresholds: 不同任务 (summaries vs math) 对 reward score 的 variance 本身就不同。缺乏 context-specific threshold, 会造成大量假告警。

7.5 本章小结

工程层面要把 timeline、监控和治理结合起来，监控 dashboard 和 checklist 是部署后信任的重要基础。

7.6 Ops Playbook

1. **Observe**: 聚合 reward scores、rejection logs、prompt hash。
2. **Assess**: 用 evidence matrix 与 counterfactual prompt 检查 drift。
3. **Act**: 让 AI 推荐 low-risk 缓解动作并生成 rollback plan, 人工批准后执行。
4. **Document**: 把决策写回 checklist / runbook, 供下一轮 evaluation 使用。

阶段	输出	核心参与者
Observe	Reward + guardrail logs	SRE + Data Eng
Assess	Evidence scorecard + drift report	Alignment + QA
Act	Rollback plan/mitigation action	Product + Legal
Document	Runbook entry + retrospective	Ops + PM

表 8: Ops Playbook 的可执行交付物

Ops runbook 的价值

把每次 Act 往返写成 runbook 条目，不仅可以 guarantee 复现，也在 board review 时提供透明的 audit trail。

AI 主要做 triage，决策仍需人类把关

即使 AI 建议某条规则，仍要在高风险线路上让人类审核，防止自动化误判导致不可逆后果。

7.7 本章小结

工程层面要把 timeline、监控、治理、drift detection 与 ops playbook 串成闭环，才能在灰度/全量阶段维持 alignment 信任。

8 部署与信任

8.1 部署复盘与回滚

每次 release 后都需要做 pre-mortem、post-mortem 与 rollback 验证：

- **Pre-mortem**：在 rollout 之前模拟 worst-case prompt drift，确认 guardrail 覆盖。
- **Post-mortem**：收集 rejection log、reward score drift，在 incident log 中备注。
- **Rollback 验证**：设计 rollback playbook，先在 staging 里演练 restore checkpoint、recover guardrail。

预拟事故的价值

在产品经理批准 rollout 之前先做一次预估风险演练，可以把 high-risk prompt 列入 watchlist，避免事故发生时手忙脚乱。

复盘阶段	内容
Pre-mortem	drift risk list、evidence matrix 检查、guardrail traceability
Post-mortem	reward score drift graph、human override log、root cause analysis
Rollback	reference checkpoint + runbook、alert escalation path

表 9: 部署复盘与回滚交付物

8.2 多角色治理与信任

Alignment pipeline 不只是 research，治理团队、法律、SRE 都需要参与：

- 研发团队负责 reward model + policy update。
- 运营/监控团队负责 drift alert、dashboard。
- 法务/合规负责 guardrail audit、privacy review。
- PM + decision board 根据 evidence ranking 最终决定 rollout 或 rollback。

多角色治理的设想

把 evidence matrix 声明为 multi-stakeholder checkpoint，例如：每次 policy update 都要让 compliance team 复核 long-form prompts。

风险放大链条

如果缺乏 governance checkpoint，就会出现 reward model fine-tune 后拉高某类 prompt，但 compliance 没有 catch，导致 high-risk reply 直接进入 production。

8.3 本章小结

部署与信任需要 pre-mortem/post-mortem+rollback 以及多角色的 evidence governance，只有这样才能在不断迭代的 RLHF pipeline 中维持 alignment 信任。



9 案例与研究方向

9.1 Visual Agent Evidence

关键幻灯片展示了 evidence matrix 与 agent swarm 之间的耦合：

Larger and larger models

The blessings of scale
AI training runs, estimated computing resources used
Floating-point operations, selected systems, by type, log scale



<https://www.economist.com/interactive/briefing/2022/06/11/huge-foundation-models-are-turbo-charging-ai-progress>
<https://ai-2027.com/>

2

图 2: Slide 2 分析 agent swarm、data quality 与 governance 的关系，并附带 evidence matrix。

9.2 Slides 与实践映射

Language models as assistants?

How do we get from *this*

Stanford University is located in _____

to *this*?





图 3: Slide 3 展示了 RLHF pipeline、ops playbook 与治理 checkpoint 的融合，是讲座中强调 actionability 的视觉证据。

Slide 3 把 timeline、monitoring、governance 串成矩阵，提醒团队在每个阶段都要有明确的可交付 artifact。

幻灯片到产出的映射

在部署前，把 slide 中的 timeline、artifact 与 checkpoints 映射为 sprint backlog，可以确保每个 deliverable 都有人负责。

9.3 Research Directions

未来研究可以关注：

- 把 reward model calibration 与 policy evaluation auto-connected
- Multi-agent 身份下的 preference alignment
- Explainability layer 使 KL 约束可解释
- Sim-to-real research 让 reward model 适应更宽泛场景

Archit 还特别强调，需要把理论研究与实际 deployment 反馈循环起来：新的研究方向必须能生成可执行 playbook，而不仅仅是 paper-level insight。

研究方向的工程可解释性

让研究成果可落地的关键是**工程可解释性**：解释 KL margin、reward model drift、agent dash board 指标，才能让产品经理和法律团队信任 alignment pipeline。

9.4 本章小结

案例部分把 slide 上的视觉证据、agent swarm 结构与未来研究方向串起来，提醒我们 RLHF 还在快速演化。

10 行动清单与下一步

10.1 部署前准备

在 rollout 之前，需要收敛以下交付物：

- **Data readiness**: 确认 preference dataset 覆盖新的 prompt cluster，避免 distribution shift。
- **Model readiness**: 检查 RLHF 有 limit order，DPO/dRL 版本保持 KL margin。
- **Governance readiness**: 所有 guardrail policies 都写入 policy doc，compliance team 签署。

准备阶段的自动化清单

把 readiness checklist 反向链接到 issue tracker，每个 item 通过 automation bot ping 相关 owner，确保没有漏项。

10.2 上线后反馈

部署后要保持持续反馈循环：

- 依赖 **evidence dashboard** 触发 auto-alert，当 reward drift+latency spikes 同时发生时自动 escalate。
- 每周汇报 **ops scorecard**: reward score drift、human override、rejection trend。
- 用 **post-deployment study** 检查 new prompts、adversarial tests、user complaints 是否同步反馈到 labeling pipeline。

持续反馈的重要性

Auto-alert 帮助快速发现 drift，但真正的 alignment 还是要靠 weekly review meeting，把 quantitative signals 转换成 qualitative insights。

10.3 本章小结

完整的行动清单包括部署前的 readiness checklist 与 deployment 后的 feedback loop，只有严密闭环才能把 RLHF pipeline 的 research 变成 resilient product。

11 幻灯片与可视化证据

11.1 策略与证据分层: Slide 0-04

Recap: What kinds of things does pretraining learn?

- *Stanford University is located in _____, California.* [Trivia]
- *I put ____ fork down on the table.* [syntax]
- *The woman walked across the street, checking for traffic over ____ shoulder.* [coreference]
- *I went to the ocean to see the fish, turtles, seals, and ____.* [lexical semantics/topic]
- *Overall, the value I got from the two hours watching it was the sum total of the popcorn and the drink. The movie was ____.* [sentiment]
- *Iroh went into the kitchen to make some tea. Standing next to Iroh, Zuko pondered his destiny. Zuko left the ____.* [some reasoning – this is harder]
- *I was thinking about the sequence that goes 1, 1, 2, 3, 5, 8, 13, 21, ____* [some basic arithmetic; they don't learn the Fibonacci sequence]

5

图 4: Slide 0-04 把 reward model、policy update、治理流程叠加在一张画布上，强调 evidence-to-action 的 track。

Slide 0-04 展示了多个 evidence signal 如何在同一个 timeline 中被收集与审查，提醒 teams 不能只关注一个 benchmark，而要将 evidence matrix 变成操作性的 dashboard。

分层 evidence dashboard

在 dashboard 中将 benchmark、human eval、deployment logs 做 stacked view，可以更容易定位哪一层 signal 首先 drift。

11.2 运营节奏：Slide 0-05

Language models as world models?

Language models may do rudimentary modeling of *agents*, *beliefs*, and *actions*:

Pat watches a demonstration of a bowling ball and a leaf being dropped at the same time in a vacuum chamber. Pat, who is a physicist, predicts that the bowling ball and the leaf will fall at the same rate.

Changing the last sentence of the prompt, we get:

...Pat, who has never seen this demonstration before, predicts that the bowling ball will fall to the ground first. This is incorrect. In a vacuum chamber, there is no air

Language Models as Agent Models [Andreas, 2022]

6

图 5: Slide 0-05 画出了 alignment-engineering 的节奏感 (data → training → deployment → monitoring), 结合 action items。

每个阶段都配有 artifacts: data stage 有 prompt catalog; training stage 有 KL margin report; deployment stage 有 drift alarm; monitoring stage 有 ops playbook。这样的节奏图可以作为 quarterly planning 的 reference。

操作节奏的关键

用 timeline+artifact view 让跨职能团队可以在 planning 会议中快速达成共识, 从而避免 alignment 逻辑在交付与监控之间断层。


11.3 质量矩阵：Slide 0-06

Language models as world models?

...*math*:

We can describe circles in the xy -plane using equations in terms of x and y . Circle equations questions require us to understand the connection between these equations and the features of circles.

For example, the equation $(x + 2)^2 + (y - 3)^2 = 4^2$ is graphed in the xy -plane below. It is a circle with a center at $(-2, 3)$ and a radius of 4.



<https://www.khanacademy.org/test-prep/sat/x0a8c2e5f:untitled-652>

7

图 6: Slide 0-06 把质量、信任与治理矩阵化, 强调不同 stakeholder 的衡量标准。

该幻灯片把 quality gate、trust signal 和 governance checkpoints 组合成一个矩阵，便于把 evidence 逐层传递给 product、ops、legal。

不要孤立强化某条 signal

只加强 automation metric（如 latency）而不结合 governance checklist，会导致高效但不安全的版本上线。Slide 0-06 提醒我们要在矩阵中保持 balance。

11.4 本章小结

这些幻灯片提供了 visual anchor，把 abstract 的 RLHF pipeline 编织成 layer-by-layer 的 evidence-dashboard、ops rhythm、governance matrix，有助于 cross-team alignment。

12 总结与延伸

- 1. 从预训练 LM 到助手需要三步：instruction finetuning、奖励建模、策略优化。
- 2. **RLHF**：训练奖励模型 + PPO 优化，是 ChatGPT 等模型的核心技术。
- 3. **DPO**：将偏好优化简化为监督学习，无需 RL 基础设施。
- 4. KL 正则化防止 reward hacking，是偏好优化的关键组件。
- 5. RL 在 LLM 推理（数学、编程）中展现出巨大潜力。
- 6. 偏好比较比绝对评分更可靠，Bradley-Terry 模型是标准框架。
- 7. 部署阶段需要 evidence dashboard、drift alarm 与 ops playbook，形成实时监控闭环。
- 8. 将每次 drift intervention 写入 runbook，与 governance checklist 联动，确保审计跟踪和快速恢复。

12.1 总结表

主题		核心收获	工程行动
Instruction Fine-tuning		提供基本能力	用大规模 instruction data 初始化模型
RLHF + KL		通过奖励模型 + KL 限制实现 alignment	维持 reference policy，避免 reward hacking
DPO		偏好优化可以不依赖 RL	直接训练策略，降低基础设施复杂度
Pipeline Monitoring		需要 timeline + checklist	建立 dashboard、guardrail checklist
Evidence Matrix		多信号联合验证对齐	把 benchmark, drift, red team 和 logs 结构化
Deployment Trust		Pre-mortem/post-mortem multi-role governance	+ 建立 rollback runbook、明确责任与 evidence matrix 对齐

表 10: RLHF 架构及执行要点

12.2 拓展阅读

- Ouyang et al., *Training Language Models to Follow Instructions with Human Feedback* (InstructGPT, 2022)。
- Rafailov et al., *Direct Preference Optimization: Your Language Model is Secretly a Reward Model* (DPO, 2023)。
- DeepSeek-AI, *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning* (2025)。
- Chung et al., *Scaling Instruction-Finetuned Language Models* (FLAN-T5, 2022)。