

课程笔记

CS224R Lecture 10: 强化学习用于 LLM 推理

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 80 分钟

讲者: Aviral Kumar (Carnegie Mellon University)

课程主页: cs224r.stanford.edu

目录

1 引言：为什么需要 RL 来做推理	2
1.1 NTP 的失败模式	2
1.2 本章小结	3
2 讲座大纲	3
3 Part 1: 经典 RL 技术用于 LLM 推理	4
3.1 将推理建模为 RL 问题	4
3.2 数据扩增：扩展问题和解答数量	4
3.3 离线 RL：利用负样本的优势	5
3.4 在线 RL：REINFORCE 和 PPO	6
3.5 本章小结	7
4 Part 2: 训练”Thinking”模型	8
4.1 DeepSeek-R1：通过 RL 激励推理能力	8
4.2 涌现的推理行为	9
4.3 Kimi K1.5：扩展 RL 训练	9
4.4 Thinking 模型的效果	10
4.5 Test-Time Compute 与 Meta-RL	10
4.6 本章小结	10
5 总结与延伸	10

1 引言：为什么需要 RL 来做推理

本讲由 CMU 的 Aviral Kumar 客座讲授，聚焦于强化学习（RL）在大语言模型（LLM）推理中的应用。讲者将推理限定在数学问题求解场景下进行阐述，并以时间线为轴将内容分为两大部分：经典 RL 技术和现代扩展。

核心动机

传统的 next-token prediction (NTP) 训练范式存在根本性局限：学习到的模型 $\hat{p}_\theta(\mathbf{y}|\mathbf{x})$ 与真实分布 $p^*(\mathbf{y}|\mathbf{x})$ 的误差正比于 $|\mathcal{D}(\mathbf{y}|\mathbf{x})|^{-\alpha}$ ，即误差随与目标输入 $\mathbf{x}$ 相似的数据量增加而减小。对于推理问题，高质量的问题-解答数据极其稀缺，预计到 2028 年互联网高质量文本数据将耗尽。

1.1 NTP 的失败模式

仅靠监督训练的模型在解决如 AIME（美国数学邀请赛）或 IMO（国际数学奥林匹克）等困难数学问题时，虽然能生成“看上去像解答”的文本，但逻辑推理链条往往存在关键错误。模型会跳过必要的推理步骤，或者在证明过程中对个别项进行分析而忽略整体结构。

The Conventional Way of Training




图 1: 传统训练方式：next-token prediction 的误差界¹

¹Slides 第 3 页。

But in Many Problems, Data is Limited/Biased...

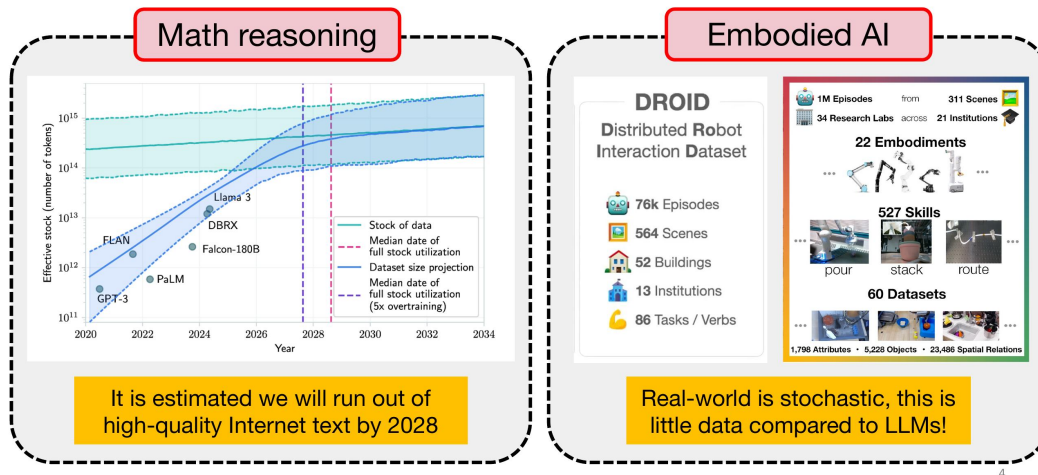


图 2: 数据稀缺问题: 数学推理和具身 AI 领域的限制²

1.2 本章小结

NTP 在推理场景下失效的核心原因是高质量推理数据不足。RL 的价值在于不依赖人工标注的完整解答，而是通过奖励信号（如答案是否正确）引导模型自主发现正确的推理路径。

2 讲座大纲

讲者将 RL for Reasoning 以 DeepSeek-R1 / “thinking” 模型为分界点，分为两个历史阶段：

Outline: RL for Reasoning




图 3: 讲座大纲: 经典技术 vs 现代扩展³

²Slides 第 4 页。

- **Part 1 — 经典 RL 技术:** Imitation Learning、Offline RL、Online RL
- **Part 2 — 现代扩展:** 在线 RL 训练”thinking”模型、DeepSeek-R1、Kimi K1.5 等

3 Part 1: 经典 RL 技术用于 LLM 推理

3.1 将推理建模为 RL 问题

MDP 建模

将数学推理问题建模为 MDP:



- **状态 s_t :** 问题描述 + 到目前为止生成的解答前缀 (token 序列)
- **动作 a_t :** 下一步推理步骤 (可以是一个 token 或一个推理步骤/句子)
- **奖励 r :** 通常是稀疏的终端奖励, 仅当完整解答生成后验证答案是否正确 (outcome-based reward)
- **策略 $\pi_\theta(a_t|s_t)$:** 语言模型本身

3.2 数据扩增: 扩展问题和解答数量

在最简单的设定下, 收集更多的 (问题, 解答) 对来做监督微调 (SFT)。Setlur et al. (NeurIPS 2024) 的实验表明:

- 在 GSM8K 上, SFT 测试误差随问题数增长的收敛速率约为 $|\mathcal{D}|^{-0.15}$
- 在 MATH 上更慢, 约为 $|\mathcal{D}|^{-0.05}$

Warmup: Scale #{Questions, Oracle Ans}



Setlur et al. **RL on Incorrect Synthetic Data Scales the Efficiency of LLM Math Reasoning by Eight-Fold**. NeurIPS 2024.

10

图 4: Warmup: 扩展问题数和 Oracle 解答的 scaling 行为⁴

³Slides 第 6 页。

RFT (Rejection Fine-Tuning)


RFT 是一种简单的利用 RL 信号改进 SFT 的方法：用当前模型采样多个解答，仅保留答案正确的解答用于微调。这等价于一种简化的 offline RL，因为它通过奖励信号过滤了训练数据。

3.3 离线 RL：利用负样本的优势

关键洞察：不仅使用正确解答（正样本），还应利用**错误解答**（负样本）来提供对比信号。

Per-Step Advantage 的概念

对于错误解答中的每一步推理，可以通过从该步出发多次 rollout 来估计该步的“优势” (advantage)。如果从某个中间步出发的 rollout 总是失败，说明该步是一个“错误步骤”；如果有时成功有时失败，说明该步是“尚可的步骤”。这本质上是在估计 rollout 策略的值函数。



Connection: This is equivalent to the value function of the *rollout* policy....

Setlur et al. **RL on Incorrect Synthetic Data Scales the Efficiency of LLM Math Reasoning by Eight-Fold**. NeurIPS 2024.

15

图 5: 负样本 on-policy 数据提供的优势信号⁵

离线 RL 使用这些优势估计的两种方式：


1. **Option 1:** 仅使用估计的优势进行加权 SFT（对正确步骤加大权重，对错误步骤降低权重）
2. **Option 2:** 使用 DPO (Direct Preference Optimization)，保留来自 π 的部分 rollout 进行偏好对比训练

⁴Slides 第 10 页。


⁵Slides 第 15 页。

Using Advantages for Offline RL (DPO)

Option 2: Retain partial rollouts from $\tilde{\pi}$ for training



Incorrect solution
from base π



Setlur et al. **RL on Incorrect Synthetic Data Scales the Efficiency of LLM Math Reasoning by Eight-Fold**. NeurIPS 2024.

20

图 6: 利用 Advantage 进行 Offline RL (DPO)⁶

离线 RL 的局限

Offline RL 的关键问题在于：用来估计 advantage 的 rollout 策略 $\tilde{\pi}$ 与当前正在训练的策略 π_θ 之间存在分布偏移 (distribution shift)。随着训练进行， π_θ 更新后 advantage 估计会变得不准确。

3.4 在线 RL: REINFORCE 和 PPO

为了解决离线 RL 的分布偏移问题，在线 RL 在训练过程中持续用当前策略采样新数据。
在线 RL 的基本流程：


1. 用当前策略 π_θ 对问题采样多个解答
2. 用奖励模型或验证器评估这些解答
3. 估计每步的优势 (advantage)
4. 用策略梯度方法（如 REINFORCE 或 PPO）更新策略

⁶Slides 第 20 页。

Per-Step Advantages in Online RL


A solution from
~~base model~~

current π



Question: Should we do rollouts from $\tilde{\pi}$ on the fly?

Fit a parametric model to advantage predictions



Setlur et al. **Rewarding Progress: Scaling Automated Process Supervision for LLM Reasoning**. arXiv 2024.

图 7: Per-Step Advantages in Online RL⁷

一个关键问题是：**是否应该在线实时做 rollout 来估计 advantage**？讲者提到可以训练一个参数化的过程奖励模型（Process Reward Model, PRM）来预测每步的 advantage，从而避免昂贵的在线 rollout。

3.5 本章小结

经典 RL 技术（SFT → RFT → Offline RL → Online RL）形成了一个逐步强化的工具链。核心 takeaway 是：RL 训练可以显著提高 LLM 推理的数据效率，相比纯 SFT 可提升约 8 倍。

⁷Slides 第 25 页。

4 Part 2: 训练”Thinking”模型



Main papers covered:

- DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025
- Kimi K1.5: Scaling Reinforcement Learning with LLMs.
- **[Optional]** Optimizing Test-Time Compute requires Solving a Meta-RL Problem
Setlur, Qu, Yang, Zhang, Smith, Kumar. CMU MLD Blog, 2025

30

图 8: Part 2: 训练”Thinking”模型的主要论文⁸

4.1 DeepSeek-R1: 通过 RL 激励推理能力

DeepSeek-R1 是”thinking model”范式的标志性工作。其核心发现是：**仅通过 RL 训练（不需要人工标注的推理链）**，模型就能自发涌现出复杂的推理行为。

DeepSeek-R1 的训练流程

1. 在基础模型上直接应用 GRPO (Group Relative Policy Optimization) 进行 RL 训练
2. 奖励仅基于最终答案是否正确 (outcome reward) + 格式奖励
3. 模型自发学会了：验证 (verification)、回溯 (backtracking)、设定子目标 (subgoal setting)、反向推理 (backward chaining) 等元策略

GRPO (Group Relative Policy Optimization)

GRPO 是 PPO 的简化变体。对于每个问题采样一组解答，用组内的相对奖励（减去组内均值后标准化）作为优势估计，避免了训练额外的 critic/value 网络。这在大规模 LLM 训练中更加高效。

⁸Slides 第 30 页。

4.2 涌现的推理行为

“Action” Space: Incorporating Meta Strategies



Gandhi et al. **Cognitive Behaviors that Enable Self-Improving Reasoners**. arXiv 2025.

图 9: “Action” Space: 涌现的元策略对比⁹

Gandhi et al. (2025) 的研究表明，能否在 RL 训练中涌现认知行为取决于基础模型是否已经具备这些行为的“种子”。DeepSeek 系列模型在 RL 训练过程中，验证和回溯行为的频率先上升后下降；而 Meta 的 Llama 模型则完全没有展现出这些行为，RL 训练也未能改善其推理能力。

RL 并非万能

RL 无法让模型学会它“完全不会”的行为。如果基础模型在预训练阶段没有接触过推理链式思考的数据，单靠 RL 很难从零涌现出复杂推理行为。基础模型的能力是 RL 发挥作用的前提。

4.3 Kimi K1.5: 扩展 RL 训练

Kimi K1.5 的核心贡献在于如何在大规模上有效地进行 RL 训练：

- 更长的上下文窗口（128K tokens）
- 更好的采样策略和奖励设计
- 实验表明 RL 训练的性能随计算量增加而持续提升

⁹Slides 第 35 页。

4.4 Thinking 模型的效果

Results: Thinking Models Top the Leaderboards!

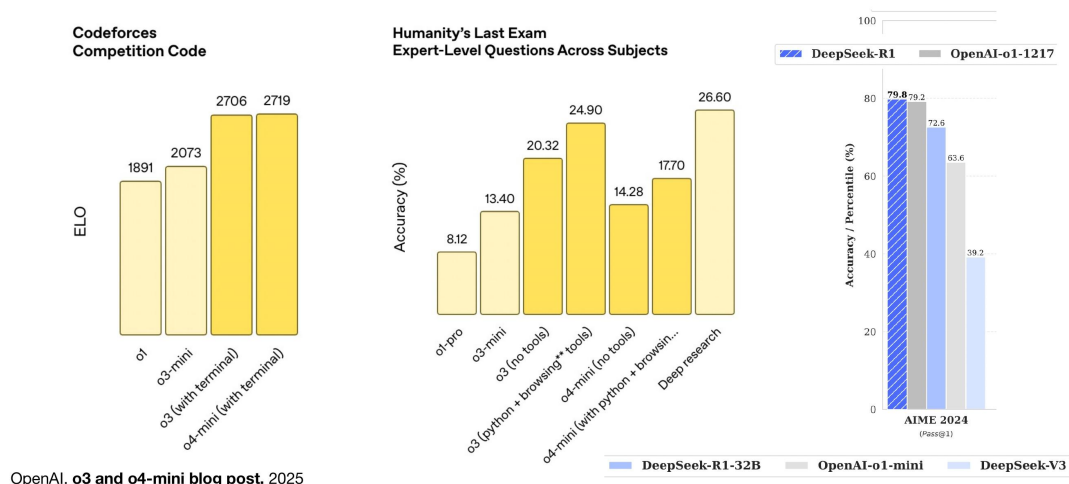


图 10: Thinking 模型在各 benchmark 上的表现¹⁰

Thinking 模型在 Codeforces 竞赛编程、Humanity's Last Exam、AIME 等多个基准上取得了显著提升。DeepSeek-R1 在 AIME 2024 上达到 79.8% 的 Pass@1，与 OpenAI o1-1217 的 79.2% 相当。

4.5 Test-Time Compute 与 Meta-RL

讲者最后提到，优化 test-time compute（推理时计算量分配）本质上是一个 Meta-RL 问题：模型需要学习在推理时如何“花费”计算预算。

4.6 本章小结

DeepSeek-R1 等 thinking model 证明了：(1) RL 可以激励 LLM 自主发展推理能力；(2) 关键前提是基础模型需具备推理行为的“种子”；(3) GRPO 等简化的策略优化方法在大规模训练中既高效又有效。

5 总结与延伸

本讲的核心信息是：经典 RL 的基本思想（策略梯度、advantage estimation、on/off-policy 区分）在 LLM 推理中同样适用且至关重要。

关键 takeaway：

1. SFT 受限于数据稀缺，纯靠扩展数据的 scaling 速率很慢
2. RL 通过利用负样本和 advantage 信号，将数据效率提升了约 8 倍
3. 在线 RL（如 GRPO/PPO）通过持续采样避免了分布偏移

¹⁰Slides 第 40 页。

4. Thinking 模型展示了 RL 可以从简单的 outcome reward 中涌现复杂推理行为
5. 基础模型的预训练质量是 RL 成功的前提条件

拓展阅读

- DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via RL (2025)
- Kimi K1.5: Scaling Reinforcement Learning with LLMs (2025)
- Setlur et al., “RL on Incorrect Synthetic Data Scales the Efficiency of LLM Math Reasoning by Eight-Fold,” NeurIPS 2024
- Gandhi et al., “Cognitive Behaviors that Enable Self-Improving Reasoners,” arXiv 2025
- Setlur et al., “Rewarding Progress: Scaling Automated Process Supervision for LLM Reasoning,” arXiv 2024