


课程笔记

CS224R Lecture 12: 多任务 RL 与目标条件 RL

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1	Model-Based RL 补充：合成数据生成	2
1.1	Dyna 风格方法的细节	2
1.2	何时选择 Model-Based RL	2
1.3	本章小结	2
2	多任务强化学习	2
2.1	动机与问题定义	2
2.2	任务描述的形式	2
2.3	多任务 Imitation Learning	3
2.4	本章小结	3
3	目标条件强化学习	3
3.1	将目标作为任务描述	3
3.2	Hindsight Relabeling	4
3.3	为什么 Hindsight Relabeling 有效	4
3.4	本章小结	4
4	总结与延伸	4

1 Model-Based RL 补充：合成数据生成

本讲前半部分继续完成上一讲关于 model-based RL 的内容，重点讨论如何利用学到的模型生成合成数据以及何时应选择 model-based RL。

1.1 Dyna 风格方法的细节

合成数据生成的关键设计选择

使用学到的模型生成数据时需要决定：

- **Rollout 长度**：短 rollout 减少误差累积，但提供的信息量有限
- **起始状态分布**：可以从真实数据中采样起始状态，然后用模型 rollout
- **合成数据与真实数据的比例**：需要平衡模型偏差和数据效率

1.2 何时选择 Model-Based RL

讲者总结了选择 model-based vs model-free 方法的指导原则：

- 真实数据收集昂贵 → 偏向 model-based
- 状态空间低维且动力学可预测 → model-based 更有效
- 环境高度随机或部分可观测 → model-free 可能更稳健

1.3 本章小结

Model-based RL 通过学习世界模型实现数据增强，但需要在模型偏差和数据效率之间取得平衡。

2 多任务强化学习

2.1 动机与问题定义

现实世界的智能体通常需要完成多种不同的任务，而不是单一任务。多任务 RL 的目标是训练一个能同时处理多个任务的策略。

多任务 MDP 的形式化

将多任务问题建模为一组 MDP $\{\mathcal{M}_i\}$ ，它们共享状态空间和动作空间，但可能有不同的奖励函数。可以定义聚合 MDP：

$$\tilde{\mathcal{M}} = (\mathcal{S} \times \mathcal{Z}, \mathcal{A}, \tilde{p}, \tilde{r}, \gamma)$$

其中 $\mathcal{Z}$ 是任务描述空间 (task descriptor)，策略 $\pi(a|s, z)$ 以任务描述 z 为条件。

2.2 任务描述的形式

任务描述 z 可以采用多种形式：

- **One-hot 编码**: 简单直接, 但无法泛化到新任务
- **自然语言指令**: 如"pick up the red block"
- **目标状态**: 将任务描述为需要达到的目标状态
- **奖励函数参数**: 直接参数化奖励

2.3 多任务 Imitation Learning

最直接的多任务学习方式: 收集多个任务的演示数据, 训练条件策略 $\pi_{\theta}(a|s, z)$ 。

多任务学习中的数据共享

多任务学习的一个关键优势是**数据共享**: 不同任务之间可能有共同的技能或子结构。例如, "拿起红色方块" 和 "拿起蓝色方块" 共享 "抓取" 技能。通过在共享架构中联合训练, 模型可以利用跨任务的共同结构。

2.4 本章小结

多任务 RL 通过引入任务描述将单任务 MDP 扩展为多任务框架, 核心优势在于跨任务的知识共享。

3 目标条件强化学习

3.1 将目标作为任务描述

目标条件 RL (Goal-Conditioned RL) 是多任务 RL 的一个重要特例: 任务描述就是一个目标状态 g 。

目标条件 RL 的形式化

- 策略: $\pi(a|s, g)$, 其中 g 是目标状态
- 奖励: 通常定义为目标达成奖励

$$r(s, a, g) = \begin{cases} 1 & \text{if } d(s, g) < \epsilon \\ 0 & \text{otherwise} \end{cases}$$

或者连续形式: $r(s, a, g) = -d(s, g)$

- 目标: 学习一个通用策略, 能够从任意初始状态到达任意目标状态

3.2 Hindsight Relabeling

HER (Hindsight Experience Replay)

HER 是目标条件 RL 中最重要的技术之一。核心思想极其简洁：

即使一条轨迹没有达到预期目标，我们也可以假装它达到了某个目标（即实际到达的状态）。

具体来说：

1. 策略试图达到目标 g ，但实际到达了状态 s_T
2. 将目标重新标记为 $g' = s_T$
3. 这条”失败”的轨迹在新目标下变成了”成功”的经验
4. 用重标记后的数据训练目标条件策略

Hindsight Relabeling 的隐含假设

HER 假设**奖励函数可以根据任意目标重新计算**。这在目标达成任务中自然成立，但在奖励函数复杂或不可分解的任务中可能不适用。此外，HER 生成的数据分布偏向于”容易到达”的状态，可能对学习困难目标的帮助有限。

3.3 为什么 Hindsight Relabeling 有效

从信息论角度看，HER 解决了目标条件 RL 中的**稀疏奖励问题**。在没有 HER 的情况下，如果目标空间很大，随机策略几乎不可能恰好到达指定目标，导致所有经验的奖励都是零。HER 通过”改变问题来适应答案”的策略，将每条轨迹都变成有用的训练数据。

3.4 本章小结

目标条件 RL 是多任务 RL 的自然特例。Hindsight relabeling 通过”重新解释”失败经验解决了稀疏奖励问题，是该领域最优雅的技术之一。

4 总结与延伸

本讲覆盖了从 model-based RL 的补充内容到多任务 RL 和目标条件 RL 的完整体系：

1. Model-based RL 通过合成数据生成提升数据效率
2. 多任务 RL 通过条件策略 $\pi(a|s, z)$ 实现跨任务知识共享
3. 目标条件 RL 将目标状态作为任务描述，适合导航和操作任务
4. Hindsight relabeling 是解决稀疏奖励问题的关键技术

拓展阅读

- Andrychowicz et al., “Hindsight Experience Replay,” NeurIPS 2017
- Schaul et al., “Universal Value Function Approximators,” ICML 2015
- Yu et al., “Meta-World: A Benchmark and Evaluation for Multi-Task and Meta Reinforcement Learning,” CoRL 2020
- Ghosh et al., “Learning to Reach Goals via Iterated Supervised Learning,” ICLR 2021