

课程笔记

CS224R Lecture 13: 元强化学习

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1 从多任务 RL 到元学习	2
1.1 回顾多任务 RL	2
1.2 元学习的核心思想	2
1.3 本章小结	2
2 Meta-RL 方法分类	2
2.1 方法 1: 基于上下文的方法 (Context-Based)	2
2.2 方法 2: 基于梯度的方法 (Gradient-Based)	3
2.3 两类方法的比较	3
2.4 本章小结	3
3 Meta-RL 的理论视角	4
3.1 Meta-RL 作为 POMDP	4
3.2 后验采样与 Thompson Sampling	4
3.3 本章小结	4
4 Meta-RL 的应用	4
4.1 机器人操作	4
4.2 大语言模型中的 In-Context Learning	4
4.3 本章小结	5
5 总结与延伸	5

1 从多任务 RL 到元学习

1.1 回顾多任务 RL

上一讲讨论了多任务 RL：通过将状态增广为 (s, z) (其中 z 是任务描述), 训练条件策略 $\pi(a|s, z)$ 来处理多个任务。但多任务 RL 有一个关键局限：它假设在**训练时就知道所有任务**。

多任务 RL 的局限

多任务 RL 通过一个共享策略覆盖所有任务。如果测试时遇到的新任务与训练任务差异较大, 性能可能急剧下降。此外, 随着任务数量增多, 学习一个对所有任务都表现良好的策略变得越来越困难 (任务干扰问题)。

1.2 元学习的核心思想

Meta-RL 的定义

元强化学习 (Meta-RL) 的目标不是学习”如何解决一个具体任务”, 而是学习”如何快速学习新任务”。

形式化地说: 给定一个任务分布 $p(\mathcal{T})$, Meta-RL 在训练阶段利用从 $p(\mathcal{T})$ 采样的大量任务学习一个”学习算法”或”快速适应机制”。测试时面对一个新任务 $\mathcal{T}_{\text{new}} \sim p(\mathcal{T})$, 仅需少量数据即可适应。

1.3 本章小结

Meta-RL 将学习的层次从”学习策略”提升到”学习如何学习策略”, 适用于需要快速适应新任务的场景。

2 Meta-RL 方法分类

2.1 方法 1: 基于上下文的方法 (Context-Based)

核心思想是将新任务的经验作为上下文输入给策略网络, 让网络根据上下文推断任务并做出决策。

上下文策略

$$\pi_{\theta}(a|s, c)$$

其中 $c = \{(s_1, a_1, r_1, s'_1), \dots, (s_k, a_k, r_k, s'_k)\}$ 是在新任务上收集的少量经验。策略网络需要从这些经验中推断出任务的特性。

常用架构:

- 将上下文通过 RNN/LSTM 编码为隐状态
- 将上下文通过 Transformer 的注意力机制编码
- 将上下文通过集合编码器 (permutation-invariant) 编码

RL² (Learning to Reinforcement Learn)

RL² 是最早的 context-based meta-RL 方法之一。它将整个 RL 过程视为一个更大的 POMDP，其中 RNN 的隐状态编码了关于当前任务的“信念”。外层 RL 算法训练 RNN 使其能在内层快速适应新任务。

2.2 方法 2：基于梯度的方法 (Gradient-Based)

MAML (Model-Agnostic Meta-Learning)

MAML 的核心思想是学习一组好的初始化参数 θ ，使得对任何新任务，只需少量梯度步即可适应。

内层更新（任务适应）：

$$\theta'_i = \theta - \alpha \nabla_{\theta} \mathcal{L}_{\mathcal{T}_i}(\theta)$$

外层更新（元学习）：

$$\theta \leftarrow \theta - \beta \nabla_{\theta} \sum_i \mathcal{L}_{\mathcal{T}_i}(\theta'_i)$$

关键：外层优化的目标是让**适应后**的参数 θ'_i 在任务 $\mathcal{T}_i$ 上表现好，而非原始参数 θ 。

MAML 的计算开销

MAML 需要对“梯度”求梯度（二阶导数），计算开销较大。虽然可以用一阶近似（如 FO-MAML、Reptile）来降低开销，但这会牺牲一定的精度。在 RL 中，由于策略梯度本身方差就很高，MAML 的训练稳定性是一个挑战。

2.3 两类方法的比较

	Context-Based	Gradient-Based
适应方式	前向传播（推断）	梯度下降
适应速度	极快（一次前向）	需要若干梯度步
表达能力	受限于网络容量	理论上可精确适应
训练难度	相对容易	需要二阶优化
典型方法	RL ² , PEARL	MAML, ProMP

表 1: 两类 Meta-RL 方法的比较

2.4 本章小结

Meta-RL 有两大技术路线：context-based 方法通过编码经验实现隐式适应，gradient-based 方法通过学习好的初始化实现快速微调。

3 Meta-RL 的理论视角

3.1 Meta-RL 作为 POMDP

Meta-RL 的 POMDP 视角

可以将 meta-RL 视为在一个更大的 POMDP 中做 RL：

- 隐状态包含任务身份
- 观测是当前状态和历史经验
- 最优策略需要在交互过程中推断任务身份（贝叶斯推断）

从这个视角看，context-based 方法本质上是在近似这个 POMDP 的最优策略。

3.2 后验采样与 Thompson Sampling

在理想情况下，meta-RL 的最优行为应该类似于 Thompson Sampling：

1. 维护对任务身份的后验信念 $p(\mathcal{T}|\text{history})$
2. 从后验中采样一个任务假设
3. 按照该假设下的最优策略行动
4. 收集新数据后更新后验

3.3 本章小结

从理论角度看，Meta-RL 可以统一理解为在任务不确定的 POMDP 中做最优决策，这为理解和改进 meta-RL 方法提供了原则性的框架。

4 Meta-RL 的应用

4.1 机器人操作

Meta-RL 在机器人领域有天然的应用场景：机器人需要快速适应不同的物体、不同的抓取目标、不同的动力学参数等。

4.2 大语言模型中的 In-Context Learning

In-Context Learning 作为 Meta-Learning

大语言模型的 in-context learning（通过 prompt 中的示例来完成新任务）可以看作是一种 context-based meta-learning。LLM 在预训练阶段见过大量“任务”，学会了从上下文中推断任务并生成对应的输出。这与 RL² 的思想一脉相承。

4.3 本章小结

Meta-RL 的思想已经渗透到了机器人学和自然语言处理等多个领域，in-context learning 可以看作是 meta-learning 在大规模预训练中的自然涌现。

5 总结与延伸

Meta-RL 的核心价值在于实现**快速适应**：

1. 多任务 RL 学习一个覆盖所有任务的策略，meta-RL 学习快速适应新任务的能力
2. Context-based 方法通过编码历史经验实现隐式推断
3. Gradient-based 方法（MAML）通过学习好的初始化实现快速微调
4. 理论上 meta-RL 等价于在任务不确定的 POMDP 中做最优决策
5. LLM 的 in-context learning 是 meta-learning 的大规模实现

拓展阅读

- Finn et al., “Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks (MAML),” ICML 2017
- Duan et al., “RL²: Fast Reinforcement Learning via Slow Reinforcement Learning,” ICLR 2017
- Rakelly et al., “Efficient Off-Policy Meta-Reinforcement Learning via Probabilistic Context Variables (PEARL),” ICML 2019
- Zintgraf et al., “VariBAD: A Very Good Method for Bayes-Adaptive Deep RL,” ICLR 2020