


课程笔记

CS224R Lecture 14: 探索与元探索

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

目录

1 探索问题的本质	2
1.1 为什么探索很重要	2
1.2 探索在 RL 应用中的体现	2
1.3 本章小结	2
2 经典探索方法	2
2.1 Multi-Armed Bandit 设定	2
2.2 ϵ -Greedy	2
2.3 Upper Confidence Bound (UCB)	3
2.4 Thompson Sampling	3
2.5 本章小结	3
3 深度 RL 中的探索	3
3.1 从 Bandit 到 MDP	3
3.2 基于计数的探索	4
3.3 基于好奇心的探索	4
3.4 本章小结	4
4 元探索：学习如何探索	4
4.1 什么是元探索	4
4.2 Meta-RL 中的探索挑战	4
4.3 DREAM 和后验采样方法	5
4.4 本章小结	5
5 总结与延伸	5

1 探索问题的本质

1.1 为什么探索很重要

在强化学习中，智能体必须在**利用**（exploitation，选择已知最好的动作）和**探索**（exploration，尝试可能更好的动作）之间取得平衡。

探索的核心困境

如果我们总是选择当前估值最高的动作（贪心策略），可能永远发现不了真正的最优策略。例如在多臂赌博机中，如果第一次拉臂恰好获得了正奖励，贪心策略会一直拉同一个臂，即使其他臂的期望奖励更高。

1.2 探索在 RL 应用中的体现

- **机器人**：探索不同的抓取策略、运动模式
- **大语言模型**：在 RLHF/RL for reasoning 中，探索不同的推理路径
- **推荐系统**：探索用户可能喜欢但尚未展示过的内容

1.3 本章小结

探索是所有 RL 问题的根本挑战之一。没有有效探索，智能体会陷入次优策略。

2 经典探索方法

2.1 Multi-Armed Bandit 设定

Multi-Armed Bandit

Bandit 问题是探索问题的最简化版本： K 个臂（动作），每个臂有未知的奖励分布 $p(r|a)$ 。没有状态转移，目标是在 T 轮交互中最大化累积奖励。遗憾（regret）定义为与最优臂的差距：

$$\text{Regret}(T) = T \cdot \mu^* - \sum_{t=1}^T r_t$$

2.2 ϵ -Greedy

最简单的探索策略：以概率 $1 - \epsilon$ 选择当前最优动作，以概率 ϵ 随机选择。

ϵ -Greedy 的局限

ϵ -Greedy 的探索是**无方向的**——它在所有动作上均匀随机探索，不考虑哪些动作更有信息价值。在动作空间大或环境复杂时，这种盲目探索效率极低。

2.3 Upper Confidence Bound (UCB)

UCB 算法

UCB 的核心思想是**乐观主义** (optimism in the face of uncertainty): 对不确定性高的动作赋予更高的估值, 从而鼓励探索。

$$a_t = \arg \max_a \left[\hat{\mu}_a + c \sqrt{\frac{\ln t}{N_a}} \right]$$

其中 $\hat{\mu}_a$ 是动作 a 的经验均值, N_a 是动作 a 被选择的次数。第二项是不确定性奖励——被选择次数越少的动作, 不确定性越高, 越会被优先探索。

2.4 Thompson Sampling

Thompson Sampling

Thompson Sampling 采用贝叶斯方法:

1. 对每个动作的奖励分布维护一个后验分布 $p(\mu_a | \text{data})$
2. 每轮从后验中采样: $\tilde{\mu}_a \sim p(\mu_a | \text{data})$
3. 选择采样值最高的动作: $a_t = \arg \max_a \tilde{\mu}_a$
4. 收集奖励后更新后验

Thompson Sampling 在实践中通常表现优异, 且具有理论最优的 regret bound。

2.5 本章小结

经典探索方法从简单的 ϵ -greedy 到有原则的 UCB 和 Thompson Sampling, 核心区别在于如何利用不确定性来指导探索。

3 深度 RL 中的探索

3.1 从 Bandit 到 MDP

在 MDP 中, 探索问题更加复杂:

- 动作不仅影响即时奖励, 还影响未来的状态
- 需要探索**状态-动作对**而非仅是动作
- 有些状态本身就很难到达, 需要长时间的定向探索

3.2 基于计数的探索

Count-Based Exploration

基本思想：对访问次数少的状态-动作对给予额外的探索奖励：

$$r_{\text{explore}}(s, a) = \frac{\beta}{\sqrt{N(s, a)}}$$

在深度 RL 中，由于状态空间连续且高维，无法直接计数。常用的近似方法包括：

- 哈希计数：将状态通过哈希函数映射到离散空间
- 密度模型：训练密度模型 $\hat{p}(s)$ ，用 $-\log \hat{p}(s)$ 作为新颖性度量
- RND (Random Network Distillation)：用随机网络的预测误差度量新颖性

3.3 基于好奇心的探索

另一种思路：探索奖励 = 模型预测误差。如果对某个状态的预测误差大，说明这个状态是“新颖的”，值得继续探索。

好奇心陷阱

基于预测误差的探索方法有一个著名的失败模式：**噪声电视问题** (noisy TV problem)。如果环境中存在本质上不可预测的随机性（如电视屏幕上的静态噪声），模型的预测误差永远不会降低，导致智能体被这种无意义的随机性“吸引”，无法继续有意义的探索。

3.4 本章小结

深度 RL 中的探索需要在连续高维空间中处理新颖性度量，count-based 方法和好奇心方法各有优势和局限。

4 元探索：学习如何探索

4.1 什么是元探索

Meta-Exploration

元探索 (meta-exploration) 将元学习的思想应用于探索问题：不是手工设计探索策略，而是**学习一个探索策略**。

在 meta-RL 的框架下：

- 外层 (meta) 学习如何在新任务上有效探索
- 内层 (task) 利用探索收集的数据快速适应新任务

4.2 Meta-RL 中的探索挑战

在 meta-RL 中，智能体在每个新任务上的前几次交互至关重要——它们决定了智能体能否快速推断出任务的特性。因此，元探索关注的是：**在有限的交互次数内，如何收集最有信息量的数据**。

与经典探索的区别

经典探索关注单个任务中的 exploration-exploitation 权衡。元探索关注的是跨任务的探索策略学习——训练一个能在新任务上有效探索的策略。这是一个更高层次的优化问题。

4.3 DREAM 和后验采样方法

讲者介绍了如何在 meta-RL 中实现有效探索：

- 维护对任务身份的信念 (belief)
- 使用 Thompson Sampling 的思想指导探索
- 外层 RL 训练使内层探索策略最大化信息增益

4.4 本章小结

元探索将探索策略本身作为学习对象，通过在多个任务上训练来学习高效的探索行为。

5 总结与延伸

1. 探索是 RL 的核心挑战， ϵ -greedy 到 UCB/Thompson Sampling 形成了一个日益精细的工具链
2. 深度 RL 中需要用密度模型或网络预测误差来近似新颖性
3. 基于好奇心的方法需警惕噪声电视问题
4. 元探索将”如何探索”本身作为可学习的能力
5. 在机器人和 LLM 等真实应用中，有效探索直接决定了学习效率

拓展阅读

- Auer et al., “Finite-time Analysis of the Multiarmed Bandit Problem,” Machine Learning 2002
- Bellemare et al., “Unifying Count-Based Exploration and Intrinsic Motivation,” NeurIPS 2016
- Burda et al., “Exploration by Random Network Distillation,” ICLR 2019
- Pathak et al., “Curiosity-driven Exploration by Self-Supervised Prediction,” ICML 2017
- Liu et al., “Explore then Execute: Adapting without Rewards via Factorized Meta-Reinforcement Learning,” 2022