

课程笔记

# CS224R Lecture 16: Autonomy —Chelsea Finn

基于 Stanford CS224R 公开资料整理

2025 年 3 月 18 日



视频作者/频道: Stanford CS224R: Reinforcement Learning

发布日期: 2025 年 3 月 18 日

视频时长: 约 80 分钟

讲者: Chelsea Finn (Stanford CS224R 研究员)

视频链接: <https://cs224r.stanford.edu/>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

# 目录

|                                      |           |
|--------------------------------------|-----------|
| <b>1 自主机器人学习的逻辑脉络</b>                | <b>2</b>  |
| 1.1 Human-in-the-loop 与 Autonomy 的落差 | 2         |
| 1.2 面对现实的评估标准                        | 2         |
| 1.3 本章小结                             | 2         |
| <b>2 自动奖励与理解信号</b>                   | <b>3</b>  |
| 2.1 图像与语言的目标表示                       | 3         |
| 2.2 视觉-语言 reward 组合                  | 3         |
| 2.3 基于成功分类器的自我监督                     | 4         |
| 2.4 多模态 reward 过滤                    | 4         |
| 2.5 本章小结                             | 4         |
| <b>3 Reset-free 控制与记忆管理</b>          | <b>5</b>  |
| 3.1 重置假设的弱化                          | 5         |
| 3.2 持续 episodic buffer               | 5         |
| 3.3 经验撤销与环境多样性                       | 6         |
| 3.4 本章小结                             | 6         |
| <b>4 自主目标设定与课程学习</b>                 | <b>7</b>  |
| 4.1 目标库与分层 curriculum                | 7         |
| 4.2 Goal-Query 与代理思维                 | 7         |
| 4.3 本章小结                             | 7         |
| <b>5 安全探索与长期运行</b>                   | <b>8</b>  |
| 5.1 约束优化与软边界                         | 8         |
| 5.2 长时间 horizon 的监控                  | 8         |
| 5.3 本章小结                             | 9         |
| <b>6 实践建议与系统运维</b>                   | <b>10</b> |
| 6.1 Autonomy 监控仪表盘                   | 10        |
| 6.2 跨阶段反馈循环                          | 10        |
| 6.3 本章小结                             | 10        |
| <b>7 多尺度探索与跨任务泛化</b>                 | <b>11</b> |
| 7.1 多阶段探索策略                          | 11        |
| 7.2 跨任务泛化指标                          | 11        |
| 7.3 本章小结                             | 12        |
| <b>8 系统集成与部署流程</b>                   | <b>13</b> |
| 8.1 Slide 09-10 Pipeline             | 13        |
| 8.2 跨团队反馈与知识共享                       | 13        |
| 8.3 本章小结                             | 13        |

9 总结与延伸 14

9.1 核心总结表 . . . . . 14

9.2 进一步阅读 . . . . . 14

9.3 本章小结 . . . . . 14

# 1 自主机器人学习的逻辑脉络

## 1.1 Human-in-the-loop 与 Autonomy 的落差

当前机器人学习体系依赖于人类的监督：奖励函数、环境重置、数据采集均靠工程师完成。《Autonomy》讲座提出挑战：让机器人在复杂物理世界中像婴儿一样主动探索，而不是等着人类定目标。

## RL for Robots 🤖: Autonomous Learning

CS224R: Deep Reinforcement Learning

图 1: Slide 1 概览讲座的核心主题：Autonomy 既是 reward, reset, goal 设置的集合。

### Autonomy 的三维目标

1. 自动构造奖励或理解任务成果；
2. 在不重置的世界里持续操作；
3. 自主选择目标并安全探索。

## 1.2 面对现实的评估标准

讲者强调三个评价维度：**可学习性**（是否能获得足够 signal）、**可扩张性**（是否不依赖人工重置）、**可持续性**（是否能长期运行并在新的目标上迁移）。教学逻辑：先从 reward 说起，再从环境与目标的逻辑演化到安全与系统集成。

### 教学逻辑映射

Autonomy 研究线索依次是：自动奖励 → Reset-free 控制 → Goal Management → Safe Exploration → 系统监控。每一段都以旧假设（reward, reset, goal）为起点，描述如何撤回它们。

## 1.3 本章小结

本章梳理了自主机器人学习的现状与教学逻辑，以“奖励-环境-目标-安全-系统”五阶段为后续章节的纲领框架。

## 2 自动奖励与理解信号

### 2.1 图像与语言的目标表示

自主奖励的核心要求是减少人工工程量。Chelsea 讲述了用**目标图像或语言描述**自动化奖励的管线：预训练模型提取视觉语义，比较当前状态与目标的 embedding 缩放，从而给出拖拽式奖励。

#### Reminders

- Project milestone due tonight
- HW4 due next Friday

图 2: Slide 2 展示目标-当前状态之间的 embedding 距离如何作为即时 reward。

#### Embedding Distance Reward

- 使用 VAE/CLIP 等模型提取 ‘f(I)’;
- 奖励采用  $r_t = -\|\phi(I_t) - \phi(I_g)\|_2$ ;
- 可通过 scratch/finetune 弱化域差异，但核心是通过 representation 比较状态。

### 2.2 视觉-语言 reward 组合

Slide 03 展示了将自然语言描述与视觉 embedding 结合生成 reward 的流程：LLM 生成 task prompt，VLM 依据 prompt 评估 current frame，最后用 ensemble output 过滤。通过少量 human-in-the-loop 的特殊 cases，系统可以辨别不安全的 reward signal。

## Plan for Today

- Why aren't robots autonomous already?
- Defining the problem: **autonomous RL**
- Developing the algorithms
  - Learning policies without human intervention
  - Single life RL

**Goal:** Build autonomous agents that can learn and interact in the real world

图 3: Slide 3 展示 LLM 与 VLM 结合产生 reward 的体系, 并强调 filter 阶段的重要性。

### LLM + VLM Reward Pipeline

- LLM 接受 task prompt, 生成 structured description;
- VLM (如 CLIP/BLIP) 对当前 frame 打分;
- 通过 confidence filter (如 softmax temperature) 控制 reward 强度。

## 2.3 Reward Pipeline 深度解析

在 slide 03 所示流程基础上, 讲者细化了 reward pipeline 的三段: **signal extraction** (从 sensors 获取图像/语言)、**affinity scoring** (embedding similarity)、**confidence gating** (置信度过滤与 ensemble)。这三段必须在每次模型更新后同步改动, 才能保证 reward not drift。

### Pipeline 抽象框架

- Signal extraction: logging sensors + normalization;
- Affinity scoring: embedding 距离或 classifier probability;
- Confidence gating: 用 threshold/ensemble/temporal smoothing filter 掉异常 reward。

## 2.4 基于成功分类器的自我监督

讲者借助 few-shot 标注让 robot 学会识别成功状态: 收集少量 positive/negative 快照, 训练二分类器  $\sigma(s)$ , 然后该 classifier 输出是 reward 函数。该方式非常适合完成“目标数量未知”的任务。

### Success Classifier Pipeline

- 收集 50-100 个自定义“成功”帧，生成负样本；
- 训练轻量 CNN/RNN 输出概率；
- 将概率直接用作 reward，或结合时间衰减防止过早收敛。

## 2.5 多模态 reward 过滤

Chelsea 进一步指出：CLIP/LLM 生成 reward 时，必须加入**可信度过滤**，避免模型对 irrelevant features（如背景）给予高分。常用做法是 ensemble 多个模态、加入 temporal consistency 正则化。

### 不要让 pretrained 模型 hallucination 结果传递给 policy

Clip-based reward 可能强化背景闪光点。建议：

- 使用 temporal smoothing 保证 reward 连续；
- 对于多模态判断，采用 majority vote/variance penalty；
- 保留 human-in-the-loop audit 通道，应急 override。

## 2.6 本章小结

自动奖励通过图像、语言、模型分类器等多种信号取代传统手工 reward，并强调需要对多模态输出进行置信度控制。

## 3 Reset-free 控制与记忆管理

### 3.1 重置假设的弱化

传统 RL 依赖人为或 simulator 重置。Chelsea 提出“让 policy 本身来 reset”——在每轮任务结束后启动另一个 policy，让环境回到新的初始集合，使 robot 能持续运行。

#### Plan for Today

- Why aren't robots autonomous already?
- Defining the problem: autonomous RL
- Developing the algorithms
  - Learning policies without human intervention
  - Single life RL

图 4: Slide 4 讲解前向/后向控制器如何交替执行任务与 reset。

图中 timeline 表示一次任务执行后的回收过程：任务 policy（中间）完成 goal 后，将 current state 交给 reset policy。reset policy 运行后把 system 带回 base manifold，继续提供任务起点。

#### Forward-Backward Controller 机制

- $\pi_f$ : 从 initial state 探索 task-specific trajectory;
- $\pi_b$ : 接受当前 state, 尝试回到 initial manifold;
- 轮流训练两者,  $\pi_b$  的成功率定义新 episode 的起点。

### 3.2 持续 episodic buffer

Reset-free 要求 long-lived buffer 记住“最近 failed states”，以便策略不断学习重置。Chelsea 建议维护 prioritized replay buffer，同时引入 **time-aware sampling**，优先回放发生在最近一次 reset 之后的数据。



### Time-Aware Replay

- 将每个 transition 附加 timestamp;
- 在训练中采用  $w_t \propto \exp(-\lambda(t_{now} - t))$  近似 latest priority;
- 保证新数据被充分利用, 同时保留少量 rare event。

### 3.3 经验撤销与环境多样性

讲者进一步指出: 自主系统需具备**撤销经验**的能力, 即模型在 fail 的轨迹上回退, 并尝试新的策略组合。这涉及动态规划多个 reset-policy 以覆盖不同物理扰动。

### Fail-fast but recover-fast

鼓励策略快速尝试多个动作组合, 如果当前控制失败, 马上启动 reset policy; 同时记录失败模式供 future policy adaptation。

### 3.4 本章小结


Reset-free 框架用 forward-backward controllers、time-aware buffer 和 fast recovery 实现持续运行, 避免依赖人工 reset。

## 4 自主目标设定与课程学习

### 4.1 目标库与分层 curriculum

Chelsea 使用 “goal replay buffer” 记录已达成或接近的目标，结合 **curriculum policy** 选择难度适中的目标进行训练。每次 policy 达成目标后，把该目标与其能力指标一同写入 “目标状态 tracker”。

Reinforcement Learning = Trial-and-Error



Slide adapted from Archit Sharma

图 5: Slide 5 讲述如何在 goal-conditioned RL 中实现自动 curriculum。

| 阶段 | 核心措施                                           |
|----|------------------------------------------------|
| 探索 | 采样训练目标时，偏向 novel/uncertain states；             |
| 平衡 | 设定 success rate window（比如 50%-80%）保持学习区；       |
| 进阶 | 每成功一个目标，使用 parameterized difficulty increment； |

### 4.2 Goal-Query 与代理思维

讲者提到 “Goal-Query” 模块——agent 在训练中不断提问 “我应该完成哪个 skill 以便后续推广？” 并基于 novelty score 选择目标。这个过程照顾 exploration (novel targets) 与 exploitation (熟悉目标) 的平衡。

#### Goal-Query 流程

1. 通过 uncertainty estimate 计算每个 stored goal 的 novelty；
2. 如果 novelty 超过 threshold，调度 exploration goal；
3. 结合 skill graph 推测 goal 间依赖，决定是否先学习基础 goal。

### 4.3 Goal space engineering

Chelsea 强调: goal space 应支持动态缩放, 对不同目标设定中心/半径/priority。例如, 把 complex goal 拆成 primitives, 训练时多次 sample Primitive-level goal, 再用 scheduler 提升到 composite goal。

| 策略                  | 作用                                                       |
|---------------------|----------------------------------------------------------|
| Primitive sampling  | 从基础动作组合生成 reward-distinct goals;                         |
| Composite scheduler | 当 primitive success rate 达标时, 按比例加权 composite goal 选择概率; |
| Priority annealing  | 根据 novelty/entropy 动态调整 goal priority;                   |

#### 4.4 本章小结

自主目标设定把课程学习、Goal-Query 与 difficulty scheduler 结合, 使机器人能在没有人类指定任务的情况下逐步积累技能。

## 5 安全探索与长期运行

### 5.1 约束优化与软边界

#### Standard Reinforcement Learning

$s_0, a_0, s_1, a_1 \dots s_H$

$s'_0, a'_0, s'_1, a'_1 \dots$

*How does this happen?*

```
import gym
env = gym.make("CartPole-v1")
observation = env.reset()
for _ in range(1000):
    env.render()
    action = env.action_space.sample() # you can
    observation, reward, done, info = env.step(action)
    if done:
        observation = env.reset()
env.close()
```

[Code snippet from <https://gym.openai.com/>]

**Only in simulation!**

Slide adapted from Archit Sharma

图 6: Slide 6 将安全约束视为 reward penalty, 用于 soft policy gradient。

#### 安全探索策略

- 将 safety constraint 转化为 penalty term  $c(s_t, a_t)$ ;
- 用 Lagrangian multiplier  $\lambda$  控制 penalty 强度;
- 在 uncertainty 高时 (如 new goal), 降低 exploration rate, 避免 high-risk 动作。

### 5.2 长时间 horizon 的监控

Chelsea 强调: Autonomy 不仅是一次训练, 而是多次 deployment 的 property, 因此需要系统级监控:

- 记录每个 goal 的 success/failure 轨迹;
- track  $\Delta reward$  与  $\Delta constraint$  以判断 drifting;
- 对于重复失败, 动态回退 reward 模型或缩小 goal space。

#### 部署时留有回退通道

部署 pipeline 需保留“回滚 checkpoint”与“重新训练 reward 估计”的机制, 以便在出现 hallucination reward、reset policy 失效等问题时快速救火。

### 5.3 本章小结

安全探索通过 penalty/constraint 架构保障行为，长期运行则靠监控统计与回退计划，并最终形成可靠的 Autonomy 系统。

## 6 实践建议与系统运维

### 6.1 Autonomy 监控仪表盘

讲者建议建立包含 reward accuracy、reset success、goal coverage 三个指标的仪表盘,用于日常 re-view。

| 维度              | 指标                                                  |
|-----------------|-----------------------------------------------------|
| Reward fidelity | classifier precision/recall, clip similarity drift; |
| Reset coverage  | 近期 forward-backward > 80% 成功率;                      |
| Goal expansion  | 活跃 goal 数与每周新增 goal;                                |

### 6.2 跨阶段反馈循环

- 每运行一次 Autonomy experiment, 记录:
1. 当前 reward 模型与 safety penalty 版本;
  2. Reset policy 的 failure pattern;
  3. 新目标/技能的添加、旧目标的 retire 决策;
- 这些信息形成一个 cross-team log, 便于 future replication。

| Feedback Loop 模板                                                                                                                                                   |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div>1. Pre-scale: 确认 reward/safety/checkpoint 状态;</div> <div>2. Scale: 运行 policy, 同步 metrics;</div> <div>3. Post-scale: 复盘 metrics drift, 如需 rollback 立即触发。</div> |

### 6.3 本章小结

实践层面, Autonomy 需要仪表盘、跨阶段反馈以及回退计划, 确保研究结果可反复部署。

## 7 多尺度探索与跨任务泛化

### 7.1 多阶段探索策略

Slide 07 展示 multi-stage exploration framework: 将 exploration policy 分成 coarse-grained 与 fine-grained 两层, 分别控制不同尺度的目标与动作序列。这样的层次结构既能发现 macro-level goal cluster, 又能自动收敛到 micro-level 执行步骤。

#### The Continual Real World




图 7: Slide 7 说明 multi-stage exploration 如何协同扩展 goal space。

#### Multi-Stage Exploration

- Coarse policy 采样未见过的 goal cluster;
- Fine policy 负责该 cluster 内的精细动作;
- 定期更新 cluster centroids based on success rate 以维持 coverage。

### 7.2 跨任务泛化指标

Slide 08 提出 transfer matrix 检验 policy 在不同 goal 组合上的 capability, 关键指标包括 success coverage、policy entropy 与 transfer ratio。讲者建议在实验报告中同时展示 base goals 与 transfer goals 的 performance, 避免过拟合单一场景。

| 指标               | 说明                                                |
|------------------|---------------------------------------------------|
| Success coverage | 在 stored goals 中达到成功的比例, 低于 70% 表明 coverage gap;  |
| Policy entropy   | 监控 policy 在不同 goals 上的多样性, 过低说明 degenerate;       |
| Transfer ratio   | 一个 goal 的 reward 在另一 goal 上带来的 improvement, 衡量泛化; |

### 7.3 本章小结


多尺度探索与泛化指标帮助团队识别在哪些 goal 上要打破窄瓶颈，并提供衡量 transfer 成效的工具。



## 8 系统集成与部署流程

### 8.1 Slide 09-10 Pipeline

Slide 09-10 归纳 Autonomy 系统：Reward module、Reset policy、Goal manager、Safety guard 分层工作，结果推送至 dashboard 供 operator 审查。



Slide adapted from Archit Sharma

图 8: Slide 10 展示 Autonomy 系统的 modular pipeline。

#### 部署流水线关键节点

- Reward model update 触发 shadow policy test, 并在 simulation 中做 sanity check;
- Reset controller 每天运行 recovery routine, 确保 forward-backward policy 仍然可靠;
- Goal manager 基于 live metric 更新 goal library, 淘汰 stale 或 unsafe goal;

### 8.2 跨团队反馈与知识共享

讲者提醒：Autonomy 需要跨团队反馈循环，例如 operator 将 reset failure case 上传 shared log, policy 团队据此调整 goal selection 或 reward normalization。文档记录与 weekly review meeting 有助于维护知识。

### 8.3 本章小结

系统集成关注 pipeline 的组织化与跨团队沟通，确保 Autonomy 不仅在研究中有效，也能在部署时快速响应异常。

## 9 案例研究：Vision-guided Autonomy

### 9.1 现实场景中的任务拆解

Slide 09 展示了一个 vision-guided manipulation case，包含 grasp、transport、place 三个模块，每个模块又嵌套自主 reward、reset 与 goal manager。讲者强调：真实场景常常有 long-tailed failure mode，需要在 pipeline 中引入 anomaly detection。

#### Plan for Today

- Why aren't robots autonomous already?
- Defining the problem: autonomous RL
- Developing the algorithms
  - Learning policies without human intervention
  - Single life RL

图 9：Slide 9 展示 vision-guided manipulation 的工作流，强调各 module 如何协同。

Vision-guided Autonomy 切分

- Grasp module: 使用 visual affordance 预测 grasp point;
- Transport module: 通过 goal-conditioned policy 将物体移动;
- Place module: 利用 success classifier 判断目标放置是否完成。

### 9.2 可观察性与异常响应

讲者建议在每个阶段记录 anomaly metric: vision 模型 confidence drop、reset policy failure rate、goal coverage drop。把这些度量填入 dashboard，可以 trigger automated rollback 或 reward recalibration。

| 异常响应矩阵                 |                                                    |
|------------------------|----------------------------------------------------|
| 异常类型                   | 响应                                                 |
| Vision confidence drop | 进入 safe mode，降低 exploration rate;                  |
| Reset failure          | 立即触发 manual inspection，并回滚到最近 stable checkpoint;   |
| Goal coverage shrink   | 扩展 goal replay buffer，重新 thaw failed goal cluster; |

### 9.3 本章小结

通过 vision-guided manipulation 案例，展示 Autonomy pipeline 在线下与线上部署中的可观察性与异常响应策略。

## 10 总结与延伸

### 10.1 核心总结表

| 维度    | 核心洞察                                                           | 实践启示                                              |
|-------|----------------------------------------------------------------|---------------------------------------------------|
| 奖励信号  | 图像、语言、success classifier 取代人工 reward                           | 设计 reward pipeline 时加入置信度/ensemble 机制;            |
| 环境运维  | Forward-backward controllers 与 time-aware buffer 实现 reset-free | 每个 reset policy 都需要 recovery 记录并与 scheduler 绑定;   |
| 目标管理  | Goal-Query 与 curriculum policy 实现难度自适应                         | 维护 goal repository, 并记录 novelty/skill dependency; |
| 安全与运维 | safety penalty + regular monitoring 防止 drift                   | 搭建 dashboard, 保留 rollback 通道;                     |

### 10.2 进一步阅读

- Sharma et al., “Autonomous Reinforcement Learning: Formalism and Benchmarking,” ICLR 2022
- Eysenbach et al., “Leave No Trace: Learning to Reset for Safe and Autonomous RL,” ICLR 2018
- Pong et al., “Skew-Fit: State-Covering Self-Supervised RL,” ICML 2020
- Nair et al., “Visual Reinforcement Learning with Imagined Goals,” NeurIPS 2018
- Ma et al., “VIP: Towards Universal Visual Reward and Representation via Value-Implicit Pre-Training,” ICLR 2023

### 10.3 本章小结

通过奖赏、reset、goal、安全与监控五个维度的系统讲解，本讲展示了自主机器人学习的完整路径，并为部署级 Autonomy 提供了可执行的反馈/回退机制。