

课程笔记

CS224R Lecture 17: 用强化学习推进机器人智能

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 60 分钟

讲者: Ashish Kumar (Guest Lecture)

课程主页: cs224r.stanford.edu

目录

1 模仿学习 vs 强化学习：实际对比	2
1.1 何时选择 RL	2
1.2 本章小结	2
2 Sim-to-Real Transfer	2
2.1 为什么需要仿真	2
2.2 Domain Randomization	3
2.3 本章小结	3
3 机器人移动：腿式运动	3
3.1 四足机器人行走	3
3.2 Teacher-Student 框架	4
3.3 本章小结	4
4 机器人操作	4
4.1 灵巧操作的挑战	4
4.2 RL 在操作中的应用	4
4.3 本章小结	5
5 人形机器人	5
5.1 双足行走与全身控制	5
5.2 本章小结	5
6 总结与延伸	5

1 模仿学习 vs 强化学习：实际对比

本讲由 Ashish Kumar 客座讲授，聚焦于 RL 在机器人领域（特别是移动和操作）中的实际应用。讲者首先对比了”实际有效的”模仿学习和强化学习。

IL vs RL 的实践特征

- **模仿学习：**
 - 数据高效，适合能获取高质量演示的场景
 - 性能上限受限于演示者的能力
 - 难以超越人类水平
- **强化学习：**
 - 可以发现超越人类的策略
 - 通常需要仿真环境（sim-to-real transfer）
 - 奖励设计是关键挑战
 - 训练周期长但推理高效

1.1 何时选择 RL

RL 的适用条件

RL 在以下场景中相比 IL 更有优势：

- 有高质量的**仿真器**可用
- 任务目标可以用奖励函数量化
- 需要**超越**人类演示者的水平
- 演示数据难以获取（如危险操作）
- 需要对环境变化具有**鲁棒性**

1.2 本章小结

IL 和 RL 各有适用场景，实际系统中常常结合使用（如 IL warm-start + RL fine-tuning）。

2 Sim-to-Real Transfer

2.1 为什么需要仿真

在真实机器人上做 RL 面临巨大挑战：

- 数据收集慢（真实时间运行）
- 安全风险（机器人可能损坏自身或环境）

- 难以大规模并行化

仿真环境解决了这些问题，但引入了 **sim-to-real gap**：仿真和真实世界之间的差异。

Sim-to-Real Gap 的来源

- **动力学差异**：仿真器无法完美模拟真实物理（摩擦、接触、变形）
- **感知差异**：仿真的视觉/触觉与真实传感器不同
- **执行器差异**：真实电机有延迟、噪声、非线性特性
- **环境差异**：真实环境有未建模的物体、光照变化等

2.2 Domain Randomization

域随机化

Domain Randomization 是弥合 sim-to-real gap 的主要方法之一：

在仿真中随机化各种环境参数（摩擦系数、物体大小、质量、视觉外观、传感器噪声等），使策略在训练阶段就“见过”各种可能的环境变体。

核心假设：如果策略能在足够多样的仿真环境中都表现良好，那么真实世界可以被视为这些变体中的一个。

Domain Randomization 的局限

- 过度随机化可能导致策略过于保守
- 需要确保真实世界参数在随机化范围内
- 对某些物理现象（如软体接触），即使随机化也难以覆盖
- 选择哪些参数进行随机化以及随机化的范围需要领域知识

2.3 本章小结

Sim-to-real transfer 是 RL 用于真实机器人的关键桥梁，domain randomization 是目前最常用的方法。

3 机器人移动：腿式运动

3.1 四足机器人行走

讲者展示了使用 RL 训练四足机器人（如 Unitree Go1/A1）在各种地形上行走的案例。

腿式运动的 RL 框架

- **状态**: 关节角度、角速度、IMU 数据（倾斜角、角速度）
- **动作**: 每个关节的目标角度（PD 控制器跟踪）
- **奖励**: 前进速度 + 能量惩罚 + 姿态惩罚 + 脚步频率奖励
- **训练**: 在 Isaac Gym 等 GPU 并行仿真器中进行，可以同时运行数千个环境

3.2 Teacher-Student 框架

特权信息蒸馏

一种强大的 sim-to-real 训练范式：

1. **Teacher 阶段**: 在仿真中训练 teacher 策略，允许访问**特权信息**（如精确的地形高度图、物体质量、摩擦系数）
2. **Student 阶段**: 训练 student 策略仅使用**真实可用的传感器**（如本体感知、摄像头），通过蒸馏模仿 teacher 的行为

Teacher 可以学得更好（因为有更多信息），student 则学会从有限传感器中推断出等效的信息。

3.3 本章小结

RL + sim-to-real 已经成为腿式机器人控制的主流范式，teacher-student 框架有效解决了感知受限问题。

4 机器人操作

4.1 灵巧操作的挑战

灵巧操作（如用多指手抓取和操作物体）比移动更具挑战性：

- 接触动力学高度非线性
- 状态空间维度更高
- 任务多样性更大
- Sim-to-real gap 在接触建模上更严重

4.2 RL 在操作中的应用

讲者展示了多个使用 RL 进行灵巧操作的案例，包括：

- 旋转魔方（OpenAI Rubik's Cube）
- 笔旋转（pen spinning）

- 灵巧抓取 (dexterous grasping)

这些任务都使用了大规模并行仿真 + domain randomization + teacher-student 的范式。

4.3 本章小结

RL 已经在多种机器人操作任务上展示了超越人类水平的能力，但仿真器质量仍是关键限制因素。

5 人形机器人

5.1 双足行走与全身控制

讲者简要介绍了 RL 在人形机器人上的应用进展：

- 双足稳定行走
- 全身协调（同时走路和操作）
- 对外力扰动的鲁棒性

人形机器人的特殊挑战

相比四足机器人，人形机器人的 RL 训练面临更大挑战：

- 不稳定的双足支撑（更窄的稳定裕度）
- 更高的自由度（全身 30+ 关节）
- 上肢和下肢需要协调
- 跌倒的后果更严重（硬件昂贵）

5.2 本章小结

人形机器人代表了 RL for robotics 的前沿挑战，当前进展快速但离稳定部署仍有距离。

6 总结与延伸

1. RL 和 IL 各有优势，实际系统常结合使用
2. Sim-to-real transfer 是 RL 用于真实机器人的核心流程
3. Domain randomization 和 teacher-student 框架是弥合 sim-to-real gap 的关键技术
4. RL 已在腿式运动和灵巧操作上取得突破性进展
5. 人形机器人代表了下一代挑战
6. 仿真器质量和奖励设计仍然是实际应用的瓶颈

拓展阅读

- Kumar et al., “Rapid Motor Adaptation (RMA),” RSS 2021
- Tobin et al., “Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World,” IROS 2017
- OpenAI, “Solving Rubik’s Cube with a Robot Hand,” 2019
- Rudin et al., “Learning to Walk in Minutes Using Massively Parallel Deep RL,” CoRL 2022
- Radosavovic et al., “Real-World Humanoid Locomotion with RL,” Science Robotics 2024