

课程笔记

CS224R Lecture 18: 深度 RL 前沿与研究方法

基于公开课程资料整理

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 80 分钟

讲者: Chelsea Finn

课程主页: cs224r.stanford.edu

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 Part 1: 深度 RL 的开放问题与前沿	2
1.1 问题定义层面的挑战	2
1.1.1 奖励设计	2
1.1.2 状态与动作空间设计	3
1.1.3 环境设计与基准	3
1.2 方法层面的挑战	3
1.2.1 样本效率	3
1.2.2 泛化能力	3
1.2.3 多智能体与博弈	3
1.3 部署与评估层面的挑战	4
1.3.1 安全性与可信度	4
1.3.2 可重复性	4
1.4 本章小结	4
2 Part 2: 如何做深度 RL 研究	5
2.1 研究的心态与方法论	5
2.2 实验设计	5
2.3 调试 RL 算法	5
2.4 如何选择研究方向	6
2.5 本章小结	6
3 总结与延伸	6

1 Part 1: 深度 RL 的开放问题与前沿

Chelsea Finn 在本讲中总结了深度 RL 领域的开放问题和前沿方向，并提供了深度 RL 研究的实践建议。

1.1 问题定义层面的挑战

1.1.1 奖励设计

奖励设计的根本困难

在现实应用中，设计正确的奖励函数往往比解决 RL 问题本身更困难：

- **奖励稀疏**：大多数时间步没有有意义的反馈
- **奖励误指定**：设计的奖励可能导致非预期行为（reward hacking）
- **多目标冲突**：多个奖励目标之间的权重很难调节

Reward Hacking

当奖励函数不完美时，RL 智能体会找到“合法但非预期”的方式来最大化奖励。经典案例：

- 赛车游戏中收集奖励币而非完成赛道
- 机器人通过抖动而非行走来最大化速度奖励
- LLM 通过重复输出来最大化长度奖励

Reward hacking 是 RL 对齐（alignment）问题的核心挑战之一。

Non-rewarding, non-verifiable domains

No problem


Games
Math reasoning
Coding problems

Challenge: rewards don't exist, or very delayed

1. LLMs for chatbots

Right now: preference optimization

“what you want to hear”



People don't actually give good preferences!

Personalization vs. polarization.

Balancing multiple objectives that may compete with each other.

5

5

图 1: 课程用聊天机器人、机器人折叠和推荐系统说明：一旦任务缺少可靠奖励或客观可验证指标，RL 的问题设定本身就会变成研究难点。

1.1.2 状态与动作空间设计

如何选择合适的状态表示和动作空间也是一个重要的设计问题：

- 状态应该包含足够的信息（满足 Markov 性），但也不能太高维
- 动作空间的粒度影响学习效率
- 在 LLM 中，是 token 级还是 sentence 级的动作空间

1.1.3 环境设计与基准

好的 RL 基准的标准

一个有用的 RL 基准应该：

- 捕捉真实应用中的核心挑战
- 可以快速迭代（计算开销适度）
- 评估指标有意义且可靠
- 与真实世界性能有相关性

当前的挑战是：很多流行的 RL 基准与真实应用的需求脱节。

1.2 方法层面的挑战

1.2.1 样本效率

尽管已有很多改进，深度 RL 的样本效率仍然远低于人类学习。

1.2.2 泛化能力

RL 中的泛化问题

当前 RL 方法的泛化能力有限：

- 在训练环境外的新环境中性能急剧下降
- 对奖励函数的微小变化过度敏感
- 难以将在一个任务上学到的知识迁移到相关任务

提升 RL 泛化能力是实现真实世界部署的关键。

1.2.3 多智能体与博弈

多智能体 RL 面临额外的挑战：

- 环境非平稳（其他智能体的策略在变化）
- 协调与竞争的平衡
- 通信协议的学习

How to leverage video gen models?

Rich world knowledge. They **should** be useful.

But there are large, nuanced challenges!

Example: Train $s_t, a_{t:t+h} \rightarrow s_{t+1:t+h}$ on demos + one policy's roll-outs

Evaluate if new policy's actions $\tilde{a}_{t:t+h}$ lead to good outcomes

These will be out of distribution!

+ Small physical inaccuracies lead to poor performance!

Possible solution 1: Train on data from more policies?

Possible solution 2: Use the model in other ways?

e.g. train $s_t \rightarrow s_{t+1:t+h}$ on only demos
predict future video + run goal-conditioned policy



Source: <https://deepmind.google/models/veo/>

12

图 2: 讲者把 video generation / world model 放进方法前沿中讨论: 它们提供了丰富先验, 但在策略分布外使用时又会因为物理误差和分布外动作而失真。

1.3 部署与评估层面的挑战

1.3.1 安全性与可信度

部署 RL 系统的风险

将 RL 系统部署到真实世界时面临多重风险:

- 分布外 (out-of-distribution) 的状态可能导致灾难性行为
- RL 策略的决策过程难以解释
- 对抗攻击可能利用策略的弱点
- 长期影响难以预测

1.3.2 可重复性

深度 RL 实验的可重复性问题一直备受关注:

- 对随机种子敏感
- 超参数调优开销大
- 不同实现之间的差异可能很大

1.4 本章小结

深度 RL 面临从问题定义到方法再到部署的全方位挑战。奖励设计、泛化能力和安全性是最核心的开放问题。

2 Part 2: 如何做深度 RL 研究

2.1 研究的心态与方法论

Chelsea Finn 的研究建议

1. **从问题出发**: 先理解要解决什么问题, 再考虑用什么方法。不要”拿着锤子找钉子”
2. **先理解再创新**: 深入理解现有方法的优缺点, 创新自然产生
3. **简单优先**: 从最简单的方法/实验开始, 逐步增加复杂性
4. **建立直觉**: 用简单环境建立对算法行为的直觉, 然后推广到复杂场景

2.2 实验设计

RL 实验的最佳实践

- **控制变量**: 每次只改变一个因素
- **多种子运行**: 至少 3-5 个随机种子
- **有意义的基线**: 选择强基线而非稻草人
- **消融实验**: 验证每个设计选择的贡献
- **诊断工具**: 监控学习曲线、值函数估计误差、策略熵等

How to scale up?

Large scale RL for LLMs is exciting! Yet, currently fairly short-horizon or very online.

Can we do large-scale RL with longer horizons & with less online data?

1. Can we train & use accurate **value functions** at scale?

Algorithms like PPO only use value functions for reducing gradient variance, may not be accurate enough for actor-critic algorithms

2. Can we enable large-scale “**batch online**” RL?

Hard to interleave model updates & data collection in many applications, esp for large models!
(e.g. when collecting dialog with real users, when collecting data on real robots)

More practical: few iterations of
[collect large batch of data, update model]
(possibly asynchronously!)

New considerations, e.g. **expressive policies** for enough data breadth

15




图 3: 课程把“如何扩展 RL”具体化为 batch-online、价值函数精度和更新频率三个实验设计问题, 这些问题决定算法能否真正扩展到长时程和大模型场景。

2.3 调试 RL 算法

RL 算法的调试比监督学习困难得多。讲者给出的调试策略:

1. **在简单环境中验证**：先确认算法在 CartPole/Pendulum 上正确工作
2. **检查奖励曲线**：奖励应该单调（或大致单调）增长
3. **检查值函数**：值函数估计应该接近真实回报
4. **可视化策略行为**：观察智能体实际在做什么
5. **检查梯度**：确保梯度没有爆炸或消失

RL 调试的常见陷阱

- 奖励 scale 不当导致值函数发散
- 折扣因子 γ 选择不当
- 数据归一化/标准化遗漏
- exploration 不足导致策略收敛到局部最优
- bug 可能被随机性掩盖——即使有 bug，RL 有时也能学到“还行”的策略

2.4 如何选择研究方向

讲者对选择研究方向提供了建议：

- 关注真正重要的问题而非热门话题
- 寻找理论与实践的差距
- 跨领域思考（NLP $\times$ RL、robotics $\times$ RL）
- 与从业者交流了解真实需求

2.5 本章小结

好的 RL 研究需要清晰的问题定义、严谨的实验设计和有效的调试策略。简单优先、控制变量是核心方法论。

3 总结与延伸

1. 深度 RL 的开放问题横跨问题定义、方法和部署三个层面
2. 奖励设计（避免 reward hacking）、泛化能力和安全性是最重要的方向
3. 好的研究从理解问题开始，不是从方法开始
4. RL 实验需要多种子、强基线和消融实验
5. 调试 RL 需要系统性的方法，可视化和简单环境验证至关重要
6. 跨领域融合（RL + LLM, RL + robotics）是当前最活跃的前沿

拓展阅读

- Henderson et al., “Deep Reinforcement Learning that Matters,” AAAI 2018
- Amodei et al., “Concrete Problems in AI Safety,” arXiv 2016
- Engstrom et al., “Implementation Matters in Deep Policy Gradients,” ICLR 2020
- Andrychowicz et al., “What Matters in On-Policy Reinforcement Learning? A Large-Scale Empirical Study,” ICLR 2021