

课程笔记

CS224R Lecture 19: Q-Learning 复习与总结

五道口纳什 & Codex

2025 年春季



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 约 60 分钟

讲者: Anakietta (TA)

课程主页: cs224r.stanford.edu

目录

1	MDP 基础回顾	2
1.1	马尔可夫决策过程	2
1.2	值函数与 Q 函数	2
1.3	Bellman 方程	2
1.4	本章小结	3
2	表格型 Q-Learning	3
2.1	Q-Learning 算法	3
2.2	收敛性条件	3
2.3	本章小结	3
3	Fitted Q-Iteration 与深度 Q 网络	3
3.1	从表格到函数近似	3
3.2	DQN 的关键技巧	4
3.3	DQN 的改进	4
3.4	本章小结	4
4	从 DQN 到 Actor-Critic	5
4.1	Q-Learning 的局限	5
4.2	Actor-Critic 方法	5
4.3	本章小结	5
5	总结与延伸	5

1 MDP 基础回顾

本讲由助教 Anakietette 主讲，作为课程总复习，从 MDP 基础出发回顾 Q-learning 的完整理论链条。

1.1 马尔可夫决策过程

MDP 五元组

MDP 由 $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$ 定义：

- $\mathcal{S}$: 状态空间
- $\mathcal{A}$: 动作空间
- $P(s'|s, a)$: 状态转移概率
- $R(s, a)$ 或 $R(s, a, s')$: 奖励函数
- $\gamma \in [0, 1)$: 折扣因子

Markov 性: 下一个状态仅依赖当前状态和动作，与历史无关。

1.2 值函数与 Q 函数

核心定义

状态值函数: 在状态 s 下遵循策略 π 的期望累积回报

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s \right]$$

动作值函数 (Q 函数): 在状态 s 下执行动作 a 后遵循策略 π 的期望累积回报

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t) \mid s_0 = s, a_0 = a \right]$$

两者的关系: $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s, a)$

1.3 Bellman 方程

Bellman 期望方程

$$Q^\pi(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \sum_{a'} \pi(a'|s') Q^\pi(s', a')$$

Bellman 最优方程:

$$Q^*(s, a) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) \max_{a'} Q^*(s', a')$$

1.4 本章小结

MDP 提供了 RL 的形式化框架。值函数和 Q 函数是评价策略好坏的核心工具，Bellman 方程描述了它们的递归关系。

2 表格型 Q-Learning

2.1 Q-Learning 算法

Q-Learning 更新规则

Q-Learning 是一种 off-policy、model-free 的算法，直接学习最优 Q 函数：

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

其中：

- α : 学习率
- $r + \gamma \max_{a'} Q(s', a')$: TD target (时序差分目标)
- $r + \gamma \max_{a'} Q(s', a') - Q(s, a)$: TD error

Q-Learning 的 Off-Policy 特性

Q-Learning 是 off-policy 的，因为它使用 $\max_{a'}$ 来计算 TD target，无论行为策略（用来收集数据的策略）是什么。这意味着我们可以用任意策略（如 ϵ -greedy）来探索，同时学习最优策略。

2.2 收敛性条件

Q-Learning 的收敛保证

在表格型设定下（有限状态和动作空间），如果满足以下条件，Q-Learning 保证收敛到 Q^* ：

1. 每个状态-动作对被访问无穷多次
2. 学习率满足 Robbins-Monro 条件: $\sum_t \alpha_t = \infty$, $\sum_t \alpha_t^2 < \infty$

2.3 本章小结

表格型 Q-Learning 通过 TD 更新直接逼近最优 Q 函数，具有理论收敛保证。

3 Fitted Q-Iteration 与深度 Q 网络

3.1 从表格到函数近似

当状态空间连续或很大时，无法维护 Q 值表格。解决方案是用函数近似器（如神经网络）来参数化 Q 函数。

Fitted Q-Iteration (FQI)

FQI 将 Q-Learning 转化为监督学习问题：

1. 用当前 Q 网络计算 TD target: $y_i = r_i + \gamma \max_{a'} Q_{\theta^-}(s'_i, a')$
2. 将 (s_i, a_i) 作为输入, y_i 作为标签, 训练 Q 网络:

$$\min_{\theta} \sum_i (Q_{\theta}(s_i, a_i) - y_i)^2$$

3. 更新目标网络 $\theta^- \leftarrow \theta$
4. 重复

3.2 DQN 的关键技巧

DQN (Deep Q-Network) 的创新

DQN 引入了两个关键技巧使深度 Q-Learning 稳定工作：

1. **Experience Replay**: 将历史经验存储在 replay buffer 中, 训练时随机采样 mini-batch。这打破了数据的时间相关性, 提高了样本利用率。
2. **Target Network**: 使用一个周期性更新的目标网络 Q_{θ^-} 来计算 TD target。这减少了“移动的目标”问题带来的不稳定性。

函数近似 Q-Learning 的不稳定性

与表格型不同, 使用函数近似的 Q-Learning **不保证收敛**。Bellman 更新的收缩性质在函数近似下可能失效, 导致：

- Q 值发散 (overestimation bias 的累积)
- 训练不稳定 (oscillation 或 divergence)
- 对超参数敏感

这就是为什么需要 target network、experience replay 等稳定化技巧。

3.3 DQN 的改进

- **Double DQN**: 用当前网络选择动作, 目标网络评估值, 减少 overestimation
- **Dueling DQN**: 将 Q 函数分解为 $V(s) + A(s, a)$, 分别估计状态值和优势
- **Prioritized Experience Replay**: 按 TD error 大小优先采样, 关注更有学习价值的经验

3.4 本章小结

从表格 Q-Learning 到 DQN 的核心跨越是函数近似。Experience replay 和 target network 是确保训练稳定的关键技巧。

4 从 DQN 到 Actor-Critic

4.1 Q-Learning 的局限

Q-Learning 在连续动作空间的困难

Q-Learning 需要计算 $\max_{a'} Q(s', a')$ ，在离散动作空间中可以遍历所有动作。但在连续动作空间中，这个最大化操作变成了一个连续优化问题，计算代价很高。

4.2 Actor-Critic 方法

解决方案：同时学习策略（actor）和值函数（critic）：

- **Actor**: $\pi_{\theta}(a|s)$ ，参数化策略，输出动作
- **Critic**: $Q_{\phi}(s, a)$ ，评估 actor 选择的动作好坏
- Actor 用策略梯度更新，critic 用 TD 学习更新

4.3 本章小结

Actor-Critic 方法结合了策略梯度和值函数方法的优点，是处理连续动作空间的主流范式。

5 总结与延伸

本讲作为课程总复习，梳理了从 MDP 基础到深度 Q-Learning 的完整知识链条：

1. MDP 五元组提供了 RL 的形式化框架
2. Bellman 方程是求解最优策略的理论基础
3. 表格型 Q-Learning 具有收敛保证
4. DQN 通过 experience replay 和 target network 实现了深度 Q-Learning
5. Double DQN、Dueling DQN 等改进解决了 overestimation 问题
6. Actor-Critic 扩展到连续动作空间

拓展阅读

- Watkins & Dayan, “Q-Learning,” Machine Learning 1992
- Mnih et al., “Human-level Control through Deep Reinforcement Learning (DQN),” Nature 2015
- Van Hasselt et al., “Deep Reinforcement Learning with Double Q-Learning,” AAAI 2016
- Lillicrap et al., “Continuous Control with Deep Reinforcement Learning (DDPG),” ICLR 2016
- Sutton & Barto, “Reinforcement Learning: An Introduction,” 2nd Edition, 2018