

课程笔记

CS231N Lecture 14: Generative Models (Part 2)

基于 Justin Johnson 授课内容整理

2025 年 5 月 20 日



视频作者/频道: Stanford Online

发布日期: 2025-05-20

视频时长: 1:12:00

视频链接: <https://www.youtube.com/watch?v=>

目录

1 生成式建模回顾

上一讲我们已经把生成式建模的前半张图铺好了：判别式模型直接预测条件分布 $p(y | x)$ ，生成式模型则试图建模数据分布本身，或者建模条件生成分布 $p(x | y)$ 。这一讲继续往下走，重点是另一半 family tree：隐式密度模型，以及它们最终如何走到今天的 diffusion / latent diffusion / text-to-image pipeline。

Lecture 14: Generative Models (part 2)

Stanford CS231n 10th Anniversary

Lecture 14 - 1

May 20, 2025

图 1: 本讲标题页：Generative Models (part 2)¹

本讲主线

- **显式密度**：autoregressive、VAE，能写出或近似写出 $p(x)$ 。
- **隐式密度**：GAN 不给你显式 $p(x)$ ，但能从学到的分布里采样。
- **扩散模型**：通过逐步去噪来学习数据流形，训练更稳定，样本质量更好。
- **现代大模型管线**：VAE + GAN + diffusion + transformer + text encoder，几乎全部一起上。

1.1 从显式到隐式

回顾一下上一讲的结论。autoregressive 模型把图像拉直成序列，用 RNN 或 Transformer 按顺序建模；VAE 通过 encoder / decoder 和变分下界学习一个近似密度。两者都属于显式密度范式，区别只是一个能精确算似然，一个只能优化下界。

本讲要讨论的第一类新东西是 GAN。它不再执着于输出密度值，而是学一个能产生样本的映射。只要生成的样本看起来像真数据，它就算赢了。这个思路的好处是样本质量可以很高，坏处是训练极不稳定。

¹Slides 第 1 页。

1.2 为什么训练生成模型这么难

生成模型的根问题始终没变：我们有一个容易采样的先验分布 $p(z)$ ，也有真实而复杂的数据分布 $p_{\text{data}}(x)$ ，但我们并不知道如何把前者对齐到后者。不同方法的差别在于，它们用什么机制来对齐这两个世界。

所有生成模型都在做同一件事

它们都在尝试解决“如何把简单噪声 z 变成复杂数据 x ”这个问题，只不过：

- VAE 用 encoder / decoder 和 ELBO；
- GAN 用对抗训练；
- diffusion 用逐步去噪；
- latent diffusion 则把这些模块拼成工业级系统。

2 GAN

2.1 生成器与判别器

GAN 的标准设定很简单：从先验 $p(z)$ 采样一个 latent z ，经过生成器 $G(z)$ 得到一个样本；再把这个样本送入判别器 $D(x)$ ，让判别器判断它是真的还是假的。生成器希望骗过判别器，判别器希望把真伪分开。

Generative Adversarial Networks: Training Objective

Jointly train generator G and discriminator D with a **minimax game**

Train G and D using alternating gradient updates

$$\begin{aligned} & \min_G \max_D \left(E_{x \sim p_{\text{data}}} [\log D(x)] + E_{z \sim p(z)} [\log (1 - D(G(z)))] \right) \\ &= \min_G \max_D V(G, D) \end{aligned}$$

While True:

$$\begin{aligned} D &= D + \alpha_D \frac{dV}{dD} \\ G &= G - \alpha_G \frac{dV}{dG} \end{aligned}$$

Goodfellow et al., "Generative Adversarial Nets", NeurIPS 2014

Stanford CS231n 10th Anniversary

Lecture 14 - 21

May 20, 2025

图 2: GAN 的训练目标：生成器和判别器做 minimax 对抗²

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))]$$

²Slides 第 21 页。

这个式子最关键的点不是数学形式本身，而是**训练视角**。固定生成器时，判别器是在做二分类；固定判别器时，生成器是在通过判别器的梯度，去优化自己输出样本的分布。

判别器输出的语义

- $D(x) = 1$ 表示“我认为这是一个真实样本”。
- $D(x) = 0$ 表示“我认为这是一个假样本”。
- 判别器一般输出概率而不是硬标签，因此训练目标写成 log-likelihood 更自然。

2.2 训练循环

GAN 的训练是交替进行的：先更新判别器，再更新生成器，再更新判别器，循环往复。判别器更新时希望把真样本打高分、假样本打低分；生成器更新时则希望让判别器把自己的输出误判为真。

生成器常用的“非饱和”损失

实践中，生成器常常不直接最小化 $\log(1 - D(G(z)))$ ，而改为最小化

$$\mathcal{L}_G = -\log D(G(z)).$$

这样在训练初期判别器很强、生成器很弱时，梯度会更有用。

GAN 里一个常见误解是把 $V(G, D)$ 当成普通 loss 来看。其实不行。它是一个博弈值，数值大小本身没有稳定的可解释性。判别器强，值会变；生成器强，值也会变。你不能像看分类 loss 那样看它单调下降。

2.3 为什么 GAN 难训

GAN 的难点主要有四个。

1. **非平稳**：判别器面对的“数据集”会随着生成器变强而不断变化。
2. **信号稀薄**：训练初期判别器可能过强，生成器梯度会变得很差。
3. **没有好曲线看**：generator loss / discriminator loss 通常都不太能反映真实进展。
4. **容易塌缩**：mode collapse 会让生成器只记住少数几个样本模式。

GAN 训练不是普通分类问题

判别器虽然形式上像分类器，但它面对的正负样本分布在训练过程中不断变化。这和 ImageNet 这类静态数据集完全不同，因此“看 loss 曲线”这套经验在这里经常失效。

2.4 理论与局限

从理论上讲，如果判别器足够强，可以写出最优判别器，并且证明在理想条件下，唯一的均衡点是 $p_G(x) = p_{\text{data}}(x)$ 。但这里的“理想条件”非常苛刻：无限容量、完美优化、有限样本误差忽略不计。现实里的神经网络都不满足这些前提。

更麻烦的是，GAN 的样本质量虽然高，但它没有反向映射。也就是说，你一般能从 $z \mapsto x$ ，却没法从一个真实样本方便地回到对应的 latent z 。这和 VAE 非常不同。

GAN 的优缺点

- 优点：采样快，样本锐利，很多时候视觉质量非常好。
- 缺点：训练不稳定，mode collapse 严重，loss 曲线不可信。
- 额外限制：通常没有显式的 $x \rightarrow z$ 编码器。

2.5 GAN 的经典现象

GAN 很喜欢在 latent space 里表现出平滑插值。若从两个 latent 向量 z_0, z_1 之间做线性插值，生成图像往往会平滑变形，而不是跳变。这说明生成器学到了一些有用的语义结构。

Rectified Flow: Sampling

Choose number of steps T (often $T=50$)

Sample $x \sim p_{\text{noise}}$


For t in $[1, 1 - \frac{1}{T}, 1 - \frac{2}{T}, \dots, 0]$:

Evaluate $v_t = f_\theta(x_t, t)$

Step $x = x - v_t/T$

Return x

```
sample = torch.randn(x_shape)
for t in torch.linspace(1, 0, num_steps):
    v = model(sample, t)
    sample = sample - v / num_steps
```



Liu et al., "Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow", 2022
Lipman et al., "Flow Matching for Generative Modeling", 2022

Stanford CS231n 10th Anniversary

Lecture 14 - 56

May 20, 2025

图 3: rectified flow 的采样图展示了“从噪声一步步走向数据”的几何直觉。GAN 和 diffusion 都共享“从简单分布到复杂分布”的大目标，但实现方式不同³

GAN 的另一个典型问题是 mode collapse: 生成器可能只输出极少数模板，但这些模板足够“真”，以至于判别器也未必能轻易抓出来。于是看起来好像训练成功了，实际上多样性已经没了。

2.6 GAN 的历史位置

GAN 在 2016 到 2021 左右长期占据生成式建模主流。DCGAN、StyleGAN 等工作把 GAN 推到很高的样本质量，尤其是在图像领域。但后来 diffusion 以更稳定的训练、更可靠的 loss 和更好的规模化能力逐步取代了它。

³Slides 第 56 页。

GAN 留下来的真正遗产

GAN 的遗产不只是“能生成很漂亮的图”，还包括 latent space 结构化、生成质量评估、以及对生成模型训练稳定性的长期刺激。很多今天的工业级系统仍会把 GAN 作为局部模块塞进去。

3 Diffusion

3.1 为什么 diffusion 成了主流

GAN 解决了样本质量问题，但代价是训练地狱。diffusion 则用另一种方式换取稳定：把“生成”拆成很多步的“去噪”。每一步只做一点点修正，最后从纯噪声走向数据分布。

Diffusion Models

Sohl-Dickstein et al., "Deep Unsupervised Learning using nonequilibrium thermodynamics", ICML 2015
Song and Ermon, "Generative modeling by estimating gradients of the data distribution", NeurIPS 2019
Ho et al., "Denoising Diffusion Probabilistic Models", NeurIPS 2020
Song et al., "Score-Based Generative Modeling through Stochastic Differential Equations", ICLR 2021
Song et al., "Denoising Diffusion Implicit Models", ICLR 2021

Stanford CS231n 10th Anniversary

Lecture 14 - 36

May 20, 2025

图 4: Diffusion Models 章节开始：从 GAN 转向逐步去噪的思路⁴

3.2 直觉

最朴素的 diffusion 直觉是这样的：训练一个网络，输入一个带噪样本，输出“去掉一点噪声之后”的样本。训练时让它学会不同噪声强度下的修复；采样时从纯噪声开始，重复应用这个网络，最终逐步回到清晰样本。

⁴Slides 第 36 页。

Optimal Prediction

Training

```
for (x, y) in dataset:
    z = torch.randn_like(x)
    t = random.uniform(0, 1)
    xt = (1 - t) * x + t * z
    if random.random() < 0.5: y = y_null
    v = model(xt, y, t)
    loss = (z - x - v).square().sum()
```


Q: What is the optimal prediction for the network?

There may be many pairs (x, z) that give the same x_t ; network must average over them

Full noise ($t=1$) is easy: optimal v is mean of p_{data}

No noise ($t=0$) is easy: optimal v is mean of p_{noise}

Middle noise is hardest, most ambiguous



Dhariwal and Nichol, "Diffusion Models beat GANs on Image Synthesis", arXiv 2021
Ho and Salimans, "Classifier-Free Diffusion Guidance", arXiv 2022

Stanford CS231n 10th Anniversary

Lecture 14 - 77

May 20, 2025

图 5: Optimal Prediction: 训练目标就是让网络在中等噪声区域学会最合理的“去噪方向”⁵

训练目标的核心是：给网络一个中间状态 x_t 和噪声水平 t ，让它预测一个合适的方向。对于 rectified flow，这个方向可以直接理解为从数据样本指向噪声样本的速度向量。

3.3 Rectified flow

在讲义里最容易写清楚、也最容易实现的一种 diffusion 变体就是 rectified flow。它的训练流程可以压缩成三步。

1. 从数据分布采样 x ，从噪声分布采样 z ，再采样一个 $t \sim U[0, 1]$ 。
2. 构造中间点 $x_t = (1 - t)x + tz$ 。
3. 让网络输入 (x_t, t) ，预测速度向量 $v = z - x$ 。

$$\mathcal{L}(\theta) = \mathbb{E} \left[\|f_{\theta}(x_t, t) - (z - x)\|_2^2 \right]$$

rectified flow 的好处

- 训练像普通回归，loss 好看且可解释。
- 采样时只需要反复沿预测速度场前进。
- 比 GAN 更稳定，比传统 diffusion 更容易用几何直觉理解。

3.4 采样

采样阶段从纯噪声 $x_1 \sim p_{\text{noise}}$ 开始，设定若干步数 T ，然后从 $t = 1$ 迭代到 $t = 0$ 。每一步调用网络预测速度 v_t ，再沿这个速度方向做小步更新。

⁵Slides 第 76 页。

Rectified Flow: Sampling

Choose number of steps T (often $T=50$)

Sample $x \sim p_{noise}$


For t in $[1, 1 - \frac{1}{T}, 1 - \frac{2}{T}, \dots, 0]$:

Evaluate $v_t = f_\theta(x_t, t)$

Step $x = x - v_t/T$

Return x

```
sample = torch.randn(x_shape)
for t in torch.linspace(1, 0, num_steps):
    v = model(sample, t)
    sample = sample - v / num_steps
```



Liu et al., "Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow", 2022
Lipman et al., "Flow Matching for Generative Modeling", 2022

Stanford CS231n 10th Anniversary

Lecture 14 - 56

May 20, 2025

图 6: Rectified Flow: Sampling。采样时从纯噪声出发，沿着学到的向量场逐步走向数据分布⁶

这和 GAN 的区别非常明显。GAN 采样时是一跳到位，diffusion 采样时是一小步一小步走。前者快，但训练不稳定；后者慢一点，但稳定得多。

3.5 为什么中间噪声最难

一个很重要的经验是，中等噪声水平往往最难学。极高噪声和极低噪声都比较简单，因为模型只要学会数据均值或噪声均值就行；但中间位置会有很多不同的 (x, z) 对应同一个 x_t ，模型必须学会在这些可能性之间平均。

这也是为什么实践中会用不同的噪声采样策略，比如 log-normal 或 shifted schedule，而不是死板地均匀采样 t 。

噪声调度不是装饰品

在高分辨率任务里，合适的噪声调度会直接影响训练质量。低分辨率数据和高分辨率数据的相关结构不同，同样的 t 分布未必能同时适配两者。

3.6 条件生成与 CFG

无条件生成很少真正有用，现实里我们几乎总是想要条件生成：给定文本、类别、草图、掩码或别的用户输入，生成满足条件的样本。

条件 rectified flow 很自然：训练时把条件 y 作为额外输入，采样时也把 y 送进去即可。但实战里还会有一个关键技巧叫 classifier-free guidance (CFG)。

⁶Slides 第 56 页。




图 7: Text-to-Image: 文本编码器 + diffusion transformer + decoder, 构成现代条件生成管线⁷

CFG 的做法是: 训练时随机把一部分条件置空, 让同一个模型同时学会“有条件”和“无条件”的两种向量场。采样时再将两者做线性组合:

$$v_{\text{cfg}} = (1 + w) v(x, t, y) - w v(x, t, \emptyset)$$

其中 w 是 guidance strength。 w 越大, 模型越“听话”; 但太大也会损伤多样性。

CFG 的作用

- 提高条件遵循度。
- 几乎是现代 diffusion 系统的标配。
- 代价是采样时要多跑一次模型, 成本翻倍。

3.7 Diffusion 的三种视角

这一讲特意强调, diffusion 不是只有一种数学解释。

1. **Latent variable model**: 把“加噪后的轨迹”看成潜变量, 和 VAE 很像。
2. **Score matching**: 学习 $\nabla_x \log p(x)$, 也就是把样本往高密度区域推的向量场。
3. **SDE / ODE**: 把采样理解成数值积分过程, rectified flow 可以看作某种 Euler 风格更新。

这三种解释表面上不同, 但最后落到工程上, 很多算法长得非常像: 采样噪声、输入噪声级别、输出一个回归目标、最小化一个均方误差。

⁷Slides 第 101 页。

4 Latent diffusion 与现代管线

4.1 为什么要进 latent space

直接在像素空间上做 diffusion 会很贵，尤其是高分辨率图像和视频。一个非常实用的想法是先
用 encoder 把图像压到较小的 latent 空间，再在 latent 上做 diffusion，最后用 decoder 还原。

Diffusion Learns the Score Function

For any distribution $p(x)$ over $x \in \mathbb{R}^N$ the **score function**

$$s: \mathbb{R}^N \rightarrow \mathbb{R}^N \quad s(x) = \frac{\partial}{\partial x} \log p(x)$$

Is a vector field pointing toward areas of high probability density

Diffusion learns a neural network to approximate the score
function of p_{data}

Song and Ermon, "Generative Modeling by Estimating Gradients of the Data Distribution", NeurIPS 2019
Ho et al, "Denoising Diffusion Probabilistic Models", NeurIPS 2020

Stanford CS231n 10th Anniversary

Lecture 14 - 117

May 20, 2025

图 8: Diffusion is a Latent Variable Model: 前向过程加噪，反向过程学去噪，和 VAE 的 latent 视角非常接近⁸

这就是 latent diffusion。工程上，encoder / decoder 往往来自 VAE，diffusion 模型只在 latent 上运行。这样序列长度更短、计算量更低、训练更稳定。

4.2 现代系统为什么是拼装怪

现代生成模型管线不是“单一模型统治一切”，而是拼装怪：

- 用 **VAE** 把图像压到 latent；
- 用 **GAN** 或其他对抗模块提高局部重建质量；
- 用 **diffusion** 在 latent 上建模生成；
- 用 **transformer** 做主干网络；
- 用 **text encoder** 提供条件信号；
- 必要时再加 **distillation** 降低采样步数。

⁸Slides 第 116 页。

现代生成模型不是单模型思维

真正能跑起来的系统，几乎都不是单纯的 VAE、GAN 或 diffusion，而是这些方法的组合体。你在论文里看到的是一个名字，在产品里看到的是一堆模块。

4.3 Text-to-Image

文本到图像的流程最典型。先把 prompt 送入预训练文本编码器，比如 T5 或 CLIP；然后把文本 embedding 和 noisy latent 一起送入 diffusion transformer；最后把生成出来的 clean latent 通过 decoder 还原成图像。




图 9: Text-to-Image 的标准管线：文本编码器、latent diffusion transformer、decoder⁹

这一类系统很重要的一点是：文本编码器通常是冻结的。它提供的是语义条件，不参与 diffusion 的主训练。真正要学的是如何把语义条件和噪声轨迹对齐。

4.4 Text-to-Video

视频生成和图像生成的结构非常像，只是 latent 多了一个时间维度。也就是说，除了空间上的 $H \times W$ ，还要建模帧之间的动态关系。于是 sequence length 会猛增，算力成本也猛增。

- 图像生成通常已经有几百到上千个 token。
- 视频生成会直接冲到几万甚至更多 token。
- 这也是为什么视频 diffusion 模型特别贵。

⁹Slides 第 101 页。

4.5 为什么又回到 Transformer

在 diffusion 主干网络里，Transformer 重新变得非常重要。原因很直接：它对序列建模灵活，而且能把 noisy latent、时间步和条件信号统一接入。现代 diffusion transformer (DiT) 基本已经成了主流结构之一。

Transformer 在 diffusion 中的角色

- 负责处理序列化的 latent token。
- 通过 cross-attention / joint attention 接收文本条件。
- 通过 scale-and-shift 或类似机制注入时间步。

4.6 高质量视频生成

讲义里提到了 Sora 和 Veo 这类最新视频模型。它们的共同点是：大规模 latent 视频建模、强条件控制、以及非常昂贵的训练和推理成本。概念上和图像 diffusion 没有本质区别，但规模一上去，工程复杂度就完全不同了。

4.7 为什么还要 distillation

diffusion 的最大问题之一是慢。无论是 rectified flow 还是更传统的 diffusion，都要多次迭代模型才能得到最终样本。于是就有了 distillation：把多步采样“蒸馏”成更少步，甚至一步。

- 优点：显著降低采样时间。
- 缺点：通常会牺牲一部分样本质量。
- 现实里：几乎所有大模型都会想办法做某种 distillation。

5 总结

5.1 这一讲到底解决了什么

如果把这一讲压缩成一句话，那就是：现代生成式建模的工业实践，已经不是在 VAE、GAN、diffusion 里选一个，而是把它们全部组合起来。

Diffusion Learns the Score Function

For any distribution $p(x)$ over $x \in \mathbb{R}^N$ the **score function**

$$s: \mathbb{R}^N \rightarrow \mathbb{R}^N \quad s(x) = \frac{\partial}{\partial x} \log p(x)$$

Is a vector field pointing toward areas of high probability density

Diffusion learns a neural network to approximate the score function of p_{data}

Song and Ermon, "Generative Modeling by Estimating Gradients of the Data Distribution", NeurIPS 2019
Ho et al, "Denoising Diffusion Probabilistic Models", NeurIPS 2020

Stanford CS231n 10th Anniversary

Lecture 14 - 117

May 20, 2025

图 10: 从 latent variable 角度看, diffusion 和 VAE、GAN 其实共享同一个核心难题: 如何把简单噪声和复杂数据对齐¹⁰

最后的 Takeaways

1. **GAN** 让我们拿到了高质量样本, 但训练太不稳定。
2. **Diffusion** 把生成变成逐步去噪, 训练稳定、样本强。
3. **Rectified flow** 给了 diffusion 一个特别清楚的几何解释。
4. **Latent diffusion** 是真正的工业主力, 因为它把计算量压到了可接受范围。
5. **Text-to-image / text-to-video** 的核心不是“生成图像或视频”, 而是把条件信号接入一个可控的 latent generative pipeline。

5.2 与前两讲的联系

这三讲其实是连在一起的。第 13 讲讲的是 autoregressive、VAE、GAN 的前半部分; 第 14 讲把 GAN 和 diffusion 的后半部分收完。到了现代, 生成模型通常不再是单一算法, 而是多个算法模块的混合系统。

- 如果你要高质量静态图像, latent diffusion 是主流。
- 如果你要更强的条件控制, CFG 和 text encoder 是标配。
- 如果你要更快采样, distillation 是绕不开的。
- 如果你要真正理解现代系统, 就得同时懂 VAE、GAN 和 diffusion。

¹⁰Slides 第 116 页。

5.3 延伸阅读

- Goodfellow et al., Generative Adversarial Nets (2014)
- Ho et al., Denoising Diffusion Probabilistic Models (2020)
- Song et al., Score-Based Generative Modeling through SDEs (2021)
- Liu et al., Flow Straight and Fast / Flow Matching for Generative Modeling (2022)
- 近年的 latent diffusion / DiT / video diffusion technical reports