


课程笔记

CS231N Lecture 18: What We See and What We Value

基于 Fei-Fei Li 授课内容整理

2025



视频作者/频道: Stanford Online

发布日期: 2025

视频时长: 1:05:12

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 导言：为什么最后一讲不再讲新算法	2
2 See What Humans See：先理解人类视觉为何如此重要	3
2.1 视觉是生物智能最重要的入口之一	3
2.2 对象识别为什么看似容易、实则极难	3
2.3 前深度学习时代：从心理学启发到统计学习	3
2.4 ImageNet 改变了问题规模，也改变了研究节奏	4
2.5 视觉理解不会停在对象标签	5
2.6 从 scene graph 到 captioning，再到视频理解	5
2.7 Compositional generalization：为什么 scene graph 很关键	5
2.8 Captioning 与 storytelling：视觉第一次真正接上语言	6
2.9 这一部分真正想说明什么	7
3 See What Humans Don't See：AI 如何补足人类盲点	7
3.1 超人类感知不是神话，而是某些任务的自然结果	7
3.2 AI 还能把图像变成社会科学的测量仪器	8
3.3 人类视觉其实远没有我们想象得可靠	8
3.4 医疗是 AI 补盲最有说服力的应用场景	9
3.5 Hand Hygiene：为什么这个案例非常典型	9
3.6 ICU 与 Aging in Place：AI 瞄准的是 healthcare 的 dark spaces	10
3.7 偏见不是边角问题，而是视觉系统的结构性风险	10
3.8 隐私保护不是让系统少看一点，而是重新设计它怎么看	11
3.9 这一部分的真正结论	11
4 See What Humans Want to See：把视觉能力约束到人的目标	12
4.1 从 “replace humans” 转向 “augment humans”	12
4.2 医疗 ambient intelligence 是 human-centered AI 的代表场景	12
4.3 视觉的终点不是描述世界，而是进入行动闭环	12
4.4 Open-World Robotics：LLM 和 VLM 是怎么接到机器人上的	13
4.5 Benchmark 也必须从 “漂亮” 走向 “生态有效”	14
4.6 为什么 BEHAVIOR 这类 benchmark 会让人 “有点沮丧”	14
4.7 从数字孪生到脑机接口：lecture18 给出的未来方向	14
4.8 决定机器人该做什么的人，不应该只是研究者	15
4.9 这一部分真正想传达什么	15
5 全讲总结：把 CS231N 从模型课收回到人类课	16
5.1 命题一：视觉 AI 首先是对世界结构的学习	16
5.2 命题二：AI 的价值不只在于复制人类，还在于补足人类	16
5.3 命题三：最难的问题不是能不能做，而是该不该做、该怎么做	16
5.4 把三条主线翻译成真实系统设计问题	16
5.5 给做视觉研究和做系统的人各留一个提醒	16

1 导言：为什么最后一讲不再讲新算法

这一讲不是在课程末尾再补一套新模型，而是把整门 CS231N 的技术线索重新放回到一个更大的问题里：**视觉 AI 到底应该学会什么，以及这些能力最终服务于谁**。讲者一开始就明确说明，这是一场“perspective talk”，目标不是引入新 loss、新网络结构，而是从研究史、社会影响和 human perspective 三个维度，把已经学过的视觉技术重新组织起来。¹

本讲不是算法加餐，而是课程总收束

1. 它回顾视觉智能的发展主线：从人类视觉能力启发，到对象识别、关系理解、视频理解。
2. 它强调 AI 的第二层价值：不仅复制人类能力，还要帮助人类看见看不到、看不全、看不稳的东西。
3. 它把最终问题拉回到价值对齐：AI 不只是“会不会做”，还包括“该不该做”、“怎样做才尊重人”。

从结构上看，整场讲座可以压缩成三句话：

- **See what humans see**：先理解人类为什么能把视觉变成一种高效的智能能力。
- **See what humans don't see**：再讨论 AI 如何超越或补足人类感知的盲点。
- **See what humans want to see**：最后约束这些能力，让它们服务于人的真实偏好与价值。




图 1: Lecture 18 的三段式逻辑：从能力、到补足、再到价值对齐

读这讲的正确方式

这不是一篇“技术细节最密”的 lecture，而是一篇“概念跨度最大”的 lecture。它的价值不在于证明某个模型更强，而在于给出一个判断框架：当我们构建视觉系统时，应该同时问**能力边界、应用场景、人的偏好、风险与责任**。

¹根据 lecture18 字幕 00:00:05-00:01:15，讲者明确说明本讲不再教授新的算法材料，而是从 long-term research evolution 与 human perspective 回看 AI。

2 See What Humans See: 先理解人类视觉为何如此重要

2.1 视觉是生物智能最重要的人口之一

讲者从进化史开始讲视觉，不是为了增加背景故事，而是为了回答一个很根本的问题：**为什么计算机视觉会成为 AI 最早、也最核心的子方向之一**。早在约 5.4 亿年前，动物界出现最初的感光细胞之后，视觉就不再只是一个“传感器”，而是推动生物体快速识别环境、躲避危险、寻找食物、识别同伴的关键能力。²

这段回顾对应着一个研究启示：**视觉不是普通输入模态，它天然携带了大量压缩后的世界结构**。人类依赖视觉完成生存、工作、娱乐、社交与学习，这意味着如果机器也能稳定地解析视觉世界，它就有机会触碰到更一般的智能。




图 2: 从进化视角理解视觉智能：视觉先是生存能力，随后才成为机器学习问题³

2.2 对象识别为什么看似容易、实则极难

人类看一张图片，往往几乎不费力就能说出“这是一只狗”、“那是一辆车”。但讲者紧接着提醒：**这种 effortless 感受会误导我们低估对象识别的计算难度**。从数学上看，同一对象会随着光照、纹理、遮挡、背景、视角、尺度而发生近乎无限的外观变化；从建模上看，模型既要对这些变化保持鲁棒，又要在类别边界上足够敏感。⁴

对象识别的真正难点

- **类内变化巨大**：同一类别在现实世界里几乎没有标准外观。
- **类间差异微妙**：很多错误并不是把猫认成车，而是把近邻类别混掉。
- **环境扰动复杂**：背景、遮挡、模糊、阴影都会破坏模式稳定性。
- **监督信号稀疏**：标注只给类别名，却不告诉模型什么特征才该保留。

这也解释了为什么整个计算机视觉领域会长期把对象识别当作“基础构件”。如果一台机器连图中最基本的对象都无法稳定识别，就更谈不上关系理解、场景推理、视频分析或具身行动。

2.3 前深度学习时代：从心理学启发到统计学习

讲者把 pre-deep-learning 的对象识别史分成两大波。第一波非常“人类中心”：研究者会先内省自己如何看世界，然后猜测视觉系统也许是在识别若干部件、形状或几何原语，再把它们组合成对

²根据字幕 00:01:15-00:03:05，讲者以 Cambrian explosion 与 Andrew Parker 的视觉军备竞赛观点解释视觉的进化意义。

³根据字幕 00:01:15-00:03:05 整理。讲者强调视觉既是进化史中的关键转折，也是现代 AI 的起点之一。

⁴根据字幕 00:07:13-00:08:15，讲者用 lighting, texture, background, occlusion, viewing angle, scaling 等变化解释 object recognition 的根本困难。

象。⁵

这一思路的优点是解释性强，缺点是对真实世界的变化过于脆弱。它能处理“规范对象”，但很难覆盖自然场景里的外观复杂性。因此这类模型常常在理论上优雅，在开放环境里失败。

第二波是统计机器学习的进入。它的重要性不只在用了 SVM、Bayesian 模型或 random field，而在于研究范式变化了：

1. 不再先写死识别规则，而是让模型从数据中估计参数。
2. 不再只追求单个例子的正确解释，而是追求总体分布上的泛化。
3. 不再把视觉问题当成几何拼图，而是把它当成学习问题。

阶段	核心假设	主要瓶颈
部件/形状组合	对象可以由有限几何部件拼装出来	面对真实世界外观变化时脆弱，覆盖面不足
统计学习阶段	用参数化模型从数据中学习判别边界	数据规模有限，特征表达能力不足
深度学习阶段	表示学习与大规模监督共同发挥作用	对算力、数据、标注体系提出更高要求

表 1: 对象识别研究范式的三次跃迁：从规则解释到统计学习，再到大规模表示学习

为什么第一波方法“看起来对”却跑不通

因为人类解释自己认知过程时，经常只看到了结果，没有看见底层表征如何形成。“对象由部件组成”在概念上没错，但这句话距离一个可扩展、可鲁棒的识别系统还差了很多层。

2.4 ImageNet 改变了问题规模，也改变了研究节奏

计算机视觉真正进入现代阶段，靠的不是某一个巧妙 trick，而是**数据、算力和模型在同一时间到位了**。讲者把 ImageNet 放在极其关键的位置：它把“机器能认多少类”这个问题从小规模实验室玩具，推进到接近真实世界复杂度的量级。

ImageNet 的意义至少有三层：

- 它提供了前所未有的大规模视觉词汇表。
- 它提供了公开 benchmark，使算法比较进入同一坐标系。
- 它让深网络终于有足够多的数据去学到层级表示。

2012 年之后，AlexNet 成为拐点，不是因为卷积本身突然诞生，而是因为卷积网络、GPU 训练与大规模监督终于形成共振。之后整个视觉领域迅速从“手工特征 + 传统分类器”转向“端到端表示学习”。

⁵根据字幕 00:08:18-00:09:23，讲者回顾 70s-90s 基于 parts / shapes composition 的一系列 heroic attempts。

2012 年真正改变了什么

不是简单地把分类精度提高了几个点，而是改变了研究者对“视觉能不能靠学习直接解决”的信念。自此以后，识别、检测、分割、描述、生成与多模态模型都开始受益于同一种大规模学习范式。

2.5 视觉理解不会停在对象标签

这节课最有价值的一点，是它没有把“识别对象”当成终点。讲者明确往后推了好几层：**对象只是开始，关系、属性、语言、时间和行动才是更完整的视觉智能。**

为什么这么说？因为单个对象标签往往不足以描述真实场景。“图里有一个人、一只羊驼”和“人骑着羊驼”是完全不同的语义层次。真正能支撑搜索、描述、问答和机器人决策的，不是孤立名词，而是结构化场景理解。



图 3: 视觉任务的语义升级路径：对象识别只是第一层，更高层次是关系、语言与行动

2.6 从 scene graph 到 captioning，再到视频理解

讲者回顾了这一系列扩展任务的内在逻辑：

1. **Scene graph / relationship understanding**: 让模型不只列对象名词，而是刻画对象之间的结构关系。
2. **Image captioning / storytelling**: 让视觉表示进入语言空间，支持更自然的人机接口。
3. **Dynamic scene understanding**: 让模型处理对象运动、交互变化、时序依赖与未来预测。

这一系列任务难度层层上升。对象识别只需要回答“有什么”；关系理解要回答“彼此如何关联”；captioning 要回答“如何用自然语言压缩这个场景”；视频理解则要再进一步回答“谁在什么时候做了什么，以及接下来可能发生什么”。

为什么视频理解比图像理解更难

- 它需要同时保持空间结构和时间结构。
- 它必须区分短时动作与长时情节。
- 它要求模型处理主体交互，而不仅是主体存在。
- 它离真实世界更近，因此也更接近后续的机器人与 agent 问题。

2.7 Compositional generalization: 为什么 scene graph 很关键

字幕里有一段很值得单独拆开看。讲者引用心理学家的观点说，**复杂自然场景中的对象关系，必须作为理解的一部分被编码。**这句话看似简单，实际上是在指出分类时代的局限：只知道“person”

和“horse”同时出现，还远远不足以恢复图像语义；真正有意义的是“person riding horse”、“horse wearing hat”这样的结构表达。⁶

scene graph 的好处在于，它把视觉理解拆成了更可组合的单元：

- 对象节点：谁在场景中出现。
- 属性节点：对象有什么状态或特征。
- 关系边：对象之间以何种方式相连。

这种表示直接带来一种非常重要的能力：**组合泛化**。如果模型见过“person wearing hat”和“horse standing”，那么它未必需要大量见过“horse wearing hat”的训练样本，也有机会通过组合规则去理解这个不常见关系。讲者举的例子很典型：“person sitting on chair”和“fire hydrant on the lawn”常见，但“person sitting on fire hydrant”就很少见；scene graph 之类的组合表示，正是为了让模型在长尾关系上也能做出合理推断。




图 4: scene graph 的核心思想：把名词、属性与关系显式结构化，支持长尾组合推断

这一步为什么重要

因为很多真实世界错误都不是“看不见对象”，而是“看见了对对象，但没理解它们之间的关系”。从安全场景到具身智能，关系理解都比孤立分类更接近决策所需的语义。

2.8 Captioning 与 storytelling：视觉第一次真正接上语言

讲者随后回顾了 2014–2018 这一波工作：用 CNN 提取图像表示，再接上 LSTM 之类的语言模型，实现 image captioning、dense captioning 与 storytelling。⁷

这件事在今天的多模态 LLM 时代看起来已经很自然，但在当时意义非常大。因为它第一次大规模证明了：**视觉系统不必只输出标签，也可以输出一句话、一段描述，甚至一组区域级说明**。这等于把视觉模型从“分类器”推进到了“语言接口”。

⁶根据字幕 00:15:43–00:18:39，讲者用 Jeremy Wolfe 的观点引出 relationship understanding、scene graph 与 zero-shot unusual relationship。

⁷根据字幕 00:18:39–00:20:23，讲者提到 Andrej Karpathy 等人在 CNN + LSTM 时代推动 image captioning、dense captioning 和视觉叙事任务。

任务	输出形式	能力提升
图像分类	单个类别标签	回答“这是什么”
关系理解	结构化对象关系	回答“谁和谁如何关联”
图像描述	一句或多句自然语言	回答“这幅图在发生什么”
Dense captioning	区域级语言描述	回答“图中各局部各自在做什么”
视频叙事	时序化语言输出	回答“一段时间内事件如何展开”

表 2: 从标签到语言的升级：视觉系统的输出空间越来越接近人类交流方式

这一步还带来一个长期影响：一旦视觉表示进入语言空间，它就天然可以和问答、检索、对话、规划与 agent 系统连起来。也正因为如此，captioning 并不只是一个中间时代任务，而是后来多模态大模型的直接前身之一。

2.9 这一部分真正想说明什么

“See what humans see”并不是一句空话，它代表视觉 AI 的第一阶段目标：把人类已经擅长的视觉感知任务，系统地变成机器可学习、可扩展、可比较的问题。其核心结论可以概括成三点：

- 视觉之所以重要，是因为它承载了大量关于世界结构的先验。
- 对象识别之所以难，是因为真实世界变化无限，而监督信号有限。
- 现代视觉突破不是单点发明，而是数据、算力、表示学习范式共同成熟的结果。

第一部分的收束

如果说课程前半程回答的是“机器怎样看见东西”，那么这一部分回答的是“为什么视觉本身就值得成为 AI 的主战场”。这为后面讨论 superhuman perception、人类盲点和 human-centered AI 提供了历史与方法论基础。

3 See What Humans Don't See: AI 如何补足人类盲点

3.1 超人类感知不是神话，而是某些任务的自然结果

在讲完机器如何学会人类已经会做的事之后，讲者把问题推进了一步：**AI 是否应该只停在模仿人类**？答案显然是否定的。对很多 fine-grained 任务来说，人类本来就不擅长，或者代价太高；此时机器完全可以成为一种“超人类感知工具”。

鸟类细粒度分类、车型识别、工业缺陷检测、医学影像中的微弱模式识别，都属于这一类。它们的共同点是：类别空间很细、视觉差异很小、人类经验不稳定、规模化分析困难。此时机器的价值不在于像人，而在于比人更稳定、更可重复、更能处理海量数据。

什么叫“超人类”

这里的 superhuman 并不是说模型在所有视觉任务上全面超过人类，而是指在某些**定义清晰、标注充分、目标单一**的子任务上，模型可以达到高于普通人的分辨率、速度或一致性。

3.2 AI 还能把图像变成社会科学的测量仪器

本讲里一个很有启发性的例子，是把街景中的汽车识别结果当成“社会透镜”。讲者提到，研究者可以从城市街景中识别车辆类型，再把车型分布与教育水平、收入、投票倾向、环境差异等宏观变量联系起来，从而用视觉信号研究社会结构。⁸

这件事非常重要，因为它重新定义了计算机视觉的用途。视觉系统不再只回答“图里是什么”，而可以回答“一个城市或一个社会系统正在呈现什么统计规律”。单个人类观察者无法手工完成这样的大规模汇总，而 AI 能在海量图像中提取稳定的统计结构。




图 5: 视觉系统作为“社会测量仪器”：从街景对象识别走向城市级统计分析

这里的关键不是相关性本身，而是尺度

对单个样本做判断，人类并不弱；但在跨城市、跨区域、跨时间的大规模观察上，AI 可以把原本不可测的社会模式变成可分析数据。这是“看见人类看不见的东西”的一种典型形式。

3.3 人类视觉其实远没有我们想象得可靠

讲者随后故意做了几个经典实验，目的不是炫心理学常识，而是提醒我们：**人类视觉的成功经验容易让人忘记自己的局限**。Stroop test 告诉我们注意力会被自动化阅读过程干扰；change blindness 告诉我们即使场景发生显著变化，人类也可能需要较长时间才察觉。⁹

这些实验之所以重要，是因为它们把“人类有偏差”从抽象判断变成了可观察事实：

- 我们的注意力资源有限。
- 我们会受先验和自动加工过程影响。
- 我们在持续监控任务中容易疲劳。
- 我们对显著变化的察觉并不总是及时。




图 6: 人类视觉的三类局限：注意力、先验偏置与疲劳一致性问题

⁸根据字幕 00:26:28-00:27:24，讲者回顾了利用街景车辆分布推断教育、收入、投票与环境模式的工作。

⁹根据字幕 00:27:24-00:28:47，讲者先用 Stroop test 展示视觉注意力冲突，再用 engine 消失的 change blindness 实验说明大变化也可能被忽略。

“人类在环”并不自动等于安全

很多系统设计里喜欢说“最后让人来确认”，好像只要有人盯着屏幕就能兜底。但如果任务本身就是持续、重复、长时间、高压力的视觉监测，那么人类很可能恰恰是最不稳定的那一环。

3.4 医疗是 AI 补盲最有说服力的应用场景

讲者随后把话题从心理学实验迅速转到医疗现场，这个转折非常有力。因为在医疗场景里，注意力缺口和人为遗漏不再只是“有趣现象”，而会变成病人风险、流程延迟与系统成本。字幕里提到，美国医疗系统中的 medical errors 长期是极严重的问题，而手术室里对纱布、针、器械的人工盘点，仍然高度依赖手工 checklist。¹⁰

这里 AI 的角色不是取代医生，而是把医生、护士和手术团队从低效、重复、易漏的视觉盘点中解放出来。理想的系统会做几件事：

1. 持续监测关键物品是否进入和离开工作区。
2. 在出现数量不匹配时实时预警，而不是收尾时才发现。
3. 把高频重复工作交给机器，让医护把注意力保留给判断与沟通。




图 7: 医疗 ambient intelligence 的基本闭环：持续感知、稳定追踪、异常告警、由人完成最终决策

为什么医疗监测特别适合 human-centered AI

- 高风险，但又有大量重复视觉劳动。
- 对一致性要求很高，人类疲劳成本很大。
- 最终责任必须由专业人员承担，因此天然适合“机器辅助 + 人类决策”。
- 价值清晰：减少错误、降低等待、提升照护覆盖面。

3.5 Hand Hygiene: 为什么这个案例非常典型

讲者在医疗案例里首先讲了 hand hygiene，而不是更“高级”的诊断任务，这个选择其实非常说明问题。洗手这件事看起来简单，但对降低 hospital-acquired infection 极其关键；与此同时，它又特别适合暴露人类审计体系的局限。医院当然可以雇审计员去盯，但这会立刻遇到三个问题：人手不够、成本过高、长期观察的一致性极差。¹¹

讲者还顺手对比了一个常见但不够好的技术方案：RFID。一个佩戴工牌的人靠近洗手池或消毒液分发器，并不等于他真的完成了 hand hygiene 动作。这说明高风险场景里，**邻近性信号不等于行为信号**。视觉系统的价值，恰恰在于它能够直接分类“是否真的发生了洗手动作”，而不是靠弱代理变量猜测。

¹⁰根据字幕 00:28:47-00:30:56，讲者以手术室物品追踪、遗留物风险与人工 checklist 的局限，说明 AI 辅助监测的实际价值。

¹¹根据字幕 00:42:11-00:44:36，讲者说明 hospital-acquired infection 的严重性、人工 auditor 的局限、RFID 的非特异性，以及 privacy-preserving depth sensor 的优势。

为什么深度传感器比普通摄像头更合适

- 它保留了动作轮廓和空间位置，足以做行为识别。
- 它天然弱化面部与身份细节，更容易满足隐私要求。
- 在 hospital corridor 这种狭小空间里，它比简单 proximity sensing 更接近真实任务目标。

讲者给出的一个很有冲击力的结论是：如果拿同一段视频去做标注，算法的一致性明显高于单个人类观察者，甚至要汇总多个人的判断才能接近 AI 的稳定性。这正是“see what humans don’t see”的现实含义：**不是 AI 比人更懂医疗，而是 AI 在重复、细粒度、长期视觉审计上比人更稳。**

3.6 ICU 与 Aging in Place: AI 瞄准的是 healthcare 的 dark spaces

讲者接着把“dark spaces of healthcare”这个概念讲得很具体。所谓 dark spaces，不一定是灯光昏暗的地方，而是那些**持续重要、风险很高、又很难长期获得高质量人工监测**的空间。ICU 是典型例子：病人生死攸关，资源消耗极大，医护人力高度紧张，而很多关键恢复指标又依赖持续观察。

¹²

其中一个具体任务是 **mobilization**，也就是帮助 ICU 病人安全地完成移动和起身。对普通人来说，下床、上床、起身坐下似乎只是日常动作；但对 ICU 患者，这些动作既代表恢复进展，也伴随很高风险。AI 在这里可以监测“getting out of bed / getting in bed / getting out of chair / getting in chair”等事件，并把这些信息交给医护做更好的恢复管理。

而到了 aging in place 场景，目标又略有不同：不是医院内的高密度照护，而是让老年人能够更安全、更独立地留在家中生活。此时 thermal camera、mobility monitoring、sleep pattern、dietary pattern 等传感器信号，构成的是一种**早期异常发现系统**。它不一定给出诊断，但可以在系统过载之前发出足够早的风险信号。




图 8: healthcare dark spaces: 病房、ICU 与家庭照护都需要长期稳定的感知支持

3.7 偏见不是边角问题，而是视觉系统的结构性风险

讲者在这一段里把另一类“看不见”也点了出来：**我们经常看不见自己视觉系统里的偏见**。棋盘阴影错觉等视觉幻觉说明，人类视觉天然带着关于光照、几何与世界结构的内建假设；而在人脸识别、公平性问题中，数据分布与社会历史又会进一步把偏差放大。¹³

这段话最重要的不是“AI 也有 bias”，而是：**AI 会放大它所吸收的人类偏差**。如果训练数据对某些肤色、性别、年龄群体覆盖不足，那么模型在这些人群上的错误率就会更高；当系统被部署到

¹²根据字幕 00:44:48-00:47:30，讲者讨论 ICU mobilization、labor shortage、smart sensor 在 ICU 与老年居家照护中的作用。

¹³根据字幕 00:31:01-00:33:00，讲者用 checker shadow illusion 说明人类视觉系统的先验偏差，并转向 face recognition fairness 的社会后果。

自动驾驶、医疗或公共服务场景时，这种差异会转化为现实世界的不公平。

Bias 的真正危险

偏见可怕的地方不在于它让系统“不够完美”，而在于它会把历史中的不平等编码进一个看起来客观、自动、可扩展的系统里。规模化之后，伤害会比单个人类判断更广。

3.8 隐私保护不是让系统少看一点，而是重新设计它怎么看

紧接着，讲者提出另一种更微妙的“看不见”：有些时候，我们不是想让 AI 看得更多，而是想让它只看见对任务必要的那一部分。医疗病房、家庭监护、老人照护、儿童活动识别，都存在这样的张力：你需要模型理解行为，却不希望它暴露身份、面部、家庭内部布局等高度私密信息。¹⁴

这类问题最容易被误解成“把图像打码就好了”。但讲者特别强调，真正有价值的方案往往要把硬件与软件一体设计：例如专门设计镜头或编码方式，让传感器从源头就只保留动作结构所需的信息，而不保留人脸身份或室内细节。




图 9: 视觉隐私保护的设计思路：不是简单减信息，而是面向任务重构可见性

隐私友好视觉系统的设计原则

- 从源头约束：传感器或编码阶段就控制可见信息。
- 只保留任务必要特征：例如动作轨迹，而不是完整身份。
- 兼顾可用性：保护隐私不能把任务信号也一起毁掉。
- 把 privacy 当成系统目标，而不是部署后的补丁。

3.9 这一部分的真正结论

“See what humans don’t see” 表面上讲的是 superhuman vision，实际上包含了三层不同含义：

1. 比人看得更细：在 fine-grained 任务上实现高分辨率区分。
2. 替人看得更稳：在长期监测与高风险环境中减少遗漏与疲劳。
3. 按人要求地看：在隐私、公平和责任约束下，只看该看的部分。

技术能力越强，越不能省掉 human perspective

因为 AI 不只是一个新传感器，它是一个会被规模化部署的判断系统。它可以帮我们补盲，也可以把偏差、监控和不公平放大。能力和约束必须一起设计。

¹⁴根据字幕 00:33:00–00:36:58，讲者系统讨论 visual privacy，包括 blurring、masking、dimensionality reduction、federated learning、encryption 以及硬件与软件联合设计的 privacy-preserving action recognition。

4 See What Humans Want to See: 把视觉能力约束到人的目标

4.1 从“replace humans”转向“augment humans”

这一部分是整场讲座的价值核心。讲者明确反对把 AI 粗暴地理解为取代劳动的机器，相反，她反复强调的词是 **augment**。也就是说，系统的首要目标应当是**扩大人的能力边界、缓解稀缺人力、降低重复劳动负担、提升照护和决策覆盖范围**，而不是默认让机器接管一切。

这种立场并不天真。因为很多最重要的应用场景，比如医疗、养老、家庭照护，本来就存在巨大的人力缺口。AI 在这里不是和人争工作，而是在帮系统填补长期无法靠人力单独填平的空白。

Replace 与 Augment 的差别

- **Replace mindset**: 把人看成成本，把机器看成更便宜替代品。
- **Augment mindset**: 把人看成责任主体，把机器看成扩大覆盖面与一致性的工具。

Lecture 18 明显站在后者这一边。

4.2 医疗 ambient intelligence 是 human-centered AI 的代表场景

前面提到的医疗监测，在这里被重新赋予了价值解释。为什么讲者如此看重 ambient intelligence? 因为它天然符合 human-centered design 的四个条件:

1. **需求真实**: 病房、ICU、家庭照护都有持续监测需求。
2. **人力稀缺**: 不可能全天候依赖人工高质量覆盖。
3. **风险可定义**: 跌倒、异常活动、物品遗漏、手卫生等都有明确目标。
4. **责任边界清楚**: AI 给出信号，人类负责最终理解与处置。

这也是 lecture18 的重要判断：**最值得优先做的 AI，不一定是最炫的，而是最能在真实世界里减轻人的痛点、同时保留人类主导权的。**

4.3 视觉的终点不是描述世界，而是进入行动闭环

如果说前两个部分解决的是“看见什么”与“怎么看得更好”，那么这一部分开始处理“看见之后如何行动”。讲者把话题推进到 embodied AI 与机器人，这意味着视觉系统不再停留在认知层，而是要参与决策、控制和任务完成。

机器人场景里的难点显著升级:

- 环境开放且变化剧烈，不再是静态 benchmark。
- 任务是组合式的，涉及多步骤依赖。
- 感知错误会直接传递到动作错误。
- 评估标准不再只是 accuracy，而是任务完成率、鲁棒性与安全性。

讲者给出的框架很有代表性：大模型负责把人类意图转成子任务，视觉模型理解当前场景，规划模块把这些信息变成可执行的 action sequence，最终驱动机器人操作。这里最重要的不是某一个模块，而是 perception-language-planning-action 的闭环。




图 10: 具身 AI 闭环：目标、理解、分解、规划、执行

为什么机器人会逼迫视觉系统更真实

因为机器人不能只在 representation space 里“看起来懂了”。一旦要落到执行，错误就会通过抓取失败、路径碰撞、任务中断等形式被立即暴露。机器人因此天然要求视觉表示更稳定、更结构化、更可操作。

4.4 Open-World Robotics: LLM 和 VLM 是怎么接到机器人上的

这部分字幕给出的不是抽象愿景，而是一条相当具体的技术路线。讲者想解决的问题是：**机器人能不能像 LLM 一样接受开放指令，而不是只能在预定义闭世界里执行少数固定任务？**¹⁵

她给出的例子是“open top drawer, but avoid the vase”。要完成这件事，系统至少要做四层映射：

1. 把自然语言指令解析成可执行子目标。
2. 在当前场景里找到 drawer、handle、vase 等目标物。
3. 把“靠近抽屉把手”和“远离花瓶”共同转化成 motion planning map。
4. 将空间热图进一步落到 gripper 旋转、速度和路径控制上。




图 11: open-world robotics 管线：语言 grounding 后进入动作规划

这条路线真正解决的，不是某个特定 drawer 的开合，而是机器人“泛化到没见过的环境”的能力。以前很多机器人系统之所以显得脆弱，是因为它们在训练时就已经知道世界会长成什么样；而这套 LLM + VLM + planner 的组合，至少提供了一种离开 closed world 的办法。

为什么这还远远没有被解决

因为真实家庭环境里，目标会遮挡、光照会变、物体会移动、指令会含糊、动作后果会连锁变化。LLM 和 VLM 能帮助开放指令与开放感知，但它们还没有把机器人的可靠性问题彻底解决。

¹⁵根据字幕 00:49:21-00:53:18，讲者介绍 open instruction robotics: LLM 生成代码或子任务，VLM 识别环境中的 drawer / handle / vase，再把结果更新到 motion planning heatmap 中。

4.5 Benchmark 也必须从“漂亮”走向“生态有效”

讲者提到 ecological robotic learning environment 与 BEHAVIOR benchmark, 重点不在于介绍一个数据集名称, 而在于提出 benchmark 设计哲学的变化: **如果评测环境离真实家庭、真实物体、真实多步骤任务太远, 那么机器人系统很可能只是在刷分, 而没有变得真正有用。**¹⁶

这和课程前面讲的 ImageNet 时代形成了呼应。早期 benchmark 的价值是把识别问题规模化、标准化; 而到了机器人和 agent 阶段, benchmark 的价值变成了让模型在更接近真实世界的组合任务里暴露真实短板。

Benchmark 的陷阱

如果 benchmark 只奖励单步成功率、固定视角和干净场景, 那么模型会学会迎合评测, 而不是学会服务真实世界。Lecture 18 要求我们重新思考: 什么样的 benchmark 才配得上 human-centered AI。

4.6 为什么 BEHAVIOR 这类 benchmark 会让人“有点沮丧”

讲者后面给出的数字其实很刺耳: 在不给 privileged information 的前提下, 把今天的算法直接丢进这类生态任务环境, 很多任务的表现几乎就是 0。¹⁷

这不是坏消息, 反而是 benchmark 真正有价值的证据。因为如果一个 benchmark 让大家轻松刷出高分, 那往往只能说明任务过于理想化; 而当系统一旦失去完美记忆、完美状态、magic motion 之类的强假设, 性能就迅速掉到接近零, 说明 benchmark 终于开始逼近真实世界的复杂性。

生态 benchmark 暴露出的真实缺口

- 当前算法离长程规划仍然很远。
- 当前算法离真实物理交互仍然很远。
- 当前算法离开放环境中的稳健泛化仍然很远。
- 当前算法离“没有特权信息也能做事”仍然很远。

讲者还提到, BEHAVIOR 不只是一个虚拟环境, 而是在 50 个真实场景扫描、上万物体资产、变形体/透明体/热学等属性建模、以及与 Omniverse 协同构建的物理与感知仿真基础上发展出来的。这意味着它追求的不只是 render 得好看, 而是让任务结构、物理属性和感知输入都尽量接近现实。

4.7 从数字孪生到脑机接口: lecture18 给出的未来方向

在收尾前, 讲者还快速扫过了几条未来线索: real-to-sim transfer、digital twin、用同一生态环境研究视觉障碍患者, 以及利用 EEG 控制机器人完成烹饪等动作。¹⁸

这些例子共同指向一件事: 视觉 AI 的未来不是只做“更强分类器”, 而是和机器人、临床、认知科学、辅助技术深度耦合。尤其是 EEG 控制机器人的例子, 虽然还非常早期, 但它很直观地展示

¹⁶根据字幕 00:54:40-00:55:10, 讲者介绍 ecological robotic learning 与 BEHAVIOR benchmark, 强调 everyday household activity 与 virtual interactive ecological environments。

¹⁷根据字幕 01:00:30-01:01:29, 讲者明确说 today's algorithms still cannot do behavior tasks; 在没有 privileged information 的 top row 条件下, 三个 behavior task 的表现接近 zero。

¹⁸根据字幕 01:01:44-01:04:29, 讲者提到数字孪生、视觉障碍研究场景, 以及通过 EEG 信号控制机器人完成整套操作。

了 lecture18 想强调的方向：AI 与机器人最动人的用途之一，是帮助那些因为身体条件受限而无法直接行动的人恢复行动能力。

4.8 决定机器人该做什么的人，不应该只是研究者

这一段是 lecture18 最“人本”、也最不像传统技术课的一段。讲者提出一个很直接的问题：**到底是谁来决定机器人应该学哪些任务？**如果只靠实验室研究者拍脑袋，得到的任务列表很可能只是“技术上好做”，或者“研究者自己觉得有趣”，而不一定是普通人真正愿意交给机器的事情。

因此，讲者介绍了一个 human-centered survey：研究者汇总了来自美国和欧洲劳工调查中的大量日常活动任务，再邀请约 1,400 名受访者表达他们愿意让机器人帮忙完成哪些工作、又不愿意把哪些任务交出去。¹⁹

这个结果非常有信息量。人们一般欢迎机器人做清洁、铲雪、重复劳动、脏活累活；但对情感性强、社交意义强、象征意义强的任务则明显抗拒，比如打开圣诞礼物、购买婚戒、某些婴儿照护细节等。也就是说，**任务是否自动化，不只取决于技术可行性，还取决于情感、社会与文化含义。**




图 12: 机器人任务偏好：脏活累活偏好高，情感与象征性任务偏好低²⁰

这项调查的价值不在于给出一个固定榜单

它真正重要的地方在于提出了一种原则：**机器人任务空间不该只由技术供给决定，也要由人的偏好来定义。** Human-centered AI 不是在系统做完之后征求意见，而是在任务定义阶段就把人的选择权纳入进来。

4.9 这一部分真正想传达什么

“See what humans want to see” 的意思不是“让 AI 更讨喜”，而是把系统从根上绑定到人的目的上。它要求研究者同时回答三个问题：

1. 这个系统究竟在帮谁？
2. 它是在替代人的判断，还是在增强人的能力？
3. 它优化的任务目标，是技术人员自定的，还是经过人的真实偏好校验的？

Lecture 18 的核心价值判断

真正高级的 AI 不是能力无限扩张，而是在能力越来越强时，仍然知道自己该停在哪、该向谁负责、该为哪些真实需求服务。

¹⁹ 根据字幕 00:55:10–00:57:18，讲者介绍从政府劳动调查中整理日常任务，并在线招募约 1,400 名参与者评估机器人任务偏好。

²⁰ 根据字幕 00:55:10–00:58:01 整理。讲者给出的实例包括 clean kitchen floor、shoveling snow、folding laundry、opening Christmas gift、buying wedding rings 等。

5 全讲总结：把 CS231N 从模型课收回到人类课

如果把整门 CS231N 看成一条主线，那么 Lecture 18 做的是一次“高层反编译”：它把前面学过的卷积网络、识别、检测、分割、生成、多模态与具身智能问题，重新还原成三个更大的研究命题。

5.1 命题一：视觉 AI 首先是对世界结构的学习

从进化视角到对象识别史，这一讲提醒我们，视觉不是随机输入，而是世界结构最密集的表达之一。对象、属性、关系、语言、动作，这些层层递进的任务共同构成了视觉智能的扩展路径。

5.2 命题二：AI 的价值不只在于复制人类，还在于补足人类

无论是 fine-grained recognition、社会统计、医疗监测，还是长期持续感知任务，AI 都可以成为一种超越人类尺度、稳定性和覆盖面的工具。但这类能力只有在公平、隐私与责任边界被认真对待时，才是真正有价值的进步。

5.3 命题三：最难的问题不是能不能做，而是该不该做、该怎么做

这一讲最终把问题交还给 human-centered AI：自动化什么、保留什么、增强谁、如何评估“有用”，这些都不是模型精度曲线自己会回答的。它们需要研究者主动把人的价值、偏好与制度约束嵌入系统设计。

5.4 把三条主线翻译成真实系统设计问题

如果把 lecture18 的三条主线落到工程上，可以得到下面这张很实用的检查表。它的价值在于：每做一个视觉系统，都可以拿这张表过一遍，判断自己究竟在解决哪一层问题。

主线	系统目标	常见失败模式	研究者必须补问的问题
See what humans see	学会可靠的对象、关系、语言与时序理解	只会背训练分布，离开 benchmark 就不稳	我们究竟学到了世界结构，还是学到了数据集套路？
See what humans don't see	补足人类在尺度、一致性、疲劳和长尾上的短板	把偏差、不公平或监控一起规模化放大	模型补的是人的盲点，还是放大了人的弱点？
See what humans want to see	让能力真正服务人的目标、偏好和责任边界	技术上可行，但任务本身不值得自动化	谁定义任务？谁承担后果？谁有权拒绝自动化？

表 3: lecture18 的三层问题可以直接转成系统设计审查表

为什么这张表值得记下来

很多坏系统并不是因为模型不够强，而是因为它们从一开始就答错了问题。它们也许能“see”，但没有想清楚“why”、“for whom”与“at what cost”。

5.5 给做视觉研究和做系统的人各留一个提醒

对研究者来说，这一讲最重要的提醒是：不要把 benchmark 上的成功直接误认为世界中的成功。ImageNet 时代证明了标准化评测的力量，但 lecture18 又反过来提醒，真实世界中的价值判断、隐私边界、长程行为与具身执行，并不会因为 top-1 accuracy 提升而自动解决。

对系统工程师来说，这一讲最重要的提醒是：**不要把 human-in-the-loop 当成免责条款**。如果系统设计本身忽视了人的疲劳、注意力上限、偏好差异与责任链条，那么把最终确认塞给人类，只是在把系统缺陷转嫁给一线使用者。

三条最终 takeaway

1. 视觉 AI 的历史，是把人类感知能力转化为可学习系统的历史。
2. 现代 AI 最有价值的方向之一，是补足人类盲点，而不是机械复制人类。
3. 能力越强，越需要 human perspective；否则 AI 放大的不只是效率，也可能是平等、监控与错误。

把这一讲放在整门课最后，其实非常合适。因为学完模型之后，学生最容易产生的错觉是：只要模型更大、数据更多、benchmark 更高，问题就自然解决了。Lecture 18 明确告诉我们并非如此。真正成熟的视觉研究者，需要同时理解**表示、应用、风险与价值**。

这也是整门课最值得带走的一句话

我们当然要 build AI to see things，但更重要的是 build AI to help people, respect people, and remain answerable to people.