

课程笔记

CS336 2026 Lecture 13: Data I

基于 Stanford CS336 Spring 2026 官方可执行讲义重新整理

2026 年春季

3.1 Pre-Training Data

We create our dataset for language model pre-training from a variety of data sources containing knowledge until the end of 2023. We apply several de-duplication methods and data cleaning mechanisms on each data source to obtain high-quality tokens. We remove domains that contain large amounts of personally identifiable information (PII), and domains with known adult content.

课程/频道: Stanford CS336

发布日期: Spring 2026

材料类型: 官方可执行讲义 lecture13-slides.py

课程主页: <https://cs336.stanford.edu/>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	Lecture 13: Data I 的核心主线	2
2	为什么数据最重要	2
3	Raw sources: 互联网不是一个可直接训练的数据集	4
4	Copyright、licenses、fair use 与 lawsuits	6
5	Common Crawl: web-scale raw source	7
6	Specialized sources: Wikipedia、GitHub、arXiv	8
7	经典数据集: BERT、WebText、CCNet、C4	9
8	GPT-3、The Pile、Gopher、LLaMA、RefinedWeb	10
9	案例复盘: 同一个 raw source 可以长成完全不同的数据集	12
10	现代 filtering: Dolma、DCLM、Nemotron-CC	13
11	Code data: The Stack 与 Stack v2	15
12	CommonPile: 只用 permissively licensed data 可行吗	16
13	实操视角: 设计一个训练数据管线要问什么	17
14	数据质量评估与反馈闭环	17
14.1	本章小结	18
15	总结与延伸	19

1 Lecture 13: Data I 的核心主线

前面的课程默认“给定数据”，然后讨论如何训练语言模型。Lecture 13 开始反过来问：**到底训练什么数据？**课程的核心结论很直接：data does not fall from the sky。训练数据不是“整个互联网”的自然副产品，而是一条从 live service 到 raw data，再到 processed data 的工程、法律和伦理管线。

本讲总结先行

- Live service → raw data → processed data, 中间有 crawling、HTML extraction、filtering、deduplication、PII handling、license checks。
- 数据是区分语言模型的重要因素，因为架构和训练流程越来越公开，数据细节却常被保密。
- 数据管线涉及 copyright、privacy、robots.txt、ToS、licensing、fair use、shadow libraries 等问题。
- 大部分 pipeline 是启发式的，仍有大量改进空间。

2 为什么数据最重要

3.1 Pre-Training Data

We create our dataset for language model pre-training from a variety of data sources containing knowledge until the end of 2023. We apply several de-duplication methods and data cleaning mechanisms on each data source to obtain high-quality tokens. We remove domains that contain large amounts of personally identifiable information (PII), and domains with known adult content.

图 1: Llama 3 报告中架构和训练流程相对透明，但数据细节非常有限。

来源: CS336 Lecture 13 官方源引用图。

读图：为什么模型公司对 data 更保密

开源权重模型往往公开 architecture、parameter count、training recipe，甚至并行策略；但数据来源、比例、清洗规则、过滤器和法律授权常只给模糊描述。原因包括竞争优势和版权责任。数据成为模型差异化的核心资产。

术语消化：训练阶段和数据质量

阶段	数据形态	目标
Pre-training	大量原始或轻清洗文本、代码、网页、书籍等。	建立通用语言和世界知识。
Mid-training	更高质量、能力导向的数据。	强化代码、数学、推理、多语等能力。
Post-training	聊天、偏好、RL、工具使用轨迹。	对齐交互行为和任务偏好。

Source	Type	Tokens	Words	Bytes	Docs
Pretraining ♦ OLMo 2 1124 Mix					
DCLM-Baseline	Web pages	3.71T	3.32T	21.32T	2.95B
StarCoder filtered version from OLMoE Mix	Code	83.0B	70.0B	459B	78.7M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
arXiv	STEM papers	20.8B	19.3B	77.2B	3.95M
OpenWebMath	Math web pages	12.2B	11.1B	47.2B	2.89M
Algebraic Stack	Math proofs code	11.8B	10.8B	44.0B	2.83M
Wikipedia & Wikibooks from Dolma 1.7	Encyclopedic	3.7B	3.16B	16.2B	6.17M
Total		3.90T	3.48T	22.38T	3.08B

图 2: OLMo 2 pre-training 数据示例。

来源: CS336 Lecture 13 官方源引用图。

Source	Type	Tokens	Words	Bytes	Docs
Mid-Training ♦ Dolmino High Quality Subset					
DCLM-Baseline FastText top 7% FineWeb ≥ 2	High quality web	752B	670B	4.56T	606M
FLAN from Dolma 1.7 decontaminated	Instruction data	17.0B	14.4B	98.2B	57.3M
peS2o from Dolma 1.7	Academic papers	58.6B	51.1B	413B	38.8M
Wikipedia & Wikibooks from Dolma 1.7	Encyclopedic	3.7B	3.16B	16.2B	6.17M
Stack Exchange 09/30/2024 dump curated Q&A data	Q&A	1.26B	1.14B	7.72B	2.48M
High quality total		832.6B	739.8B	5.09T	710.8M
Mid-training ♦ Dolmino Math Mix					
TuluMath	Synthetic math	230M	222M	1.03B	220K
Dolmino SynthMath	Synthetic math	28.7M	35.1M	163M	725K
TinyGSM-MIND	Synthetic math	6.48B	5.68B	25.52B	17M
MathCoder2 Synthetic Ajibawa-2023 M-A-P Matrix	Synthetic Math	3.87B	3.71B	18.4B	2.83M
Metamath OWM-filtered	Math	84.2M	76.6M	741M	383K
CodeSearchNet OWM-filtered	Code	1.78M	1.41M	29.8M	7.27K
GSM8K Train split	Math	2.74M	3.00M	25.3M	17.6K
Math total		10.7B	9.73B	45.9B	21.37M

图 3: OLMo 2 mid-training / Dolmino 数据示例。

来源: CS336 Lecture 13 官方源引用图。

Category	Prompt Dataset	Count	# Prompts used in SFT	# Prompts used in DPO	Reference
General	Tulu 3 Hardcoded[†]	24	240	–	–
	OpenAssistant ^{1,2,4}	88,838	7,132	7,132	Köpf et al. (2024)
	No Robots	9,500	9,500	9,500	Rajani et al. (2023)
	WildChat (GPT-4 subset) ⁴	241,307	100,000	100,000	Zhao et al. (2024)
	UltraFeedback ^{α,2}	41,635	–	41,635	Cui et al. (2023)
Knowledge	FLAN v2 ^{1,2,4}	89,982	89,982	12,141	Longpre et al. (2023)
Recall	SciRIFF ⁴	35,357	10,000	17,590	Wadden et al. (2024)
	TableGPT ⁴	13,222	5,000	6,049	Zha et al. (2023)
Math	Tulu 3 Persona MATH	149,960	149,960	–	–
Reasoning	Tulu 3 Persona GSM	49,980	49,980	–	–
	Tulu 3 Persona Algebra	20,000	20,000	–	–
	OpenMathInstruct 2 ⁴	21,972,791	50,000	26,356	Toshniwal et al. (2024)
	NuminaMath-TIR ^α	64,312	64,312	8,677	Beeching et al. (2024)
Coding	Tulu 3 Persona Python	34,999	34,999	–	–
	Evol CodeAlpaca ^α	107,276	107,276	14,200	Luo et al. (2023)
Safety	Tulu 3 CoCoNot	10,983	10,983	10,983	Brahman et al. (2024)
& Non-Compliance	Tulu 3 WildJailbreak^{α,4}	50,000	50,000	26,356	Jiang et al. (2024)
	Tulu 3 WildGuardMix^{α,4}	50,000	50,000	26,356	Han et al. (2024)
Multilingual	Aya ⁴	202,285	100,000	32,210	Singh et al. (2024b)
Precise IF	Tulu 3 Persona IF	29,980	29,980	19,890	–
	Tulu 3 IF-augmented	65,530	–	65,530	–
<i>Total</i>		23,327,961	939,344	425,145 ⁷	

图 4: Tulu post-training 数据示例。

来源: CS336 Lecture 13 官方源引用图。

读图: OLMo/Tulu 三张图的教学含义

三张图展示了从大量弱筛网页和通用语料,到更有针对性的高质量数据,再到 instruction/chat 数据的移动。数据量通常下降,人工或模型筛选强度上升,目标也从“预测文本”转向“表现出想要的行为”。

3 Raw sources: 互联网不是一个可直接训练的数据集

“语言模型训练在整个互联网”是非常粗糙的说法。更准确地说,很多原始数据来自 public web 的 crawls,但 live servers 不能直接训练。需要 crawler 发现 URL、下载页面、保存 raw HTTP response,再把 HTML 等格式转换为文本。

术语消化: 从 live service 到 processed data

层次	例子	问题
Live service	网站、GitHub、arXiv、Wikipedia。	动态页面、认证、rate limit、ToS、robots.txt。
Raw data	WARC、git repo、PDF、LaTeX source、XML dump。	格式复杂,噪声大,重复多。
Processed data	WET/text、filtered docs、deduped corpus。	转换损失、过滤 bias、PII、版权和质量控制。




图 5: Decline of consent: C4、RefinedWeb、Dolma 等常见数据 URL 的 robots.txt/ToS 限制随时间增加。

来源: CS336 Lecture 13 官方源引用图。

读图：限制增加意味着什么

越来越多网站通过 robots.txt、ToS 或其他方式表达不希望被爬取。即使技术上可访问，也不代表合规、礼貌或可用于训练。未来数据获取的成本会更高，许可数据和自有数据的重要性会上升。




图 6: 不良 crawler 行为会造成服务压力和公众反弹。

来源: CS336 Lecture 13 官方源引用图。

Shadow libraries 的边界

LibGen、Z-Library、Anna's Archive、Sci-Hub 等 technically 是 web 的一部分，但它们绕过版权和付费墙。课程强调从法律角度这是 piracy/copyright infringement。训练数据工程不能把“能下载”当成“能使用”。

本章小结：raw source 不是 raw permission

网页能访问、能下载、能解析，并不意味着能训练。真实数据管线至少要同时处理四种约束：技术可达性、站点意愿、法律授权、社会接受度。这四个维度任一出问题，都可能让数据集不可持续。

4 Copyright、licenses、fair use 与 lawsuits

几乎互联网上的原创表达都受 copyright 保护。Copyright 保护 expression，而不是 idea；保护门槛很低，不需要注册即存在，但美国起诉通常需要先注册。使用 copyrighted work 的主要路径是获得 license，或主张 fair use。

术语消化：fair use 四因素

1. 使用目的和性质：教育用途、transformative use 更有利。
2. 作品性质：事实性、非虚构作品更有利。
3. 使用数量和实质性：片段比整部作品更有利。
4. 对原作品市场的影响：若替代原作品市场，更不利。

这些因素需要具体案件具体分析；本笔记只解释课程内容，不构成法律建议。

课程提到的诉讼包括 The New York Times v. OpenAI、作者诉 Anthropic、作者诉 Meta。讲义中的核心 takeaway 是：截至课程材料所述，一些具体案件中训练被认为 fair use，但盗版复制明确违法，且这一领域仍在快速演化。

训练数据的法律风险不是只看模型是否背诵

复制数据本身可能已经构成争议；训练是否 transformative、模型是否输出受保护表达、是否影响原市场、是否违反 ToS，都是不同问题。数据管线需要记录来源、许可证、过滤规则和使用理由。

术语消化：训练数据法律/合同术语

术语	课程中的含义	数据工程后果
Copyright	保护原创表达，不保护抽象 idea。门槛很低，网页文字通常也受保护。	不能把“公开网页”直接等同于“可训练数据”。
License	权利人承诺在特定条件下不追究使用。	需要保存 license、版本、适用范围和限制。
Creative Commons	一组允许分发/改编的开放许可证，但不同 CC 条款差异很大。	需要区分 CC-BY、CC-BY-SA、NC、ND 等条件。
Fair use	美国法下四因素平衡判断，是否适用取决于具体事实。	不能在数据表里简单标成“fair use = yes”。
Terms of Service	网站合同条款，可能限制 bot 下载或训练用途。	即使版权层面可争辩，合同层面仍可能违规。

如何把法律问题变成数据工程字段

高质量数据集至少应记录：source URL、crawl time、license 字段、robots.txt/ToS 状态、是否来自 shadow library、是否包含个人信息、处理步骤、过滤器版本、dedup 策略、下游用途假设。没有这些 provenance 字段，后续很难审计风险。

5 Common Crawl: web-scale raw source




图 7: Web crawler 架构：从 seed URLs 出发，下载页面并把超链接加入队列。

来源：Wikipedia WebCrawlerArchitecture, 本地化后供 CS336 Lecture 13 使用。

爬、是否尊重 robots.txt、如何避免压垮网站。Common Crawl 每月增加数十亿网页，但 crawl 本身仍只是 raw source。

Common Crawl 提供 WARC 和 WET。WARC 保存 raw HTTP response，例如 HTML；WET 是转换成 text 后的结果。HTML-to-text 是 lossy process，会影响最终模型。

Text Extraction	CORE	EXTENDED
resiliparse	24.1	13.4
trafilatura	24.5	12.5
WET files	20.7	12.2

图 8: HTML-to-text 工具选择会影响下游 LM accuracy。

来源: CS336 Lecture 13 官方源引用图。

读图：为什么 WET 不是无害中间格式

HTML 包含正文、导航、广告、脚本、评论、页脚。不同 extraction 工具会保留或丢弃不同内容。若正文抽取差，模型会学到网页模板噪声；若抽取过严，又会丢掉有用长尾内容。

术语消化：Common Crawl 到训练文本的处理链

步骤	做什么	主要风险
HTML extraction	从 WARC/HTML 中抽正文。	boilerplate、广告、导航、评论混入或正文丢失。
Language ID	判断文档语言。	多语混合、代码混合、低资源语言误判。
Quality filtering	用规则或模型判断是否像高质量文本。	过滤掉长尾有用内容，引入 Wikipedia/指令数据偏差。
Deduplication	移除重复或近重复文档/段落。	太弱会重复训练，太强会误删模板相似但内容不同的文本。
Toxicity/PII filtering	去除有害内容或个人信息。	过强会损害分布覆盖，过弱会带来安全和隐私风险。

6 Specialized sources: Wikipedia、GitHub、arXiv

Wikipedia 是高质量知识源：范围有 notability 和 reliable sources 约束，定期 dumps 可直接下载，无需 crawl。但它不是完美源：编辑集中在少数贡献者，且 data poisoning 可能在 dump 前短暂注入恶意内容。

GitHub 对代码能力重要，也可能帮助 reasoning。其数据包括 repository 内容和 metadata，例如 issues、pull requests、comments。代码数据必须处理 forks、重复、license、malware、PII 和 generated files。

arXiv 提供论文 metadata、PDF 和可选 LaTeX source。它适合科学/数学/CS 内容，但不是 peer review，且许可有 all rights reserved 和 Creative Commons 等差异。

源不等于数据集

Wikipedia、GitHub、arXiv 都是 sources。真正进入模型的是经过选择、清洗、格式转换、去重、分片和混合权重设定后的 datasets。数据集设计是模型设计的一部分。

三类专门数据源的互补性

来源	强项	局限
Wikipedia	高密度百科知识、结构清晰、多语 dumps。	不是原创思想库，主题受 notability 和编辑群体影响。
GitHub	代码、工程过程、issues/PR/comments。	license、fork/duplicate、malware、PII、bot activity。
arXiv	科研论文、LaTeX source、metadata permissive。	未同行评审，PDF/LaTeX 解析复杂，领域分布不均。

7 经典数据集：BERT、WebText、CCNet、C4

BERT 使用 Wikipedia 和 BooksCorpus。BooksCorpus 来自 Smashwords 上免费的自出版书籍，后来因违反 ToS 等问题下线。GPT-2 的 WebText 则用 Reddit 高 karma 外链作为 quality surrogate，并产生 OpenWebText 的开源复刻。

CCNet 试图自动构造大规模高质量预训练数据：去重、语言识别、用 KenLM 5-gram 模型筛出像 Wikipedia 的文本。C4 从 Common Crawl 2019 snapshot 出发，用手工规则过滤自然语言文本，成为 T5 的重要贡献之一。




图 9: C4 domain analysis: 规则过滤后的 Common Crawl 仍有明显 domain 组成和偏差。

来源: Stanford CS324 lecture image, 本地化后供 CS336 Lecture 13 使用。

读图：C4 domains 告诉我们什么

C4 不只是“网页文本”。它的 domain distribution 反映了 crawl、HTML extraction 和过滤规则共同造成的选择偏差。模型学到的风格、知识和价值取向会受这些 domain 比例影响。

经典数据集的谱系

数据集	主要来源	关键处理	教学结论
BERT data	Wikipedia + BooksCorpus	文档级序列，BooksCorpus 来自免费自出版书。	早期 LM 数据更窄、更人工。
WebText	Reddit 高 karma 外链网页	英文过滤、近重复移除。	用社交信号做代理质量筛选。
CCNet	Common Crawl	去重、fastText 语言识别、KenLM 质量过滤。	自动化 web filtering 的早期范式。
C4	Common Crawl snapshot	手工规则、坏词/非英文/短页过滤。	简单规则可规模化，但偏差明显。
GPT-3 data	CC、WebText2、Books、Wikipedia	质量分类器、fuzzy dedup。	私有数据细节开始变模糊。

8 GPT-3、The Pile、Gopher、LLaMA、RefinedWeb

GPT-3 数据包括 processed Common Crawl、WebText2、神秘 books corpora 和 Wikipedia，总计约 400B tokens。处理上使用 quality classifier 区分 WebText/Wikipedia/Books 与其他网页，并做 fuzzy deduplication。

The Pile 是开源模型社区对 GPT-3 数据不透明的回应，聚合 22 个高质量 domain，包括 Pile-CC、PubMed Central、arXiv、Enron emails、Project Gutenberg、Books3、StackExchange 等。

Component	Raw Size	Weight	Epochs	Effective Size	Mean Document Size
Pile-CC	227.12 GiB	18.11%	1.0	227.12 GiB	4.33 KiB
PubMed Central	90.27 GiB	14.40%	2.0	180.55 GiB	30.55 KiB
Books3 [†]	100.96 GiB	12.07%	1.5	151.44 GiB	538.36 KiB
OpenWebText2	62.77 GiB	10.01%	2.0	125.54 GiB	3.85 KiB
ArXiv	56.21 GiB	8.96%	2.0	112.42 GiB	46.61 KiB
Github	95.16 GiB	7.59%	1.0	95.16 GiB	5.25 KiB
FreeLaw	51.15 GiB	6.12%	1.5	76.73 GiB	15.06 KiB
Stack Exchange	32.20 GiB	5.13%	2.0	64.39 GiB	2.16 KiB
USPTO Backgrounds	22.90 GiB	3.65%	2.0	45.81 GiB	4.08 KiB
PubMed Abstracts	19.26 GiB	3.07%	2.0	38.53 GiB	1.30 KiB
Gutenberg (PG-19) [†]	10.88 GiB	2.17%	2.5	27.19 GiB	398.73 KiB
OpenSubtitles [†]	12.98 GiB	1.55%	1.5	19.47 GiB	30.48 KiB
Wikipedia (en) [†]	6.38 GiB	1.53%	3.0	19.13 GiB	1.11 KiB
DM Mathematics [†]	7.75 GiB	1.24%	2.0	15.49 GiB	8.00 KiB
Ubuntu IRC	5.52 GiB	0.88%	2.0	11.03 GiB	545.48 KiB
BookCorpus2	6.30 GiB	0.75%	1.5	9.45 GiB	369.87 KiB
EuroParl [†]	4.59 GiB	0.73%	2.0	9.17 GiB	68.87 KiB
HackerNews	3.90 GiB	0.62%	2.0	7.80 GiB	4.92 KiB
YoutubeSubtitles	3.73 GiB	0.60%	2.0	7.47 GiB	22.55 KiB
PhilPapers	2.38 GiB	0.38%	2.0	4.76 GiB	73.37 KiB
NIH ExPorter	1.89 GiB	0.30%	2.0	3.79 GiB	2.11 KiB
Enron Emails [†]	0.88 GiB	0.14%	2.0	1.76 GiB	1.78 KiB
The Pile	825.18 GiB			1254.20 GiB	5.91 KiB

图 10: The Pile: 22 个 curated high-quality domains 的组合。

来源: Stanford CS324 lecture image, 本地化后供 CS336 Lecture 13 使用。

读图: The Pile 的价值和争议

The Pile 让数据组成更透明, 推动开源模型训练。但其中 Books3 来自 shadow library Bibliotik, 后来因 copyright lawsuits 下线。透明不等于没有法律/伦理风险。

Gopher 的 MassiveText 说明数据描述本身也很有价值: MassiveWeb、C4、Books、News、GitHub、Wikipedia, 并使用 English filtering、deduplication、train-test overlap、manual quality rules 和 Google SafeSearch toxicity filtering。LLaMA 则使用 CommonCrawl/CCNet/C4/GitHub/Wikipedia/Project Gutenberg/Books3/arXiv/StackExchange, 总计约 1.2T tokens, 并被 RedPajama/SlimPajama 复刻。

RefinedWeb 的主张是 web data is all you need: 使用 WARC 和 trafilatura 抽取文本, Gopher rules 过滤, 避免 ML-based filtering 以减少 bias, 并用 MinHash over 5-grams 做 fuzzy deduplication。FineWeb 在此基础上扩展到 95 个 Common Crawl dumps, 结果达到 15T tokens。

这些数据集的代际变化

早期数据集强调“有一批可训练文本”: Wikipedia、BooksCorpus、WebText。GPT-3 之后, 数据集开始强调“大规模 web + 多源混合 + 去重过滤”: The Pile、MassiveText、LLaMA data、RefinedWeb。到 Dolma/DCLM/Nemotron-CC 阶段, 重点进一步变成“过滤器和数据处理算法本身”: 谁能从巨大 raw pool 中筛出更高质量、更少偏差、更可审计的数据。

不要把 token 数当成唯一质量指标

15T tokens 不必然优于 3T tokens, 3T tokens 也不必然优于 800GB。数据价值取决于覆盖、质量、去重、许可证、语言分布、代码/数学/学术比例、污染控制和与目标能力的匹配。Scaling laws 只能在数据分布相对稳定时外推; 换数据 pipeline 会改变曲线。

手工规则和模型过滤的偏差不同

手工规则透明、便宜、可解释，但可能粗糙，例如删除包含代码符号的页面。模型过滤更强，但会把训练 classifier 的正负例偏差扩散到整个语料。数据过滤没有中立方案，只有可审计的 trade-off。

9 案例复盘：同一个 raw source 可以长成完全不同的数据集

Common Crawl 是最典型例子。C4、CCNet、RefinedWeb、FineWeb、Dolma、DCLM、Nemotron-CC 都可以从 Common Crawl 或 web crawl 出发，但它们的目标和处理哲学不同。C4 强调简单可复制规则；CCNet 强调 Wikipedia-like quality；RefinedWeb 强调 WARC 抽取和弱模型过滤；DCLM 强调标准化数据处理竞赛；Nemotron-CC 则强调不要过度过滤，宁可用 ensemble classifier 和 synthetic rephrasing 提升质量。

同源不同集的关键差异

1. **抽取器不同**：WET、trafilatura、jusText、resiliparse 会改变保留正文的边界。
2. **语言识别不同**：阈值高会损失多语和 code-mixed 文本，阈值低会混入噪声。
3. **质量定义不同**：像 Wikipedia、像 instruction data、像教育内容、像高投票网页，是四种不同的“好”。
4. **去重粒度不同**：文档级去重、段落级去重、MinHash 近重复、benchmark decontamination 对模型记忆和泛化影响不同。
5. **安全过滤不同**：bad-word lists、toxicity classifiers、PII redaction 会改变社会偏见和内容覆盖。

数据管线如何影响模型行为

如果过滤器偏好百科式文本，模型可能更正式但长尾对话能力弱；如果偏好 Reddit 外链，模型可能更了解网络文化但噪声和偏见更重；如果偏好代码和 PR metadata，模型会更擅长软件工程；如果大量使用合成 instruction data，模型会更会“回答问题”，但风格和事实分布会向 teacher model 靠拢。数据处理不是清洁工序，而是行为塑形。

可复现性不只需要发布 URL 列表

即使公开所有 URLs，如果没有 crawl time、HTML extraction version、过滤器权重、dedup hash、语言识别阈值和删除策略，别人仍然无法复现同一数据集。网页会变，robots.txt 会变，内容会消失，许可证会改。数据集复现比代码复现更脆弱。

术语表：数据处理方法

方法	做什么	什么时候会出问题
Language ID	判断文本语言，常用 fastText 等分类器。	多语混合、代码、专有名词、低资源语言会被误判。
Exact dedup	删除完全相同文档或段落。	只能去掉显式重复，模板改写和轻微变化仍保留。
Fuzzy dedup	用 MinHash/Jaccard 等检测近重复。	阈值太低误删，阈值太高重复训练。
Quality rules	按标点、词数、坏词、HTML 特征等过滤。	透明但粗糙，容易删掉代码、列表、非标准文本。
Quality classifier	用模型判断文本是否高质量。	继承训练正负例偏差，可能把“像某数据集”当成“好”。
PII redaction	删除邮箱、电话、地址、公开 IP 等个人信息。	规则漏检或误删真实技术内容。
Benchmark decontamination	移除与评测集重叠的训练文本。	近似匹配难，时间戳和复制传播会破坏假设。

为什么 Data I 值得单独一讲

模型能力常被解释为参数量、架构或训练 FLOPs 的结果，但这些变量背后还有一个更不透明的变量：模型到底读过什么。数据源决定知识覆盖，过滤器决定语言风格和价值偏好，去重决定记忆压力，许可证决定可持续性，PII/安全过滤决定社会风险。忽略数据，就无法真正解释模型行为。

10 现代 filtering: Dolma、DCLM、Nemotron-CC

Source	Doc Type	UTF-8 bytes (GB)	Documents (millions)	Unicode words (billions)	Llama tokens (billions)
Common Crawl	 web pages	9,022	3,370	1,775	2,281
The Stack	 code	1,043	210	260	411
C4	 web pages	790	364	153	198
Reddit	 social media	339	377	72	89
PeS2o	 STEM papers	268	38.8	50	70
Project Gutenberg	 books	20.4	0.056	4.0	6.0
Wikipedia, Wikibooks	 encyclopedic	16.2	6.2	3.7	4.3
Total		11,519	4,367	2,318	3,059

图 11: Dolma 数据概览：Reddit、PeS2o、C4、Project Gutenberg、Wikipedia/Wikibooks 等组成。

来源：Dolma overview image, 本地化后供 CS336 Lecture 13 使用。

读图：Dolma 的 pipeline

Dolma 的 Common Crawl 处理包括语言识别、Gopher/C4 规则过滤、toxicity filtering、Bloom filter deduplication。它体现了现代开源数据集的折中：不用强模型过滤以减少 bias，但仍大量依赖启发式。




Figure 4: **Construction of DCLM-BASELINE from DCLM-POOL.** Before this pipeline, we extracted DCLM-Pool from Common Crawl with `resiliparse`. Percentages are based on the total number of original documents.

图 12: DCLM: 从 240T token DCLM-pool 中用 quality classifier 过滤出 baseline 数据。

来源：CS336 Lecture 13 官方源引用图。

Table 4: **Quality filtering comparison** (1B–1x scale). We evaluate various choices for model-based quality filters. Training a `fastText` classifier for filtering performs best.

Filter	CORE	EXTENDED
RefinedWeb reproduction	27.5	14.6
Top 20% by Pagerank	26.1	12.9
SemDedup [1]	27.1	13.8
Classifier on BGE features [185]	27.2	14.0
AskLLM [146]	28.6	14.3
Perplexity filtering	29.0	15.0
Top-k average logits	29.2	14.7
fastText [87] OH-2.5 +ELI5	30.2	15.4

图 13: DCLM quality classifier 与其他 filtering 方法的比较。

来源：CS336 Lecture 13 官方源引用图。

读图：model-based filtering 的优缺点

DCLM 使用正例 OpenHermes/ELI5、负例 RefinedWeb 训练 `fastText` classifier，在大池子上过滤。优点是质量提升明显；风险是 classifier 会继承正负例选择偏差，把“像某些高质量数据”误当成“真正有用数据”。

Model-based filtering 的机制

把一个小的人工/模型选定数据集当作“好文本”正例，把普通 web 文本当作负例，训练 classifier 后打分整个 Common Crawl pool。这个过程实质上是在定义“模型应该多学哪类文本”。因此 classifier 的训练集就是隐含的数据价值观。

Dataset	ARC-E	ARC-C	H	W	RACE	PIQA	SIQA	CSQA	OBQA	MMLU	Avg
FineWebEdu-2	71.9	44.7	75.4	67.0	36.8	79.5	45.2	25.5	43.8	42.4	53.2
FineWebEdu	73.6	48.0	70.7	64.6	38.0	76.4	43.5	30.0	44.4	42.9	53.2
DCLM	74.7	47.0	76.3	69.1	36.5	79.7	45.6	44.1	44.0	53.4	57.0
Nemotron-CC	75.3	50.7	75.9	67.8	37.9	80.5	45.1	47.7	44.2	53.0	57.8
Nemotron-CC-HQ	78.8	52.9	76.6	69.4	36.4	80.1	46.6	55.8	45.4	59.0	60.1

图 14: Nemotron-CC: 在不过度过滤的前提下保留更多 token, 并结合 classifier ensemble 和 synthetic rephrasing。

来源: CS336 Lecture 13 官方源引用图。

读图: Nemotron-CC 的动机

FineWebEdu 和 DCLM 可能移除 90% 数据, 质量高但 token 少。Nemotron-CC 试图 “need more tokens but preserve quality”: 用 Nemotron-340B-instruct 打分并蒸馏 classifier, 结合 DCLM classifier, 对低质量数据重写, 对高质量数据生成任务。

合成数据和重写的风险

用 LM rephrase 低质量数据或从高质量数据生成 QA pairs, 可以提高可学信号密度; 但也可能引入 teacher model 的风格偏差、事实错误、重复模板和版权继承问题。合成数据应记录生成模型、prompt、过滤器和去重策略。

11 Code data: The Stack 与 Stack v2

The Stack 从 GitHub Archive 获取 repo names, git clone 大量 repositories, 只保留 permissively licensed 代码, 用 go-license-detector 检测 license, 并用 MinHash/Jaccard 去重。Stack v2 扩展到 issues、comments、PRs、Software Heritage repos 和 docs crawls。

```

<pr>Title: title\nusername_0: description
<pr_status>opened
<repo_name>reponame

<pr_base>
<pr_file>filepath_1
<pr_base_code>file_content/changes_1
...
<pr_file>filepath_N
<pr_base_code>file_content/changes_N

<pr_diff>
<pr_file>filepath_1
<pr_diff_hunk>diff_hunk_1
...
<pr_diff_hunk>diff_hunk_K
...
<pr_file>filepath_M
<pr_diff_hunk>diff_hunk_1
...
<pr_diff_hunk>diff_hunk_J

<pr_comment>username_id: comment
<pr_event_id>comment_id
...
...
<pr_review>username_id: review_comment\n
<pr_event_id>review_id
<pr_review_state>[approved, rejected, commented, changes_required]
...
...
<pr_review_comment>
<pr_event_id>comment_id
<pr_in_reply_to_review_id>review_id (opt)
<pr_in_reply_to_comment_id>comment_id (opt)
<pr_file>filepath
<pr_diff_hunk_comment_line>line_number
<pr_diff_hunk>diff_hunk_content
<pr_comment>username_id: comment

```

图 15: Stack v2 pull request 数据: 把结构化 PR 对象线性化成 token sequence, 并加入 diff 周边上下文。

来源: CS336 Lecture 13 官方源引用图。

读图：为什么 PR metadata 有价值

代码文件教模型语法和 API, PR/issue/comment 教模型软件工程过程: bug report、review、patch rationale、discussion。Agentic coding models 很可能受益于这种过程数据, 但也要处理 PII、bot activity、malware 和 license。

代码数据的特殊性

代码不是普通文本: 它有许可证、依赖、可执行语义、测试、提交历史和安全风险。高质量代码数据不只是.py/.js 文件, 还包括 README、issue、PR、review、diff context、CI log。面向 coding agents 的数据尤其需要过程信息。

12 CommonPile: 只用 permissively licensed data 可行吗




图 16: CommonPile: 收集 8TB permissively licensed data。

来源: CS336 Lecture 13 官方源引用图。




图 17: CommonPile/Comma results: 只用 permissive data 可以做到不错, 但 token 规模仍是瓶颈。

来源: CS336 Lecture 13 官方源引用图。

读图: permissive data 也有细节

License laundering 可能把 copyrighted work 重新包装成 permissive license; collection license 不一定延伸到单个文档; 合成数据若来自未授权数据训练的模型, 法律状态也不清楚。只说“permissive”不够, 仍需 provenance 审计。

13 实操视角：设计一个训练数据管线要问什么

数据管线 checklist

1. **来源**：每个 source 是 live service、public dump、licensed corpus、synthetic data 还是 user data?
2. **权限**：是否有 license? ToS 是否允许? robots.txt 怎么处理? 是否含 shadow-library 风险?
3. **抽取**：HTML/PDF/LaTeX/code/XML 如何转文本? 转换器版本和失败率是什么?
4. **过滤**：使用手工规则、语言识别、quality classifier、toxicity filter 还是 PII filter? 阈值怎么定?
5. **去重**：document-level、paragraph-level、MinHash、Bloom filter、benchmark overlap 分别怎么做?
6. **混合**：web、code、math、academic、books、Q&A、multilingual、synthetic data 的比例如何决定?
7. **审计**：能否追踪某条训练样本的 provenance? 能否删除某类数据? 能否复现实验?

数据配比不是静态表格

Pre-training 早期可能需要最大覆盖和多样性；mid-training 可能提高代码、数学、高质量学术文本或教育文本比例；post-training 则加入 instruction、preference、tool-use、RL trajectories。数据 mix 应服务训练阶段和目标能力，而不是一次性固定。

数据工作最容易隐藏在“清洗过”三个字里

论文常写 “we cleaned and deduplicated the data”，但这句话可能包含数百个规则、多个模型过滤器、人工审计、legal review 和大量失败样本。对复现和安全来说，清洗规则和过滤器版本与模型 architecture 一样重要。

14 数据质量评估与反馈闭环

数据管线不是一次性脚本，而是一个需要闭环优化的系统。训练前可以用静态统计检查语料，例如语言分布、重复率、平均文档长度、域名分布、许可证比例、PII 命中率、毒性分数、代码/数学/学术文本比例；训练中可以看 loss 曲线和 domain-level loss；训练后再用 evaluation suite 反推哪些能力缺口对应哪些数据缺口。

从 eval 回到 data 的闭环

1. 如果代码 benchmark 弱，检查代码数据比例、license 过滤是否过严、是否缺少 issue/PR/文档数据。
2. 如果数学推理弱，检查是否有足够高质量 LaTeX、竞赛题、步骤化解答和去重后的合成数据。
3. 如果多语能力弱，检查 language ID 阈值是否把 code-switching 和低资源语言误删。

4. 如果模型幻觉强，检查高权威来源比例、重复低质网页、知识密度和事实性过滤。
5. 如果安全性差，检查 harmful data、jailbreak data、refusal data 和 policy data 的覆盖及标注质量。

数据审计指标

指标	看什么	为什么重要
Domain mix	web、books、code、academic、forums、Q&A、news 的比例。	决定模型知识和风格来源。
Duplication rate	exact/near duplicate 的比例和重复 token 权重。	重复会浪费 compute，也可能导致 memorization。
Document quality score	规则分、classifier 分、人审样本。	过滤策略是否过强或过弱。
License coverage	permissive、unknown、restricted、licensed 的比例。	决定法律和发布风险。
PII/toxicity rate	隐私和有害内容命中率。	决定安全和合规处理需求。
Benchmark overlap	与 eval/test 集的 exact/fuzzy overlap。	避免评价污染和能力高估。

数据闭环也可能过拟合

如果只根据现有 benchmark 补数据，模型会越来越适合 benchmark，而不一定更适合真实用户。数据迭代应该同时看 held-out eval、fresh eval、private eval、真实使用反馈和安全审计。

14.1 本章小结

Lecture 13 的后半部分说明，同样叫“web data”可以有完全不同的数据哲学：C4 偏规则过滤，RefinedWeb/FineWeb 偏大规模 web，DCLM 偏模型质量分类器，Nemotron-CC 偏保留更多 token 和合成增强，CommonPile 偏许可可审计。数据集不是自然物，而是价值判断和工程约束的产物。

Data I 的根本观点

如果说前几讲讨论的是“如何更有效地训练模型”，这一讲讨论的是“训练目标从哪里来”。数据决定模型看见什么语言、知识、代码、价值观、错误、重复和法律风险。架构可以复现，GPU 可以租，优化器可以开源；但高质量、合规、目标明确的数据管线最难复制。

和下一讲的连接

Data I 主要讲来源、法律边界和经典/现代数据集谱系。下一步自然是更细的数据处理问题：如何做 dedup、contamination removal、PII filtering、quality classifiers、data mixing、curriculum、post-training data 和 evaluation-driven data iteration。

15 总结与延伸

Lecture 13 的核心是把“数据”从抽象名词还原成生产系统。网页不是直接可训练文本，Common Crawl 不是高质量数据，许可证不是一行元数据，过滤器不是中立工具。数据工程涉及来源、转换、过滤、去重、版权、隐私、质量和长期维护。

最终 takeaways

1. Data does not fall from the sky; 数据获取和清洗需要大量工程和人类判断。
2. 模型公司常公开架构和训练流程，却隐藏数据细节，说明数据是核心竞争力。
3. Public web 受动态内容、认证、robots.txt、ToS、rate limit 和法律限制约束。
4. Copyright/fair use/licensing 是训练数据管线不可避免的一部分。
5. Common Crawl 是 raw source，不是成品训练集；HTML extraction 和 filtering 会塑造模型。
6. 现代数据集在规则过滤、模型过滤、合成重写、dedup、license 审计之间折中。
7. 下一步数据课程自然会进入更细的 processing、mixing 和 post-training 数据设计。

拓展阅读

- Common Crawl, C4, CCNet, RefinedWeb, FineWeb.
- The Pile, Dolma, DCLM, Nemotron-CC, The Stack, CommonPile.
- Copyright Act, Creative Commons, fair use, Terms of Service.
- LLaMA, GPT-3, Gopher, OLMo 2, Tulu data reports.