


课程笔记

CS336 Lecture 13: Data

基于讲者授课内容整理

2025 年春季



视频作者/频道: Stanford CS336

发布日期: 2025-03

视频时长: -

视频链接: <https://stanford-cs336.github.io/spring2025/>

目录

1 导言：为什么这一讲是数据	2
1.1 为什么公司对数据这么保密	2
2 训练阶段与术语	2
3 公开数据配方的典型例子	3
3.1 OLMo / AI2 的公开路径	3
3.2 典型混合的结构	3
4 预训练语料：从 Wikipedia 到 Common Crawl	3
4.1 BERT 的数据	3
4.2 GPT-2 与 OpenWebText	4
4.3 Common Crawl 及其后续处理	4
4.4 CCNet、C4 与 GPT-3	4
4.5 The Pile 与开放社区	4
5 更系统的数据工程：Gopher、LLaMA、RefinedWeb、Dolma、DCLM	5
5.1 Gopher 的 MassiveText	5
5.2 LLaMA 与 RedPajama	5
5.3 RefinedWeb 与 FineWeb	5
5.4 Dolma、DataComp-LM 与 Nemotron-CC	5
6 长上下文、任务化数据与指令数据	6
6.1 长上下文	6
6.2 任务数据	6
6.3 指令跟随与聊天数据	6
7 版权、许可与 fair use	7
7.1 基本框架	7
7.2 Fair use 的四个因素	7
7.3 条款与授权	7
8 总结	8

1 导言：为什么这一讲是数据

这节课的核心观点很直接：如果前几讲回答的是“给定数据，模型怎么训练”，那么这一讲要回答的是“到底该用什么数据训练”。讲者的立场很明确，数据不是训练流水线里的一个可有可无的附件，而是决定语言模型上限的关键因素。

这一讲的主线

1. 先区分训练阶段：pre-training、mid-training、post-training。
2. 再看不同模型公开了多少数据细节，为什么公开程度差异这么大。
3. 之后按数据类型梳理主流语料：网页、书籍、百科、代码、论文、对话、合成数据。
4. 最后讨论版权、许可协议和 fair use 这些绕不开的法律问题。

讲者对“data is the most important thing”这个判断非常强。理由并不是抽象口号，而是现实中的工程分工：架构往往由小团队定义，数据工作却是高度并行、长期、需要大量人工和自动化协作的系统性工作。模型做大之后，数据质量、覆盖面和过滤策略会直接决定你能不能把算力用在刀刃上。

1.1 为什么公司对数据这么保密

公开模型的论文通常会详细讲结构、训练流程和损失函数，但对数据只给出很粗粒度的描述。原因大致有两个：

- **竞争原因**：数据配方本身就是产品竞争力的一部分。
- **法律风险**：版权、隐私、条款违约都可能带来诉讼。

这也解释了为什么“公开权重”并不等于“公开数据”。前者解决的是模型可用性，后者涉及的是数据供应链和合规问题。

2 训练阶段与术语

数据工作通常不止一阶段。比较清晰的划分是：

阶段	目标	典型数据
Pre-training	学到语言分布与通用知识	大规模原始网页、书籍、百科、代码、论文
Mid-training	纠偏和补强某些能力	更高质量的网页、数学、代码、长上下文、合成任务
Post-training	对齐成可对话、可指令跟随的模型	指令数据、聊天数据、偏好数据、RL 数据

表 1: 语言模型常见训练阶段

这里的一个实用术语是：

Base model 与 Instruct model

Base model 通常指 pre-training 加上 mid-training 后的检查点。

Instruct/chat model 通常指 post-training 后的模型，也就是能更自然地跟人对话的版本。

讲者强调，阶段边界在现实里并不总是严格清晰。很多新模型会在训练流程里插入更多子阶段，但基本方向都一样：先用大规模低质量数据打底，再用更小规模高质量数据修正和对齐。

3 公开数据配方的典型例子

3.1 OLMo / AI2 的公开路径

一个很重要的对照组是 AI2 的开放模型路线。它们在论文里会更明确地展示训练数据混合方式，因此我们能够看到 pre-training、mid-training 和 post-training 各自大概在用什么：

- **Pre-training**: 网页、代码、学术论文、数学、Wikipedia 等混合，规模很大。
- **Mid-training**: 从大规模网页里筛到更高质量的子集，并加入 FLAN 类数据和合成数据。
- **Post-training**: 以对话和指令数据为主，外加合成生成的数据。

这类公开配方的价值在于，它让我们能把“模型效果”拆成“数据选择”的结果，而不是只看最终指标。

3.2 典型混合的结构

阶段	常见来源	讲者强调的特点
Pre-training	Web pages, code, papers, math, Wikipedia	覆盖广、噪声大、体量最大
Mid-training	过滤后的网页、FLAN、GSM8K、synthetic data	质量更高，面向具体能力
Post-training	chat logs, instruction data, preference data	让模型“像助手”而不是“像语料库”

表 2: 从粗到细的数据混合

讲者还特别点到，很多所谓“看起来像模型能力”的东西，实际上是在数据阶段被提前塑形的：数学、代码、长上下文、安全拒答、对话风格，都可以通过数据设计明显影响。

4 预训练语料：从 Wikipedia 到 Common Crawl

4.1 BERT 的数据

一个早期但典型的例子是 BERT。它的训练数据由两部分构成：

- **BooksCorpus**: 来自 Smashwords 的自出版电子书，规模约 7 千本、接近 10 亿词。

- **Wikipedia**: 自由编辑的百科全书，提供相对高质量的通用文本。

这个组合说明了早期预训练数据的思路：先找高质量、结构化、可长期复用的文本，再把它们拼成足够大的训练集。

4.2 GPT-2 与 OpenWebText

GPT-2 的 WebText 思路很有代表性：从 Reddit 中高 karma 帖子的外链网页出发，用“人类实际愿意转发什么”作为粗糙的质量代理。开源复现版本 OpenWebText 进一步通过 URL 抽取、英文过滤和去重来构建类似数据集。

这类数据集有一个共同点：它们不是“干净数据”，而是“经过一系列启发式筛选后，尽可能接近人类偏好分布”的网页文本。

4.3 Common Crawl 及其后续处理

Common Crawl 是整个网页语料生态的底层原料。它每月左右进行一次大规模网络爬取，产物通常经历 WARC 到 WET 再到可训练纯文本的多级转换。讲者特别强调，HTML 到文本的转换并不是无关紧要的前处理，转换策略会显著影响下游效果。

网页语料的三个现实问题

1. 网页噪声非常大，绝大多数内容不是训练语言模型的好材料。
2. 相同内容会以很多近重复版本出现，必须做去重。
3. 语言识别和质量过滤通常依赖启发式或分类器，而不是“直接相信网页”。

4.4 CCNet、C4 与 GPT-3

在 Common Crawl 之上，各种后续数据集做了不同程度的清洗：

- **CCNet**: 做去重、语言识别和质量过滤，尤其关注低资源语言。
- **C4**: T5 相关数据集，使用大量规则清洗 Common Crawl，输出大规模可训练文本。
- **GPT-3 数据**: Common Crawl、WebText2、Books1/Books2、Wikipedia 的组合，约 570GB、4000 亿 token 级别。

这些例子说明了一个趋势：数据处理越往后越强调过滤、去重和配比，而不是“收集越多越好”。

4.5 The Pile 与开放社区

The Pile 是开源模型生态的重要里程碑。它把很多不同来源的高质量文本放在一起，包括书籍、论文、代码、百科、问答和其他领域文本。它的意义不只在规模，也在于它把“数据配方”变成了社区可讨论、可复现实验的问题。

5 更系统的数据工程：Gopher、LLaMA、RefinedWeb、Dolma、DCLM

5.1 Gopher 的 MassiveText

Gopher 使用的 MassiveText 展示了一个更工程化的配方：在 MassiveWeb、C4、Books、News、GitHub、Wikipedia 等来源上做拼接和过滤。讲者给出的重点不是某个单一来源，而是这种“混合 + 规则过滤 + 质量筛选”的整体范式。

5.2 LLaMA 与 RedPajama

LLaMA 的公开数据配方更加系统，包含 Common Crawl、C4、GitHub、Wikipedia、Project Gutenberg、Books3、arXiv 和 Stack Exchange 等来源。后续社区复现的 RedPajama 和 SlimPajama 则进一步强调了可复现、可去重和子集精炼。

5.3 RefinedWeb 与 FineWeb

RefinedWeb 的口号很直接：网页数据本身就足够强，关键在处理方式。它强调：

- 用更稳健的 HTML-to-text 工具提取正文。
- 采用基于规则的过滤，减少模型偏置。
- 用 MinHash 做模糊去重。

FineWeb 在此基础上进一步改进，加入更大规模的 Common Crawl snapshot、更系统的语言识别和隐私清理，形成更现代的高质量网页语料。

5.4 Dolma、DataComp-LM 与 Nemotron-CC

这三类数据集反映了更近一代的数据思路：

- **Dolma**：把 Reddit、学术论文、Wikipedia、C4、Project Gutenberg 等多种来源组合起来，强调来源多样性。
- **DataComp-LM**：尝试为数据处理方法建立统一基准，尤其关注模型式过滤的可比较性。
- **Nemotron-CC**：继续追求规模，同时尝试通过分类器集成和合成数据重写，在保留质量的同时扩大有效 token 数。

数据集	关键动作	讲者强调的意义
MassiveText	规则过滤 + 多源混合	说明网页不是单一语料，而是可被工程化利用的资源
LLaMA data RefinedWeb FineWeb	多语种、多来源、手工规则 MinHash、语言识别、PII 处理	开源模型需要更明确的数据公开 网页数据仍然可以继续改进
Dolma	多域聚合	来源多样性很重要
DCLM	统一的处理基准	数据处理方法本身应成为研究对象
Nemotron-CC	分类器集成 + 合成重写	质量和规模可以同时追求

表 3: 几类代表性数据工程路线

6 长上下文、任务化数据与指令数据

6.1 长上下文

模型想要做书本级问答、长文档总结或多轮推理，就需要更长的上下文窗口。但 Transformer 的注意力代价对序列长度是二次增长，因此讲者认为不应在 pre-training 阶段就一开始全都用长上下文，而更适合在后期单独扩展。

LongLoRA 是一个典型思路：把 LLaMA2 7B 的上下文从 4K 扩到 100K，并借助 shifted sparse attention 与 positional interpolation，让长上下文训练更现实。

6.2 任务数据

另一条路线是把现有 NLP 数据集转成指令式 prompt：

- **Super-Natural Instructions**：大量任务模板，强调将原始任务转成统一 prompt 形式。
- **FLAN**：把多种任务改写成 zero-shot、few-shot 和 CoT 版本，进一步提高模型泛化。

这类数据的核心不是“新知识”，而是“如何把已有监督数据变成更容易迁移的训练格式”。

6.3 指令跟随与聊天数据

讲者把大量篇幅放在 open-ended instruction/chat 数据上，因为这是现代助手模型最关键的 post-training 来源之一。

- **Alpaca**：用 self-instruct 从 text-davinci-003 生成 52K 级别数据。
- **Vicuna**：使用 ShareGPT 中的真实聊天记录。
- **Baize**：用 self-chat 生成对话，并以上下文种子扩大覆盖。
- **WizardLM**：通过 Evol-Instruct 让问题更难、更广。
- **MAmmoTH2**：面向数学能力的数据构造，强调从 Common Crawl 中抽取高价值问答。
- **OpenHermes 2.5**：把多个来源的数据合并成更大的指令混合。

- **Llama 2 chat**: 更高质量、但规模相对较小的人工标注数据。
- **Llama-Nemotron post-training**: 结合真实提示、合成回答和 reasoning traces。

为什么合成数据这么重要

合成数据的价值不只在“便宜”，而在于它能主动覆盖人类日志里不容易出现的能力区域，比如更难数学题、结构化的多步推理、或者特定风格的对话行为。问题不是“要不要合成”，而是“怎么过滤、怎么混合、怎么验证”。

7 版权、许可与 fair use

这一讲后半部分把技术问题拉回现实世界：数据不只是抓取和清洗，还涉及版权法、许可协议和平台条款。

7.1 基本框架

- **版权**保护的是表达，而不是思想本身。
- **许可**本质上是“允许你做某件事而不被起诉”的合同安排。
- **Fair use** 是美国法里判断合理使用的四因素测试。

7.2 Fair use 的四个因素

1. 使用目的和性质：教育、研究、转换性用途更有利。
2. 作品性质：事实性内容通常比纯创作内容更容易被合理使用。
3. 使用量与实质性：用小片段比整部复制更有利。
4. 对市场的影响：是否替代了原作品的市场。

对 foundation model 的现实风险

模型训练会先复制数据到自己的流程里，这本身就可能触发法律争议。即使训练行为具有转换性，语言模型也可能显著影响原作品的市场，尤其是作者、插画师、摄影师和教育内容生产者。

7.3 条款与授权

除了版权，平台条款也会限制数据使用。例如某些内容即使在版权上可用，也可能因为服务条款不允许下载或再分发而不能直接拿来训练。讲者特别强调，模型开发者通常必须同时面对：

- 版权许可，
- 服务条款，
- 隐私要求，
- 数据删除与合规义务。

8 总结

这一讲的结论可以压缩成三句话：

本讲 Takeaways

1. 数据不是自然生成的，必须通过收集、清洗、过滤、去重和重配比来构造。
2. 数据决定的不只是“有没有知识”，还决定模型的能力边界、交互方式和对齐效果。
3. 数据工作里既有大量启发式工程，也有绕不开的法律与伦理问题。

更具体一点说，现代语言模型的数据管线通常遵循一个模式：从原始互联网和用户行为中得到粗糙材料，再通过大规模工程把它们变成可训练、可控、可合规的数据集合。讲者希望传达的不是某个单一配方，而是一个研究和工程视角：**数据本身就是模型设计的一部分。**