成本下降发生在三个层次

模型结构

小模型 / 稀疏激活
混合精度 / MTP

软硬配合

芯片与模型协同
适合任务的执行

资源调度

不同时段与任务
空闲资源用于跑批

单位有效任务成本下降

同时考察：回答效果 · 首包时延 · 生成速度 · 并发