

访谈笔记

杨植麟访谈：K2 模型、Scaling Law 与 Agent 未来

张小[国]商业访谈录 & AI

2026 年 3 月 28 日



视频作者/频道：张小[国]商业访谈录

发布日期：2025 年 7 月

视频时长：约 90 分钟

视频链接：未填写

目录

1 攀登无尽的雪山：AI 创业的心路	2
1.1 从”向延绵而未知的雪山前进”到”Beginning of Infinity”	2
1.2 本章小结	2
2 过去一年全球大模型的范式级变化	2
2.1 第一个范式：强思考的推理模型	2
2.2 第二个范式：Agent 强化学习	3
2.3 Claude vs. OpenAI 的技术路线差异	4
2.4 第三个趋势：模型公司做一方产品	4
2.5 本章小结	4
3 OpenAI L1-L5 分级的再思考	4
3.1 五个层级的含义	4
3.2 本章小结	5
4 K1.5 到 K2：月之暗面的技术演进	5
4.1 K1.5：强化学习技术验证	5
4.2 K2：追求更好的基础模型	5
4.2.1 方向一：Token Efficiency——把每份数据的价值最大化	6
4.2.2 方向二：Agentic 能力与泛化	6
4.3 K2 的研发过程	7
4.4 本章小结	7
5 Agent 的定义与未来	7
5.1 Agent 的两个核心特征	7
5.2 通用性是 Agent 最缺的能力	7
5.3 本章小结	8
6 Scaling Law 与模型架构	8
6.1 预训练 Scaling 的新瓶颈	8
6.2 Muon 优化器：突破 Adam 的 10 年统治	8
6.3 RL Scaling 的发现	8
6.4 本章小结	9
7 模型训练的评估困境	9
7.1 Benchmark 失效与 Agent 泛化	9
7.2 评估困境的根源	9
7.3 本章小结	9
8 一方产品 vs. 第三方生态	10
8.1 两种产品范式	10
8.2 本章小结	10

9 总结与延伸	10
9.1 核心观点梳理	10
9.2 延伸思考	10
9.3 拓展阅读	11

1 攀登无尽的雪山：AI 创业的心路

1.1 从”向延绵而未知的雪山前进”到”Beginning of Infinity”

杨植麟是月之暗面（Moonshot AI）创始人兼 CEO。时隔一年（2025 年 7 月），再次接受访谈时，他用《无穷的开始》（*The Beginning of Infinity*）的哲学来描述自己的感受：

问题不可避免，但问题可以解决

David Deutsch 在《无穷的开始》中提出两句核心命题：

1. 问题是不可避免的（Problems are inevitable）
2. 问题是可以解决的（Problems are soluble）

研发 AI 的过程恰好体现了这一哲学：解决了强化学习的很多问题，就面临评估、验证等新问题；解决了预训练效率问题，又面临 Agent 泛化问题。每次解决一个问题，技术就再攀登几百米，同时看到新的问题。

杨植麟认为，AGI 可能不是某一级台阶，而是一个方向。今天的 AI 在很多领域已经比 99% 的人类做得更好——在某种意义上可以视为部分 AGI。但很难说某个时间点突然达到 AGI，它更像是持续攀登的过程。

雪山可能没有尽头

杨植麟表达了一个乐观的观点：他希望这座雪山一直没有尽头——”所谓的 Beginning of Infinity 就是这个意思，它可能是一座无限的山”。而且到某个阶段，可能不再是人类在爬，而是用 AI 来攀登——比如用 K2 模型来参与模型训练、数据处理相关的工作。AI 正在成为”人类文明的放大器”。

1.2 本章小结

AI 创业是一个持续解决问题、又发现新问题的过程。AGI 不是一个终点，而是一个方向。AI 正在从工具演变为研发过程中的参与者。

2 过去一年全球大模型的范式级变化

2.1 第一个范式：强思考的推理模型

以 O1 为代表的基于强化学习的推理模型（Reasoning Model），是过去一年最重要的技术突破之一。

推理模型的本质：猜想-验证循环

推理模型的核心能力是”反思” (Reflection)，它本质上包含两种能力：

1. **提出猜想**：在解决问题过程中不断提出新的假设
2. **自我验证**：对每个猜想进行隐式的验证，判断对错

通过多次”猜想 → 验证 → 新猜想 → 再验证”的循环，模型可以将 Pass@2 的问题变成 Pass@1——本质上是等价地尝试了多次。这与人类做科研、解题的过程非常相似。

杨植麟将这种推理模型形象地比喻为”**缸中之脑**”——它不需要与外界交互，只是在自己的大脑中思考，就能通过猜想-验证循环解决问题。

串行 vs. 并行采样

推理模型的有效工作方式主要是串行的——每次猜想基于前一次的结果。虽然也可以搭配并行策略（同时采样多个方案），但最近的研究表明，串行的上限通常更高。这与月之暗面的实验结论一致。

2.2 第二个范式：Agent 强化学习

与推理模型的”缸中之脑”不同，Agent 模型通过多轮交互与外界环境进行互动：

- 边思考边执行操作（搜索、浏览器、写代码等）
- 通过多轮方式解决问题
- 下一步行为取决于外界反馈和状态更新

两种 Test-Time Scaling 的统一

推理模型和 Agent 模型都指向同一个核心概念——**Test-Time Scaling**：

- **推理模型**：Scale 单轮内的思考 Token 数量（更多的内部推理）
- **Agent 模型**：Scale 多轮交互的轮次数量（更多的外部交互）

两者都是在推理时投入更多计算资源来完成更复杂的任务。传统对话模型可能只输出几百个 Token，而推理/Agent 模型可以花费数小时、消耗大量 Token 来完成复杂任务。

2.3 Claude vs. OpenAI 的技术路线差异

Reasoning 和 Agent 不必然是线性依赖

杨植麟指出一个有趣的观察：Claude 的模型在 Reasoning 基准上表现并不突出，但在 Agent 任务上表现非常好。这说明：

- Reasoning 和 Agent 对应两种不同的 Test-Time Scaling 维度
- 两者在研发上不是必然的先后顺序
- 但要达到 Agent 的最高水平，最终仍需要很强的 Reasoning 能力

Claude 可能更多投入在 Agent（多轮交互）方向，OpenAI 更多投入在 Reasoning（深度思考）方向。不同的技术路径会导致短期产品差异，但长期来看两者都不可或缺。

2.4 第三个趋势：模型公司做一方产品

正向设计 vs. 逆向工程

杨植麟区分了两种产品开发方式：

- **第三方逆向工程**：基于现有基础模型，通过设计框架、工具、System Prompt 来逆向工程模型的训练过程，找到最佳的使用方式（如 Manus 等）
- **一方正向设计**：模型公司先设计好工具和 Context Engineering 方法，然后在这个环境中训练模型，使模型天然在自己的环境中表现最好（如 Claude Code、ChatGPT Agent）

第二种方式的上限可能更高，因为可以更好地整合工具和模型，端到端地做训练。

2.5 本章小结

过去一年的三大范式级变化：(1) 推理模型（缸中之脑式的猜想-验证循环），(2) Agent 模型（与外界多轮交互），(3) 模型公司做一方产品。推理和 Agent 是两种 Test-Time Scaling 维度，最终需要结合。

3 OpenAI L1-L5 分级的再思考

3.1 五个层级的含义

OpenAI 定义了 AI 能力的五个层级：L1 ChatBot → L2 Reasoning → L3 Agent → L4 Innovation → L5 Organization。

层级之间不是线性关系

杨植麟对 L1-L5 的关键洞察：

1. 这五个层级并不完全是串行的——有些能力是并行发展的
2. Agent 的上限取决于 Reasoning 能力，但 Agent 不必等 Reasoning 完全成熟才能开始
3. Innovation 的标志是”模型参与模型开发”——比如 K2 参与 K3 的开发
4. Organization 的雏形已经出现——Multi-Agent 系统中不同 Agent 承担不同角色

用 L4 的技术解决 L3 的问题

一个有趣的循环依赖：要解决 Agent 泛化问题 (L3)，可能需要 Innovation (L4) 的技术——即用 AI 来训练和对齐 AI。这说明这些层级之间存在复杂的交互关系，而非简单的顺序依赖。

3.2 本章小结

L1-L5 是几个重要的技术里程碑，但并非严格的线性关系。Reasoning 和 Agent 是 Innovation 和 Organization 的前提，但它们之间存在复杂的相互依赖。每个层级的能力都会持续提升，没有明确的”封顶”。

4 K1.5 到 K2：月之暗面的技术演进

4.1 K1.5：强化学习技术验证

K1.5 主要是强化学习技术路线的验证——月之暗面是较早在这条路线上投入的团队。关键发现：

端到端 Reward 胜过 Process Reward

K1.5 的重要技术发现：不太需要 Process Reward Model (PRM) 或 Value Function。直接使用端到端的 Reward 就可以把训练做得非常好。Process Reward 在训练过程中甚至可能有副作用。这在早期并不是非常明确的结论。

4.2 K2：追求更好的基础模型

K2 的设计目标有两个核心方向：

4.2.1 方向一：Token Efficiency——把每份数据的价值最大化

为什么 Token Efficiency 比 Compute Efficiency 更重要

高质量数据的增长非常缓慢——可以近似看作一个常数（如 30T 高质量 Token）。在这个约束下：

- **Compute Efficiency** (训练更快)：虽然有价值，但不能提升智能上限——你只是更快地训练完同样的数据
- **Token Efficiency** (学得更好)：同样的数据，模型吸收得更多、压缩率更高、loss 降得更快——直接提升智能上限

月之暗面通过三种方式提升 Token Efficiency：

1. **Muon 优化器**：基于矩阵正交化的新优化器，取代使用了 10 年的 Adam。在 Compute Optimal 条件下，Token Efficiency 提升约 2 倍——等于学 1 份数据相当于 Adam 学 2 份
2. **更大的稀疏度**：通过更大的稀疏度加入更多参数，参数越多，同样数据的吸收效果越好
3. **数据 Rephrase**：对高质量数据进行改写，使同一份数据以不同形式被多次学习，提升泛化性

Muon 优化器的技术背景

Muon 优化器由 Keller 提出，核心思想是不把矩阵中的每个参数元素独立考虑（如 Adam 那样），而是考虑参数之间的依赖关系（dependency），通过矩阵正交化的方式实现更高效的学习。

月之暗面的贡献是将 Muon 在大规模语言模型上实际落地。早期通过 Moonlight 项目首次在一定规模的语言模型上验证，后续进一步 Scale 时发现新问题（如 MaxLogit 爆炸），通过提出新的 Clipping 方式解决。

数据改写不等于简单复制

单纯重复学习同一份数据会导致过拟合和泛化问题。改写的关键是引入“新的熵”——使改写后的数据在保留核心知识的同时具有一定的多样性，从而提升泛化能力。但改写方式的选择至关重要，如何引入新的信息熵仍是活跃的研究方向。

4.2.2 方向二：Agentic 能力与泛化

Agent 泛化是当前最大挑战

对于 Agentic 模型，当前最大的挑战是**泛化**：

- 现有 RL 技术的局限：训练任务和评价指标往往是单点的（如只训练 SWE-Bench）
- 指标提升不代表泛化提升：SWE-Bench 分数提高，不意味着模型在其他代码任务上也好
- Agent 的泛化问题比对话模型更严重
- Benchmark 不够用或已失效

杨植麟认为可能的解法是”用 AI 训练 AI”：让模型参与到自身的训练和对齐过程中，用更 AI-Native 的方式提升泛化性。

4.3 K2 的研发过程

- 技术积累从一年前开始（Muon 优化器等技术需要长周期的 Scaling 实验验证）
- K2 本身的训练周期并不长，但前置的技术准备需要大量时间
- 遇到的主要挑战：Muon 优化器在大规模训练时出现 MaxLogit 爆炸问题（小规模实验中无法复现）
- 研究团队和训练团队是同一个团队——因为训练中的问题需要深入理解底层技术才能解决

4.4 本章小结

K1.5 验证了端到端 Reward 的强化学习路线。K2 聚焦两个方向：(1) Token Efficiency（Muon 优化器 + 稀疏度 + 数据改写），(2) Agentic 泛化能力。Agent 泛化是当前最大瓶颈，可能需要用 AI 训练 AI 来突破。

5 Agent 的定义与未来

5.1 Agent 的两个核心特征

Agent

杨植麟对 Agent 的定义简洁而本质：

1. **多轮** (Multi-turn)：可以进行多次交互，这是 Test-Time Scaling 的一种方式，使模型能完成复杂任务
2. **工具** (Tool Use)：连接大脑与外部世界的方式——搜索引擎连接互联网，代码能力连接数字世界的一切自动化

5.2 通用性是 Agent 最缺的能力

从通用 Agent 到垂直应用

如果 Agent 有足够好的泛化能力，就不需要大量的垂直 Agent：

- 通用 Agent 只需接入不同的工具（定制数据库、定制 API、定制文档接口等），就能完成垂直领域任务
- 但当前 Agent 最缺的正是这种泛化能力——能否泛化到训练中没有见过的工具和环境
- Benchmark 过拟合是一个风险：刷几个 Benchmark 的分数，不代表真实场景的泛化能力

Agent 的目的不是模拟人

杨植麟指出一个重要的区分：Agent 的目的是通用 (General Purpose)，而不是模拟人。人类也是通用的 (Universal Constructor)，Agent 的行为方式与人类相似只是一个巧合结果——就像飞机的设计目的是交通工具，不是为了像鸟一样飞。

5.3 本章小结

Agent 的两个核心特征是多轮交互和工具使用。当前最大挑战是泛化能力——能否在没见过的工具和环境上表现良好。Agent 的目标是通用智能，不是模拟人类行为。

6 Scaling Law 与模型架构

6.1 预训练 Scaling 的新瓶颈

高质量数据接近常数

高质量训练数据的增长速度远慢于算力增长：

- 高质量文本数据量可以近似看作常数
- 多模态数据无法有效提升文本的“智商”
- 这使得 Token Efficiency 成为比 Compute Efficiency 更重要的优化方向

6.2 Muon 优化器：突破 Adam 的 10 年统治

Adam 优化器统治了深度学习训练领域近 10 年。Muon 优化器通过考虑参数之间的矩阵结构依赖关系，实现了约 2 倍的 Token Efficiency 提升：

- Adam：独立考虑每个参数元素，忽略参数间的结构关系
- Muon：考虑矩阵参数间的 dependency，通过正交化方式优化
- 效果：30T 高质量 Token 的学习效果等价于 Adam 学习 60T Token

6.3 RL Scaling 的发现

强化学习中的 Curriculum 设计

在 Agent 训练中，不能一上来就让模型解决最难的任务（如证明未解数学猜想），否则 Sample Efficiency 极低。更好的方式是：

- 使用中等难度的任务进行训练
- 逐步提升难度（爬山过程）
- 搭配好的 Sampling 策略

这本质上是一个 Curriculum Learning 的过程。

6.4 本章小结

预训练 Scaling 的新瓶颈是高质量数据的有限性。Muon 优化器通过矩阵正交化突破 Adam 的 10 年统治, 实现 2 倍 Token Efficiency 提升。RL 训练需要 Curriculum 设计来保证 Sample Efficiency。

7 模型训练的评估困境

7.1 Benchmark 失效与 Agent 泛化

Benchmark 过拟合的风险

当前 Agent 领域面临严重的评估问题:

- 可用的 Agent Benchmark 数量有限
- 刷高 Benchmark 分数不代表真实能力——很多时候是对特定任务的过拟合
- 用户在 OOD (Out-of-Distribution) 场景的体感与 Benchmark 分数脱节
- ”种瓜得瓜、种豆得豆”——训练什么就提升什么, 但泛化有限

7.2 评估困境的根源

杨植麟认为, 评估困境的根源是:

1. 强化学习最终依赖于好的评估/验证——数学题和有 Test Case 的编程可以自动验证, 但复杂的端到端任务很难找到好的评估方式
2. 模型能力提升带来的新问题: 任务复杂度增加, 评估方式需要跟上
3. Agent 任务的长尾分布特性: 难以覆盖所有真实场景

7.3 本章小结

Benchmark 失效和 Agent 泛化不足是当前最突出的评估困境。根源在于复杂任务难以自动验证, 以及训练分布与真实使用场景之间的 Gap。用 AI 参与评估和训练 (AI 训练 AI) 可能是突破方向。

8 一方产品 vs. 第三方生态

8.1 两种产品范式

模型公司做一方产品的逻辑

- **第三方范式**：给定一个模型，逆向工程最佳的使用方式（System Prompt、工具设计、Context Engineering），本质是去拟合模型的训练分布
- **一方范式**：先设计好工具和环境，然后在这个环境中训练模型。模型天然在自己的环境中表现最好，无需逆向工程

Cloud Code 和 ChatGPT Agent 都是一方产品的代表。月之暗面目前仍以模型为主线，但认为一方产品将是重要趋势。

8.2 本章小结

一方产品通过正向设计环境 + 训练模型，上限更高；第三方产品通过逆向工程模型使用方式，灵活但受限于模型训练分布。未来两种范式将共存互补。

9 总结与延伸

9.1 核心观点梳理

杨植麟访谈的核心要点

1. **AI 是一座无尽的雪山**：问题不可避免，但问题可以解决。每解决一个问题就攀登几百米，同时发现新问题
2. **两种 Test-Time Scaling**：推理模型（缸中之脑，Scale 思考 Token）和 Agent（与世界交互，Scale 轮次）
3. **Token Efficiency 比 Compute Efficiency 重要**：高质量数据是瓶颈，Muon 优化器实现 2 倍提升
4. **Agent 泛化是最大挑战**：Benchmark 过拟合严重，可能需要 AI 训练 AI 来突破
5. **AGI 是方向不是终点**：不会有某一刻突然达到 AGI，而是各项能力持续提升
6. **一方产品趋势**：模型公司正向设计环境 + 训练模型，上限更高

9.2 延伸思考

- **AI 的自我改进**：当 K2 能参与 K3 的开发时，会形成怎样的加速循环？
- **评估范式革新**：如何设计不会被过拟合的 Agent 评估方法？
- **数据瓶颈突破**：除了改写和合成，还有哪些提升 Token Efficiency 的路径？
- **通用 Agent 的门槛**：Agent 需要多强的泛化能力才能真正替代垂直解决方案？

9.3 拓展阅读

- K2 技术报告（月之暗面官方发布）
- David Deutsch, *The Beginning of Infinity*
- Moonlight: 大规模语言模型上的 Muon 优化器
- OpenAI L1-L5 分级体系
- Claude Code 与 ChatGPT Agent 的一方产品设计