

课程笔记

KAIST CS492D Lecture 4: Score-Based Models

基于 Minhyuk Sung 授课内容整理

2025 年秋季

CS492C: Diffusion and Flow Models

Score-Based Models

LECTURE 5
MINHYUK SUNG

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Minhyuk Sung (KAIST)

发布日期: 2025

视频时长: 57 分钟

视频链接: <https://www.youtube.com/watch?v=AG4qcza52yo>

目录

1 DDPM 回顾	2
1.1 扩散模型的基本框架	2
1.2 前向跳跃分布与训练	2
1.3 三种预测目标	2
1.4 生成模型的必要性	3
1.5 本章小结	3
2 Score Function 的定义与性质	3
2.1 Score Function 的定义	3
2.2 高斯分布的 Score Function	4
2.3 从条件 Score 到边缘 Score	5
2.4 本章小结	5
3 Tweedie's Formula	5
3.1 公式陈述与直觉	5
3.2 简单高斯案例验证	6
3.3 在扩散模型中的应用	6
3.4 本章小结	7
4 Langevin Dynamics: 基于 Score 的采样	7
4.1 核心思想	7
4.2 Langevin Dynamics 的关键性质	8
4.3 本章小结	8
5 Score Matching: 学习 Score Function	9
5.1 问题设定	9
5.2 Denoising Score Matching	9
5.3 与 DDPM 训练的等价性	10
5.4 本章小结	10
6 Noise-Conditioned Score Networks (NCSN)	10
6.1 低密度区域的 Score 估计问题	10
6.2 多尺度噪声的解决方案	11
6.3 退火 Langevin Dynamics	11
6.4 与扩散模型逆向过程的联系	12
6.5 本章小结	12
7 Score-Based Models 与 DDPM 的统一视角	12
7.1 两条研究路径的汇合	12
7.2 等价关系的数学总结	13
7.3 本章小结	13

8 总结与延伸	13
8.1 核心要点回顾	13
8.2 拓展阅读	14

1 DDPM 回顾

本节课的主题是 Score-Based Models（基于分数的模型），但在展开新内容之前，讲者首先回顾了上节课介绍的 DDPM（Denoising Diffusion Probabilistic Models）的核心思想，为后续理解 score function 与扩散模型之间的深层联系打下基础。

1.1 扩散模型的基本框架

扩散模型的基本思路是将数据的生成过程定义为一个**序列化的过程** (sequential process)。与传统的 VAE 等模型只有单一隐变量不同，扩散模型将数据点 x_0 逐步映射到一系列隐变量 $x_1, x_2, \dots, x_T$ ，使得最终的隐变量 x_T 服从一个已知的分布（通常是标准高斯分布）。生成过程则是这个前向过程的逆过程：从标准高斯样本 x_T 出发，逐步还原到数据点 x_0 。

扩散模型的两个关键特征

1. **马尔可夫性**：前向过程中 x_t 的采样仅依赖于 x_{t-1} ，逆向过程中 x_{t-1} 的采样仅依赖于 x_t 。
2. **高斯前向转移**：前向转移分布被定义为特定形式的高斯分布，由参数 β_t 控制：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

1.2 前向跳跃分布与训练

由于前向转移分布是带有线性均值的高斯分布，我们可以推导出**前向跳跃分布** (forward jump distribution) 的解析形式，即直接从 x_0 采样任意中间时刻 x_t 的分布：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ 。这意味着在训练时我们不需要逐步运行前向过程，可以直接“跳跃”采样 x_t 。

前向跳跃 vs. 逆向跳跃

在前向过程中，由于转移分布的均值是条件变量的线性函数，多步高斯分布的复合仍然是高斯分布，因此可以得到闭式的跳跃分布。但在逆向过程中，由于逆向转移分布的均值是神经网络输出的**非线性函数**，多步迭代的复合分布**不再是高斯分布**，因此逆向过程不能跳过中间步骤，必须逐步迭代采样。

1.3 三种预测目标

DDPM 框架中，训练神经网络有三种等价的预测目标：

1. **均值预测器** (Mean Predictor)：直接预测逆向转移分布的均值 $\mu_\theta(x_t, t)$ 。
2. **干净样本预测器** (Clean Sample Predictor / x_0 -prediction)：预测给定 x_t 时原始数据点 x_0 的期望值 $\hat{x}_\theta(x_t, t) \approx \mathbb{E}[x_0 | x_t]$ 。
3. **噪声预测器** (Noise Predictor / ϵ -prediction)：预测从 x_0 采样 x_t 时使用的标准高斯噪声 $\epsilon_\theta(x_t, t) \approx \mathbb{E}[\epsilon_t | x_t]$ 。

三种预测器之间的等价关系

已知 $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon_t$ ，其中 $\epsilon_t \sim \mathcal{N}(0, I)$ ，则从任一预测器的输出都可以计算出其他两个的值，三者只是参数化方式不同。最终的训练损失在去掉时间步权重后都可以简化为形如 $\|f_\theta(x_t, t) - f_{\text{target}}\|^2$ 的简单 L2 损失。

无论选择哪种预测目标，DDPM 的训练过程都是：采样 $x_0 \sim p_{\text{data}}$ ，采样 $t \sim \text{Uniform}(1, T)$ ，采样 $\epsilon \sim \mathcal{N}(0, I)$ ，计算 $x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$ ，然后最小化对应的 L2 损失。

1.4 生成模型的必要性

讲者提出了一个发人深省的问题：如果我们已经拥有 50 亿张图片的数据集，为什么还需要生成模型？为什么不直接从中采样一张？

生成模型相比直接检索的优势

1. **压缩**：一个预训练的扩散模型可能只有数百 MB，却编码了数十亿张图片中的分布信息，压缩比极高。
2. **新颖性与多样性**：生成模型能产生全新的、数据集中不存在的图片，而非简单复制。
3. **隐私保护**：生成模型有可能（虽然无法完全保证）不直接输出训练数据中的原始图片，在一定程度上保护数据隐私。
4. **条件生成**：生成模型可以根据输入条件（如文本描述）生成与条件对齐的新数据，这是简单检索难以做到的。

隐私保护并非绝对

讲者明确指出，扩散模型**不能保证**不生成训练数据中的原始图片。实际上已有研究表明，某些预训练模型确实会生成几乎可在互联网上搜索到的图片。因此，隐私保护只是“潜力”，而非“保证”。

1.5 本章小结

DDPM 通过定义高斯马尔可夫前向过程和可学习的逆向过程，将复杂的数据分布建模问题转化为简单的去噪任务。前向跳跃分布的闭式解使训练高效，三种等价的预测目标为实现提供了灵活性。但噪声预测器 (ϵ -prediction) 的**物理含义**是什么？这正是本节课 Score-Based Models 要回答的核心问题。

2 Score Function 的定义与性质

2.1 Score Function 的定义

Score function（分数函数）在统计学中有精确的定义，它是概率密度函数对数的梯度：

Score Function 的定义

给定概率密度函数 $p(x)$ ，其 score function 定义为：

$$s(x) = \nabla_x \log p(x)$$

其中 ∇_x 表示关于数据点 x 的梯度（而非关于模型参数的梯度）。

需要特别注意的是，这里的“score”不是通常意义上的“分数”，而是一个在统计学中有特定含义的术语。Score function 是一个向量场——对于每一个数据空间中的点 x ，它给出一个与 x 同维度的向量，指向使对数概率增大最快的方向。

Score Function 的直观理解

Score function $\nabla_x \log p(x)$ 可以理解为一个“指导方向”：

- 在高概率密度区域附近，score 的大小较小（因为已接近“山顶”）。
- 在低概率密度区域，score 指向高概率密度区域的方向。
- score 为零的点对应概率密度的极值点。

直观地说，score function 告诉我们“应该往哪个方向走，才能到达概率更高的地方”。

2.2 高斯分布的 Score Function

为了建立直觉，我们来计算高斯分布的 score function。对于条件分布（即前向跳跃分布）：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$$

其 score function 为：

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{1 - \bar{\alpha}_t}$$

这个推导很直接：先写出高斯分布的概率密度函数，取对数后只保留与 x_t 相关的项（即二次型项），然后对 x_t 求梯度即可。

噪声预测与 Score Function 的关系

回顾 $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t$ ，可以得到：

$$\epsilon_t = \frac{x_t - \sqrt{\bar{\alpha}_t} x_0}{\sqrt{1 - \bar{\alpha}_t}}$$

因此：

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{\epsilon_t}{\sqrt{1 - \bar{\alpha}_t}}$$

即 DDPM 中的噪声预测器所预测的 ϵ_t ，与条件 score function 之间只差一个缩放因子！噪声预测的物理意义就是在学习 score function（up to scale）。

这个发现揭示了 DDPM 噪声预测器的深层含义：表面上我们在“预测噪声”，实际上我们在学习前向跳跃分布的 score function。

2.3 从条件 Score 到边缘 Score

上面我们讨论的是条件分布 $q(x_t | x_0)$ 的 score function，因为我们知道 x_0 。但在生成过程中，我们并不知道 x_0 ，我们真正需要的是边缘分布 $q(x_t)$ 的 score function：

$$\nabla_{x_t} \log q(x_t) = ?$$

其中 $q(x_t) = \int q(x_t | x_0) q(x_0) dx_0$ 。由于 $q(x_0)$ （真实数据分布）通常未知且复杂， $q(x_t)$ 一般没有解析形式。

然而，通过数学推导可以证明：

$$\nabla_{x_t} \log q(x_t) = \mathbb{E}_{q(x_0|x_t)} [\nabla_{x_t} \log q(x_t | x_0)]$$

边缘 Score 是条件 Score 的后验期望

边缘分布的 score function 等于条件 score function 在后验分布 $q(x_0 | x_t)$ 下的期望。这意味着我们训练的噪声预测网络 $\epsilon_\theta(x_t, t)$ 实际上是在学习对所有可能的 x_0 取后验平均的 score function。

2.4 本章小结

Score function 定义为对数概率密度的梯度，它编码了关于概率分布的完整信息。高斯分布的 score function 有简洁的闭式解，而 DDPM 中的噪声预测器本质上是在学习前向跳跃分布的 score function（差一个缩放因子）。边缘分布的 score 等于条件 score 在后验下的期望，这为理解扩散模型中神经网络的学习目标提供了严格的数学解释。

3 Tweedie's Formula

3.1 公式陈述与直觉

Tweedie's formula 是理解 score function 与扩散模型联系的关键数学工具。它回答了这样一个问题：如果我们知道边缘分布 $p(x)$ 和似然分布 $p(x | \mu)$ ，能否从观测 x 推断出隐变量 μ 的期望？

Tweedie's Formula

考虑以下生成过程：先从先验分布 $p(\mu)$ 采样均值 μ ，然后从似然分布 $p(x | \mu) = \mathcal{N}(x; \mu, \sigma^2 I)$ 采样观测 x 。令边缘分布为 $p(x) = \int p(x | \mu) p(\mu) d\mu$ ，则后验均值为：

$$\mathbb{E}[\mu | x] = x + \sigma^2 \nabla_x \log p(x)$$

Tweedie's Formula 的直觉

这个公式有非常优美的直觉解释：

- 如果我们只知道观测 x 而没有其他信息，对 μ 的最朴素估计就是 x 本身。
- 但 score function $\nabla_x \log p(x)$ 提供了一个“修正方向”：它指向高概率密度区域。
- Tweedie's formula 告诉我们，最优的后验均值估计就是在朴素估计 x 的基础上，沿着 score 方向做一步校正，校正幅度与噪声方差 σ^2 成正比。

3.2 简单高斯案例验证

讲者用一个简单的例子来验证 Tweedie's formula 的正确性和直觉：

设 $p(\mu) = \mathcal{N}(0, 1)$, $p(x | \mu) = \mathcal{N}(x; \mu, \sigma^2)$ 。由高斯分布的性质（先验和似然都是高斯时，边缘分布也是高斯），可得：

$$p(x) = \mathcal{N}(0, 1 + \sigma^2)$$

因此 score function 为：

$$\nabla_x \log p(x) = -\frac{x}{1 + \sigma^2}$$

代入 Tweedie's formula：

$$\mathbb{E}[\mu | x] = x + \sigma^2 \cdot \left(-\frac{x}{1 + \sigma^2}\right) = x \cdot \frac{1}{1 + \sigma^2}$$

直觉验证：收缩估计

结果 $\mathbb{E}[\mu | x] = \frac{x}{1 + \sigma^2}$ 具有“收缩”（shrinkage）效应：

- 当 $x > 0$ 时， $\mathbb{E}[\mu | x] < x$ ：估计的均值比观测值更靠近零（先验均值的方向）。
- 当 $x < 0$ 时， $\mathbb{E}[\mu | x] > x$ ：同理，向零的方向收缩。
- σ^2 越大（噪声越大），收缩越强：在高噪声下，我们更信任先验。
- $\sigma^2 \rightarrow 0$ 时， $\mathbb{E}[\mu | x] \rightarrow x$ ：噪声消失时，观测本身就是最好的估计。

这完全符合贝叶斯推断的直觉。

3.3 在扩散模型中的应用

将 Tweedie's formula 应用到扩散模型的前向跳跃分布 $q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I)$ ，其中“均值”角色由 $\sqrt{\bar{\alpha}_t} x_0$ 扮演，“方差”为 $\sigma_t^2 = 1 - \bar{\alpha}_t$ ，可以得到：

$$\mathbb{E}[\sqrt{\bar{\alpha}_t} x_0 | x_t] = x_t + (1 - \bar{\alpha}_t) \nabla_{x_t} \log q(x_t)$$

整理后：

Tweedie's Formula 在扩散模型中的形式

$$\mathbb{E}[x_0 | x_t] = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t + (1 - \bar{\alpha}_t) \nabla_{x_t} \log q(x_t))$$

这表明：知道边缘 score function $\nabla_{x_t} \log q(x_t)$ 就等价于知道在给定 x_t 下 x_0 的最优估计。Score function 包含了“去噪”所需的全部信息。

条件 Score 与边缘 Score 的区别

这里出现的 $\nabla_{x_t} \log q(x_t)$ 是**边缘**分布的 score，而非条件分布 $q(x_t | x_0)$ 的 score。条件 score 可以直接用高斯分布公式计算，但边缘 score 需要对所有可能的 x_0 做积分平均。在训练时，神经网络通过大量样本的平均来隐式学习边缘 score。

3.4 本章小结

Tweedie's formula 在“观测即均值加噪声”的模型中，给出了后验均值的优雅闭式解：只需在观测值上加上 score function 方向的校正。在扩散模型中，它将 score function 与去噪操作（从 x_t 恢复 x_0 的期望）紧密联系起来，提供了理解 score-based 方法的关键桥梁。

4 Langevin Dynamics：基于 Score 的采样

4.1 核心思想

前面我们建立了 score function 的概念，并看到它编码了关于概率分布的丰富信息。现在的关键问题是：如果我们知道某个分布的 score function，能否从该分布中采样？

答案是肯定的，Langevin dynamics（朗之万动力学）正是实现这一目标的方法。它源自统计物理学，核心思想是：通过 score function 引导的迭代过程，可以从**任意初始分布**出发，最终收敛到目标分布。

Langevin Dynamics 采样过程

给定目标分布 $q(x)$ 的 score function $\nabla_x \log q(x)$ ，Langevin dynamics 的迭代更新公式为：

$$x_{k+1} = x_k + \eta \nabla_x \log q(x_k) + \sqrt{2\eta} z_k, \quad z_k \sim \mathcal{N}(0, I)$$

其中 $\eta > 0$ 是步长参数。当 $\eta \rightarrow 0$ 且迭代次数 $K \rightarrow \infty$ 时， x_K 的分布收敛到 $q(x)$ 。

Langevin Dynamics 的三个组成部分

Langevin dynamics 的更新公式由三部分组成：

1. **当前位置** x_k ：粒子的当前状态。
2. **Score 引导** $\eta \nabla_x \log q(x_k)$ ：将粒子推向高概率密度区域的确定性力。
3. **随机噪声** $\sqrt{2\eta} z_k$ ：防止粒子陷入局部极值，确保对目标分布的充分探索。

如果只有 score 引导而没有噪声注入，粒子只会收敛到概率密度的极大值点（模式），而不会形成正确的分布。噪声项的存在确保了最终样本的多样性。

4.2 Langevin Dynamics 的关键性质

Langevin dynamics 有一个非凡的性质：它不需要知道概率密度函数 $q(x)$ 本身，只需要 score function $\nabla_x \log q(x)$ 。

Score Function 足以完全描述分布

Score function $\nabla_x \log q(x)$ 在满足一定正则条件时，唯一确定了概率分布 $q(x)$ (up to normalization constant)。这是因为：

- $\nabla_x \log q(x) = \frac{\nabla_x q(x)}{q(x)}$ ，包含了 $q(x)$ 的局部梯度信息。
- 通过 Langevin dynamics，我们可以从 score function 恢复出采样过程。
- 这也意味着：即使不知道概率密度函数的归一化常数（这在高维空间中通常难以计算），只要知道 score function 就足以进行采样。

在传统的概率模型中，从复杂分布采样通常需要计算累积分布函数的逆（inverse CDF），这在高维空间中几乎不可行。Langevin dynamics 提供了一种替代方案：只需计算对数概率密度对数据点的梯度，然后通过迭代过程即可采样。

Langevin Dynamics 的实践限制

理论上的收敛保证需要步长 $\eta \rightarrow 0$ 和无限次迭代，实践中两者都无法满足。有限步长和有限迭代次数会引入近似误差。此外，在多模态分布中，Langevin dynamics 可能需要很长时间才能在不同模式之间跳转（mixing problem）。

4.3 本章小结

Langevin dynamics 是一种基于 score function 的采样方法，它通过“score 引导 + 随机噪声注入”的迭代过程，可以从任意初始分布出发收敛到目标分布。这个方法的核心优势在于：只需要 score function 而非概率密度函数本身就可以进行采样，从而避免了高维空间中归一化常数难以计算的问题。

5 Score Matching: 学习 Score Function

5.1 问题设定

前面我们看到：(1) score function 完全描述了概率分布；(2) 通过 Langevin dynamics 可以利用 score function 采样。那么关键问题变成了：**如何从数据中学习 score function？**

最直接的想法是定义一个 score 匹配目标：

$$\mathcal{L}_{\text{SM}} = \mathbb{E}_{q(x)} \left[\|s_\theta(x) - \nabla_x \log q(x)\|^2 \right]$$

其中 $s_\theta(x)$ 是我们用神经网络参数化的 score estimator。

直接 Score Matching 的困难

上面的损失函数有一个根本性的问题：它需要知道真实分布 $q(x)$ 的 score function $\nabla_x \log q(x)$ ，而这正是我们要学习的目标。这似乎陷入了“鸡生蛋、蛋生鸡”的循环。

5.2 Denoising Score Matching

解决这个问题的关键洞察是：虽然我们不知道原始数据分布 $q(x)$ 的 score function，但如果我们定义一个**加噪版本**的分布 $q_\sigma(x_t)$ ：

$$q_\sigma(x_t) = \int q(x_t | x_0) q(x_0) dx_0$$

其中 $q(x_t | x_0) = \mathcal{N}(x_t; x_0, \sigma^2 I)$ ，那么**条件 score** $\nabla_{x_t} \log q(x_t | x_0)$ 是已知的：

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{x_t - x_0}{\sigma^2}$$

Denoising Score Matching (DSM) 损失

经过数学推导（省略恒等变换的细节），可以证明 score matching 目标等价于：

$$\mathcal{L}_{\text{DSM}} = \mathbb{E}_{q(x_0)} \mathbb{E}_{q(x_t|x_0)} \left[\|s_\theta(x_t) - \nabla_{x_t} \log q(x_t | x_0)\|^2 \right]$$

由于 $\nabla_{x_t} \log q(x_t | x_0)$ 有闭式解，这个损失是可计算的！

DSM 的训练过程

Denoising Score Matching 的训练步骤极其简单：

1. 采样一个数据点 $x_0 \sim q(x_0)$ （即取一个训练样本）。
2. 采样噪声 $\epsilon \sim \mathcal{N}(0, I)$ ，得到 $x_t = x_0 + \sigma \epsilon$ 。
3. 计算 score 目标 $\nabla_{x_t} \log q(x_t | x_0) = -\epsilon/\sigma$ 。
4. 最小化 $\|s_\theta(x_t) + \epsilon/\sigma\|^2$ 。

可以看到，这与 DDPM 的噪声预测训练在本质上是**完全相同**的。

5.3 与 DDPM 训练的等价性

在 DDPM 中，噪声预测器的训练目标是：

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{x_0, t, \epsilon} \left[\|\epsilon_\theta(x_t, t) - \epsilon\|^2 \right]$$

而在 denoising score matching 中，score 网络的训练目标是：

$$\mathcal{L}_{\text{DSM}} = \mathbb{E}_{x_0, t, \epsilon} \left[\left\| s_\theta(x_t, t) + \frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}} \right\|^2 \right]$$

两者的关系是 $s_\theta(x_t, t) = -\epsilon_\theta(x_t, t)/\sqrt{1 - \bar{\alpha}_t}$ ，即 score 网络和噪声预测网络只差一个与时间步相关的缩放因子。

DDPM 与 Score-Based Models 的统一

DDPM 的噪声预测框架和 score-based 的 score matching 框架是**同一枚硬币的两面**：

- DDPM 视角：训练一个神经网络来预测加在数据上的噪声。
- Score-based 视角：训练一个神经网络来估计加噪数据分布的 score function。
- 两种视角在数学上完全等价，只差一个缩放因子。

5.4 本章小结

Score matching 通过巧妙地将不可计算的边缘 score matching 目标转化为可计算的 denoising score matching 目标，解决了“如何从数据中学习 score function”的问题。这个训练目标与 DDPM 的噪声预测训练在数学上完全等价，从而将两个看似不同的研究方向统一起来。

6 Noise-Conditioned Score Networks (NCSN)

6.1 低密度区域的 Score 估计问题

直接用 score matching 学习原始数据分布 $p_{\text{data}}(x)$ 的 score function 存在一个严重的问题。

低密度区域的 Score 不准确

在多模态分布中，不同模式之间存在**低概率密度区域**（low density regions）。在这些区域：

1. 训练数据极少，因此 score 的估计非常不准确。
2. 然而，Langevin dynamics 的采样起点往往落在这些低密度区域（因为初始分布通常是均匀的或高斯的）。
3. 不准确的 score 会导致采样过程的初始阶段充满噪声，粒子在低密度区域“乱跑”，难以有效到达高密度区域。

讲者通过一个二维分布的动画生动地说明了这个问题：当从均匀分布的采样点出发，如果低密度区域的 score 不准确，粒子在采样初期会做随机运动而非有方向地向高密度区域移动。

6.2 多尺度噪声的解决方案

解决低密度区域 score 不准确问题的核心思想是：对数据添加**不同级别的高斯噪声**，从而“填充”低密度区域。

当噪声方差 σ^2 较大时，加噪后的分布 $q_\sigma(x)$ 变得更加“平滑”：

- 原本的低密度区域被噪声“填充”，不再有近零概率密度的区域。
- Score function 在整个空间上都能被准确估计。
- 但代价是分布变得模糊，丧失了细节信息。

当噪声方差 σ^2 较小时：

- 加噪后的分布更接近原始数据分布，包含精细的结构信息。
- 但低密度区域的 score 仍然不准确。

NCSN 的核心思想：多尺度 Score 学习

NCSN (Noise-Conditioned Score Networks) 的核心思想是同时学习多个噪声级别下的 score function：

$$s_\theta(x, \sigma) \approx \nabla_x \log q_\sigma(x)$$

其中 σ 取一系列递减的值 $\sigma_1 > \sigma_2 > \dots > \sigma_L$ 。网络以 x 和 σ 为输入，输出对应噪声级别下的 score。

6.3 退火 Langevin Dynamics

有了多尺度的 score function，采样时使用**退火 Langevin dynamics** (Annealed Langevin Dynamics)：

退火 Langevin Dynamics 采样算法

1. 从高方差 (σ_1 大，分布模糊) 开始：score 在整个空间上都较准确，引导粒子从初始位置向高密度区域移动。
2. 逐步降低噪声级别 ($\sigma_2, \sigma_3, \dots$)：score 变得越来越精确，引导粒子向真实分布的高密度区域细化。
3. 在最低噪声级别 (σ_L 小，接近原始分布) 收敛：粒子位于原始分布的高密度区域。

在每个噪声级别上运行若干步 Langevin dynamics，然后切换到下一个（更低的）噪声级别。

退火 Langevin Dynamics 的物理类比

这个过程类似于金属退火 (annealing):

- 高温阶段 (大噪声): 分子可以自由移动, 跨越势垒, 探索能量全景。
- 缓慢冷却 (逐步减噪): 分子逐渐稳定在能量最低的构型。
- 低温阶段 (小噪声): 分子被锁定在精确的低能量状态。

类似于模拟退火 (simulated annealing) 中的温度调度。

6.4 与扩散模型逆向过程的联系

退火 Langevin dynamics 的多尺度降噪过程, 实际上与扩散模型的逆向过程有着深刻的联系:

Score-Based Model 与 DDPM 的对应关系

概念	DDPM 视角	Score-Based 视角
前向过程	逐步加噪 (方差递增)	数据分布逐步模糊
逆向过程	逐步去噪	退火 Langevin dynamics
网络输出	噪声 ϵ_θ	Score s_θ
训练目标	噪声预测 L2	Denoising score matching
σ_t 大	前向过程早期	退火初期 (粗导航)
σ_t 小	前向过程后期	退火末期 (精细化)

DDPM 中前向过程的方差递增恰好对应 score-based 模型中从小噪声到大噪声的多尺度分布; DDPM 的逆向去噪过程恰好对应退火 Langevin dynamics 中从大噪声到小噪声的逐步精化。

6.5 本章小结

NCSN 通过引入多尺度噪声来解决 score function 在低密度区域估计不准确的问题。退火 Langevin dynamics 从高噪声 (粗导航) 开始逐步降低到低噪声 (精细化), 使采样过程既能有效跨越低密度区域, 又能在最终收敛到准确的目标分布。这个框架与 DDPM 的逆向去噪过程在数学上完全等价, 只是提供了不同的视角和直觉。

7 Score-Based Models 与 DDPM 的统一视角

7.1 两条研究路径的汇合

历史上, DDPM 和 score-based models 是两条独立发展的研究路径:

两条路径的发展历程

- **DDPM 路径**: Ho et al. (2020) 基于变分推断和 ELBO 推导出训练目标。从概率图模型和变分自编码器的传统出发, 定义前向/逆向马尔可夫链, 通过最大化 ELBO 来训练逆向过程。
- **Score-Based 路径**: Song & Ermon (2019, 2020) 基于 score matching 和 Langevin dynamics。从统计学中的 score function 出发, 通过 denoising score matching 训练 score estimator, 用退火 Langevin dynamics 采样。

两条路径最终在 Song et al. (2021) 的 Score-Based SDE 框架中被统一。

7.2 等价关系的数学总结

我们已经在前面的各节中逐步建立了所有等价关系, 这里做一个系统性的总结:

1. **训练目标等价**: DDPM 的 ϵ -prediction 损失 $\equiv$ Denoising Score Matching 损失 (差缩放因子)。
2. **网络输出等价**: $\epsilon_{\theta}(x_t, t) = -\sqrt{1 - \bar{\alpha}_t} s_{\theta}(x_t, t)$ 。
3. **采样过程等价**: DDPM 的逆向采样 $\equiv$ 退火 Langevin dynamics (离散化形式)。
4. **Tweedie 连接**: $\mathbb{E}[x_0 | x_t]$ 可以用 score function 表示, 也可以用噪声预测器表示。

统一视角的实际意义

理解这种等价性不仅是学术上的优雅, 更有重要的实际意义:

- 可以借用 score-based 理论来分析 DDPM 的性质 (如收敛性、采样质量)。
- 可以借用 DDPM 的实践技巧来改进 score-based 采样 (如 schedule 设计)。
- Score function 的视角为条件生成 (classifier guidance, classifier-free guidance) 提供了自然的理论基础。
- Song et al. 的连续时间 SDE 框架将离散步骤推广到连续过程, 开启了更灵活的采样器设计 (如 DDIM, DPM-Solver 等)。

7.3 本章小结

DDPM 和 score-based models 虽然从不同的出发点和动机发展而来, 但在数学上完全等价。DDPM 提供了概率图模型和变分推断的视角, 而 score-based models 提供了 score function 和 Langevin dynamics 的物理直觉。理解两种视角对于深入掌握扩散模型理论至关重要。

8 总结与延伸

8.1 核心要点回顾

本节课围绕 Score-Based Models 展开, 系统地建立了以下核心概念:

1. **Score Function**: 定义为 $\nabla_x \log p(x)$, 它是一个向量场, 指向概率增大的方向, 完全编码了概率分布的信息。
2. **噪声预测即 Score 学习**: DDPM 中的噪声预测器 ϵ_θ 与 score function 之间只差一个缩放因子, 揭示了噪声预测的深层物理意义。
3. **Tweedie's Formula**: 提供了从 score function 到后验均值估计 (去噪) 的直接公式: $\mathbb{E}[\mu | x] = x + \sigma^2 \nabla_x \log p(x)$ 。
4. **Langevin Dynamics**: 一种仅依赖 score function 的采样方法, 通过“梯度上升 + 噪声注入”的迭代过程收敛到目标分布。
5. **Denoising Score Matching**: 将不可计算的 score matching 目标转化为可计算的去噪目标, 其训练过程与 DDPM 完全等价。
6. **多尺度噪声与退火策略**: 通过多个噪声级别的 score function 和退火 Langevin dynamics 解决低密度区域 score 不准确的问题, 这与 DDPM 的逆向去噪过程等价。

8.2 拓展阅读

- **Song & Ermon (2019)**: *Generative Modeling by Estimating Gradients of the Data Distribution* – 提出 NCSN, 首次将 score matching 与退火 Langevin dynamics 结合用于图像生成。
- **Ho et al. (2020)**: *Denoising Diffusion Probabilistic Models (DDPM)* – 从变分推断角度推导扩散模型训练目标。
- **Song et al. (2021)**: *Score-Based Generative Modeling through Stochastic Differential Equations* – 提出 Score SDE 框架, 将 DDPM 和 NCSN 统一为连续时间过程。
- **Vincent (2011)**: *A Connection Between Score Matching and Denoising Autoencoders* – 首次建立 denoising score matching 的理论基础。
- **Efron (2011)**: *Tweedie's Formula and Selection Bias* – Tweedie's formula 在统计学中的经典论述。