

课程笔记

KAIST CS492D Lecture 5: Denoising Diffusion Implicit Models (DDIM)

基于 Minhyuk Sung 授课内容整理

2025 年秋季

CS492C: Diffusion and Flow Models

Denoising Diffusion Implicit Models

LECTURE 6
MINHYUK SUNG

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Minhyuk Sung (KAIST)

发布日期: 2025

视频时长: 57 分钟

视频链接: <https://www.youtube.com/watch?v=vRvT1NOKsxw>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言与背景回顾	2
1.1 从 DDPM 到加速采样的动机	2
1.2 Score-Based Models 与 DDPM 的联系	2
1.3 连续时间视角的预告	3
1.4 本章小结	3
2 DDIM 的核心思想：非马尔可夫前向过程	3
2.1 DDPM 前向过程的回顾	3
2.2 DDIM 的思路：直接定义跳跃与后验分布	4
2.3 推导过程：归纳法确定系数	5
2.4 ELBO 的不变性	6
2.5 本章小结	6
3 DDIM 的采样过程	6
3.1 通用采样公式	6
3.2 三种预测器的等价性	7
3.3 σ_t 参数化与特殊情况	7
3.4 本章小结	8
4 确定性采样：$\sigma_t = 0$ 的特殊情况	8
4.1 从随机过程到确定性映射	8
4.2 确定性采样的实际意义	8
4.3 本章小结	9
5 加速生成：减少采样步数	9
5.1 子序列采样策略	9
5.2 确定性采样在步数减少时的优势	9
5.3 FID 评估指标	10
5.4 加速采样的里程碑	10
5.5 本章小结	11
6 隐空间中的语义操作	11
6.1 确定性编码与解码	11
6.2 隐空间插值	11
6.3 与其他隐空间的对比	12
6.4 本章小结	12
7 实验结果与分析	12
7.1 不同 η 和步数下的 FID 对比	12
7.2 样本质量的定性观察	13
7.3 本章小结	13

8 总结与延伸	13
8.1 核心要点回顾	13
8.2 后续发展方向	14
8.3 拓展阅读	14

1 引言与背景回顾

本节课是 KAIST CS492D “Design and Learning of Visual Generative Models” 课程的第五讲，由 Minhyuk Sung 教授主讲。课程的核心主题是 **Denoising Diffusion Implicit Models (DDIM)**，这是加速扩散模型生成过程的里程碑式工作（Song et al., ICLR 2021）。

1.1 从 DDPM 到加速采样的动机

在前几讲中，我们已经学习了 DDPM (Denoising Diffusion Probabilistic Models) 的基本框架：通过逐步添加高斯噪声的前向过程 (forward process)，将数据分布转化为标准高斯分布；再通过训练神经网络学习逆过程 (reverse process)，从噪声逐步恢复出干净数据。

DDPM 的核心瓶颈：采样速度

DDPM 通常需要 $T = 1000$ 步的迭代去噪过程来生成一张高质量图像。每一步都需要一次完整的神经网络前向传播，这使得生成速度远慢于 GAN 等单步生成模型。如何在不牺牲质量的前提下减少采样步数，是扩散模型研究的核心挑战之一。

讲者通过对比三类主流生成模型的优劣来引出 DDIM 的研究动机：

表 1: 主流生成模型特性对比

模型	样本质量	多样性	生成速度
GAN	高	低 (模式崩塌)	快 (单步)
VAE	低	高	快 (单步)
DDPM	高	高	慢 (~1000 步)

扩散模型在质量和多样性上都表现优异，唯一的短板在于生成速度。DDIM 正是解决这一问题的第一个重要突破。

1.2 Score-Based Models 与 DDPM 的联系

讲者在开场部分简要回顾了 score-based generative models 与 DDPM 的关系。两者的核心思想高度相似：

Score Function (得分函数) 的核心角色

对于数据分布 $q(\mathbf{x}_t)$ ，其 score function 定义为：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)$$

在 score-based models 中，我们训练一个神经网络 $s_\theta(\mathbf{x}_t, t)$ 来近似这个 score function。通过 Langevin dynamics 迭代采样，可以从任意先验分布出发，逐步趋近数据分布的高密度区域。

Score-based models 的基本流程是：

1. 对原始数据分布 $q(\mathbf{x}_0)$ 添加不同程度的高斯噪声，得到一系列模糊分布 $q(\mathbf{x}_t)$
2. 训练 score predictor 网络，通过最小化 L2 损失来匹配每个噪声水平下的 score function

3. 采样时从高噪声水平开始，利用 annealed Langevin dynamics 逐步降低噪声水平

多尺度噪声的必要性

如果只添加少量噪声（小方差），score function 在远离数据点的低密度区域几乎为零，网络既难以准确学习、也无法提供有效的梯度引导采样点移动。如果只添加大量噪声（大方差），虽然覆盖范围广，但模糊后的分布与原始分布偏差很大。因此，必须使用从大到小的多尺度噪声调度（noise schedule），先粗略定位、再精细恢复——这正是 DDPM 和 score-based models 共享的核心设计思想。

讲者指出，DDPM 的训练目标（噪声预测损失 $\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2$ ）实际上等价于 score matching 的目标。Score function 与噪声预测器之间存在如下关系：

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{x}_0) = -\frac{\epsilon}{\sqrt{1 - \bar{\alpha}_t}}$$

其中 ϵ 是添加的噪声， $\bar{\alpha}_t$ 是累积噪声调度参数。因此，噪声预测网络 ϵ_θ 本质上就是在学习 score function 的缩放版本。

1.3 连续时间视角的预告

讲者还提到，当我们将扩散过程推广到连续时间域时，前向过程可以描述为随机微分方程(SDE)：

$$d\mathbf{x} = f(\mathbf{x}, t) dt + g(t) d\mathbf{w}$$

其逆过程同样有闭式 SDE 表达，且核心仍依赖 score function。DDPM 和 score-based models 都可视为对这个连续过程的不同离散化方案。

统一框架下的不同视角

DDPM 从概率图模型（马尔可夫链）出发定义前向和逆向过程；score-based models 从 Langevin dynamics 出发学习 score function。两者在数学上等价，仅是同一框架的不同参数化。这一统一视角（Song et al., ICLR 2021, “Score-Based Generative Modeling through Stochastic Differential Equations”）为后续的 DDIM、DPM-Solver 等加速方法奠定了理论基础。

1.4 本章小结

本节回顾了 DDPM 与 score-based models 的等价性，明确了扩散模型面临的采样速度瓶颈。DDPM 需要约 1000 步迭代才能生成高质量样本，而本讲将介绍的 DDIM 通过重新定义前向过程（从马尔可夫过程推广到非马尔可夫过程），可以将步数降低到 50 步左右而几乎不损失质量。

2 DDIM 的核心思想：非马尔可夫前向过程

2.1 DDPM 前向过程的回顾

在 DDPM 中，前向过程被定义为一个马尔可夫链：

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1})$$

其中每一步的转移分布为：

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

由此可以推导出两个关键分布：

- **跳跃分布** (marginal): $q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$
- **后验分布** (posterior): $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$, 也是高斯分布 (闭式可解)

ELBO 中真正需要的分布

在推导变分下界 (ELBO) 时，我们需要的并不是前向转移分布 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ 本身，而是：

1. 跳跃分布 $q(\mathbf{x}_t|\mathbf{x}_0)$ ——用于采样训练数据
2. 后验分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ ——逆过程的匹配目标

这一观察是 DDIM 的关键出发点：既然 ELBO 只依赖这两个分布，我们是否可以跳过定义前向转移分布，直接定义这两个分布？

2.2 DDIM 的思路：直接定义跳跃与后验分布

DDIM 的核心创新在于颠倒了推导顺序：

表 2: DDPM 与 DDIM 的推导顺序对比

DDPM	DDIM
先定义 $q(\mathbf{x}_t \mathbf{x}_{t-1})$	直接定义 $q(\mathbf{x}_t \mathbf{x}_0)$
推导 $q(\mathbf{x}_t \mathbf{x}_0)$	直接定义 $q(\mathbf{x}_{t-1} \mathbf{x}_t, \mathbf{x}_0)$
推导 $q(\mathbf{x}_{t-1} \mathbf{x}_t, \mathbf{x}_0)$	前向转移分布由上述两个隐含确定

具体来说，DDIM 做了以下设定：

保持跳跃分布不变。 对于所有 t ，DDIM 要求：

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

这与 DDPM 完全相同。

重新定义后验分布。 DDIM 将后验分布参数化为：

$$q_{\sigma}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_{t-1}; \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_0}{\sqrt{1 - \bar{\alpha}_t}}, \sigma_t^2 \mathbf{I}\right)$$

其中 σ_t 是一个可自由选择的超参数，控制每步逆过程中注入噪声的程度。

非马尔可夫性的含义

在 DDIM 的前向过程中, $\mathbf{x}_{t-1}$ 的采样依赖于 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ (而不仅仅是 $\mathbf{x}_t$)。这打破了马尔可夫假设——当前状态不仅依赖于前一步, 还依赖于原始数据。这就是 “Implicit” 一词的来源: 前向转移分布 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ 不再被显式定义, 而是由跳跃分布和后验分布隐式 (implicitly) 确定。

2.3 推导过程: 归纳法确定系数

讲者详细展示了如何通过数学归纳法确定后验分布中的系数。

核心约束。 我们需要满足: 对于所有 t , 通过后验分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 和跳跃分布 $q(\mathbf{x}_t|\mathbf{x}_0)$ 导出的 $q(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 必须与 DDPM 中的跳跃分布一致。

高斯分布的闭式合成。 讲者利用了一个关键的数学事实:

高斯分布的边缘化性质

如果先验分布 $p(\mathbf{z})$ 和似然分布 $p(\mathbf{x}|\mathbf{z})$ 都是高斯分布, 且似然的均值是 $\mathbf{z}$ 的线性函数, 那么边缘分布 $p(\mathbf{x}) = \int p(\mathbf{x}|\mathbf{z})p(\mathbf{z})d\mathbf{z}$ 也是高斯分布, 且均值和方差可以通过闭式表达计算。这是整个推导能够进行的数学基础。

假设后验分布的均值为 $\mathbf{x}_0$ 和 $\mathbf{x}_t$ 的线性组合:

$$\mu_{t-1}(\mathbf{x}_t, \mathbf{x}_0) = w_0 \cdot \mathbf{x}_0 + w_t \cdot \mathbf{x}_t$$

通过匹配 $q(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 的均值和方差, 可以解出:

$$w_0 = \sqrt{\bar{\alpha}_{t-1}} - \sqrt{\bar{\alpha}_t} \cdot \frac{\sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2}}{\sqrt{1 - \bar{\alpha}_t}}, \quad w_t = \frac{\sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2}}{\sqrt{1 - \bar{\alpha}_t}}$$

方差约束: σ_t 不能任意大

由于方差必须非负, σ_t^2 有一个上界:

$$\sigma_t^2 \leq 1 - \bar{\alpha}_{t-1}$$

当 σ_t^2 取到上界时, 后验分布的方差部分恰好与 DDPM 的后验分布一致。这表明 DDPM 是 DDIM 在特定方差选择下的特殊情况。

2.4 ELBO 的不变性

训练目标保持不变——无需重新训练

由于 DDIM 保持了跳跃分布 $q(\mathbf{x}_t|\mathbf{x}_0)$ 与 DDPM 完全一致，两者的 ELBO（变分下界）在相差一个与模型参数无关的常数因子下是等价的。这意味着：

1. 用 DDPM 目标训练的噪声预测网络 ϵ_θ 可以直接用于 DDIM 的采样过程
2. 不需要任何额外的微调或重新训练
3. 仅通过改变推理时的采样策略即可获得加速

这是 DDIM 最具实用价值的特性：**训练一次，多种方式推理。**

这一点在深度学习中是相当罕见的——通常我们训练一个模型后，推理方式是固定的。但对于扩散模型，由于其迭代采样的特殊结构，我们可以在推理阶段灵活选择采样策略（马尔可夫 vs 非马尔可夫、随机 vs 确定性），而不需要修改训练过程。

2.5 本章小结

DDIM 的核心思想是：直接定义跳跃分布和后验分布（而非前向转移分布），由此构建一个非马尔可夫的前向过程。通过数学归纳法和高斯分布的闭式合成性质，可以推导出后验分布中系数的解析表达式。关键在于，DDIM 的跳跃分布与 DDPM 完全一致，因此 ELBO 不变，已训练的 DDPM 模型可以直接用于 DDIM 采样。

3 DDIM 的采样过程

3.1 通用采样公式

给定当前时间步 t 的含噪样本 $\mathbf{x}_t$ ，DDIM 的单步更新公式为：

$$\mathbf{x}_{t-1} = \underbrace{\sqrt{\bar{\alpha}_{t-1}} \hat{\mathbf{x}}_0(\mathbf{x}_t)}_{\text{预测的干净数据}} + \underbrace{\sqrt{1 - \bar{\alpha}_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)}{\sqrt{1 - \bar{\alpha}_t}}}_{\text{“方向”指向}\mathbf{x}_t} + \underbrace{\sigma_t \epsilon_t}_{\text{随机噪声}}$$

其中 $\hat{\mathbf{x}}_0(\mathbf{x}_t)$ 是通过噪声预测网络对 $\mathbf{x}_0$ 的估计：

$$\hat{\mathbf{x}}_0(\mathbf{x}_t) = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{\bar{\alpha}_t}}$$

$\epsilon_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是独立采样的高斯噪声。

采样公式的直观解读

DDIM 的单步更新可以分解为三个组成部分：

1. **信号分量**： $\sqrt{\bar{\alpha}_{t-1}} \hat{\mathbf{x}}_0$ ——根据当前对干净数据的最佳估计，按 $t-1$ 时刻的信噪比进行缩放
2. **方向分量**：指向从 $\hat{\mathbf{x}}_0$ 到 $\mathbf{x}_t$ 方向的向量，保留了噪声的“方向信息”
3. **随机分量**： $\sigma_t \epsilon_t$ ——额外注入的噪声，其大小由 σ_t 控制

当 $\sigma_t = 0$ 时，随机分量消失，整个过程变为确定性的。

3.2 三种预测器的等价性

讲者指出，在实现 DDIM 采样时，可以使用三种等价的网络参数化：

1. **噪声预测器** (ϵ -prediction)： $\epsilon_\theta(\mathbf{x}_t, t) \approx \epsilon$ ，预测添加的噪声
2. **干净数据预测器** ($\mathbf{x}_0$ -prediction)： $\hat{\mathbf{x}}_{0,\theta}(\mathbf{x}_t, t) \approx \mathbf{x}_0$ ，直接预测原始数据
3. **均值预测器** (μ -prediction)： $\mu_\theta(\mathbf{x}_t, t) \approx \mu_{t-1}$ ，预测后验均值

预测器之间的转换关系

三种预测器之间可以通过简单的线性变换相互转换：

$$\hat{\mathbf{x}}_0 = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta}{\sqrt{\bar{\alpha}_t}}, \quad \epsilon_\theta = \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \hat{\mathbf{x}}_0}{\sqrt{1 - \bar{\alpha}_t}}$$

无论网络内部使用哪种参数化，DDIM 的采样算法只需要 $\hat{\mathbf{x}}_0$ 的估计值即可。在实践中， ϵ -prediction 是最常用的参数化方式（DDPM 原始论文所采用），而 $\mathbf{x}_0$ -prediction 在某些改进方法中也有应用。

3.3 σ_t 参数化与特殊情况

σ_t 的选择控制了采样过程中随机性的程度。DDIM 论文中引入了参数 $\eta \geq 0$ 来统一参数化：

$$\sigma_t(\eta) = \eta \cdot \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}} \cdot \sqrt{1 - \frac{\bar{\alpha}_t}{\bar{\alpha}_{t-1}}}$$

表 3: η 参数的特殊取值及对应的采样行为

η	采样性质	等价模型
0	完全确定性采样	DDIM（纯确定性）
1	随机采样，方差与 DDPM 一致	等价于 DDPM
> 1	更大的随机性	超越 DDPM 的噪声注入

DDPM 是 DDIM 的特殊情况

当 $\eta = 1$ 时, DDIM 的后验分布 $q_\sigma(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的方差恰好等于 DDPM 中推导出的后验方差 $\tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$ 。此时 DDIM 退化为 DDPM 的马尔可夫采样过程。然而, 由于两者的 ELBO 是等价的, 使用不同的 η 值采样不会影响训练目标——这是训练与推理解耦的关键。

3.4 本章小结

DDIM 的采样公式由三个分量组成: 信号项、方向项和随机项。超参数 σ_t (或等价地 η) 控制随机性的大小。 $\eta = 0$ 给出确定性采样, $\eta = 1$ 退化为 DDPM。无论选择哪个 η , 都不需要重新训练模型。

4 确定性采样: $\sigma_t = 0$ 的特殊情况

4.1 从随机过程到确定性映射

当 $\sigma_t = 0$ (即 $\eta = 0$) 时, DDIM 的采样公式退化为:

$$\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \hat{\mathbf{x}}_0(\mathbf{x}_t) + \sqrt{1 - \bar{\alpha}_{t-1}} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)}{\sqrt{1 - \bar{\alpha}_t}}$$

这个更新规则是完全确定性的——没有任何随机噪声注入。这意味着:

确定性采样的核心性质

在 DDIM 确定性采样模式下:

1. 从相同的初始噪声 $\mathbf{x}_T$ 出发, 经过整个逆过程后一定得到相同的输出 $\mathbf{x}_0$
2. 噪声空间 $\mathbf{x}_T$ 到数据空间 $\mathbf{x}_0$ 之间建立了一个确定性的双射映射
3. 生成结果完全可复现: 只需记住初始噪声 $\mathbf{x}_T$

这与 DDPM 的随机采样形成鲜明对比——DDPM 中即使从相同的 $\mathbf{x}_T$ 出发, 由于每步都注入随机噪声, 最终生成的结果每次都不同。

4.2 确定性采样的实际意义

确定性采样带来了若干重要的实际好处:

可复现性。 在实际应用中 (如 Stable Diffusion), 用户生成了一张满意的图片后, 若想再次生成完全相同的结果, 在随机采样模式下几乎不可能。而使用 DDIM 确定性采样, 只需记录初始噪声种子 (seed), 即可精确复现任意生成结果。

语义隐空间。 确定性映射意味着 $\mathbf{x}_T$ 空间中的每个点都唯一对应数据空间中一张图片。这为隐空间中的操作 (如插值、编辑) 提供了基础。

与 Neural ODE 的联系。确定性 DDIM 可以被理解为 neural ODE 的一种离散化：

DDIM 与概率流 ODE 的关系

当 $\sigma_t = 0$ 时，DDIM 的迭代更新对应于以下常微分方程（ODE）的 Euler 离散化：

$$d\mathbf{x} = \left[f(\mathbf{x}, t) - \frac{1}{2}g(t)^2 \nabla_{\mathbf{x}} \log q_t(\mathbf{x}) \right] dt$$

这就是 Song et al. (2021) 提出的**概率流 ODE**（probability flow ODE）。ODE 的解轨迹是确定性的，且保持了与 SDE（随机微分方程）相同的边缘分布。使用更高阶的 ODE 求解器可以进一步减少采样步数。

4.3 本章小结

$\sigma_t = 0$ 的确定性 DDIM 建立了噪声空间到数据空间的确定性映射，实现了生成结果的精确可复现性，并为隐空间操作提供了基础。它可以被理解为概率流 ODE 的 Euler 离散化，这一联系为后续使用更高阶 ODE 求解器加速采样提供了理论依据。

5 加速生成：减少采样步数

5.1 子序列采样策略

DDIM 的另一个核心贡献是提出了**步数跳跃**（stride / subsequence sampling）策略。在训练时，模型可能使用了 $T = 1000$ 个时间步。但在采样时，我们不必遍历所有时间步，而是选择一个子序列。

具体来说，设原始时间步集合为 $\{1, 2, \dots, T\}$ ，我们选择一个大小为 $S < T$ 的子序列 $\tau = \{\tau_1, \tau_2, \dots, \tau_S\}$ ，其中 $\tau_S = T$ 。采样时只在子序列 τ 的时间步上执行逆过程更新。

步数跳跃的数学合理性

DDIM 的采样公式只依赖于 $\bar{\alpha}_t$ 和 $\bar{\alpha}_{t-1}$ 的值，而不要求时间步必须是连续的整数。因此我们可以将公式中的 $t \rightarrow \tau_i$ ， $t-1 \rightarrow \tau_{i-1}$ 进行替换：

$$\mathbf{x}_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}} \hat{\mathbf{x}}_0(\mathbf{x}_{\tau_i}) + \sqrt{1 - \bar{\alpha}_{\tau_{i-1}} - \sigma_{\tau_i}^2} \cdot \frac{\mathbf{x}_{\tau_i} - \sqrt{\bar{\alpha}_{\tau_i}} \hat{\mathbf{x}}_0(\mathbf{x}_{\tau_i})}{\sqrt{1 - \bar{\alpha}_{\tau_i}}} + \sigma_{\tau_i} \epsilon$$

这本质上是在一个更粗粒度的噪声调度上执行 DDIM 更新，数学上完全合法。

例如，从 $T = 1000$ 步的模型中，我们可以均匀选取 $S = 50$ 步：

$$\tau = \{20, 40, 60, \dots, 980, 1000\}$$

这将采样步数从 1000 减少到 50，加速 20 倍。

5.2 确定性采样在步数减少时的优势

讲者展示了 DDIM 论文中的实验结果，揭示了一个重要的经验规律：

确定性采样对步数减少更鲁棒

实验表明（以 CIFAR-10 上的 FID 分数为例）：

- 当使用完整的 1000 步时，DDPM ($\eta = 1$, 随机采样) 和 DDIM ($\eta = 0$, 确定性采样) 性能相当
- 当步数减少到 50-100 步时，确定性 DDIM 的质量退化明显小于随机 DDPM
- 当步数进一步减少到 10-20 步时，确定性 DDIM 仍能保持可接受的质量，而随机采样的质量急剧下降

直观解释：随机采样中每步注入的噪声在步数较少时会累积更大的误差；而确定性采样不注入额外噪声，误差累积更可控。

5.3 FID 评估指标

讲者在展示实验结果时介绍了 FID (Fréchet Inception Distance) 指标：

FID 指标简介

FID 衡量生成图像分布与真实图像分布之间的距离。具体步骤：

1. 用预训练的 Inception 网络提取真实图像和生成图像的特征向量
2. 分别拟合两组特征的高斯分布（均值 μ 、协方差 Σ ）
3. 计算两个高斯分布之间的 Fréchet 距离

FID 越低越好，表示生成分布越接近真实分布。FID 同时衡量了样本质量（保真度）和多样性。

5.4 加速采样的里程碑

讲者提到了扩散模型加速采样的发展路线：

表 4: 扩散模型加速采样的发展历程

方法	典型步数	策略
DDPM (2020)	~1000	马尔可夫随机采样
DDIM (2021)	~50	非马尔可夫确定性/半确定性采样
DPM-Solver (2022)	~10-20	高阶 ODE 求解器
Consistency Models / 蒸馏	~1-4	蒸馏 + 一致性约束

从 1000 步到 1 步：开放问题

讲者指出，如果能在无需微调的前提下实现单步高质量生成，将具有巨大的商业和学术价值。目前的现状是：

- 从 1000 步降到 10-50 步可以仅通过改变采样策略实现（如 DDIM、DPM-Solver）
- 进一步降到 1-4 步则需要额外的蒸馏训练（如 Consistency Distillation、Progressive Distillation）
- 单阶段训练就能实现单步高质量生成仍是一个开放问题

以 Flux 模型为例，其标准版本使用约 20 步，而 Schnell 版本通过蒸馏实现了 1-4 步生成。

5.5 本章小结

DDIM 通过子序列采样策略，可以在不重新训练的前提下将采样步数从 1000 降低到约 50。确定性采样模式（ $\eta = 0$ ）在步数减少时表现出更强的鲁棒性。这一方法是扩散模型加速采样领域的开创性工作，后续的 DPM-Solver、一致性模型等方法在此基础上进一步将步数降低到了个位数。

6 隐空间中的语义操作

6.1 确定性编码与解码

DDIM 确定性采样建立的 $\mathbf{x}_T \leftrightarrow \mathbf{x}_0$ 双射映射，使得我们不仅可以从 $\mathbf{x}_T$ 生成 $\mathbf{x}_0$ （解码），还可以从 $\mathbf{x}_0$ 恢复 $\mathbf{x}_T$ （编码）。编码过程通过运行 DDIM 的前向方向实现：

$$\mathbf{x}_{t+1} = \sqrt{\bar{\alpha}_{t+1}} \hat{\mathbf{x}}_0(\mathbf{x}_t) + \sqrt{1 - \bar{\alpha}_{t+1}} \cdot \frac{\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \hat{\mathbf{x}}_0(\mathbf{x}_t)}{\sqrt{1 - \bar{\alpha}_t}}$$

这意味着对于任意真实图片 $\mathbf{x}_0$ ，我们可以找到其在噪声空间中的“对应点” $\mathbf{x}_T$ ，从该点出发再执行 DDIM 解码可以精确恢复原图。

DDIM 隐空间的语义结构

由于确定性映射的存在，噪声空间 $\mathbf{x}_T$ 实际上成为了一个具有语义结构的隐空间。在这个空间中：

- 相似的图像在隐空间中的表示也相近
- 隐空间中的线性运算（如插值）在数据空间中对应有意义的语义变化
- 不同于 VAE 的隐空间（低维），DDIM 的隐空间与数据空间维度相同

6.2 隐空间插值

DDIM 论文展示了隐空间插值的有趣应用。给定两张真实图片 $\mathbf{x}_0^{(1)}$ 和 $\mathbf{x}_0^{(2)}$ ：

1. 通过 DDIM 编码分别得到 $\mathbf{x}_T^{(1)}$ 和 $\mathbf{x}_T^{(2)}$

2. 在隐空间中进行球面线性插值 (SLERP):

$$\mathbf{x}_T^{(\lambda)} = \frac{\sin((1-\lambda)\theta)}{\sin\theta} \mathbf{x}_T^{(1)} + \frac{\sin(\lambda\theta)}{\sin\theta} \mathbf{x}_T^{(2)}, \quad \lambda \in [0, 1]$$

$$\text{其中 } \theta = \arccos\left(\frac{\langle \mathbf{x}_T^{(1)}, \mathbf{x}_T^{(2)} \rangle}{\|\mathbf{x}_T^{(1)}\| \|\mathbf{x}_T^{(2)}\|}\right)$$

3. 对插值点 $\mathbf{x}_T^{(\lambda)}$ 执行 DDIM 解码得到插值图片

为什么使用球面插值 (SLERP) 而非线性插值

由于隐空间中的噪声向量 $\mathbf{x}_T$ 是从标准高斯分布中采样的, 在高维空间中, 这些向量近似均匀分布在一个超球面上 (范数集中在 $\sqrt{d}$ 附近)。线性插值 (LERP) 会产生范数较小的中间点, 偏离高斯分布的典型集合 (typical set), 可能导致质量下降。球面插值 (SLERP) 保持向量范数不变, 生成的中间点仍在超球面上, 因此更合理。

6.3 与其他隐空间的对比

表 5: 不同模型隐空间特性对比

模型	隐空间维度	编码确定性	插值质量
VAE	低维	随机	中等
GAN	低维	通常无编码器	好
DDIM	与数据等维	确定性	好

DDIM 编码的精度依赖步数

DDIM 编码过程本质上是 ODE 积分的数值近似。使用的步数越少, 数值误差越大, “编码 → 解码” 的重建质量越低。在需要精确重建的应用 (如图像编辑) 中, 通常需要使用较多的步数 (如 100-200 步) 来保证编码精度。

6.4 本章小结

DDIM 的确定性采样构建了噪声空间到数据空间的双射映射, 使噪声空间获得了语义结构。通过编码-插值-解码的流程, 可以实现高质量的图像插值。球面线性插值 (SLERP) 比线性插值更适合高斯分布的隐空间。

7 实验结果与分析

7.1 不同 η 和步数下的 FID 对比

DDIM 论文在 CIFAR-10 数据集上进行了系统性的消融实验, 考察 η 和采样步数 S 对 FID 的影响。

关键观察如下:

1. **全步数 ($S = 1000$):** 所有 η 值的 FID 都相当, 约为 3-4。DDPM ($\eta = 1$) 略优于确定性 DDIM ($\eta = 0$)

2. **中等步数** ($S = 50 \sim 100$): 确定性 DDIM ($\eta = 0$) 显著优于 DDPM ($\eta = 1$), FID 差距可达 5-10
3. **少步数** ($S = 10 \sim 20$): 确定性 DDIM 仍能保持较好的质量 (FID ~ 10 -15), 而 DDPM 的 FID 急剧恶化 (>50)

步数减少时的质量-速度权衡

虽然确定性 DDIM 在减少步数时更为鲁棒, 但步数减少到一定程度后, 质量仍会不可避免地下降。这是因为较大的时间步跨度使得每步更新的“跳跃”更大, 噪声预测网络在远离训练分布的区域的预测准确性会降低。DDIM 论文的实验表明, 在 CIFAR-10 上约 $S = 50$ 步即可达到与 1000 步 DDPM 相当的质量。

7.2 样本质量的定性观察

讲者还讨论了 DDIM 生成样本的一些定性特征:

- 确定性 DDIM 生成的图像通常比 DDPM 略微“锐利”(sharper), 因为没有额外噪声的注入
- DDPM 的随机性有时反而能带来更多的多样性和“自然感”
- 在步数充足 (≥ 50) 的情况下, 两者的视觉质量差异不大

7.3 本章小结

实验结果验证了 DDIM 在减少采样步数方面的优势: 确定性采样在步数减少时质量退化更缓慢。约 50 步的 DDIM 即可匹配 1000 步 DDPM 的质量, 实现约 20 倍加速。

8 总结与延伸

8.1 核心要点回顾

DDIM 是扩散模型加速采样的奠基性工作, 其核心贡献可以归纳为以下几点:

1. **非马尔可夫前向过程**: 通过直接定义跳跃分布和后验分布 (而非前向转移分布), 构建了比 DDPM 更通用的扩散框架。后验分布中引入了自由参数 σ_t , 控制采样的随机性程度。
2. **ELBO 不变性**: 由于跳跃分布与 DDPM 保持一致, DDIM 的训练目标与 DDPM 完全等价。这意味着已有的 DDPM 模型可以直接用于 DDIM 采样, 无需任何重新训练。
3. **确定性采样**: 当 $\sigma_t = 0$ 时, 采样过程变为完全确定性的, 建立了噪声空间到数据空间的双射映射。这带来了可复现性、语义隐空间、以及与 ODE 求解器的联系。
4. **加速生成**: 通过子序列采样策略, 可以将步数从 1000 降低到约 50, 实现 20 倍加速。确定性采样模式在步数减少时表现出更强的鲁棒性。
5. **隐空间操作**: 确定性 DDIM 的编码-解码对称性使得隐空间插值等语义操作成为可能。

DDIM 的深远影响

DDIM 不仅本身是一个实用的加速采样方法，更重要的是它揭示了扩散模型一个关键的设计原则：**训练与推理的解耦**。模型训练一次后，可以在推理时自由选择不同的采样策略（步数、随机性程度、ODE 求解器等）。这一原则被后续的几乎所有扩散模型加速工作所继承，包括 DPM-Solver、Consistency Models、Progressive Distillation 等。

8.2 后续发展方向

基于 DDIM 的框架，后续研究从多个方向进一步推进了扩散模型的采样效率：

1. **高阶 ODE 求解器** (DPM-Solver, DPM-Solver++)：将确定性 DDIM 视为概率流 ODE 的 Euler 方法，使用更高阶（2 阶、3 阶）的求解器可以在相同步数下获得更高精度，或在更少步数下达到相同质量
2. **连续时间 SDE/ODE 框架** (Score SDE)：将离散时间的 DDPM/DDIM 推广到连续时间，统一了 score-based models 和扩散模型
3. **知识蒸馏** (Progressive Distillation, Consistency Distillation)：通过蒸馏进一步将步数降低到 1-4 步
4. **Flow Matching**：从最优传输的角度重新设计扩散路径，实现更直的采样轨迹和更少的步数

8.3 拓展阅读

- Song, J., Meng, C., & Ermon, S. (2021). Denoising Diffusion Implicit Models. *ICLR 2021*. arXiv:2010.02502
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., & Poole, B. (2021). Score-Based Generative Modeling through Stochastic Differential Equations. *ICLR 2021*. arXiv:2011.13456
- Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. *NeurIPS 2020*. arXiv:2006.11239
- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., & Zhu, J. (2022). DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling. *NeurIPS 2022*. arXiv:2206.00927
- Song, Y., & Dhariwal, P. (2023). Consistency Models. *ICML 2023*. arXiv:2303.01469