

课程笔记

KAIST CS492D Lecture 8: ODE Solvers (DPM-Solver)

基于 Minhyuk Sung 授课内容整理

2025 年秋季

CS492C: Diffusion and Flow Models

ODE Solvers

LECTURE 9
MINHYUK SUNG

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Minhyuk Sung (KAIST)

发布日期: 2025

视频时长: 55 分钟

视频链接: <https://www.youtube.com/watch?v=eKW5AAy5ae8>

目录

1 引言与课程回顾	2
1.1 从 DDPM 到连续时间框架	2
1.2 SDE 与 ODE 的双重描述	3
1.3 引入 λ 函数	3
1.4 本章小结	3
2 ODE 求解基础	3
2.1 为什么需要快速 ODE 求解器	3
2.2 欧拉法 (Euler Method)	4
2.3 高阶 ODE 求解器概览	4
2.4 本章小结	4
3 线性 ODE 与精确解	5
3.1 简单线性 ODE 的解析解	5
3.2 半线性 ODE 与积分因子法	5
3.3 带常数偏移项的精确解	6
3.4 本章小结	6
4 DPM-Solver 的推导	6
4.1 PF-ODE 的半线性结构	6
4.2 利用指数积分器求解	6
4.3 一阶近似: DPM-Solver-1 即 DDIM	7
4.4 本章小结	7
5 高阶 DPM-Solver	8
5.1 二阶近似: DPM-Solver-2	8
5.2 三阶及更高阶近似	8
5.3 各阶 DPM-Solver 对比	9
5.4 本章小结	9
6 DPM-Solver++ 与实践改进	9
6.1 从噪声预测到数据预测	9
6.2 多步法 (Multistep Method)	9
6.3 时间步调度策略	10
6.4 本章小结	10
7 实验结果与性能分析	10
7.1 FID 对比	10
7.2 不同阶次的收敛行为	11
7.3 与其他加速方法的关系	11
7.4 本章小结	11

8 理论深入：从 DDIM 到 DPM-Solver 的统一视角	11
8.1 DDIM 采样公式的重新推导	11
8.2 λ 空间中的 Taylor 展开	12
8.3 本章小结	12
9 实践指南	12
9.1 推荐配置	12
9.2 实现要点	13
9.3 本章小结	13
10 总结与延伸	13
10.1 核心要点回顾	13
10.2 更广阔的视角	14
10.3 后续发展	14
10.4 拓展阅读	14

1 引言与课程回顾

本讲是 KAIST CS492D (扩散模型与流模型) 的第 8 讲, 核心议题是**如何高效求解扩散模型的逆过程 ODE**。讲者 Minhyuk Sung 首先回顾了此前课程中介绍的 DDPM、DDIM 以及连续时间 SDE/ODE 框架, 然后引出本讲的核心问题: 既然扩散模型的逆过程可以被等价地描述为一个常微分方程 (ODE), 那么我们能否利用 ODE 的特殊结构来设计更高效的求解器, 从而在极少的采样步数下获得高质量图像?

前置知识概览

理解本讲需要以下前置概念:

- **DDPM** (Denoising Diffusion Probabilistic Models): 基于马尔可夫链的离散时间扩散模型, 通常需要 $T = 1000$ 步才能完成采样
- **DDIM** (Denoising Diffusion Implicit Models): DDPM 的确定性采样变体, 可使用子序列跳步采样
- **SDE/ODE 框架**: Song et al. 提出的连续时间表述, 将扩散过程描述为随机微分方程 (SDE), 并给出等价的概率流 ODE (Probability Flow ODE)
- **Score function**: $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$, 可通过噪声预测网络 ϵ_θ 计算

1.1 从 DDPM 到连续时间框架

在 DDPM 中, 前向扩散过程定义为:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})$$

其中:

- $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$, 是累积信号保留率
- β_t 是每步的噪声调度参数

在变分扩散模型 (Variational Diffusion Model, VDM) 的更一般框架下, 前向跳跃分布可以重写为:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$$

符号混淆警告

不同论文中 α 的定义不一致。在 DDPM 原始论文中, $\alpha_t = 1 - \beta_t$; 而在 VDM/DPM-Solver 框架中, α_t 直接对应信号缩放系数 $\sqrt{\bar{\alpha}_t}$ 。阅读文献时需特别注意上下文中的符号约定, 避免混淆。

采样 $\mathbf{x}_t$ 等价于对干净数据 $\mathbf{x}_0$ 与标准高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 做线性插值:

$$\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$$

定义该框架只需要满足一个约束: 信噪比 (Signal-to-Noise Ratio, SNR) $\frac{\alpha_t^2}{\sigma_t^2}$ 关于时间 t 单调递减——即随着时间推移, 噪声逐渐占主导, 直至 $\mathbf{x}_T$ 近似于标准高斯分布。

1.2 SDE 与 ODE 的双重描述

在连续时间域中，前向扩散过程可以用 SDE 描述：

$$d\mathbf{x} = f(t)\mathbf{x}dt + g(t)d\mathbf{w}$$

其中 $f(t)$ 为漂移系数， $g(t)$ 为扩散系数， $\mathbf{w}$ 为标准维纳过程。给定前向 SDE，对应的逆时间 SDE 为：

$$d\mathbf{x} = [f(t)\mathbf{x} - g(t)^2\nabla_{\mathbf{x}}\log p_t(\mathbf{x})]dt + g(t)d\bar{\mathbf{w}}$$

Probability Flow ODE (概率流 ODE)

Anderson (1982) 证明，对于任意逆时间 SDE，都存在一个确定性的 ODE，使得两者在边际分布 $p_t(\mathbf{x})$ 上完全一致：

$$\frac{d\mathbf{x}}{dt} = f(t)\mathbf{x} - \frac{1}{2}g(t)^2\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$$

这就是概率流 ODE (PF-ODE)。由于没有随机噪声项，给定相同初始点 $\mathbf{x}_T$ ，ODE 的解是确定性的。这为利用 ODE 求解器加速采样奠定了基础。

利用噪声预测网络 $\epsilon_{\theta}(\mathbf{x}_t, t) \approx -\sigma_t\nabla_{\mathbf{x}}\log p_t(\mathbf{x})$ ，可将 PF-ODE 改写为只包含 ϵ_{θ} 的形式。

1.3 引入 λ 函数

为了简化后续推导，定义 log-SNR 的半值函数：

$$\lambda_t = \frac{1}{2}\log\frac{\alpha_t^2}{\sigma_t^2} = \log\frac{\alpha_t}{\sigma_t}$$

- λ_t 是 t 的严格单调递减函数（因为 SNR 单调递减）
- 利用 λ_t ，许多表达式可以大幅化简
- $e^{\lambda_t} = \frac{\alpha_t}{\sigma_t}$ ， $e^{-\lambda_t} = \frac{\sigma_t}{\alpha_t}$

引入 λ_t 后，前向 SDE 的漂移函数 $f(t)$ 可以更简洁地用 λ_t 表示，后续积分变量替换也将围绕 λ 进行。

1.4 本章小结

本节建立了从离散 DDPM/DDIM 到连续时间 SDE/ODE 的统一视角。关键点：(1) 扩散模型的逆过程可以等价表述为一个确定性 ODE；(2) 该 ODE 具有半线性 (semi-linear) 结构，线性部分可以解析求解；(3) 变量 λ_t 提供了更方便的参数化。

2 ODE 求解基础

2.1 为什么需要快速 ODE 求解器

扩散模型的采样过程等价于从 $t = T$ （纯噪声）到 $t = 0$ （干净数据）求解 PF-ODE。朴素方法——如 DDPM 的 1000 步采样——本质上是对 SDE 的欧拉-丸山离散化，每步都需要一次神经网络前向传播。实际应用中，我们希望将步数从数百步压缩到 10~20 步，同时保持图像质量。

核心挑战：少步高质量采样

每一次 ODE 求解器的”步” (step) 都需要调用一次噪声预测网络 ϵ_θ ，这是计算的瓶颈。因此，减少求解步数 = 减少网络推理次数 = 加速生成。目标是在 10~20 次网络评估 (NFE, Number of Function Evaluations) 内生成高质量图像。

2.2 欧拉法 (Euler Method)

给定 ODE $\frac{dx}{dt} = \mathbf{v}(\mathbf{x}, t)$ ，欧拉法是最简单的数值积分方案：

$$\mathbf{x}_{t+h} = \mathbf{x}_t + h \cdot \mathbf{v}(\mathbf{x}_t, t)$$

其中 h 为步长。直觉上，欧拉法假设在 $[t, t+h]$ 区间内速度场 $\mathbf{v}$ 不变，用起点处的速度做线性外推。

欧拉法的几何直觉

想象一条在二维平面上的曲线 (ODE 的真实轨迹)。欧拉法在当前点计算切线方向 (速度场)，然后沿切线走一小步。步长越小，近似越准确，但需要更多步。当步长较大时，直线近似偏离真实曲线，产生截断误差 (truncation error)。对于扩散模型，DDIM 的采样公式实际上就是对 PF-ODE 的一种欧拉离散化。

2.3 高阶 ODE 求解器概览

为了在较大步长下仍然保持精度，数值分析领域发展了大量高阶求解器：

求解器	阶数	每步 NFE
Euler (欧拉法)	1	1
Heun (改进欧拉法/梯形法)	2	2
Runge-Kutta 4 (RK4)	4	4
Dormand-Prince (DOPRI5)	5	6

表 1: 常见通用 ODE 求解器及其特性

通用求解器的局限性

上述求解器对任意 ODE 都适用，但它们没有利用 PF-ODE 的特殊结构。例如 Runge-Kutta 4 每步需要 4 次网络评估，在扩散模型场景下代价昂贵。DPM-Solver 的核心创新在于：利用 PF-ODE 的半线性结构，在**每步仅 1 次网络评估**的前提下实现高阶精度。

2.4 本章小结

欧拉法是最基础的 ODE 求解方案，也是 DDIM 采样的等价形式。通用高阶求解器 (如 RK4) 可以提高精度，但每步需要多次网络评估。本讲后续的重点是如何利用扩散模型 ODE 的特殊结构来设计”免费午餐”式的高阶求解器。

3 线性 ODE 与精确解

3.1 简单线性 ODE 的解析解

在讨论扩散模型的 ODE 之前，讲者从最简单的线性 ODE 入手建立直觉。考虑标量 ODE：

$$\frac{dx}{dt} = p(t) \cdot x(t)$$

其中 $p(t)$ 是已知的时间函数。假设 $x(t) > 0$ ，两边除以 $x(t)$ ：

$$\frac{1}{x(t)} \frac{dx}{dt} = p(t)$$

左侧恰好是 $\frac{d}{dt} \ln x(t)$ ，因此：

$$\ln x(t) - \ln x(s) = \int_s^t p(\tau) d\tau$$

线性 ODE 的精确解

$$x(t) = x(s) \cdot \exp\left(\int_s^t p(\tau) d\tau\right)$$

这个解是**解析**的——不需要任何离散化近似。对于线性 ODE，我们总能通过积分得到精确解。这一事实是后续推导的关键基石。

3.2 半线性 ODE 与积分因子法

扩散模型的 PF-ODE 不是纯线性的，而是**半线性**（semi-linear）的，形如：

$$\frac{d\mathbf{x}}{dt} = p(t) \cdot \mathbf{x}(t) + q(t)$$

其中 $p(t) \cdot \mathbf{x}$ 是线性部分， $q(t)$ 是非线性偏移项（在扩散模型中， $q(t)$ 包含噪声预测网络的输出）。为了解半线性 ODE，引入**积分因子**（integrating factor）：

$$\mu(t) = \exp\left(-\int_0^t p(\tau) d\tau\right)$$

$\mu(t)$ 是齐次方程 $\frac{dx}{dt} = p(t) \cdot x$ 的“逆解”。将 ODE 两边乘以 $\mu(t)$ ：

$$\mu(t) \frac{dx}{dt} - \mu(t) p(t) x(t) = \mu(t) q(t)$$

利用乘积求导法则，左侧化为 $\frac{d}{dt} [\mu(t)x(t)]$ ，积分后得到：

半线性 ODE 的精确解（Variation of Constants）

$$x(t) = \frac{\mu(s)}{\mu(t)} x(s) + \frac{1}{\mu(t)} \int_s^t \mu(\tau) q(\tau) d\tau$$

- 第一项：线性部分的精确解，只依赖初始值 $x(s)$ ，可以解析计算
- 第二项：非线性部分的积分，涉及 $q(\tau)$ （包含神经网络输出），通常需要数值近似

这就是**指数积分器**（Exponential Integrator）的基本形式：线性部分精确处理，仅对非线性部分做数值近似。

为什么叫“指数积分器”？

因为线性部分的精确解包含指数函数 $\exp(\cdot)$ 。传统欧拉法会对整个 ODE（线性 + 非线性）做近似，而指数积分器只对非线性部分做近似。在线性部分占主导的情况下（如扩散模型的 PF-ODE），这种拆分能显著提高精度。

3.3 带常数偏移项的精确解

作为练习，考虑带常数 q （不依赖 t ）的情形：

$$\frac{dx}{dt} = p(t) \cdot x(t) + c$$

将通解公式代入并化简，可以得到一个更紧凑的表达式。讲者在课上带学生推导了这一过程，核心思路是将 c 提出积分号外，然后利用 $\mu(t)$ 的性质化简。

3.4 本章小结

线性 ODE 有解析解；半线性 ODE 可以通过积分因子法将线性部分精确求解，仅剩非线性部分需要数值近似。这是 DPM-Solver 的数学基础。

4 DPM-Solver 的推导

4.1 PF-ODE 的半线性结构

回到扩散模型的 PF-ODE。利用噪声预测网络 ϵ_θ 和变分扩散模型参数化，PF-ODE 可以写成：

$$\frac{d\mathbf{x}}{dt} = \underbrace{f(t) \cdot \mathbf{x}(t)}_{\text{线性部分}} + \underbrace{g(t) \cdot \epsilon_\theta(\mathbf{x}_t, t)}_{\text{非线性部分}}$$

其中：

- $f(t)$ ：可由 α_t, σ_t 解析计算的漂移系数
- $g(t)$ ：可由 α_t, σ_t 解析计算的扩散相关系数
- $\epsilon_\theta(\mathbf{x}_t, t)$ ：噪声预测网络，是非唯一的非线性（需要神经网络评估的）部分

DPM-Solver 的核心观察

PF-ODE 具有半线性结构：线性部分 $f(t) \cdot \mathbf{x}$ 可以通过指数积分器**精确**求解，唯一需要数值近似的只有涉及 ϵ_θ 的非线性积分。这意味着我们可以最大限度地减少数值误差。

4.2 利用指数积分器求解

应用上一节的半线性 ODE 精确解，并将 λ_t 作为积分变量（替换时间 t ），可以得到：

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \alpha_t \int_{\lambda_s}^{\lambda_t} e^{-\lambda} \hat{\epsilon}_\theta(\lambda) d\lambda$$

其中：

- $\frac{\alpha_t}{\alpha_s} \mathbf{x}_s$: 线性部分的精确解
- $\hat{\epsilon}_\theta(\lambda) = \epsilon_\theta(\mathbf{x}_{\tau(\lambda)}, \tau(\lambda))$: 将噪声预测视为 λ 的函数
- 积分区间 $[\lambda_s, \lambda_t]$: 对应时间 $[s, t]$

变量替换 $t \rightarrow \lambda$ 的意义

将积分变量从时间 t 替换为 log-SNR λ 有两个好处: (1) 化简了系数中复杂的 α_t, σ_t 表达式, 使得积分核变为简单的 $e^{-\lambda}$; (2) λ 在噪声调度空间中均匀分布, 是更自然的积分变量。讲者强调这一步化简使得原本复杂的 ODE 变得出人意料地简洁。

进一步化简后, DPM-Solver 的核心公式为:

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t \int_{\lambda_s}^{\lambda_t} e^{\lambda - \lambda_t} \epsilon_\theta(\mathbf{x}_\lambda, \lambda) d\lambda$$

这个公式将求解 ODE 的问题转化为: 如何近似噪声预测的加权积分。不同阶次的近似对应不同阶次的 DPM-Solver。

4.3 一阶近似: DPM-Solver-1 即 DDIM

最简单的近似是假设在积分区间 $[\lambda_s, \lambda_t]$ 内, 噪声预测 ϵ_θ 为常数 (零阶泰勒展开):

$$\epsilon_\theta(\mathbf{x}_\lambda, \lambda) \approx \epsilon_\theta(\mathbf{x}_s, s) \quad \forall \lambda \in [\lambda_s, \lambda_t]$$

代入积分公式并计算 $e^{-\lambda}$ 的定积分, 可得:

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t (e^h - 1) \epsilon_\theta(\mathbf{x}_s, s)$$

其中 $h = \lambda_t - \lambda_s$ 。

DDIM 就是 DPM-Solver-1

将上式用 α_t, σ_t 展开, 可以验证这恰好就是 DDIM 的确定性采样公式! 也就是说, DDIM 并非对 PF-ODE 做整体欧拉离散化, 而是利用了半线性结构做**指数积分**——线性部分精确处理, 仅对噪声预测做零阶近似。这解释了为什么 DDIM 比直接欧拉法效果更好。

常见误解: DDIM 不等于朴素欧拉法

很多人认为 DDIM 就是对 PF-ODE 做欧拉离散化。实际上, DDIM 是对 PF-ODE 做一阶**指数积分**——它精确处理了线性部分, 只对非线性噪声预测做了零阶近似。这种微妙的区别在精度上有本质差异, 特别是在步数较少时。

4.4 本章小结

DPM-Solver 的推导利用了 PF-ODE 的半线性结构, 通过指数积分器精确处理线性部分, 将数值近似限定在噪声预测的积分上。一阶 DPM-Solver 等价于 DDIM。

5 高阶 DPM-Solver

5.1 二阶近似: DPM-Solver-2

一阶近似假设 ϵ_θ 在整个区间内为常数。自然的改进是使用一阶泰勒展开（线性近似），利用两个点的噪声预测值来拟合 ϵ_θ 的变化趋势。

DPM-Solver-2 的算法步骤如下：

步骤 1: 计算中间点

给定当前时间步 s 和目标时间步 t ，选取中间时间点 r （通常取区间中点），用一阶 DPM-Solver 计算中间值：

$$\mathbf{u} = \frac{\alpha_r}{\alpha_s} \mathbf{x}_s - \sigma_r(e^{h_1} - 1) \epsilon_\theta(\mathbf{x}_s, s)$$

其中 $h_1 = \lambda_r - \lambda_s$ 。

步骤 2: 利用中间点的噪声预测更新

在中间点 r 处重新评估噪声预测 $\epsilon_\theta(\mathbf{u}, r)$ ，然后用两点信息做线性插值近似积分：

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t(e^h - 1) \epsilon_\theta(\mathbf{x}_s, s) - \frac{\sigma_t}{2h_1}(e^h - 1 - h) [\epsilon_\theta(\mathbf{u}, r) - \epsilon_\theta(\mathbf{x}_s, s)]$$

其中 $h = \lambda_t - \lambda_s$ 。

二阶近似的键思想

DPM-Solver-2 每步需要 2 次网络评估（ s 处和 r 处），但获得了二阶精度。与通用的 Heun 方法不同，DPM-Solver-2 利用了 PF-ODE 的半线性结构，因此在相同 NFE 下精度更高。

5.2 三阶及更高阶近似

遵循同样的思路，可以继续做二阶泰勒展开得到 DPM-Solver-3：在区间内选取两个中间点，利用三个噪声预测值来构造二次多项式近似 ϵ_θ 在 λ 空间中的变化。

递归结构

DPM-Solver 的阶次提升具有递归结构：

- k 阶 DPM-Solver 需要 k 次网络评估
- 先用低阶 DPM-Solver 计算 $k - 1$ 个中间点
- 利用所有 k 个噪声预测值构造 $(k - 1)$ 次多项式近似
- 将多项式代入积分公式解析积分

实践中，2 阶和 3 阶已经足够好。超过 3 阶后，收益递减，因为噪声预测网络本身的近似误差成为瓶颈。

5.3 各阶 DPM-Solver 对比

方法	每步 NFE	精度阶数	备注
DDPM	1	约 0.5 阶	朴素欧拉-丸山离散化
DDIM / DPM-Solver-1	1	1 阶	指数积分 + 零阶噪声近似
DPM-Solver-2	2	2 阶	指数积分 + 一阶噪声近似
DPM-Solver-3	3	3 阶	指数积分 + 二阶噪声近似

表 2: DPM-Solver 各阶方法的特性比较

5.4 本章小结

高阶 DPM-Solver 通过在 λ 空间中对噪声预测做高阶多项式近似，在每步仅增加少量网络评估的代价下获得更高精度。这种递归构造使得从一阶到三阶的提升在概念上非常自然。

6 DPM-Solver++ 与实践改进

6.1 从噪声预测到数据预测

DPM-Solver 的原始公式基于噪声预测 ϵ_θ 。DPM-Solver++ 提出了一个关键改进：转而对**数据预测** (data prediction) $\hat{\mathbf{x}}_0$ 做多项式近似。

由 $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \epsilon$ 可得：

$$\hat{\mathbf{x}}_0(\mathbf{x}_t, t) = \frac{\mathbf{x}_t - \sigma_t \epsilon_\theta(\mathbf{x}_t, t)}{\alpha_t}$$

DPM-Solver++ 的核心改进

DPM-Solver++ 将积分对象从 ϵ_θ 换为 $\hat{\mathbf{x}}_0$ 。两者在数学上等价，但在有限步数下， $\hat{\mathbf{x}}_0$ 的变化通常比 ϵ_θ 更平滑，多项式近似误差更小。实验表明，DPM-Solver++ 在较少步数（如 10~15 步）时显著优于原始 DPM-Solver。

为什么数据预测更平滑？

直觉上， $\hat{\mathbf{x}}_0$ 是“去噪后的干净图像估计”，它在采样过程中逐渐收敛到最终图像。相比之下， ϵ_θ （噪声估计）随时间步的变化更剧烈，特别是在噪声水平发生快速变化的区域。因此，对 $\hat{\mathbf{x}}_0$ 做低阶多项式近似更合理。

6.2 多步法 (Multistep Method)

除了单步法（每步从头计算中间点），DPM-Solver++ 还支持**多步法**：利用前几步已经计算过的噪声预测值来构造高阶近似，而无需额外的网络评估。

例如，二阶多步 DPM-Solver++：

1. 在第 i 步，已有 $\epsilon_\theta(\mathbf{x}_{t_i}, t_i)$ 和 $\epsilon_\theta(\mathbf{x}_{t_{i-1}}, t_{i-1})$
2. 用这两个值做线性外推来近似区间内的噪声变化
3. 代入指数积分公式计算 $\mathbf{x}_{t_{i+1}}$

多步法的优势

多步法在每步只需 1 次网络评估 (NFE=1)，但仍可达到 2 阶甚至 3 阶精度。代价是需要保存前几步的噪声预测缓存。在固定步数预算下，多步法通常是最具性价比的选择。

6.3 时间步调度策略

DPM-Solver 的性能还受到时间步选取策略的影响。常见策略包括：

- **均匀时间步**：在 $t \in [0, T]$ 上等间距分割
- **均匀 λ 步**：在 $\lambda \in [\lambda_T, \lambda_0]$ 上等间距分割——这通常更好，因为 λ 空间的均匀性与 ODE 的数值误差分布更匹配
- **自适应步长**：根据误差估计动态调整步长（如 DOPRI5 中的方法）

不当的时间步选取会严重降低性能

在 t 空间均匀分割时，低噪声区域 (t 接近 0) 的步长在 λ 空间中过大，导致近似误差集中在最后几步——而这恰恰是图像细节被确定的关键阶段。因此，在 λ 空间中均匀分割通常是更安全的默认选择。

6.4 本章小结

DPM-Solver++ 通过对数据预测（而非噪声预测）做多项式近似来改善有限步精度，并引入多步法以在每步 1 NFE 的代价下实现高阶精度。时间步调度（特别是在 λ 空间均匀分割）对最终性能也有重要影响。

7 实验结果与性能分析

7.1 FID 对比

讲者展示了不同采样方法在 CIFAR-10 等数据集上的 FID (Frechet Inception Distance) 对比：

- **DDPM** (1000 步)：FID 约 3~4 (基线)
- **DDIM** (100 步)：FID 有明显退化，约 5~8
- **DDIM** (10 步)：FID 大幅恶化，约 20+
- **DPM-Solver-2** (15~20 步)：FID 接近 DDPM 1000 步的水平
- **DPM-Solver-3** (10~15 步)：FID 达到甚至优于 DDPM 1000 步

关键结果

使用 DPM-Solver-3，仅需 15 步即可达到 DDPM 1000 步的采样质量。这意味着约 **70 倍** 的加速，且**无需重新训练模型**——完全在推理阶段通过更优的 ODE 求解器实现。这也是讲者反复强调的一个亮点：不同的数学视角 (SDE $\rightarrow$ ODE $\rightarrow$ 半线性结构 $\rightarrow$ 指数积分器) 可以直接转化为实际性能提升。

7.2 不同阶次的收敛行为

阶次与步数的关系

- 步数充足 (> 50) 时, 各阶 DPM-Solver 差异不大, 因为欧拉法本身误差已经很小
- 步数较少 ($10 \sim 20$) 时, 高阶方法优势显著, 二阶比一阶好一个数量级
- 步数极少 (< 10) 时, 三阶比二阶仍有提升, 但收益递减
- 超过三阶后, 网络本身的近似误差 ($\epsilon_\theta \neq \epsilon^*$) 成为瓶颈

7.3 与其他加速方法的关系

DPM-Solver 属于 **Training-free** (无需额外训练) 的采样加速方法。与之互补的还有:

方法	需要训练?	核心思路
DPM-Solver/DDIM	否	更好的 ODE 离散化
知识蒸馏 (Progressive Distillation)	是	学生模型模仿多步教师
一致性模型 (Consistency Models)	是	直接学习从噪声到数据的映射
Flow Matching + Euler	否	更直的轨迹, 欧拉法更有效

表 3: 不同采样加速策略的比较

DPM-Solver 与 Flow Matching 的互补

Flow Matching 通过训练使 ODE 轨迹更直 (接近线性), 从而让欧拉法就能工作得很好。DPM-Solver 则是在给定 (可能弯曲的) ODE 轨迹上寻找更好的数值求解方案。两者的思路正交且互补: 如果 ODE 轨迹已经很直, DPM-Solver 的优势会减小; 但对于标准扩散模型的弯曲轨迹, DPM-Solver 的价值就非常显著。

7.4 本章小结

实验证明, DPM-Solver 在不重新训练模型的前提下, 将采样步数从 1000 步压缩到 10~20 步, 实现了数十倍的加速。其核心优势在于利用了扩散模型 ODE 的半线性结构, 这是通用 ODE 求解器无法做到的。

8 理论深入: 从 DDIM 到 DPM-Solver 的统一视角

8.1 DDIM 采样公式的重新推导

讲者在课上带学生将 DPM-Solver-1 的结果逐项展开, 验证其等价于 DDIM: 从 DPM-Solver-1 的公式出发:

$$\mathbf{x}_t = \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t(e^h - 1) \epsilon_\theta(\mathbf{x}_s, s)$$

其中 $h = \lambda_t - \lambda_s = \log \frac{\alpha_t}{\sigma_t} - \log \frac{\alpha_s}{\sigma_s} = \log \frac{\alpha_t \sigma_s}{\sigma_t \alpha_s}$ 。

因此 $e^h = \frac{\alpha_t \sigma_s}{\sigma_t \alpha_s}$, $e^h - 1 = \frac{\alpha_t \sigma_s - \sigma_t \alpha_s}{\sigma_t \alpha_s}$ 。

代入：

$$\begin{aligned}\mathbf{x}_t &= \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \sigma_t \cdot \frac{\alpha_t \sigma_s - \sigma_t \alpha_s}{\sigma_t \alpha_s} \cdot \epsilon_\theta(\mathbf{x}_s, s) \\ &= \frac{\alpha_t}{\alpha_s} \mathbf{x}_s - \frac{\alpha_t \sigma_s - \sigma_t \alpha_s}{\alpha_s} \cdot \epsilon_\theta(\mathbf{x}_s, s)\end{aligned}$$

统一视角

这正是 DDIM 在连续时间参数化下的采样公式。通过这一推导，我们看到了扩散模型不同理解方式之间的深层联系：

1. DDPM $\rightarrow$ DDIM (Song et al., 2020)：从随机采样到确定性采样
2. SDE $\rightarrow$ PF-ODE (Song et al., 2021)：从随机过程到确定性流
3. PF-ODE $\rightarrow$ 指数积分 (Lu et al., 2022)：从通用数值方法到结构化求解

DDIM 恰好位于最后一条线的一阶近似位置——它不是“发明”出来的，而是扩散模型 ODE 结构的自然产物。

8.2 λ 空间中的 Taylor 展开

DPM-Solver 各阶方法的统一框架可以用 ϵ_θ 在 λ 空间的 Taylor 展开来理解：

$$\epsilon_\theta(\lambda) = \epsilon_\theta(\lambda_s) + (\lambda - \lambda_s) \epsilon'_\theta(\lambda_s) + \frac{(\lambda - \lambda_s)^2}{2} \epsilon''_\theta(\lambda_s) + \dots$$

- **零阶截断** ($\epsilon_\theta \approx$ 常数) $\rightarrow$ DPM-Solver-1 = DDIM
- **一阶截断** ($\epsilon_\theta \approx$ 线性) $\rightarrow$ DPM-Solver-2
- **二阶截断** ($\epsilon_\theta \approx$ 二次) $\rightarrow$ DPM-Solver-3

高阶导数 $\epsilon'_\theta(\lambda_s)$ 无法解析获得（因为 ϵ_θ 是神经网络），但可以用有限差分来近似——这就是为什么需要在中间点额外评估网络。

8.3 本章小结

从 Taylor 展开的视角，DPM-Solver 的各阶方法形成了一个自然的精度递增族。DDIM 作为一阶特例的身份被揭示，高阶方法则是在 λ 空间中对噪声预测做更精细的多项式拟合。

9 实践指南

9.1 推荐配置

根据讲者的讨论和 DPM-Solver 的实践经验，以下是不同场景的推荐配置：

场景	推荐方法	步数
快速预览 / 交互式应用	DPM-Solver++(2M)	10~15
高质量生成	DPM-Solver++(2M)	20~25
最高质量（不计速度）	DPM-Solver++(3M)	25~50

表 4: 不同场景下的推荐 DPM-Solver 配置 (2M = 二阶多步法, 3M = 三阶多步法)

9.2 实现要点

实现中的常见陷阱

1. **数值稳定性**: e^λ 在 λ 值较大时可能溢出, 需要使用 $\log$ -space 计算
2. **时间步方向**: 扩散模型的”前向”是加噪 ($t: 0 \rightarrow T$), ”逆向”是去噪 ($t: T \rightarrow 0$)。ODE 求解的方向是逆向的, $h = \lambda_t - \lambda_s$ 通常为正值 (因为 λ 随去噪递增)
3. **多步法的预热**: 二阶多步法在第一步没有历史缓存, 需回退到一阶单步法
4. **与 Classifier-free Guidance 的兼容性**: CFG 会改变有效的 ODE, DPM-Solver++ 对此做了专门的适配

DPM-Solver 在主流框架中的集成

DPM-Solver/DPM-Solver++ 已被广泛集成在主流扩散模型库中:

- **Diffusers** (Hugging Face): `DPMSolverMultistepScheduler`
- **k-diffusion**: 作为默认采样器之一
- **Stable Diffusion WebUI**: 在 Sampler 下拉菜单中可选

在实际使用中, 通常只需将 scheduler/sampler 切换为 DPM-Solver++, 即可享受加速效果, 无需修改模型本身。

9.3 本章小结

DPM-Solver++ 的二阶多步法 (2M) 是实际应用中的最佳默认选择, 兼顾速度和质量。实现时需注意数值稳定性和多步法预热等细节。

10 总结与延伸

10.1 核心要点回顾

本讲围绕”如何高效求解扩散模型的逆过程 ODE”展开, 核心贡献如下:

1. **半线性结构的发现**: PF-ODE 的右端项可以分解为线性部分 (可精确求解) 和非线性部分 (需要数值近似), 这为高效求解提供了基础
2. **指数积分器的应用**: 通过积分因子法精确处理线性部分, 将数值近似限定在噪声预测的积分上

3. **λ 空间的参数化**: 用 $\log\text{-SNR}$ 做变量替换, 大幅简化积分表达式
4. **DDIM 的重新诠释**: DDIM 是 DPM-Solver 的一阶特例, 而非朴素欧拉法
5. **高阶方法的递归构造**: 通过在 λ 空间对噪声预测做高阶多项式近似, 以少量额外 NFE 换取显著精度提升
6. **DPM-Solver++**: 转为对数据预测做多项式近似, 进一步提升有限步精度

10.2 更广阔的视角

为什么数学理解如此重要

讲者在课程中反复强调: 所有这些加速都是在**不改变训练模型**的前提下实现的。这深刻体现了一个原则——对问题结构的数学理解可以直接转化为实际性能提升。从 DDPM 到 DDIM 到 DPM-Solver, 每一步都是对同一个扩散过程的更深入理解。

10.3 后续发展

DPM-Solver 之后, 扩散模型的加速采样继续快速发展:

- **一致性模型** (Consistency Models, Song et al., 2023): 学习直接从噪声跳到数据的映射, 可实现单步生成
- **渐进蒸馏** (Progressive Distillation, Salimans & Ho, 2022): 通过知识蒸馏将多步过程压缩为少步
- **Flow Matching** (Lipman et al., 2022): 设计更直的传输路径, 使得简单的欧拉法即可高效工作
- **Rectified Flow** (Liu et al., 2022): 通过 Reflow 操作使 ODE 轨迹趋于直线

10.4 拓展阅读

- Lu, C., et al. (2022). *DPM-Solver: A Fast ODE Solver for Diffusion Probabilistic Model Sampling in Around 10 Steps*. NeurIPS 2022.
- Lu, C., et al. (2022). *DPM-Solver++: Fast Solver for Guided Sampling of Diffusion Probabilistic Models*. arXiv:2211.01095.
- Song, J., et al. (2020). *Denoising Diffusion Implicit Models*. ICLR 2021.
- Song, Y., et al. (2021). *Score-Based Generative Modeling through Stochastic Differential Equations*. ICLR 2021.
- Karras, T., et al. (2022). *Elucidating the Design Space of Diffusion-Based Generative Models*. NeurIPS 2022.