

课程笔记

KAIST CS492D Lecture 9: Flow Matching 1

基于 Minhyuk Sung 授课内容整理

2025 年秋季

CS492C: Diffusion and Flow Models

Flow Matching 1

LECTURE 10
MINHYUK SUNG

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Minhyuk Sung (KAIST)

发布日期: 2025

视频时长: 53 分钟

视频链接: <https://www.youtube.com/watch?v=-1hgQC58Nfc>

目录

1 课程背景与回顾	2
1.1 扩散模型的速度瓶颈	2
1.2 Consistency Models 简介	3
1.3 本章小结	3
2 从扩散模型到流模型：范式转换	3
2.1 时间方向的翻转	3
2.2 扩散模型与流模型的关键区别	4
2.3 本章小结	4
3 连续正则化流 (CNF) 的基本框架	4
3.1 三个核心概念	4
3.2 流映射 (Flow Map)	4
3.3 向量场 (Vector Field)	5
3.4 概率密度路径 (Probability Density Path)	5
3.5 三者之间的关系	5
3.6 对数概率的计算	6
3.7 本章小结	6
4 Flow Matching 目标函数	6
4.1 朴素方法：全局最大似然训练	6
4.2 Flow Matching 目标：回归向量场	7
4.3 本章小结	7
5 条件流匹配 (Conditional Flow Matching)	7
5.1 条件设定的动机	7
5.2 条件概率路径	7
5.3 条件流映射	8
5.4 条件向量场	8
5.5 从条件量到边际量	9
5.6 本章小结	9
6 具体的 Flow Matching 变体	9
6.1 最简选择：Optimal Transport 路径	9
6.2 与扩散模型中 VP/VE 调度的对应	10
6.3 直线轨迹 vs 弯曲轨迹	11
6.4 本章小结	11
7 Flow Matching 与扩散模型的统一视角	11
7.1 等价性的建立	11
7.2 Flow Matching 的优势	11
7.3 本章小结	12

8	训练与推理流程	12
8.1	训练算法	12
8.2	推理（采样）算法	13
8.3	本章小结	13
9	总结与延伸	13
9.1	本讲要点回顾	13
9.2	拓展阅读	14

1 课程背景与回顾

本讲是 KAIST CS492D（扩散模型与生成模型）的第 9 讲，主题为 **Flow Matching**（流匹配）。在前几讲中，我们已经详细讨论了扩散模型（Diffusion Models）的各种变体——从 DDPM 到 DDIM，再到基于 SDE/ODE 的 Score-Based 模型和 DPM-Solver 等加速技术。本讲将从一个全新的角度引入生成模型：**Continuous Normalizing Flows**（连续正则化流）和 **Flow Matching**（流匹配）。

课程脉络回顾

在前面的课程中，我们建立了以下认知链条：

1. **DDPM**：离散时间步的去噪扩散模型，典型需要 1000 步采样
2. **DDIM**：确定性采样，将步数降至 50–200 步
3. **Score-Based SDE**：将扩散过程统一为随机微分方程（SDE）框架
4. **Probability Flow ODE**：从 SDE 导出等价的 ODE 形式，实现确定性生成
5. **DPM-Solver**：利用 ODE 结构的专用求解器，进一步将步数降至 10–15 步

本讲的 Flow Matching 将提供另一种理解和训练 ODE-based 生成模型的方式。

1.1 扩散模型的速度瓶颈

扩散模型的核心优势在于能够生成高质量、无模式崩塌（mode collapse）的输出。但其主要瓶颈始终是**采样速度**：

方法	典型步数	是否需要重新训练
DDPM	~1000	否
DDIM	50–200	否
DPM-Solver (高阶)	10–15	否
Consistency Models	1–2	是（微调）
Distillation 方法	1–5	是（微调）

表 1: 扩散模型采样加速方法对比

讲者指出，DDPM 到 DPM-Solver 的演进实现了约 **100 倍** 的加速，且不需要重新训练模型——这是扩散模型非常有吸引力的特性。但要进一步将步数降至 1–5 步，则需要 distillation 等额外训练手段。

1.2 Consistency Models 简介

Consistency Models 的核心思想

Consistency Models 的基本思想是：对于 ODE 轨迹上的所有点，训练网络使其能从轨迹的任意中间点直接预测最终输出。具体来说：

1. 从标准高斯样本出发，运行 ODE 求解器获得完整轨迹
2. 对轨迹上的每个中间点 x_t ，利用 Tweedie 公式计算最终输出的期望
3. 训练网络使得较早时刻的预测与较晚时刻的预测保持一致 (consistent)

这样，在推理时只需一步或两步即可从噪声直接跳到数据样本。

Consistency Models 和其他 distillation 方法的共同缺点是：它们都需要预训练的扩散模型作为起点，通过额外的微调来实现加速。这意味着需要在训练阶段投入更多计算资源，以换取测试时更快的速度。

1.3 本章小结

从 DDPM 到 Consistency Models，扩散模型社区在采样加速方面取得了巨大进展。然而，这些方法要么受限于特定的噪声调度 (noise schedule)，要么需要复杂的蒸馏训练。Flow Matching 将从一个完全不同的角度出发，提供更灵活、更简洁的生成模型训练框架。

2 从扩散模型到流模型：范式转换

2.1 时间方向的翻转

在正式引入 Flow Matching 之前，讲者特别强调了一个**极易混淆**的符号约定变化：

时间方向的翻转——最容易混淆的地方

扩散模型的时间方向（前向过程视角）：

- $t = 0$ ：数据分布 p_{data}
- $t = T$ ：噪声分布（标准高斯） $\mathcal{N}(0, I)$

Flow Matching 的时间方向（生成过程视角）：

- $t = 0$ ：噪声分布（标准高斯） $p_0 = \mathcal{N}(0, I)$
- $t = 1$ ：数据分布 $p_1 = p_{\text{data}}$

也就是说， x_0 在 Flow Matching 中代表高斯噪声样本， x_1 代表真实数据样本。这与扩散模型的习惯完全相反！

讲者坦言，即使是他本人也经常被这两套符号搞混。之所以保留这种不一致，是因为扩散模型和流匹配分别来自不同的文献传统，各自的论文和教材都遵循各自的约定。

2.2 扩散模型与流模型的关键区别

核心区别：参考分布的灵活性

扩散模型中，所有推导都假设参考分布（噪声分布）是标准高斯分布 $\mathcal{N}(0, I)$ 。如果更换为其他分布（如各向异性高斯），所有数学推导都需要重新进行。

流模型的一大优势是：参考分布 p_0 可以是**任意分布**。无论 p_0 怎么变化，流匹配的数学公式保持不变。这使得流模型可以被看作扩散模型的一种**泛化**。

尽管两者来自不同的文献传统，最终它们在数学上是等价的（在标准高斯参考分布的特殊情况下）。这也是本讲要揭示的一个重要洞见。

2.3 本章小结

Flow Matching 从生成过程的视角出发，将时间方向翻转，并允许任意参考分布。虽然最终可以与扩散模型建立等价关系，但这种新视角带来了更简洁的训练目标和更灵活的模型设计空间。

3 连续正则化流（CNF）的基本框架

3.1 三个核心概念

Flow Matching 的数学框架围绕三个核心概念展开，它们之间存在紧密的相互联系：

Flow Matching 的三大核心概念

1. **流映射** (Flow Map) $\phi_t(x)$: 从起始点 x 出发，沿轨迹到达时刻 t 的位置
2. **向量场** (Vector Field) $v_t(x)$: 定义 ODE 中每个时空点处的速度方向
3. **概率密度路径** (Probability Density Path) $p_t(x)$: 时刻 t 处数据点的概率分布

这三者之间的关系贯穿整个 Flow Matching 理论。

3.2 流映射 (Flow Map)

流映射 $\phi_t(x_0)$ 表示从初始点 x_0 （来自参考分布 p_0 ）出发，经过时间 t 后到达的位置。形式化定义为：

$$\phi_t(x_0) = x_0 + \int_0^t v_s(\phi_s(x_0)) ds$$

其中各符号的含义为：

- $\phi_t(x_0)$: 从 x_0 出发，在时刻 t 的轨迹位置
- $v_s(\cdot)$: 时刻 s 处的向量场（速度场）
- $\phi_0(x_0) = x_0$: 边界条件， $t = 0$ 时轨迹起点就是 x_0 本身
- $\phi_1(x_0) \sim p_1$: 边界条件， $t = 1$ 时应到达数据分布的样本

ODE 与流映射的关系

流映射本质上是以下常微分方程 (ODE) 的解:

$$\frac{d\phi_t(x_0)}{dt} = v_t(\phi_t(x_0)), \quad \phi_0(x_0) = x_0$$

这里**没有随机性**——一旦确定了起始点 x_0 和向量场 v_t , 整条轨迹就完全确定了。这也是 "Ordinary" Differential Equation 中 "Ordinary" 的含义——相对于 SDE 中的随机项。

有时为了简化符号, 我们会用 x_t 来表示 $\phi_t(x_0)$, 即从 x_0 出发在时刻 t 的轨迹点。

3.3 向量场 (Vector Field)

向量场 $v_t(x)$ 定义了每个时空点 (t, x) 处的 "速度"。它是流映射的时间导数:

$$v_t(\phi_t(x_0)) = \frac{d\phi_t(x_0)}{dt}$$

向量场编码了从噪声到数据的映射信息。如果我们能找到一个好的向量场, 使得从 p_0 采样的点能被映射到 p_1 (数据分布), 那么我们就得到了一个生成模型。

3.4 概率密度路径 (Probability Density Path)

概率密度路径 $p_t(x)$ 描述了时刻 t 处数据点 x 的概率密度。它满足以下性质:

- $p_0 = \mathcal{N}(0, I)$ (参考分布, 通常为标准高斯)
- $p_1 \approx p_{\text{data}}$ (数据分布)
- 中间时刻 p_t 是从 p_0 到 p_1 的插值

连续性方程 (Continuity Equation)

向量场和概率密度路径之间的关系由**连续性方程**给出:

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (p_t(x)v_t(x)) = 0$$

这是 Fokker-Planck 方程在无扩散项 (即 ODE 而非 SDE) 情况下的简化形式。它建立了向量场和概率路径之间的精确数学联系。

3.5 三者之间的关系

在扩散模型中, 我们的推导路径是:

$$\text{概率密度路径 } p_t \rightarrow \text{SDE/ODE 形式} \rightarrow \text{向量场 } v_t \rightarrow \text{流映射 } \phi_t$$

而在 Flow Matching 中, 我们走的是**相反的路径**:

$$\text{向量场 } v_t \rightarrow \text{流映射 } \phi_t \rightarrow \text{概率密度路径 } p_t$$

也就是说, 我们先定义向量场, 再由它推导出流映射和概率路径。

3.6 对数概率的计算

向量场还可以用来计算数据点的对数概率。对于 $x_1 \sim p_1$ ，其对数似然可以通过以下方式计算：

$$\log p_1(x_1) = \log p_0(x_0) - \int_0^1 \nabla \cdot v_t(\phi_t(x_0)) dt$$

其中各项的含义为：

- $\log p_0(x_0)$ ：起始点在参考分布下的对数概率（高斯分布，已知解析形式）
- $\nabla \cdot v_t$ ：向量场的散度（divergence）
- 积分项：沿轨迹的体积变化累积

这意味着，如果我们能找到一个使 $\log p_1(x_1)$ 最大化的向量场，就能训练出一个好的生成模型。

3.7 本章小结

连续正则化流（CNF）的框架由三个核心概念构成：流映射、向量场和概率密度路径。它们之间通过 ODE 和连续性方程相互联系。与扩散模型不同，CNF 直接从向量场出发定义生成过程，提供了更直接的数学框架。

4 Flow Matching 目标函数

4.1 朴素方法：全局最大似然训练

一种直觉方法是直接最大化数据的对数似然：

$$\max_{\theta} \mathbb{E}_{x_1 \sim p_{\text{data}}} [\log p_1(x_1)]$$

具体来说：

1. 用神经网络 $v_{\theta}(t, x)$ 参数化向量场
2. 对每个数据点 x_1 ，从 x_1 出发反向运行 ODE 到 x_0
3. 计算 $\log p_0(x_0) - \int_0^1 \nabla \cdot v_{\theta}(t, \phi_t) dt$
4. 最大化这个值

朴素方法的致命缺陷

虽然这个方法在理论上是正确的，但在实践中存在严重问题：

1. **计算代价高**：每次计算损失函数都需要求解 ODE，这本身就是一个昂贵的操作
2. **数值不稳定**：ODE 求解器在长时间积分时容易产生数值误差累积
3. **反向传播困难**：梯度需要通过整个 ODE 求解过程反向传播（需要 adjoint method），进一步增加计算成本和不确定性

这就是早期 Continuous Normalizing Flows（如 Neural ODE, Chen et al., 2018）面临的核心困难。

4.2 Flow Matching 目标：回归向量场

Flow Matching 的核心突破在于：**绕过 ODE 求解**，直接用简单的回归损失来训练向量场。
Flow Matching 的损失函数定义为：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1], x_t \sim p_t} \|v_\theta(t, x_t) - v_t(x_t)\|^2$$

其中各符号的含义为：

- $v_\theta(t, x_t)$: 神经网络预测的向量场
- $v_t(x_t)$: 目标向量场 (ground truth)
- $t \sim \mathcal{U}[0, 1]$: 均匀采样时间步
- $x_t \sim p_t$: 从时刻 t 的边际分布中采样

Flow Matching 的核心优势

这个损失函数是一个简单的**均方误差回归**，不需要求解任何 ODE！但问题在于：我们并不知道边际向量场 $v_t(x_t)$ 和边际分布 $p_t(x_t)$ 的解析形式——因为数据分布 p_{data} 本身就是未知的。这就引出了 Flow Matching 的关键创新：**Conditional Flow Matching**。

4.3 本章小结

直接最大化似然需要昂贵的 ODE 求解，而 Flow Matching 提出了简洁的回归目标函数。但边际量的不可解析性要求我们进一步引入条件版本的公式。

5 条件流匹配 (Conditional Flow Matching)

5.1 条件设定的动机

边际分布 $p_t(x)$ 和边际向量场 $v_t(x)$ 都没有解析表达式，因为它们依赖于未知的数据分布。为了解决这个问题，Flow Matching 引入了**条件版本**的各个量。

核心思想是：给定一个具体的数据点 x_1 ，将数据分布“简化”为一个集中在 x_1 附近的高斯分布 $\mathcal{N}(x_1, \sigma_{\min}^2 I)$ (其中 $\sigma_{\min}$ 极小)。这样，所有条件量都有了解析表达式。

条件设定与扩散模型的前向过程

这个条件设定与扩散模型中的前向跳跃分布 (forward transition kernel) 有着深刻的联系。在扩散模型中，给定一个数据点 x_0 (注意扩散模型的符号约定)，前向过程定义了每个时间步的条件分布 $q(x_t|x_0) = \mathcal{N}(\alpha_t x_0, \sigma_t^2 I)$ 。

在 Flow Matching 中，我们做了类似的事情：给定数据点 x_1 ，定义条件概率路径 $p_t(x|x_1)$ 。两者的数学结构完全相同，只是时间方向相反。

5.2 条件概率路径

给定数据样本 x_1 ，条件概率路径定义为：

$$p_t(x|x_1) = \mathcal{N}(x; \mu_t(x_1), \sigma_t^2(x_1)I)$$

其中 μ_t 和 σ_t 必须满足**边界条件**：

- $t = 0$ 时： $\mu_0(x_1) = 0$, $\sigma_0(x_1) = 1$, 使得 $p_0(x|x_1) = \mathcal{N}(0, I)$
- $t = 1$ 时： $\mu_1(x_1) \approx x_1$, $\sigma_1(x_1) \approx \sigma_{\min} \rightarrow 0$, 使得 $p_1(x|x_1) \approx \delta(x - x_1)$

边际概率路径通过对所有数据点积分恢复：

$$p_t(x) = \int p_t(x|x_1) p_{\text{data}}(x_1) dx_1$$

5.3 条件流映射

线性条件流映射——Flow Matching 的简洁之美

Flow Matching 的一个关键设计选择是将条件流映射定义为**线性函数**：

$$\phi_t(x_0|x_1) = \mu_t(x_1) + \sigma_t(x_1) \cdot x_0$$

这意味着，给定数据点 x_1 和噪声样本 x_0 ，从 x_0 到 x_1 的轨迹是一条**直线**（在 μ_t 和 σ_t 为线性函数时）。

必须满足边界条件：

- $\phi_0(x_0|x_1) = x_0$ ($t = 0$ 时，输出就是噪声样本)
- $\phi_1(x_0|x_1) \approx x_1$ ($t = 1$ 时，输出接近数据样本)

线性条件流映射的好处是：

1. 条件概率路径自然成为高斯分布
2. 条件向量场有解析表达式
3. 采样过程简单高效

5.4 条件向量场

从条件流映射的定义出发，条件向量场可以通过对时间求导获得：

$$u_t(x|x_1) = \frac{d\phi_t(x_0|x_1)}{dt} = \mu'_t(x_1) + \sigma'_t(x_1) \cdot x_0$$

其中 μ'_t 和 σ'_t 分别是 μ_t 和 σ_t 对时间 t 的导数。

由于 $x_0 = (\phi_t^{-1}(x|x_1)) = \frac{x - \mu_t(x_1)}{\sigma_t(x_1)}$ ，条件向量场可以写成关于 x 的函数：

$$u_t(x|x_1) = \mu'_t(x_1) + \frac{\sigma'_t(x_1)}{\sigma_t(x_1)} (x - \mu_t(x_1))$$

不要混淆条件量和边际量

条件向量场 $u_t(x|x_1)$ 依赖于具体的数据点 x_1 ，而我们最终需要的是不依赖于 x_1 的**边际向量场** $v_t(x)$ 。条件向量场本身不能直接用于生成（因为生成时我们不知道目标 x_1 ），但它是训练过程中的关键中间量。

5.5 从条件量到边际量

边际向量场可以通过条件向量场和条件概率路径的加权平均得到：

$$v_t(x) = \frac{\int u_t(x|x_1) p_t(x|x_1) p_{\text{data}}(x_1) dx_1}{p_t(x)}$$

Conditional Flow Matching 的核心定理

Flow Matching 的关键理论结果是：使用条件向量场训练的损失函数——

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x_1 \sim p_{\text{data}}, x_0 \sim p_0} \|v_\theta(t, \phi_t(x_0|x_1)) - u_t(\phi_t(x_0|x_1)|x_1)\|^2$$

——与原始的 Flow Matching 损失函数 $\mathcal{L}_{\text{FM}}(\theta)$ 具有**相同的梯度**（关于参数 θ ）。

这意味着我们可以用条件损失来等价地训练边际向量场，而条件损失中的所有量都有解析表达式！

5.6 本章小结

Conditional Flow Matching 通过引入条件设定，将不可解析的边际量转化为有解析形式的条件量。关键的理论保证是：条件损失函数和边际损失函数具有相同的梯度，因此训练效果等价。这就是 Flow Matching 能够避免 ODE 求解的根本原因。

6 具体的 Flow Matching 变体

6.1 最简选择：Optimal Transport 路径

最简单也最常用的选择是 **Optimal Transport (OT) 条件流映射**，也称为 rectified flow：

$$\phi_t(x_0|x_1) = (1-t)x_0 + tx_1$$

对应的参数为：

- $\mu_t(x_1) = tx_1$
- $\sigma_t(x_1) = 1-t$

这就是 x_0 和 x_1 之间的**线性插值**，对应的条件轨迹是一条**直线**。

OT 路径的向量场与训练目标

对于 OT 路径，条件向量场极其简洁：

$$u_t(x|x_1) = x_1 - x_0$$

这是一个**常数向量**（不依赖于 t ），方向从 x_0 指向 x_1 。

因此，Conditional Flow Matching 的训练目标变为：

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x_1, x_0} \|v_\theta(t, (1-t)x_0 + tx_1) - (x_1 - x_0)\|^2$$

训练过程极其简单：

1. 采样 $x_1 \sim p_{\text{data}}$, $x_0 \sim \mathcal{N}(0, I)$, $t \sim \mathcal{U}[0, 1]$
2. 计算 $x_t = (1-t)x_0 + tx_1$
3. 训练网络 $v_\theta(t, x_t)$ 预测 $x_1 - x_0$

6.2 与扩散模型中 VP/VE 调度的对应

除了 OT 路径，我们也可以选择与扩散模型中的 VP (Variance Preserving) 或 VE (Variance Exploding) 调度对应的参数化。

VP 对应（类比 DDPM 的噪声调度）：

- $\mu_t(x_1) = \alpha_t x_1$ ，其中 $\alpha_0 = 0$, $\alpha_1 \approx 1$
- $\sigma_t(x_1) = \sqrt{1 - \alpha_t^2}$ （保持总方差不变）

条件向量场在这种情况下变为：

$$u_t(x|x_1) = \frac{\alpha'_t}{1 - \alpha_t^2} (\alpha_t x_1 - x) + \alpha'_t x_1$$

Flow Matching 与 Score Function 的关系

条件向量场和扩散模型中的 score function（得分函数）之间存在精确的数学关系。在 VP 参数化下：

$$u_t(x|x_1) = f(t)x + g(t)\nabla_x \log p_t(x|x_1)$$

其中 $f(t)$ 和 $g(t)$ 是与噪声调度相关的系数。

这说明**训练 Flow Matching 的向量场和训练扩散模型的 score function 本质上是在做同一件事**——只是用不同的参数化和不同的损失权重。

6.3 直线轨迹 vs 弯曲轨迹

条件轨迹 vs 边际轨迹

虽然每条条件轨迹（给定 x_0 和 x_1 ）是一条直线，但边际轨迹（只给定 x_0 ，不知道目标 x_1 ）通常不是直线。这是因为同一个空间点 x_t 可能被多条不同的条件轨迹经过，而网络需要预测这些条件向量场的加权平均。

这就是为什么即使使用 OT 路径训练，实际采样时仍然需要多步 ODE 求解——因为学到的边际向量场并不是常数。

6.4 本章小结

OT 路径（线性插值）是 Flow Matching 最简单也最常用的变体，训练目标归结为预测 $x_1 - x_0$ 。通过选择不同的 μ_t 和 σ_t 函数，Flow Matching 可以复现扩散模型的各种噪声调度。这种灵活性是流模型的重要优势。

7 Flow Matching 与扩散模型的统一视角

7.1 等价性的建立

在本讲的最后部分，讲者揭示了 Flow Matching 和扩散模型之间的深层联系。当我们选择与 VP/VE 调度对应的 μ_t 和 σ_t 时：

1. Flow Matching 的条件概率路径 $p_t(x|x_1) = \mathcal{N}(\mu_t x_1, \sigma_t^2 I)$ 与扩散模型的前向跳跃分布完全一致（只是时间方向相反）
2. Flow Matching 的条件向量场与 Probability Flow ODE 中的漂移项存在精确对应关系
3. 两种训练目标在适当的参数化和损失权重下是等价的

统一视角：两条路通向同一座山

扩散模型的路径：定义前向过程（噪声注入）→ 推导反向 SDE → 得到 Probability Flow ODE → 训练 score function

Flow Matching 的路径：定义条件流映射 → 推导条件向量场 → 训练向量场预测网络
两条路最终到达同一个目标：一个能将噪声映射到数据的 ODE。不同之处在于：

- 扩散模型从概率密度路径出发推导向量场
- Flow Matching 从流映射出发推导概率密度路径
- 推导顺序相反，但结果等价

7.2 Flow Matching 的优势

尽管数学上等价，Flow Matching 框架具有以下实践优势：

特性	扩散模型	Flow Matching
参考分布	必须是标准高斯	可以是任意分布
训练目标	噪声预测 / score 预测	速度预测
理论推导	需要 SDE/Fokker-Planck	直接定义 ODE
噪声调度	需要精心设计	自由选择 μ_t, σ_t
直线路径	非自然（弯曲轨迹）	自然（OT 路径）

表 2: 扩散模型与 Flow Matching 的特性对比

为什么现代生成模型更倾向于 Flow Matching

Stable Diffusion 3 (Stability AI) 和 Flux (Black Forest Labs) 等最新图像生成模型都采用了 Flow Matching / Rectified Flow 框架。主要原因包括：

1. **更直的轨迹**：OT 路径产生的轨迹更接近直线，使得少步采样的效果更好
2. **更简单的训练**：速度预测目标比噪声预测或 score 预测更直观
3. **更灵活的设计**：可以自由选择参考分布和路径参数化
4. **更好的理论基础**：与 optimal transport 理论的自然联系

7.3 本章小结

Flow Matching 和扩散模型在数学上是等价的，但 Flow Matching 提供了更简洁的理论框架和更灵活的模型设计空间。在实践中，直线路径（OT 路径）带来的更优轨迹结构使得 Flow Matching 成为当前主流生成模型的首选训练范式。

8 训练与推理流程

8.1 训练算法

Conditional Flow Matching 的完整训练算法如下：

```

1  # v_theta: neural network parameterizing the vector field
2  # p_data: data distribution (training dataset)
3
4  for each training step:
5      # 1. Sample data and noise
6      x1 = sample_from(p_data)          # data sample
7      x0 = sample_from(Normal(0, I))    # noise sample
8      t = sample_from(Uniform(0, 1))    # time step
9
10     # 2. Compute interpolation (conditional flow map)
11     xt = (1 - t) * x0 + t * x1
12
13     # 3. Compute target (conditional vector field)
14     target = x1 - x0
15

```

```

16     # 4. Compute loss and update
17     prediction = v_theta(t, xt)
18     loss = MSE(prediction, target)
19     loss.backward()
20     optimizer.step()

```

Listing 1: Conditional Flow Matching 训练算法 (OT 路径)

训练中的注意事项

1. 时间 t 应均匀采样自 $[0, 1]$, 某些实现会对端点做小幅裁剪 (如 $[\epsilon, 1 - \epsilon]$) 以避免数值问题
2. 对于 OT 路径, 目标 $x_1 - x_0$ 不依赖于 t , 但 x_t 依赖于 t , 因此网络仍需以 t 为输入
3. 网络架构可以复用扩散模型的 U-Net 或 DiT 架构, 只需确保时间 t 的编码方式正确

8.2 推理 (采样) 算法

训练完成后, 生成新样本的过程如下:

```

1  # v_theta: trained vector field network
2  # N: number of discretization steps
3  # dt: step size = 1/N
4
5  # 1. Sample from reference distribution
6  x = sample_from(Normal(0, I))
7
8  # 2. Solve ODE from t=0 to t=1
9  for i in range(N):
10     t = i / N
11     x = x + v_theta(t, x) * dt    # Euler step
12
13  # x is now approximately a sample from p_data
14  return x

```

Listing 2: Flow Matching 采样算法 (Euler 方法)

可以使用更高阶的 ODE 求解器 (如 Heun、Dormand-Prince/RK45) 来提高采样质量或减少步数。

8.3 本章小结

Flow Matching 的训练和推理流程都极其简洁: 训练就是在随机插值点上回归速度目标, 推理就是从噪声出发求解 ODE。整个流程不涉及任何 SDE 模拟或复杂的噪声调度设计。

9 总结与延伸

9.1 本讲要点回顾

本讲介绍了 Flow Matching 作为一种全新的生成模型训练范式, 其核心贡献包括:

1. **连续正则化流 (CNF) 框架**: 基于 ODE 的确定性生成过程, 由流映射、向量场和概率密度路径三个核心概念构成
2. **Flow Matching 目标函数**: 简单的向量场回归损失, 完全避免了 ODE 求解的计算开销
3. **Conditional Flow Matching**: 通过条件化技巧, 将不可解析的边际量转化为有解析形式的条件量, 同时保证训练等价性
4. **与扩散模型的统一**: 揭示了 Flow Matching 和扩散模型在数学上的等价性, 以及 Flow Matching 在灵活性方面的优势

关键公式速查

OT 路径的条件流映射: $\phi_t(x_0|x_1) = (1-t)x_0 + tx_1$

OT 路径的条件向量场: $u_t(x|x_1) = x_1 - x_0$

CFM 训练损失: $\mathcal{L} = \mathbb{E}_{t, x_1, x_0} \|v_\theta(t, (1-t)x_0 + tx_1) - (x_1 - x_0)\|^2$

ODE 采样: $\frac{dx_t}{dt} = v_\theta(t, x_t), \quad x_0 \sim \mathcal{N}(0, I)$

9.2 拓展阅读

- **Flow Matching 原始论文**: Lipman et al., “Flow Matching for Generative Modeling”, ICLR 2023
- **Conditional Flow Matching**: Tong et al., “Improving and Generalizing Flow-Based Generative Models with Minibatch Optimal Transport”, ICML 2024
- **Rectified Flow**: Liu et al., “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow”, ICLR 2023
- **Neural ODE**: Chen et al., “Neural Ordinary Differential Equations”, NeurIPS 2018 ——连续正则化流的开创性工作
- **Stochastic Interpolants**: Albergo & Vanden-Eijnden, “Building Normalizing Flows with Stochastic Interpolants”, ICLR 2023
- **Meta Flow Matching Tutorial**: Meta AI Blog 提供了详细的教程和代码
- **Fokker-Planck 方程推导**: 关于向量场、概率路径和连续性方程之间关系的详细推导, 可参考 Song et al., “Score-Based Generative Modeling through Stochastic Differential Equations” (附录部分)