

课程笔记

KAIST CS492D Lecture 10: Flow Matching 2

基于 Minhyuk Sung 授课内容整理

2025 年秋季

CS492C: Diffusion and Flow Models

Flow Matching 2

LECTURE 11
MINHYUK SUNG

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Minhyuk Sung (KAIST)

发布日期: 2025

视频时长: 40 分钟

视频链接: <https://www.youtube.com/watch?v=o9tccBWdcQ4>

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 引言：从 Flow Matching 1 到 Flow Matching 2	2
1.1 符号约定与时间域的变化	2
1.2 条件流映射的一般形式	3
1.3 本章小结	3
2 扩散模型与流模型的等价关系	3
2.1 从变分扩散模型出发	3
2.2 Tweedie 公式的再现	4
2.3 速度场与分数函数的关系	4
2.4 速度场与噪声预测的关系	4
2.5 与 Probability Flow ODE 的一致性	5
2.6 本章小结	5
3 流模型的优势与推广能力	5
3.1 非线性条件流映射	6
3.2 任意参考分布	6
3.3 ODE vs. SDE 的出发点	6
3.4 本章小结	6
4 Rectified Flow 与直线轨迹	7
4.1 Rectified Flow 的定义	7
4.2 条件轨迹 vs. 边际轨迹	7
4.3 Reflow: 通过微调使轨迹变直	8
4.4 直线轨迹与少步生成	8
4.5 本章小结	9
5 Optimal Transport 视角	9
5.1 随机配对 vs. 最优配对	9
5.2 OT 配对对轨迹直度的影响	9
5.3 Reflow 与 OT 的关系	10
5.4 本章小结	10
6 实际应用：Stable Diffusion 3 与 Flux	10
6.1 SD3 与 Flux 的流模型基础	10
6.2 Flux 模型	11
6.3 本章小结	11
7 训练与推理的全流程对比	11
7.1 训练阶段对比	12
7.2 推理阶段对比	12
7.3 本章小结	12

8	课程知识体系总览	12
8.1	技术演进路径	12
8.2	后续课程预告	13
8.3	本章小结	13
9	总结与延伸	13
9.1	核心要点回顾	13
9.2	拓展阅读	14

1 引言：从 Flow Matching 1 到 Flow Matching 2

本讲是 KAIST CS492D（扩散模型与流模型）的第 10 讲，也是 Flow Matching 专题的第二部分。讲者 Minhyuk Sung 首先回顾了上一讲中引入的 Flow Matching 基本框架——流映射（Flow Map）、向量场（Vector Field）和概率路径（Probability Path）三大核心概念及其相互关系，然后在此基础上深入探讨以下关键问题：

1. 扩散模型与流模型的**数学等价关系**：在何种条件下两者等价，如何互相转换？
2. **速度场与分数函数的对应关系**：velocity 与 score function 之间的精确数学表达式是什么？
3. **Rectified Flow**：如何通过直线轨迹简化生成过程，又如何通过 Reflow 微调使轨迹更直？
4. **Optimal Transport** 视角：随机配对 vs. 最优配对如何影响轨迹弯曲程度？
5. **实际应用**：Stable Diffusion 3 (SD3) 和 Flux 模型如何运用 Flow Matching 技术？

前置知识回顾

理解本讲需要以下来自上一讲（Lecture 9: Flow Matching 1）的前置概念：

- **流映射 (Flow Map)** ψ_t ：从 $t = 0$ 到 t 的确定性映射， $\psi_0(\mathbf{x}) = \mathbf{x}$
- **向量场 (Vector Field)** $u_t(\mathbf{x})$ ：流映射的时间导数， $\frac{d\psi_t}{dt} = u_t(\psi_t(\mathbf{x}))$
- **概率路径 (Probability Path)** p_t ：随时间 t 变化的概率分布，满足 $p_0 = p_{\text{ref}}, p_1 = p_{\text{data}}$
- **Fokker-Planck 方程**：向量场与概率路径之间的联系方程
- **条件流匹配 (Conditional Flow Matching)**：将边际向量场分解为对条件向量场的期望

1.1 符号约定与时间域的变化

在 Flow Matching 的语境中，时间域与扩散模型有所不同：

- **扩散模型**：时间从 T （噪声端）到 0 （数据端），生成是“逆过程”
- **流模型**：时间从 0 （参考分布）到 1 （数据分布），生成是“正向过程”

具体地：

- $\mathbf{x}_0 \sim p_0 = \mathcal{N}(\mathbf{0}, \mathbf{I})$ ：来自参考分布（标准高斯）的样本
- $\mathbf{x}_1 \sim p_1 = p_{\text{data}}$ ：来自数据分布的样本

容易混淆的符号

注意在 Flow Matching 中 $\mathbf{x}_0$ 是**噪声**而 $\mathbf{x}_1$ 是**数据**，这与 DDPM 中 $\mathbf{x}_0$ 是数据、 $\mathbf{x}_T$ 是噪声的惯例恰好相反。此外，Lecture 9 中的 μ_t, σ_t 函数与变分扩散模型中的 α_t, σ_t 本质相同，只是由于时间域翻转，位置互换了。

1.2 条件流映射的一般形式

上一讲中引入了条件流映射（Conditional Flow Map）的线性高斯形式：

$$\psi_t(\mathbf{x}_0 \mid \mathbf{x}_1) = \sigma_t \cdot \mathbf{x}_0 + \alpha_t \cdot \mathbf{x}_1$$

其中：

- σ_t, α_t 是关于时间 t 的标量函数
- 边界条件： $\sigma_0 = 1, \alpha_0 = 0$ ($t = 0$ 时得到纯噪声 $\mathbf{x}_0$)； $\sigma_1 = 0, \alpha_1 = 1$ ($t = 1$ 时得到数据 $\mathbf{x}_1$)

对应的条件概率路径为高斯分布：

$$p_t(\mathbf{x} \mid \mathbf{x}_1) = \mathcal{N}(\mathbf{x}; \alpha_t \mathbf{x}_1, \sigma_t^2 \mathbf{I})$$

对条件流映射取时间导数，得到条件向量场：

$$u_t(\mathbf{x} \mid \mathbf{x}_1) = \dot{\sigma}_t \cdot \mathbf{x}_0 + \dot{\alpha}_t \cdot \mathbf{x}_1$$

1.3 本章小结

本节回顾了 Flow Matching 的基本设定，包括时间域约定、条件流映射的定义和条件向量场的推导。关键点在于：流模型的时间从 0（噪声）到 1（数据），训练目标是学习一个神经网络来预测向量场（速度），这在概念上类似于扩散模型中预测噪声。

2 扩散模型与流模型的等价关系

本节是本讲的核心理论部分，讲者详细推导了扩散模型和流模型之间的精确数学等价关系。

2.1 从变分扩散模型出发

回忆变分扩散模型（Variational Diffusion Model, VDM）中，前向过程定义为：

$$q(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \alpha_t \mathbf{x}_0, \sigma_t^2 \mathbf{I})$$

在 Flow Matching 的语境下，将这个前向过程重新解读为条件流映射：

$$\psi_t(\mathbf{x}_0 \mid \mathbf{x}_1) = \sigma_t \cdot \mathbf{x}_0 + \alpha_t \cdot \mathbf{x}_1$$

核心洞察：扩散模型是流模型的特殊情况

当条件流映射定义为上述线性高斯形式，且 α_t, σ_t 函数与变分扩散模型中的调度函数完全一致时，扩散模型可以被视为流模型的一种**特殊情况**。换言之，流模型是扩散模型的**推广**。两者的区别仅在于：

- **扩散模型**：先定义概率路径（前向加噪过程），再推导出向量场和轨迹
- **流模型**：先定义条件流映射（轨迹），再推导出向量场和概率路径

2.2 Tweedie 公式的再现

讲者在此处引入了一个重要的计算工具——Tweedie 公式。给定中间数据点 $\mathbf{x}_t = \sigma_t \mathbf{x}_0 + \alpha_t \mathbf{x}_1$ ，其中 $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{x}_1 \sim p_{\text{data}}$ ，我们可以计算 $\mathbf{x}_1$ 的后验期望：

$$\mathbb{E}[\mathbf{x}_1 | \mathbf{x}_t] = \frac{\mathbf{x}_t - \sigma_t \cdot \mathbb{E}[\mathbf{x}_0 | \mathbf{x}_t]}{\alpha_t} = \frac{\mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}{\alpha_t}$$

其中：

- $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)$ 是分数函数 (Score Function)
- 这与 Lecture 5 中介绍的 Tweedie 公式完全一致，只是使用了 Flow Matching 的符号约定

Tweedie 公式的直觉

Tweedie 公式的核心思想是：给定一个被噪声污染的观测 $\mathbf{x}_t$ ，原始信号 $\mathbf{x}_1$ 的后验均值可以通过分数函数来计算。分数函数指向对数概率密度增长最快的方向，即“数据更密集”的方向。在高斯似然模型中，这等价于从当前位置向后验均值方向移动。

2.3 速度场与分数函数的关系

这是本讲最重要的推导之一。从条件向量场出发：

$$u_t(\mathbf{x} | \mathbf{x}_1) = \dot{\sigma}_t \cdot \mathbf{x}_0 + \dot{\alpha}_t \cdot \mathbf{x}_1$$

将 $\mathbf{x}_0$ 用 $\mathbf{x}_t$ 和 $\mathbf{x}_1$ 表示： $\mathbf{x}_0 = \frac{\mathbf{x}_t - \alpha_t \mathbf{x}_1}{\sigma_t}$ ，代入得到：

$$\begin{aligned} u_t(\mathbf{x}_t | \mathbf{x}_1) &= \frac{\dot{\sigma}_t}{\sigma_t} (\mathbf{x}_t - \alpha_t \mathbf{x}_1) + \dot{\alpha}_t \mathbf{x}_1 \\ &= \frac{\dot{\sigma}_t}{\sigma_t} \mathbf{x}_t + \left(\dot{\alpha}_t - \frac{\dot{\sigma}_t \alpha_t}{\sigma_t} \right) \mathbf{x}_1 \end{aligned}$$

对 $\mathbf{x}_1$ 取期望（边际化），并利用 Tweedie 公式，得到边际向量场：

速度场与分数函数的等价公式

$$u_t(\mathbf{x}_t) = \frac{\dot{\sigma}_t}{\sigma_t} \mathbf{x}_t + \left(\dot{\alpha}_t - \frac{\dot{\sigma}_t \alpha_t}{\sigma_t} \right) \mathbb{E}[\mathbf{x}_1 | \mathbf{x}_t]$$

将 Tweedie 公式代入 $\mathbb{E}[\mathbf{x}_1 | \mathbf{x}_t]$ ，可以建立**速度场与分数函数**之间的等价关系：

$$u_t(\mathbf{x}_t) = \frac{\dot{\sigma}_t}{\sigma_t} \mathbf{x}_t + \left(\dot{\alpha}_t - \frac{\dot{\sigma}_t \alpha_t}{\sigma_t} \right) \cdot \frac{\mathbf{x}_t + \sigma_t^2 \nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t)}{\alpha_t}$$

这意味着：给定任意中间数据点 $\mathbf{x}_t$ 和时间 t ，只要知道分数函数就能计算速度场，反之亦然。

2.4 速度场与噪声预测的关系

利用分数函数与噪声预测之间的已知关系 $\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = -\frac{\epsilon}{\sigma_t}$ ，可以进一步建立速度场与噪声预测网络之间的等价关系：

$$u_t(\mathbf{x}_t) = \frac{\dot{\alpha}_t}{\alpha_t} \mathbf{x}_t - \left(\dot{\alpha}_t \frac{\sigma_t}{\alpha_t} - \dot{\sigma}_t \right) \epsilon_{\theta}(\mathbf{x}_t, t)$$

其中 ϵ_θ 是扩散模型中训练好的噪声预测网络。

速度预测 vs. 噪声预测：不只是换个输出头

虽然速度场和噪声场在数学上可以精确互转，但在**训练**时选择预测哪个量会影响梯度的数值行为。近年来的实践表明，直接训练速度预测（v-prediction）在某些调度下比噪声预测（ ϵ -prediction）具有更好的数值稳定性，特别是在 t 接近端点时。这也是 SD3 和 Flux 选择 v-prediction 的原因之一。

2.5 与 Probability Flow ODE 的一致性

讲者进一步指出，从 Flow Matching 推导出的向量场与从 SDE 框架推导出的 Probability Flow ODE (PF-ODE) 是完全一致的。回忆 PF-ODE 的一般形式：

$$d\mathbf{x} = \left[f(\mathbf{x}, t) - \frac{1}{2}g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right] dt$$

其中 $f(\mathbf{x}, t)$ 和 $g(t)$ 分别是 SDE 的漂移项和扩散系数，它们与 α_t, σ_t 的关系为：

$$f(\mathbf{x}, t) = \frac{\dot{\alpha}_t}{\alpha_t} \mathbf{x}, \quad g(t)^2 = \frac{d\sigma_t^2}{dt} - 2 \frac{\dot{\alpha}_t}{\alpha_t} \sigma_t^2$$

将这些代入 PF-ODE，可以验证其结果与 Flow Matching 推导的向量场**完全相同**。

三种等价视角的统一

到此为止，我们建立了以下三种视角的完全等价关系（在线性高斯条件路径下）：

1. **扩散模型视角**：学习分数函数 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 或噪声 ϵ
2. **Flow Matching 视角**：学习向量场/速度 $u_t(\mathbf{x})$
3. **PF-ODE 视角**：通过 SDE 到 ODE 的转换获得确定性采样路径

三者在数学上可精确互转，区别在于训练时预测哪个量、以及采样时使用哪种求解策略。

2.6 本章小结

本节建立了扩散模型与流模型之间的精确数学等价关系。核心结论是：在线性高斯条件流映射下，扩散模型是流模型的特殊情况。速度场、分数函数、噪声预测三者可以自由互转。这一等价关系不仅具有理论意义，更在实际中意味着：一个预训练好的扩散模型可以直接被“重新解读”为流模型来使用。

3 流模型的优势与推广能力

在建立了等价关系之后，讲者转向讨论流模型相对于扩散模型的**独特优势**——即流模型在哪些方面真正“超越”了扩散模型。

3.1 非线性条件流映射

扩散模型本质上使用的是线性高斯形式的条件路径。而 Flow Matching 框架允许定义任意的条件流映射，不限于线性形式：

- 可以尝试非线性的 $\psi_t(\mathbf{x}_0 | \mathbf{x}_1)$ ，例如加入余弦、sigmoid 等非线性变换
- 实验表明，虽然非线性流映射目前并没有显著超越线性形式，但框架本身的灵活性为未来探索提供了空间

3.2 任意参考分布

这是流模型最重要的推广之一。扩散模型要求参考分布必须是标准高斯分布 $\mathcal{N}(\mathbf{0}, \mathbf{I})$ ，因为整个理论（前向扩散过程）建立在高斯噪声的基础上。而流模型可以使用任意参考分布：

分布到分布的映射

Flow Matching 允许学习从任意源分布到任意目标分布的映射。这不仅包括：

- 标准高斯 $\rightarrow$ 数据分布（经典生成任务）

还包括：

- 数据分布 A $\rightarrow$ 数据分布 B（风格迁移、域转换）
- 低分辨率分布 $\rightarrow$ 高分辨率分布（超分辨率）
- 任意复杂分布之间的转换

这种灵活性是扩散模型框架所不具备的。

3.3 ODE vs. SDE 的出发点

两种建模哲学

扩散模型和流模型的另一个根本区别在于建模的出发点：

- **扩散模型**：从随机微分方程（SDE）出发，将前向扩散定义为逐步加高斯噪声的随机过程；然后发现等价的确定性 ODE 也能给出相同的边际分布
- **流模型**：直接从常微分方程（ODE）出发，定义从源分布到目标分布的确定性映射，无需引入随机性

流模型的出发点更简洁，避免了 SDE 到 ODE 转换的复杂推导。

3.4 本章小结

流模型在以下方面推广了扩散模型：(1) 条件流映射不限于线性形式；(2) 参考分布不限于标准高斯；(3) 直接从 ODE 出发，概念更简洁。这些推广为更灵活的生成模型设计提供了理论基础。

4 Rectified Flow 与直线轨迹

本节是本讲在应用层面最重要的部分，讲者详细介绍了 Rectified Flow（矫正流）的思想、训练方法以及通过 Reflow 使轨迹变直的技术。

4.1 Rectified Flow 的定义

Rectified Flow 是 Flow Matching 的一种特殊情况，其条件流映射定义为 $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 之间的**线性插值**：

$$\psi_t(\mathbf{x}_0 \mid \mathbf{x}_1) = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$$

对应的条件向量场（速度）极为简洁：

$$u_t(\mathbf{x}_t \mid \mathbf{x}_0, \mathbf{x}_1) = \mathbf{x}_1 - \mathbf{x}_0$$

即：条件速度恒定，方向始终指向从 $\mathbf{x}_0$ 到 $\mathbf{x}_1$ 的直线方向。

Rectified Flow 的训练流程

Rectified Flow 的训练过程极其简洁：

1. 从数据分布采样 $\mathbf{x}_1 \sim p_{\text{data}}$
2. 从参考分布采样 $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
3. 均匀采样时间 $t \sim \mathcal{U}(0, 1)$
4. 计算中间点 $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$
5. 计算目标速度 $v^* = \mathbf{x}_1 - \mathbf{x}_0$
6. 最小化 $\mathcal{L} = \|v_\theta(\mathbf{x}_t, t) - v^*\|^2$

4.2 条件轨迹 vs. 边际轨迹

这是理解 Rectified Flow 局限性的关键。虽然每一对 $(\mathbf{x}_0, \mathbf{x}_1)$ 的**条件轨迹**是严格直线，但训练后模型输出的**边际向量场**产生的轨迹通常**不是**直线。

条件直线不等于边际直线

考虑一个二维例子：源分布有两个高斯团，目标分布也有两个高斯团。每对 $(\mathbf{x}_0, \mathbf{x}_1)$ 之间的条件轨迹确实是直线，但由于 $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 是**独立随机配对**的，在某些中间点 $\mathbf{x}_t$ ，条件速度可能指向截然不同的方向（向上或向下）。训练后神经网络输出的是这些条件速度的**期望**，结果可能既不向上也不向下，而是指向两者的平均方向。因此边际轨迹会发生弯曲。

弯曲轨迹的后果：如果边际轨迹弯曲，在求解 ODE 时就需要足够多的时间步才能准确跟踪轨迹。步数越少，离散化误差越大，生成质量越差。理想情况下，如果所有边际轨迹都是直线，那么只需一步就能从 $\mathbf{x}_0$ 直接到达 $\mathbf{x}_1$ 。

4.3 Reflow: 通过微调使轨迹变直

为了使边际轨迹更接近直线，Liu et al. (2023) 提出了 **Reflow**（重流化）技术：

1. **第一阶段**：正常训练一个 Rectified Flow 模型（1-Rectified Flow）
2. **生成配对数据**：使用训练好的模型，从 $\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，通过完整的 ODE 求解生成 $\mathbf{x}_1$ ，记录 $(\mathbf{x}_0, \mathbf{x}_1)$ 配对
3. **第二阶段**：用这些配对数据重新训练模型（2-Rectified Flow）
4. 可以继续迭代：用 2-Rectified Flow 生成新配对，训练 3-Rectified Flow，以此类推

Reflow 为什么有效？

Reflow 之所以能使轨迹变直，核心直觉是：

- 在第一阶段， $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 是**独立**采样的随机配对，没有对应关系
- 经过第一阶段训练后，模型已经学到了一种从 $\mathbf{x}_0$ 到 $\mathbf{x}_1$ 的（弯曲的）映射
- 在 Reflow 阶段， $(\mathbf{x}_0, \mathbf{x}_1)$ 配对不再是随机的，而是由模型确定的**确定性映射**产生的。这些配对之间已经存在合理的对应关系
- 用这些“有意义的配对”重新训练，轨迹的交叉和冲突大大减少，边际轨迹自然变得更直

实验表明：

- **1-Rectified Flow**：边际轨迹明显弯曲
- **2-Rectified Flow**：轨迹显著变直
- **3-Rectified Flow**：轨迹几乎是直线

4.4 直线轨迹与少步生成

直线轨迹的直接好处是可以用**极少**的 ODE 求解步数完成生成：

- 如果轨迹是完美直线，从起点 $\mathbf{x}_0$ 预测一次速度 $v_\theta(\mathbf{x}_0, 0)$ ，沿该方向走到终点即可——这是**单步生成**
- 即使轨迹接近直线但不完美，2-4 步的 Euler 求解也能获得高质量结果
- 对比：标准扩散模型通常需要 20-100 步才能获得同等质量

从 GAN 到扩散再到单步流模型

讲者指出了生成模型发展的有趣循环：

- **GAN/VAE 时代**：单步生成，速度快但质量/多样性受限
- **扩散模型时代**：多步迭代，质量大幅提升但速度牺牲
- **Rectified Flow + Reflow**：通过微调回到单步/少步生成，同时保持高质量

这是一种“螺旋式上升”的发展路径。

4.5 本章小结

Rectified Flow 通过线性插值定义条件流映射，使训练极其简洁。然而随机配对导致边际轨迹弯曲，需要多步 ODE 求解。Reflow 技术通过使用模型自身生成的配对数据进行微调，可以有效地将边际轨迹“拉直”，从而实现少步甚至单步生成。

5 Optimal Transport 视角

轨迹弯曲的根本原因在于 $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 的**配对方式**。本节从 Optimal Transport（最优传输）的视角来理解这一问题。

5.1 随机配对 vs. 最优配对

在标准 Flow Matching 训练中， $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 是**独立**采样的：

$$\mathbf{x}_0 \sim p_0, \quad \mathbf{x}_1 \sim p_1, \quad \text{两者独立}$$

这意味着一个噪声样本 $\mathbf{x}_0$ 可能被“分配”到任意一个数据样本 $\mathbf{x}_1$ ，没有空间结构上的偏好。

最优传输（Optimal Transport）的基本思想

最优传输问题关注的是：如何找到从分布 p_0 到分布 p_1 的最“经济”的传输方案？具体地，对于 L_2 代价（又称 Wasserstein-2 距离），最优传输方案最小化：

$$W_2^2(p_0, p_1) = \inf_{\pi \in \Pi(p_0, p_1)} \int \|\mathbf{x}_0 - \mathbf{x}_1\|^2 d\pi(\mathbf{x}_0, \mathbf{x}_1)$$

其中 $\Pi(p_0, p_1)$ 是所有耦合（联合分布）的集合，其边际分别为 p_0 和 p_1 。

直觉：最优传输倾向于将“近处”的点配对，避免长距离搬运，从而最小化总搬运代价。

5.2 OT 配对对轨迹直度的影响

如果我们用最优传输方案来配对 $\mathbf{x}_0$ 和 $\mathbf{x}_1$ ，而不是随机配对，那么：

- 配对更“合理”：附近的噪声点倾向于映射到附近的数据点
- 不同配对之间的条件轨迹交叉更少
- 边际向量场的冲突更少，边际轨迹自然更直

OT 配对的计算代价

尽管 OT 配对在理论上很有吸引力，但精确计算 Optimal Transport 方案的复杂度很高。对于 n 个样本，经典算法的复杂度为 $O(n^3)$ ，这在大规模训练中不太实际。因此，实际中通常采用近似方法，例如在 mini-batch 内计算 OT (Mini-batch OT)，或者使用 Reflow 作为替代方案——Reflow 可以看作是一种“隐式的”OT 配对优化。

5.3 Reflow 与 OT 的关系

Reflow 和 Optimal Transport 之间有深刻的联系：

- Reflow 通过迭代微调，隐式地优化了 $\mathbf{x}_0 \rightarrow \mathbf{x}_1$ 的配对方案
- 每一轮 Reflow 都使配对更接近 OT 方案——因为模型学到的映射倾向于走“最短路径”
- 理论上，无限次 Reflow 迭代的极限就是 OT 映射（在某些正则性条件下）

从传输代价看轨迹弯曲

轨迹弯曲的本质是**传输代价过高**。当远处的点被配对在一起时，连接它们的直线会穿越中间区域，与其他配对的直线交叉。交叉导致边际向量场不一致（同一点处有多个方向的速度），网络只能学习期望（平均）速度，结果就是弯曲的轨迹。OT 配对通过最小化传输代价来减少交叉，Reflow 则通过迭代隐式实现类似效果。

5.4 本章小结

Optimal Transport 提供了理解轨迹弯曲问题的理论框架。随机配对导致高传输代价和轨迹交叉，OT 配对可以缓解这一问题但计算代价高。Reflow 提供了一种实用的替代方案，通过迭代微调隐式优化配对。

6 实际应用：Stable Diffusion 3 与 Flux

本节讲者简要介绍了 Flow Matching 技术在当前最先进的图像和视频生成模型中的应用。

6.1 SD3 与 Flux 的流模型基础

讲者明确指出，许多当前最先进的生成模型已经从扩散模型**转向了流模型**：

- **Stable Diffusion 3 (SD3)**：虽然名字中有“diffusion”，但实际上使用的是 Flow Matching 训练，网络预测的是速度（velocity）而非噪声
- **Flux**：Black Forest Labs 开发的模型，同样基于 Rectified Flow 技术

SD3 的关键设计选择

Stable Diffusion 3 的核心技术决策包括：

- **Rectified Flow 训练**：使用线性插值条件流映射，网络输出为速度 $v_\theta(\mathbf{x}_t, t)$
- **MM-DiT 架构**：采用 Multimodal Diffusion Transformer 作为骨干网络
- **直线轨迹目标**：通过 Reflow 等技术追求更直的生成轨迹，减少采样步数
- **速度预测 (v-prediction)**：而非噪声预测 (ϵ -prediction)，在某些噪声水平下提供更好的数值稳定性

6.2 Flux 模型

讲者提到，在课程第一讲中就让学生使用 Flux 模型生成图像。Flux 的一个关键变体是 **Flux.1-schnell**，它使用了 Rectified Flow 加 Reflow 的技术来实现**单步或少步**高质量图像生成。

Consistency Model vs. Rectified Flow：加速生成的两条技术路线

在加速扩散/流模型的采样方面，目前存在两条主要的竞争路线：

- **Consistency Model (一致性模型)**：通过 Consistency Distillation (CD) 或 Consistency Training (CT) 学习 ODE 轨迹上的“快捷映射”，直接从任意中间点跳到终点。Lecture 8/9 中讨论过
- **Rectified Flow + Reflow**：通过使轨迹本身变直来减少所需步数。本讲的主题

实验比较显示：

- Consistency Model 在 1-2 步生成时，ImageNet 64×64 上 FID 约 3-4
- 2-Rectified Flow 在 1-2 步生成时，也能达到类似的 FID

两种方法各有优劣，目前仍是活跃的研究方向。

6.3 本章小结

Flow Matching，特别是 Rectified Flow 变体，已经成为当前最先进图像生成模型（SD3、Flux）的基础技术。其核心优势在于训练简洁、轨迹可控、少步生成成为可能。

7 训练与推理的全流程对比

为了帮助读者建立完整的理解，本节以表格形式对比扩散模型和流模型在训练与推理各环节的差异。

7.1 训练阶段对比

表 1: 扩散模型 vs. 流模型：训练阶段对比

环节	扩散模型	流模型 (Rectified Flow)
时间域	$t \in \{0, \dots, T\}$ 或 $[0, T]$	$t \in [0, 1]$
前向过程	$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \epsilon$	$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$
预测目标	噪声 ϵ 或分数 $\nabla \log p_t$	速度 $v = \mathbf{x}_1 - \mathbf{x}_0$
训练损失	$\ \epsilon_\theta(\mathbf{x}_t, t) - \epsilon\ ^2$	$\ v_\theta(\mathbf{x}_t, t) - (\mathbf{x}_1 - \mathbf{x}_0)\ ^2$
数据需求	仅需 $\mathbf{x}_0 \sim p_{\text{data}}$	需要 $\mathbf{x}_0 \sim p_0$ 和 $\mathbf{x}_1 \sim p_1$

7.2 推理阶段对比

表 2: 扩散模型 vs. 流模型：推理阶段对比

环节	扩散模型	流模型
起点	$\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$	$\mathbf{x}_0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
求解方式	SDE 或 PF-ODE	ODE
每步更新	$\mathbf{x}_{t-1} = \mathbf{x}_t + f(\mathbf{x}_t, t)\Delta t$	$\mathbf{x}_{t+\Delta t} = \mathbf{x}_t + v_\theta(\mathbf{x}_t, t)\Delta t$
典型步数	20–100 步	1–10 步 (Reflow 后)
高级求解器	DPM-Solver 等	Euler / Midpoint 即可

7.3 本章小结

流模型在训练和推理两个阶段都提供了更简洁的流程。特别值得注意的是，Rectified Flow 的推理阶段在 Reflow 后可以用极少步数完成，这是其在实际部署中的最大优势。

8 课程知识体系总览

讲者在课程结尾回顾了整个课程到目前为止的知识发展脉络。

8.1 技术演进路径

从课程开始到第 10 讲，讲者构建了以下完整的技术脉络：

1. **VAE/GAN** (Lecture 1–2)：单步生成模型，质量和多样性受限
2. **DDPM** (Lecture 3–4)：引入多步迭代去噪，大幅提升生成质量
3. **DDIM** (Lecture 5–6)：DDPM 的确定性采样变体，支持跳步
4. **SDE/ODE** (Lecture 7)：连续时间框架，统一视角
5. **DPM-Solver** (Lecture 8)：利用 ODE 结构加速采样
6. **Consistency Model** (Lecture 9)：学习快捷映射实现少步生成

7. **Flow Matching** (Lecture 9–10): 更一般的框架, Rectified Flow + Reflow 实现直线轨迹和单步生成

Flow Matching 不是扩散模型的“替代品”

虽然本讲强调了流模型的优势, 但需要注意:

- 扩散模型和流模型在数学上是等价的 (在线性高斯条件路径下)
- 已训练的扩散模型可以被直接转换为流模型使用
- 选择哪种框架更多取决于实际考量: 训练稳定性、采样效率、代码复杂度等
- 当前的“最佳实践”是使用 Flow Matching 框架 + Rectified Flow 训练 + Reflow 微调

8.2 后续课程预告

讲者预告了接下来三周的课程内容:

- **下一周**: Inference-time Guidance (推理时引导), 如何在不重新训练的前提下注入用户偏好
- **之后**: Discrete Diffusion Models (离散数据的扩散模型), 将扩散/流的思想拓展到非连续数据 (如文本)

8.3 本章小结

从 GAN 到扩散模型再到流模型, 生成模型领域经历了从单步到多步再到少步的演进。Flow Matching 提供了一个统一且更灵活的框架, 既能理解扩散模型的已有成果, 又能为未来的改进提供空间。

9 总结与延伸

9.1 核心要点回顾

本讲 (Flow Matching 2) 的核心贡献在于建立了扩散模型与流模型之间的**完整数学桥梁**, 并展示了如何利用这一桥梁来设计更高效的生成模型。主要结论包括:

1. **数学等价**: 在线性高斯条件路径下, 扩散模型是流模型的特殊情况。速度场 u_t 、分数函数 $\nabla \log p_t$ 、噪声预测 ϵ_θ 三者可以精确互转
2. **三种视角统一**: SDE (扩散)、PF-ODE (概率流)、Flow ODE (流匹配) 在数学上完全一致
3. **Rectified Flow**: 线性插值定义条件轨迹, 训练目标为速度预测, 形式极其简洁
4. **轨迹弯曲问题**: 随机配对导致条件轨迹交叉, 边际轨迹弯曲, 需要多步 ODE 求解
5. **Reflow 微调**: 通过使用模型自身生成的配对数据重新训练, 可有效将轨迹拉直, 实现少步生成
6. **Optimal Transport 联系**: OT 配对可减少轨迹交叉, Reflow 隐式逼近 OT 映射
7. **实际影响**: SD3、Flux 等当前最先进模型已采用 Flow Matching / Rectified Flow 作为核心技术

9.2 拓展阅读

- Lipman, Y., et al. *Flow Matching for Generative Modeling*. ICLR 2023. Flow Matching 的奠基论文
- Liu, X., Gong, C., & Liu, Q. *Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow*. ICLR 2023. Rectified Flow 和 Reflow 的原始论文
- Esser, P., et al. *Scaling Rectified Flow Transformers for High-Resolution Image Synthesis*. ICML 2024. SD3 的技术报告，将 Rectified Flow 扩展到大规模图像生成
- Tong, A., et al. *Improving and Generalizing Flow-Based Generative Models with Minibatch Optimal Transport*. TMLR 2024. Mini-batch OT 在 Flow Matching 中的应用
- Albergo, M. S. & Vanden-Eijnden, E. *Building Normalizing Flows with Stochastic Interpolants*. ICLR 2023. Stochastic Interpolant 视角，与 Flow Matching 密切相关
- Song, Y., et al. *Consistency Models*. ICML 2023. 加速采样的竞争方案，可与 Rectified Flow 对比