

课程笔记

KAIST CS492D Guest Lecture 2: 3D 生成方法与视频模型

基于公开课程资料整理

2025 年秋季

CS492C: Diffusion and Flow Models

Generative 3D Content Creation

GUEST LECTURE 2
PHILIPP HENZLER

Fall 2025
KAIST

CS492(C): Diffusion and Flow Models (Fall 2025)

视频作者/频道: Philipp Henzler (Guest Lecture)

发布日期: 2025

视频时长: 35 分钟

视频链接: <https://www.youtube.com/watch?v=4fD2yLXo97U>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：从 3D 重建到生成式 3D	2
2 3D 生成方法的演进	2
2.1 早期方法：3D GAN (2016)	2
2.2 PlatonicGAN：摆脱 3D 数据依赖	2
2.3 PixelNeRF：多视角融合	2
2.4 共同特征与局限	2
2.5 本章小结	3
3 视频模型的 3D 理解能力	3
3.1 2D 生成模型的优势	3
3.2 视频模型是否理解 3D?	3
3.3 交互式视频模型	3
3.4 为何仍需显式 3D 建模?	4
3.5 两块拼图的组合	4
3.6 本章小结	4
4 CAT3D：多视角扩散模型 + NeRF 蒸馏	4
4.1 方法概述	4
4.2 模型架构	4
4.3 两阶段流程	5
4.4 性能	5
4.5 本章小结	5
5 B3D：前馈式 3D 生成	5
5.1 动机：消除优化瓶颈	5
5.2 核心思想：Splatter Image	5
5.3 为什么采用两阶段设计?	6
5.4 多视角 Gaussian Head	6
5.5 训练数据	6
5.6 本章小结	7
6 几何自编码器：关键技术挑战	7
6.1 问题：图像 VAE 不适用于几何数据	7
6.2 解码器架构：Transformer vs. 卷积	7
6.3 本章小结	7
7 VLM 引导的感知对齐图像压缩	8
7.1 背景：传统图像压缩的感知失配	8
7.2 方法：VLM 作为感知评判者	8
7.3 实验结果	8
7.4 本章小结	9

8 ROAR: 3D 重光照	9
8.1 动机: 细粒度控制	9
8.2 方法设计	9
8.3 光照表示: 环境贴图 + 镜面反射嵌入	9
8.4 实验效果	9
8.5 本章小结	10
9 Captive: 360 度全景生成	10
9.1 问题与挑战	10
9.2 核心思想: 立方体贴图表示	10
9.3 分布外泛化	10
9.4 本章小结	10
10 苦涩的教训与 3D 的未来	11
10.1 Bitter Lesson 视角下的 3D 生成	11
10.2 World Labs 的启示	11
10.3 本章小结	11
11 总结与延伸	11
11.1 核心要点回顾	11
11.2 关键设计原则	12
11.3 拓展阅读	12

1 引言：从 3D 重建到生成式 3D

Philipp Henzler 自 2018 年攻读博士期间便开始从事 3D 重建与生成方向的研究，主要工作包括自监督 3D 重建 (self-supervised 3D reconstruction) 和外观建模 (appearance modeling)。2022 年加入 Google 后，他致力于生成式 3D 重建和 3D 重光照 (relighting)，其团队成功将研究成果应用于 Google Shopping 产品中——先从鞋类 3D 重建开始，后借助视频模型扩展到任意物体品类。

本次演讲的核心主题是：**3D 生成方法如何与通用视频模型相结合**，以及在视频模型日益强大的今天，显式 3D 建模为何依然不可或缺。

演讲核心问题

在 2D 视频模型已经能够生成高度逼真视频的今天，我们为什么还需要显式建模 3D？3D 方法与 2D 生成模型各自的优势和劣势是什么？如何将二者结合以获得最佳效果？

2 3D 生成方法的演进

2.1 早期方法：3D GAN (2016)

最早的生成式 3D 建模方法使用生成对抗网络 (GAN)。在 2016 年的工作中，研究者构建了一个纯生成模型：从噪声隐变量出发，训练模型生成 3D 体素 (voxel) 表示，并使用 **3D 判别器** 进行对抗训练。

该方法的两个主要限制：

- **无法精确控制输入**：生成过程完全随机，无法指定生成特定物体
- **需要 3D 真值数据**：训练依赖于 3D ground truth，而高质量 3D 数据极为稀缺

2.2 PlatonicGAN：摆脱 3D 数据依赖

PlatonicGAN 的核心创新在于引入了**可微渲染器** (differentiable renderer) 和 **2D 判别器**，从而消除了对 3D 真值数据的依赖。这使得模型可以直接在互联网上的 2D 图像数据上进行训练。此外，PlatonicGAN 还引入了**图像编码器**，实现了从单张图像进行 3D 重建的能力。

可微渲染的意义

可微渲染 (differentiable rendering) 是连接 3D 表示与 2D 监督信号的桥梁。通过使渲染过程可微分，梯度可以从 2D 图像空间的损失函数反向传播到 3D 表示的参数上，从而允许使用大量的 2D 图像数据来训练 3D 生成模型，而无需昂贵的 3D 标注。

2.3 PixelNeRF：多视角融合

在基于图像的重建思路基础上，PixelNeRF 专注于**多视角输入**。其核心创新是将来自多张输入图像的编码特征聚合 (aggregate)，融合为一个一致的 3D 表示——具体形式为 NeRF (Neural Radiance Field)。

2.4 共同特征与局限

上述所有方法都有一个共同特点：它们直接预测一个**显式的、3D 一致的表示**。

显式 3D 表示的优势与劣势

优势：一旦获得 3D 模型，可以从任意视角快速、低成本地渲染，非常适合手机和平板等移动端的实时应用。

劣势：整体生成质量较低。原因有二：（1）高质量 3D 数据极度稀缺；（2）这些方法不应使用过强的归纳偏置（如渲染），但避免归纳偏置又限制了模型能力。

2.5 本章小结

3D 生成方法从依赖 3D 真值数据的 3D GAN，发展到利用可微渲染和 2D 判别器的 Platonic-GAN，再到支持多视角输入的 PixelNeRF。这些方法的共同优势在于生成显式 3D 表示、渲染成本低，但受限于 3D 数据的稀缺性，整体质量不及 2D 生成模型。

3 视频模型的 3D 理解能力

3.1 2D 生成模型的优势

与 3D 生成模型形成鲜明对比的是，2D 图像和视频生成模型能够很好地随数据和计算资源扩展 (scale)：互联网上有数十亿张 2D 图像和视频可供训练，且这些模型直接生成 2D 像素，归纳偏置有限。随着算力不断增长，这些模型产出的视频质量越来越高——例如 V3 模型已能生成具有多样相机运动、场景运动以及高度逼真物理效果的视频。

3.2 视频模型是否理解 3D？

一个自然的问题是：这些视频模型生成的结果是否在物理上是正确的？

Henzler 团队设计了一个实验来探究这个问题：

1. 给定两张重叠区域很少的场景图像 A 和 B
2. 使用现成的位姿估计器（如 DUST3R）预测相机位姿——由于图像重叠少，基于视觉对应关系的估计器效果很差
3. 使用多种视频生成模型在两张图像之间插值生成中间帧
4. 将生成的中间帧连同原始两张图像一起输入位姿估计器

关键发现：视频模型隐式理解 3D

实验结果表明，视频模型生成的中间帧显著提升了位姿估计器的精度。这意味着视频模型确实能够隐式地建模物理世界——它们生成的帧之间存在合理的 3D 几何关系，即使模型从未被显式训练去理解 3D 结构。

3.3 交互式视频模型

更进一步，类似 Genie 2 的交互式视频模型已经允许用户实时导航 3D 世界。用户可以通过键盘输入（前进、左转、右转）来控制模型生成新帧，自由地在虚拟场景中探索不同视角。更关键的是，当用户转身回看时，场景保持了一致性——教室看起来与之前完全相同。

3.4 为何仍需显式 3D 建模？

既然纯 2D 视频模型已经如此强大，为什么还需要显式建模 3D？

视频模型的根本瓶颈：推理成本

虽然视频模型能随数据和计算扩展，但其推理成本也会相应上升。这使得这些模型目前无法在手机和平板等移动设备上运行。而显式 3D 表示（如 NeRF、3D Gaussian Splatting）一旦构建完成，渲染成本极低，完全可以在移动端实时运行。

3.5 两块拼图的组合

Henzler 指出，我们其实已经拥有了两块互补的拼图：

- **生成式图像/视频模型**：产出高度逼真的 2D 图像
- **NeRF/3DGS 重建方法**：将多张图像蒸馏为高效的 3D 表示，支持快速渲染

将二者组合——用生成模型产出多视角图像，再用 3D 重建方法将其蒸馏为高效 3D 表示——正是后续工作 CAT3D 和 B3D 的核心思路。

3.6 本章小结

视频模型已经展现出隐式的 3D 理解能力，但其推理成本限制了在移动端的部署。显式 3D 表示提供了低成本渲染的优势，因此「2D 生成 + 3D 蒸馏」成为兼顾质量与效率的最优策略。

4 CAT3D：多视角扩散模型 + NeRF 蒸馏

4.1 方法概述

CAT3D 是一种可以接受文本提示、单张图像或多张图像作为输入，生成完整 3D 场景的方法。其核心思想是将多视角扩散模型与 NeRF 重建流程相结合。

4.2 模型架构

CAT3D 的输入包含两类视角：

- **已观察视角 (Observed Views)**：包含输入图像及其对应的相机参数。图像通过预训练的 VAE 编码为图像隐变量 (image latent)，相机信息编码为逐像素的射线坐标图 (per-pixel ray coordinate map)，包含每个像素的射线原点和方向。
- **新视角 (Novel Views)**：没有真实图像，取而代之的是噪声隐变量，同时附带目标视角的相机位姿信息。

为帮助模型区分两类视角，还会输入一个**掩码 (mask)**，标识哪些视角是已观察的、哪些是待生成的。

射线坐标图 (Ray Coordinate Map)

射线坐标图是一种将相机位姿信息编码为空间表示的方式。对于图像中的每个像素，计算其对应的射线原点 (ray origin) 和射线方向 (ray direction)，将这些信息存储为与图像尺寸相同的坐标图。这种表示方式允许模型直接在像素级别理解 3D 几何关系。

模型在所有帧之间使用**注意力机制** (attention)，因此能够生成多视角一致的输出。训练数据为大量带位姿标注的多视角图像，监督模型在给定已知视角的条件下生成一致的新视角。

4.3 两阶段流程

CAT3D 采用两阶段流程：

1. **多视角生成**：给定少量输入视角，使用多视角扩散模型生成场景的**密集**视角集
2. **NeRF 重建**：将生成的所有视角输入标准 NeRF 管线进行 3D 重建

生成的多视角并非完美 3D 一致

多视角扩散模型生成的图像并非完全 3D 一致——不同视角之间可能存在微小的不一致。但关键洞察是：这些图像**足够一致**，使得 NeRF 重建管线能够将它们整合为一个一致的 3D 输出。NeRF 本质上充当了一个「平均化」的角色，将多视角中的不一致性消解掉。

4.4 性能

端到端地，CAT3D 能够在约 **1 分钟**内从任意数量的输入（甚至仅一张图像）生成完整的 3D 场景。

4.5 本章小结

CAT3D 验证了「2D 生成 + 3D 蒸馏」范式的可行性：多视角扩散模型负责高质量图像生成，NeRF 负责将这些图像蒸馏为一致的 3D 表示。但 NeRF 优化步骤仍然是推理速度的瓶颈。

5 B3D：前馈式 3D 生成

5.1 动机：消除优化瓶颈

CAT3D 中的 NeRF 优化步骤虽然有效，但仍需数十秒的迭代优化。一个自然的问题是：**能否用前馈模型替代优化步骤？**

B3D (Both3D) 给出了肯定的回答——它能在单个 GPU 上**不到 7 秒**内生成完整 3D 场景。

5.2 核心思想：Splatter Image

B3D 的关键思想基于 Splatter Image：为每个像素预测一个 3D Gaussian Splat 的参数。Splatter Image 本身是一种纯重建方法，无法处理未观察区域。B3D 在此基础上引入了**生成模型**，使其能够「幻想」(hallucinate) 未见区域的内容。

B3D 的两阶段生成流程

第一阶段——扩散生成：一个多视角隐扩散模型（multi-view latent diffusion model）同时生成多视角的 RGB 图像和 XYZ 点图（point map）。

第二阶段——Gaussian 回归：一个 Gaussian Head 网络接收生成的 RGB 图像和点图，回归每个像素对应 3D Gaussian 的剩余属性（opacity 和 scale），输出多视角 Splatter Image。

5.3 为什么采用两阶段设计？

这一设计选择有深刻的技术原因：

- RGB 颜色和 XYZ 位置可以从多视角数据集中可靠地获得监督信号——位置信息通过在现有多视角数据集上运行 Structure-from-Motion (SfM) 管线获得
- 但像素级 Gaussian 的 opacity 和 scale 很难获得可靠的真值，因此**不适合直接用扩散模型生成**
- 已有研究表明，给定颜色和位置信息后，**回归** opacity 和 scale 比**生成**它们容易得多

5.4 多视角 Gaussian Head

Gaussian Head 网络的关键设计要素：

- 接收所有视角的预测点图和 RGB 图像
- 将每个视角转换为对应的 Splatter Image（即每个像素一个 3D Gaussian）
- 使用**跨视角注意力**（cross-view attention）让网络能够联合推理所有 Splatter Image，确保 3D 一致性
- 最终的多视角 Splatter Image 组合在一起，代表完整的 3D 场景

5.5 训练数据

B3D 的训练需要大规模多视角数据集，团队使用 MAST3R（一种 3D Structure-from-Motion 管线）处理了以下数据集的所有场景：

- CO3D
- RealEstate10K (R10K)
- MVImgNet
- DL3DV

这确保了所有训练数据都具有密集的 XYZ 标注。结合合成物体数据集，构建了大规模训练集。

训练数据的构建策略

虽然互联网上的 3D 数据稀缺，但多视角图像数据较为丰富。通过多视角数据集上运行 SfM 管线，可以自动获得每张图像的密集深度/点图标注，从而为扩散模型的训练提供足够的监督信号。这种「利用 2D 数据间接获得 3D 监督」的策略是当前 3D 生成研究的重要范式。

5.6 本章小结

B3D 通过引入前馈 Gaussian Head 替代 NeRF 优化步骤，将 3D 生成速度从约 1 分钟提升到 7 秒以内。其两阶段设计（扩散生成 RGB+XYZ，回归 opacity+scale）巧妙地利用了不同属性在可监督性上的差异。

6 几何自编码器：关键技术挑战

6.1 问题：图像 VAE 不适用于几何数据

B3D 使用隐扩散模型同时生成 RGB 图像和 XYZ 点图，这要求对两种模态都进行自编码。然而，Henzler 发现直接使用预训练的图像 VAE 来编解码点图会产生极差的结果，且场景越大效果越差。

原因分析：

- **损失函数不匹配**：图像压缩常用的感知损失（perceptual loss）对几何数据毫无意义
- **数据范围不匹配**：图像像素值始终在 $[0, 1]$ 范围内，但几何坐标的取值范围完全不同，且随场景规模变化

图像 VAE 用于几何编码的陷阱

将为图像设计的 VAE（使用感知损失、GAN 损失等训练）直接应用于几何数据（XYZ 点图）是行不通的。几何数据与图像数据在统计分布、值域范围和语义含义上都有本质区别。必须设计专门的几何自编码器。

6.2 解码器架构：Transformer vs. 卷积

另一个有趣的发现是关于解码器架构的选择：

- 从定量指标看，卷积解码器和 Transformer 解码器的几何重建质量相当
- 但**定性观察**揭示了关键差异：卷积解码器会产生感知上令人不适的伪影，例如无法保持直线的平直性
- 因此 B3D 选择了 **Transformer 解码器**来处理 XYZ 数据

定量指标 vs. 定性评估的差异

这是一个典型案例：定量指标（如 MSE）可能无法完全反映实际的视觉质量。两种解码器在数值指标上表现相似，但卷积解码器的输出存在结构性伪影（如弯曲的直线），这在实际应用中是不可接受的。这提醒我们在评估几何重建质量时，不能仅依赖传统指标。

6.3 本章小结

几何自编码器是 3D 隐扩散模型的关键组件，但其设计面临与图像自编码器截然不同的挑战。数据分布差异、损失函数选择和解码器架构都需要针对几何数据特点重新考量。

7 VLM 引导的感知对齐图像压缩

7.1 背景：传统图像压缩的感知失配

Henzler 在这一部分介绍了一项关于自编码器训练的相关研究——虽不直接关于 3D 生成，但对理解自编码器设计有重要启发。

传统自编码器训练使用 PSNR 或 SSIM 等损失函数，但这些指标与人类感知的对齐程度很差。例如：

- 人类对**面部**和**文字**的失真非常敏感
- 但对草地、毛皮等自然纹理的失真不太在意

7.2 方法：VLM 作为感知评判者

该方法使用视觉语言模型（VLM）作为感知评判者，通过 Diffusion DPO（Direct Preference Optimization）来改善扩散自编码器的训练。

流程如下：

1. 给定原始图像，使用扩散自编码器以两个不同的噪声种子解码两次，得到解码 A 和解码 B
2. 将原始图像、解码 A 和解码 B 同时输入 VLM，提示其评判哪个解码更接近原始图像
3. VLM 输出 -5 到 +5 之间的数值评分（负值表示 A 更好，正值表示 B 更好）
4. 基于评判结果，使用 Diffusion DPO 更新自编码器

三重鲁棒性策略

由于 VLM 容易产生幻觉，研究者采用了三种策略提高评判的可靠性：

1. **顺序翻转**：不仅以 (A, B) 顺序输入，还以 (B, A) 顺序输入 VLM，消除位置偏差。
2. **多种子聚合**：对 A 和 B 分别使用多个噪声种子，将多次评判结果求和，降低 VLM 输出的噪声。
3. **LPIPS 交叉验证**：额外使用 LPIPS 指标判断哪个解码更准确，仅当 VLM 和 LPIPS 的判断一致时才将该样本用于 DPO 训练，否则丢弃。

7.3 实验结果

- **PSNR 指标**：该方法在 PSNR 上表现最差（最低分）——但这**不是**优化目标
- **感知指标**（FID、FID-DINOv2、LPIPS）：在多个数据集上表现优异
- **用户研究**（ELO 评分）：在 MSCOCO 和 CLIC 2020 数据集上获得高 ELO 分数

感知质量 vs. 信号保真度的权衡

该工作精确地揭示了一个重要的设计选择：追求人类感知质量（perceptual quality）往往需要牺牲像素级保真度（pixel-level fidelity）。一面旗帜上的星星可能位于略微不同的位置，但整体看起来「对」；文字可能不是逐像素精确匹配，但人类能正确识读。这种权衡在图像压缩和生成任务中非常普遍。

7.4 本章小结

利用 VLM 作为感知评判者进行 DPO 训练, 可以使自编码器的输出更加符合人类感知偏好, 尤其在面部和文字等人类敏感区域显著改善。这一思路有望推广到 3D 生成领域。

8 ROAR: 3D 重光照

8.1 动机: 细粒度控制

除了生成 3D 内容本身, 对输出进行细粒度控制也至关重要——**光照**是最重要的控制维度之一。ROAR 方法解决的问题是: 给定一组带位姿的图像和一个目标光照条件, 生成该光照下的 3D 模型。

8.2 方法设计

ROAR 训练了一个**多视角重光照模型**, 其架构类似于 CAT3D 和 B3D 中的多视角模型, 但增加了光照条件作为输入。

具体而言:

- 输入: 一组图像、对应位姿 + 目标光照条件
- 输出: 每个视角在目标光照下的重光照图像
- 目标: 对于 N 个视角和 M 个光照条件, 生成 $N \times M$ 张重光照图像
- 这些图像随后用于训练一个**光照条件 NeRF**

核心思路类似虚拟光舞台 (light stage) ——通过模拟不同光照条件下的物体外观, 训练 NeRF 对任意目标光照进行泛化。

8.3 光照表示: 环境贴图 + 镜面反射嵌入

光照的编码是一个非平凡的问题。ROAR 采用了双重光照表示:

ROAR 的双重光照编码

1. **全局光照嵌入**: 将环境贴图 (environment map) 通过 Transformer 编码器转换为光照嵌入向量。
2. **镜面反射嵌入**: 由于全局编码器不够强大, 无法完全捕获镜面高光细节, ROAR 额外引入了一个镜面反射嵌入 (specular embedding), 从镜面反射方向对环境贴图进行局部采样。为了处理不同粗糙度, 采用预模糊的环境贴图, 从而只需采样单个位置即可获得镜面反射信息。

8.4 实验效果

实验表明, ROAR 能够忠实地恢复不同目标光照下的镜面高光效果, 而竞争方法要么遗漏镜面高光, 要么过度补偿。

8.5 本章小结

ROAR 将「2D 生成 + 3D 蒸馏」范式扩展到了光照控制维度，通过训练多视角重光照模型生成丰富的光照-视角数据，再蒸馏为光照条件 NeRF，实现了 3D 物体的任意重光照。

9 Captive: 360 度全景生成

9.1 问题与挑战

360 度全景图像的生成面临一个严峻的数据问题：真实的 360 度全景数据**非常有限**。如何在有限数据下训练高质量的全景生成模型？

9.2 核心思想：立方体贴图表示

Captive 的关键洞察是将 360 度全景表示为**立方体贴图** (cube map)，即 6 个面的透视图像。每个单独的面都是标准透视图像，属于互联网图像的正常分布范围。

Captive 的架构设计

编码：将 6 张立方体面沿通道维度堆叠，输入 2D 编码器。

生成：几乎完全复用预训练 Stable Diffusion 模型的架构。由于预训练模型已具备生成任意透视图的能力，**冻结现有层**，仅训练新增的注意力层。

新增层的作用：学习 6 张图像之间的空间关系，即立方体各面如何在 3D 空间中关联。

数据效率：由于核心生成能力来自预训练的大规模 2D 模型，仅需**数万张**全景图像即可训练出高质量的全景生成模型。

9.3 分布外泛化

尽管训练数据仅限于自然场景的全景图，Captive 能够生成超出训练分布的内容。这得益于冻结了 2D 基础模型——它保留了生成任意类型透视图的能力，而新增的注意力层只需学习视角间的空间关系。

冻结基础模型 + 轻量适配层的范式

Captive 的成功体现了一个重要范式：冻结强大的预训练基础模型，只训练少量的适配层来学习新的约束（如多视角一致性、360 度空间关系）。这样既能利用基础模型在大规模数据上学到的强大生成先验，又能在小数据集上快速适配新任务，且保持了基础模型的分布外泛化能力。

9.4 本章小结

Captive 通过立方体贴图表示和冻结基础模型的策略，在有限全景数据下实现了高质量 360 度全景生成，并展现了良好的分布外泛化能力。

10 苦涩的教训与 3D 的未来

10.1 Bitter Lesson 视角下的 3D 生成

Henzler 引用了 Richard Sutton 的「苦涩的教训」(The Bitter Lesson) 来审视 3D 生成领域的发展趋势：

假设数据和计算资源充裕，减少归纳偏置。

在这一框架下：

- **真正的生成方法**（2D 图像/视频模型）**能够扩展** (scale)：数据充裕、归纳偏置有限
- **3D 模型无法同样扩展**：高质量 3D 数据极度稀缺
- 但 3D 模型在**成本和时间效率**上具有显著优势

3D 在内容生成中的持续重要性

虽然 2D 方法已能生成高度逼真的视频并展现了交互能力（如相机控制），但：

1. **控制精度不足**：我们尚未获得对 2D 视频模型的完全、精确的控制能力。
2. **部署困难**：这些大型模型目前无法在消费级设备上实时运行。
3. **3D 蒸馏不可或缺**：为了在移动端部署，仍然需要将生成结果蒸馏为高效的 3D 表示。这些限制意味着 3D 建模在可预见的未来仍是内容生成流程中的关键一环。

10.2 World Labs 的启示

World Labs 正在开发能够在**单个 GPU** 上实现**实时下一帧预测**的交互式 3D 模型。虽然结果尚不完美，但这是一个非常有前景的方向——预示着 2D 生成与 3D 表示之间的边界可能进一步模糊。

10.3 本章小结

3D 生成的未来可能在于「2D 负责质量、3D 负责效率」的分工协作模式。3D 方法的不可替代性在于其极低的渲染成本和在海移动端的可部署性。

11 总结与延伸

11.1 核心要点回顾

本次演讲系统地梳理了生成式 3D 方法的演进脉络和当前格局：

1. **3D 生成方法的演进**：从需要 3D 真值的 3D GAN，到利用可微渲染摆脱 3D 数据依赖的 PlaticGAN，再到多视角融合的 PixelNeRF
2. **视频模型的 3D 理解**：实验证实视频模型能隐式建模 3D 几何，但推理成本限制了部署
3. **CAT3D**：「多视角扩散 + NeRF 蒸馏」范式，约 1 分钟生成 3D 场景
4. **B3D**：前馈 Gaussian Head 替代 NeRF 优化，7 秒内生成 3D 场景
5. **几何 VAE**：图像 VAE 不适用于几何数据，需要专门的架构和损失函数设计

6. **VLM 感知对齐**: 用 VLM 作为评判者进行 DPO 训练, 改善自编码器的感知质量
7. **ROAR**: 将重光照作为额外控制维度引入 3D 生成框架
8. **Captive**: 立方体贴图 + 冻结基础模型实现数据高效的全景生成

11.2 关键设计原则

3D 生成方法的设计原则

1. **2D 生成 + 3D 蒸馏**: 利用 2D 模型的强大生成能力, 通过 3D 重建获得高效可渲染的 3D 表示。
2. **分阶段设计**: 将容易获得监督的属性 (如 RGB、XYZ) 用扩散模型生成, 将难以获得真值的属性 (如 opacity、scale) 用前馈网络回归。
3. **冻结 + 适配**: 在基础模型上冻结已学习的强大先验, 仅训练少量适配层来学习新约束。
4. **跨视角注意力**: 通过全局注意力机制确保多视角生成的 3D 一致性。

11.3 拓展阅读

- CAT3D: Create Anything in 3D with Multi-View Diffusion Models (Gao et al., Google, 2024)
- B3D: 快速前馈 3D 场景生成方法 (Google Research)
- Splatter Image: Ultra-Fast Single-View 3D Reconstruction (Szymanowicz et al., 2024)
- MAST3R: 3D Structure-from-Motion 管线
- ROAR: 3D 重光照方法 (Google Research)
- The Bitter Lesson — Richard Sutton, 2019
- Genie 2: 交互式视频生成模型 (Google DeepMind)
- World Labs: 实时 3D 世界模型