

课程笔记

Muon Optimizer: 梯度白化与 SVD

基于公开课程资料整理

2025

- Muon 优化器
 - 梯度白化 (正交化)
 - zeropower
 - newtonschulz5
 - 范数与 SVD

视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 22 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：为什么需要 Muon ?	2
2 梯度白化 (Gradient Whitening)	2
2.1 问题背景	2
2.2 白化的核心操作	2
2.3 SVD 的几何意义	2
2.4 本章小结	3
3 Muon 的适用范围	3
3.1 哪些参数用 Muon?	3
3.2 对输出层的特殊考虑	3
3.3 本章小结	3
4 从条件数理解低秩性	3
4.1 条件数的含义	3
4.2 对训练的影响	3
4.3 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 引言：为什么需要 Muon ？

Muon 是 K2 训练背后的关键优化器，由 Keller Jordan 提出。它相比 AdamW 或带动量的 SGD 具有更快的训练效率：达到相同 loss 所需的数据量或算力更少。Keller Jordan 正是凭借这篇工作拿到了 OpenAI 的 offer，可见业界对该优化器的高度认可。

Muon 的核心洞察

- 神经网络的 2D 参数矩阵大多具有**很高的条件数**（低秩）
- 梯度更新被少数主导方向（dominant directions）控制
- 对梯度矩阵进行**正交化/白化**，可以放大稀有方向的尺度
- 这些稀有方向对学习至关重要

2 梯度白化（Gradient Whitening）

2.1 问题背景

在用 SGD 或 AdamW 优化神经网络时，经验观察发现：大部分 2D 参数矩阵（隐藏层权重）的条件数很高，即矩阵是低秩的。这导致梯度更新在少数方向上幅度很大，而在大量“稀有方向”上信号极弱。

2.2 白化的核心操作

Muon 的核心：梯度白化

对梯度矩阵进行白化处理，**抹去梯度的大小/尺度，只保留方向**。这使得：

- 主导方向的过大影响被抑制
- 稀有方向的微弱信号被放大
- 所有方向获得均等的更新尺度

白化操作通过 SVD（奇异值分解）实现：

$$G = U\Sigma V^T \xrightarrow{\text{白化}} \hat{G} = UV^T$$

即去掉奇异值矩阵 Σ ，只保留旋转部分 U 和 V^T 。

2.3 SVD 的几何意义

对于梯度矩阵 G ：

- U ：左奇异向量，表示输出空间的方向
- Σ ：奇异值，表示各方向的“重要程度”（尺度）
- V^T ：右奇异向量，表示输入空间的方向

去掉 Σ 后， $\hat{G} = UV^T$ 是一个**正交矩阵**，保证了所有方向的更新幅度一致。

2.4 本章小结

梯度白化是 Muon 的核心操作：通过 SVD 去掉奇异值，将梯度矩阵正交化。这使得原本被主导方向压制的稀有信号得以放大，加速了模型学习。

3 Muon 的适用范围

3.1 哪些参数用 Muon ?

Muon 不是全局替代品

Muon 只用于优化隐藏层的 **2D 参数矩阵**。以下参数仍使用标准优化器（AdamW 或带动量的 SGD）：

- Input Embedding 层
- Output (LM Head) 层
- 标量参数 (Scalar)
- 一维向量参数 (如 RMSNorm 的 γ)

实际训练中，Muon 与 AdamW/SGD **组合使用**：隐藏层矩阵走 Muon，其余走标准优化器。

3.2 对输出层的特殊考虑

对于输出层（分类层），我们希望学到的不同特征对最终分类贡献不同的权重。如果对输出层也做白化，会抹掉这种有意义的尺度差异。因此输出层不适用 Muon。

3.3 本章小结

Muon 的适用范围严格限定在隐藏层的 2D 矩阵参数上，与标准优化器互补使用。

4 从条件数理解低秩性

4.1 条件数的含义

矩阵的条件数定义为最大奇异值与最小奇异值之比：

$$\kappa(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

条件数越大，矩阵越“病态” (ill-conditioned)，意味着信息集中在少数方向上。

4.2 对训练的影响

高条件数导致：

- 梯度在主导方向上很大，在稀有方向上很小
- 标准优化器（如 SGD）需要很多步才能在稀有方向上积累足够的更新

- 训练效率低下

Muon 通过白化将所有方向的“重要程度”拉平，从而加速收敛。

4.3 本章小结

高条件数是神经网络参数矩阵的普遍特征，它导致标准优化器在稀有方向上收敛缓慢。Muon 的白化操作本质上是在解决这个问题。

5 总结与延伸

1. Muon 通过梯度白化（SVD 去奇异值）加速神经网络训练
2. 核心洞察：隐藏层矩阵高条件数 $\Rightarrow$ 稀有方向信号弱 $\Rightarrow$ 白化放大
3. 只用于 2D 隐藏层参数，与 AdamW/SGD 组合使用
4. 达到相同 loss 所需的数据/算力显著减少

5.1 拓展阅读

- Keller Jordan 的 Muon 官方博客
- K2 技术报告中关于优化器的章节
- “Shampoo” 优化器：另一种基于矩阵预条件的方法