

课程笔记

RoPE 几何视角与 Qwen3 RoPE 计算细节

基于公开课程资料整理

2025

RoPE 旋转/几何视角 Qwen3 实现细节 Interleaved 对比

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 21 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1	引言：Multi-Head Self-Attention 的位置不敏感性	2
2	RoPE 的数学表达	2
2.1	旋转矩阵的基本性质	2
2.2	频率参数 θ	2
2.3	本章小结	2
3	几何视角：从频率理解 RoPE	3
3.1	多尺度特性	3
3.2	Qwen3 的 RoPE 配置	3
3.3	与标准 Interleaved 方案的对比	3
3.4	本章小结	3
4	总结与延伸	3
4.1	拓展阅读	3

1 引言: Multi-Head Self-Attention 的位置不敏感性

Multi-Head Self-Attention 本身是**位置不敏感的**。如果不引入位置编码，它相当于一个能力更强的词袋模型 (bag of words)。RoPE (Rotary Position Embedding) 通过旋转矩阵巧妙地将位置信息注入到注意力计算中。

RoPE 的核心思想

通过赋予 Q 和 K 与**绝对位置**相关的旋转角度，利用旋转矩阵的数学特性，最终实现**相对位置编码**。这种相对性不是预先构建的，而是数学上自然推导出来的。

2 RoPE 的数学表达

2.1 旋转矩阵的基本性质

对位置 m 的 Query 施加旋转矩阵 R_m ，对位置 n 的 Key 施加 R_n ：

$$\text{score}(m, n) = (R_m q)^T (R_n k) = q^T R_m^T R_n k = q^T R_{n-m} k$$

关键性质: $R_m^T R_n = R_{n-m}$ ，旋转矩阵的转置等于逆旋转，两个旋转的组合只依赖位置差 $n - m$ 。

相对性是推演出来的

我们事先只需要为每个绝对位置计算旋转矩阵，相对位置编码是数学推导的自然结果，不需要显式构造。

2.2 频率参数 θ

RoPE 在 embedding 向量的不同 2D 子空间 (subspace) 上施加不同频率的旋转：

$$\theta_i = \text{base}^{-2i/d}$$

- base: 一般取 10000 (标准 RoPE)，Qwen3 取 **1000000** (追求更大 context window)
- i : 子空间索引，从 0 到 $d/2 - 1$
- d : head dimension

θ_i 随 i 增大呈**指数级衰减**，取 log 后呈线性下降。

2.3 本章小结

RoPE 通过绝对位置的旋转矩阵实现相对位置编码， θ_i 控制了各子空间的旋转频率。base 越大，低频子空间的旋转越慢，有利于长距离建模。

3 几何视角：从频率理解 RoPE

3.1 多尺度特性

θ_i 的指数衰减意味着 RoPE 具有**多尺度**特性：

RoPE 的频谱

- **低索引 (i 小):** θ_i 大, 旋转频率高 $\rightarrow$ 编码**短距离**依赖 (语法、词组搭配如 “New York”)
- **高索引 (i 大):** θ_i 小, 旋转频率低 $\rightarrow$ 编码**长距离**依赖 (语义、段落结构、远程指代)

3.2 Qwen3 的 RoPE 配置

标准 RoPE 的 $\text{base} = 10000$ ，而 Qwen3 系列使用 $\text{base} = 1000000$ 。更大的 base 意味着所有频率都更低，低频子空间的旋转更加缓慢，有利于捕获更长距离的依赖关系，支持更大的 context window。

3.3 与标准 Interleaved 方案的对比

在之前介绍 LLaMA 时使用的是朴素 interleaved 版本的 RoPE 方案（将相邻维度视为一个 2D 子空间）。Qwen3 的实现在子空间划分上可能有所不同，需要查看具体代码确认。

3.4 本章小结

RoPE 的几何本质是在 embedding 的不同 2D 子空间上施加不同速率的旋转。高频子空间负责短距离语法关系，低频子空间负责长距离语义关系。Qwen3 通过增大 base 来支持更长的上下文窗口。

4 总结与延伸

1. RoPE 通过绝对位置旋转实现相对位置编码，相对性是数学推导的结果
2. $\theta_i = \text{base}^{-2i/d}$ 刻画了从高频到低频的多尺度频谱
3. 高频子空间 $\rightarrow$ 短距离依赖；低频子空间 $\rightarrow$ 长距离依赖
4. Qwen3 使用 $\text{base} = 1000000$ ，支持更大的 context window
5. 下一期将推导 attention score 的远程衰减公式

4.1 拓展阅读

- Su et al., “RoFormer: Enhanced Transformer with Rotary Position Embedding” (2021)
- Qwen3 技术报告中关于 RoPE 配置的说明
- 系列前置视频：LLaMA 2 中 RoPE 的基础介绍