

课程笔记

RoPE Attention 远程衰减推导

五道口纳什 & AI

2026 年 3 月 29 日

RoPE 几何视角

$$S(\tau) \approx \sum_{j=0}^{d/2-1} \cos(\tau \cdot \theta_j)$$

Attention Score

长距离衰减

视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 17 分钟

视频链接: 未填写

目录

1	引言	2
2	θ_j 的指数衰减	2
3	Attention Score 的推导	2
3.1	Pre-Softmax Score 的展开	2
3.2	距离 $\tau = m - n$ 的影响	2
3.3	远程衰减的物理图像	3
3.4	极端情况分析	3
3.5	本章小结	3
4	θ_j 与旋转频率的关系	3
5	总结与延伸	4
5.1	拓展阅读	4

1 引言

上一期从几何视角介绍了 RoPE 的旋转频率与多尺度特性。本期深入推导 RoPE 的 Attention Score 随距离变化的数学表达式，回答一个核心问题：**为什么 RoPE 可以同时编码短距离和长距离依赖？**

2 θ_j 的指数衰减

回顾 RoPE 的频率参数：

$$\theta_j = \text{base}^{-2j/d}$$

对 θ_j 取 log：

$$\log \theta_j = -\frac{2j}{d} \log(\text{base})$$

这是关于 j 的**线性**函数，斜率为 $-\frac{2 \log(\text{base})}{d}$ 。因此 θ_j 本身是指数级衰减的。

3 Attention Score 的推导

3.1 Pre-Softmax Score 的展开

在 RoPE 下，位置 m 的 Query 与位置 n 的 Key 的 attention score (pre-softmax) 为：

$$s(m, n) = (R_m q)^T (R_n k) = q^T R_m^T R_n k = q^T R_{n-m} k$$

将 R_{n-m} 展开到各 2D 子空间，每个子空间 j 的贡献正比于：

$$\cos((m - n) \cdot \theta_j)$$

核心公式

Attention score 正比于所有子空间的余弦函数之和：

$$s(m, n) \propto \sum_{j=0}^{d/2-1} \cos((m - n) \cdot \theta_j)$$

每个子空间贡献一个不同频率的余弦波，频率由 θ_j 决定。

3.2 距离 $\tau = m - n$ 的影响

令 $\tau = m - n$ 为 token 间距离，分析 $s(\tau)$ 的行为：

短距离 (τ 小)：

- 所有子空间的 $\cos(\tau \cdot \theta_j) \approx 1$
- 各项正值叠加，score 很高
- 模型高度关注邻近 token

长距离 (τ 大)：

- 高频子空间 (θ_j 大, j 小): $\tau \cdot \theta_j$ 变化剧烈, $\cos$ 值快速震荡
- 低频子空间 (θ_j 小, j 大): $\tau \cdot \theta_j$ 变化缓慢, $\cos$ 值缓慢下降
- 高频部分的剧烈震荡在求和时正负抵消

3.3 远程衰减的物理图像

RoPE 远程衰减的机制

RoPE 的长距离衰减是两个效应共同作用的结果:

1. **高频维度的完全抵消**: 左侧子空间旋转剧烈, 远距离时正负相消 (类似波的干涉效应)
2. **低频维度的缓慢下降**: 右侧子空间旋转缓慢, 保留了远程的微弱关联

结合起来: RoPE 在数学上主要关注局部, 但保留了远程能力。

这类似于物理学中的**波干涉现象**: 不同频率的波在远处相互抵消, 但某些特定频率 (低频) 仍能传播到远处。

3.4 极端情况分析

对于最右侧的子空间 ($j = d/2 - 1$):

$$\theta_{d/2-1} = \text{base}^{-1} \approx \frac{1}{\text{base}}$$

如果 $\text{base} = 10000$, 则 $\theta \approx 10^{-4}$, 波长极长。即使 τ 很大, $\tau \cdot \theta$ 的增长仍然非常缓慢, $\cos(\tau \cdot \theta) \approx 1$ 。这就是远程信息得以保留的原因。

3.5 本章小结

Attention score 是所有子空间余弦波的叠加。远距离时高频项抵消、低频项缓慢衰减, 共同产生了 RoPE 的远程衰减特性。RoPE 天然实现了“关注局部 + 保留远程”的注意力模式。

4 θ_j 与旋转频率的关系

表 1: 子空间索引与频率特性

子空间位置	j 值	θ_j	特性
左侧 (低索引)	小	大 (高频)	快速旋转, 编码短距离
右侧 (高索引)	大	小 (低频)	缓慢旋转, 编码长距离

RoPE 的多尺度编码

RoPE 不同维度上有不同的旋转频率。将 embedding 向量视为一个行向量时：

- 越左侧的 sub-space：频率越高，对相对位置越敏感
- 越右侧的 sub-space：频率越低，对相对位置越不敏感

这种多尺度特性是 RoPE 成功的关键。

5 总结与延伸

1. Attention score 正比于 $\sum_j \cos(\tau \cdot \theta_j)$ ，是多频余弦波的叠加
2. 远距离时高频项相消（干涉效应），低频项缓慢衰减
3. RoPE 天然实现了“局部优先 + 远程保留”的注意力模式
4. 下一期将探讨 Attention Head 的模式识别与 Attention Sink 现象

5.1 拓展阅读

- Su et al., “RoFormer” 原始论文
- NIPS 2025 Best Paper: Gated Attention 与 Attention Sink
- Blog: “Understanding RoPE through the lens of signal processing”