

课程笔记

Attention Head 模式识别与 Attention Sink

五道口纳什 & AI

2026 年 3 月 29 日

LLM 可解释性
Attention Sink
Induction Head
可视化识别
GPT2/Qwen2.5

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 21 分钟

视频链接：未填写

目录

1 引言	2
2 Attention 基础回顾	2
2.1 Pre-Softmax Attention Score	2
2.2 Multi-Layer Multi-Head 的多样性	2
2.3 本章小结	2
3 Attention Head 的典型模式	2
3.1 常见的 Head 模式	2
3.2 不同层的功能分工	3
3.3 本章小结	3
4 Attention Sink 现象	3
4.1 什么是 Attention Sink?	3
4.2 为什么会出现 Attention Sink?	3
4.3 Attention Sink 的影响	4
4.4 本章小结	4
5 Gated Attention: 缓解 Attention Sink	4
5.1 核心思想	4
5.2 本章小结	4
6 总结与延伸	4
6.1 拓展阅读	4

1 引言

过去两期深入介绍了 RoPE 的几何视角和远程衰减推导。本期聚焦于 **Attention 的可解释性**——Multi-Layer Multi-Head Attention 中各层各头到底在提取、处理和加工什么信息。

核心出发点是 Qwen 团队在 NeurIPS 获得最佳论文的 **Gated Attention** 工作，它试图缓解 Attention 中的 Attention Sink 现象。

模型可解释性作为研究方向

对于没有大规模 GPU 资源的研究者，模型可解释性是一个很好的方向：只需构造测试用例、跑前向推理、分析 Attention 模式，即可进行有意义的研究。本质上就是在“Debug 大语言模型”。

2 Attention 基础回顾

2.1 Pre-Softmax Attention Score

Attention 的核心公式：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

在 Softmax 之前的 $QK^T/\sqrt{d_k}$ 称为 **Attention Logits** 或 **Attention Score**。它决定了模型在处理位置 m 的 token 时，对位置 n 的 token 分配多少注意力。

2.2 Multi-Layer Multi-Head 的多样性

在 Transformer 中，每层有多个 Attention Head，不同层的不同 Head 学习到截然不同的注意力模式。通过可视化这些模式，可以理解模型的内部工作机制。

2.3 本章小结

Attention Score 是理解模型行为的窗口。Multi-Head 机制保证了不同 Head 可以学到不同类型的依赖关系。

3 Attention Head 的典型模式

3.1 常见的 Head 模式

通过构造测试序列并可视化不同 Head 的 Attention 矩阵，可以识别出以下典型模式：

五种典型 Attention 模式

1. **Local Head**: 主要关注相邻 token, 呈对角线形式
2. **Strided Head**: 以固定步长关注 token, 捕获周期性模式
3. **Global Head**: 几乎均匀关注所有 token
4. **Position Head**: 关注特定位置 (如句首、段落开头)
5. **Sink Head**: 将大量注意力集中在序列的第一个 token 上

3.2 不同层的功能分工

一般规律:

- **浅层 (底层)**: 更多 Local Head, 处理语法、词组搭配
- **中层**: 混合模式, 开始建立语义关联
- **深层 (顶层)**: 更多 Global 和 Position Head, 处理高层语义

3.3 本章小结

不同 Head 自然分化出不同功能。浅层关注局部语法, 深层关注全局语义, 形成了一个从底向上的抽象层次结构。

4 Attention Sink 现象

4.1 什么是 Attention Sink ?

Attention Sink 定义

在自回归语言模型中, 大量 Attention Head 会将异常高的注意力权重分配给序列的**第一个 token** (或前几个 token), 即使这些 token 在语义上并不重要。这种现象称为 **Attention Sink**。

4.2 为什么会出现 Attention Sink ?

Softmax 的特性要求注意力权重之和为 1。当模型对某些位置“没什么可注意的”时, 它需要把注意力“倾倒”到某个地方。第一个 token 成为了默认的“垃圾桶”:

Attention Sink 的成因

- Softmax 强制归一化 $\rightarrow$ 注意力必须分配到某处
- 第一个 token 对所有后续 token 都可见 (因果 mask 下)
- 模型训练中自然学会将“无意义”的注意力倾倒在此
- 并非第一个 token 本身有特殊的语义价值

4.3 Attention Sink 的影响

- **KV Cache**: 在流式推理 (sliding window) 中, 如果丢弃了第一个 token 的 KV, 模型输出质量会显著下降
- **模型质量**: 注意力资源被浪费在无意义的位置
- **可解释性**: 干扰了对模型真实注意力模式的分析

4.4 本章小结

Attention Sink 是 Softmax 归一化的副产品, 第一个 token 成为了注意力的“默认接收器”。这个现象对 KV Cache 管理、模型效率和可解释性都有重要影响。

5 Gated Attention: 缓解 Attention Sink

5.1 核心思想

Gated Attention 引入一个**门控机制**, 允许模型在某些 Head/位置上“不分配注意力”, 从而避免被迫将注意力倾倒在第一个 token:

$$\text{GatedAttention}(Q, K, V) = g \odot \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 g 是一个可学习的门控向量, 可以将某些位置的注意力输出缩放到接近 0。

5.2 本章小结

Gated Attention 通过门控机制让模型“有权不注意”, 缓解了 Softmax 强制归一化带来的 Attention Sink 问题。

6 总结与延伸

1. Multi-Head Attention 的不同 Head 自然分化出 Local、Global、Sink 等模式
2. Attention Sink 是 Softmax 归一化的副产品, 第一个 token 充当注意力“垃圾桶”
3. Gated Attention (NeurIPS Best Paper) 通过门控缓解此问题
4. 模型可解释性研究只需前向推理即可开展, 适合资源有限的研究者

6.1 拓展阅读

- Qwen/NeurIPS Best Paper: Gated Attention
- “Efficient Streaming Language Models with Attention Sinks” (Xiao et al., 2023)
- Anthropic 的 Attention Head 分类研究