

课程笔记

VLM 多模态架构：Gemini vs Qwen3-VL vs K2.5

基于公开课程资料整理

2025

原生多模态
Gemini
Kimi K2.5
Qwen3-VL

视频作者/频道：五道口纳什

发布日期：2025

视频时长：约 23 分钟

项目主页：<https://github.com/hqh1025/ai-course-notes>

目录

1 引言	2
2 模态之间的鸿沟	2
2.1 不同模态的维度特性	2
2.2 本章小结	2
3 理解“原生多模态”	2
3.1 非原生 vs. 原生	2
3.2 Qwen3 分系列 vs. K2.5 不分	3
3.3 本章小结	3
4 VLM 的一般性架构	3
4.1 三大组件	3
4.2 动态分辨率处理	3
4.3 本章小结	4
5 总结与延伸	4
5.1 拓展阅读	4

1 引言

本期是架构系列的一个特别篇，为后续 K2.5 串讲做铺垫。我们从“原生多模态”（Native Multimodal）的视角，对比三个代表性 VLM：Qwen3-VL、KiMi VL（K2.5 的前身）和 Gemini，回答两个核心问题：

1. 如何理解“原生多模态”？
2. 为什么 Qwen3 分了纯语言和 VL 两个系列，而 K2.5 不分？

2 模态之间的鸿沟

2.1 不同模态的维度特性

表 1: 不同模态的数据维度

模态	维度	特性
文本 (Text)	1D	Token Sequence
图像 (Image)	2D	Spatial
视频 (Video)	3D	Spatial + Temporal
音频 (Audio)	1D	Temporal

当前 VLM 的音频短板

Qwen3-VL 和 K2.5 虽然在视觉语言方面做得非常出色，但它们只将视频当作多帧图像序列处理，**不处理音频信息**。只有 Gemini 等少数模型支持完整的视频 + 音频输入。

模态之间是“纯粹鸿沟”的——需要**对齐**（Alignment）、**映射**（Mapping）到同一个表示空间中。

2.2 本章小结

多模态模型的核心挑战是将不同维度、不同性质的数据映射到统一的表示空间。当前主流 VLM 主要解决了文本 + 图像（+ 视频帧），音频处理仍是短板。

3 理解“原生多模态”

3.1 非原生 vs. 原生

原生多模态 (Native Multimodal) 的定义

模型并非由独立的单模态模型通过简单的胶水层拼接而成，而是从架构设计之初就将多模态理解融入到模型的核心结构中。早期的语言模型加视觉编码器的方案属于“非原生”。

非原生方案（早期 VLM）：

- 一个预训练好的视觉编码器（如 ViT）

- 一个预训练好的语言模型（如 LLaMA）
- 一个简单的投影层（MLP projector）连接两者
- 各模块可独立训练，拼接后微调

原生方案：

- 视觉和语言从一开始就在同一个模型中联合训练
- 或者虽然有独立的编码器，但通过深度融合（如交叉注意力）实现紧密耦合

3.2 Qwen3 分系列 vs. K2.5 不分

为什么 Qwen3 分了两个系列？

- **Qwen3**：纯语言模型系列（Dense + MoE）
- **Qwen3-VL**：视觉语言模型系列
- 两个系列有独立的架构代码、独立的训练流程

而 KiMi 早期有 KiMi VL 的分离版本，但到 K2.5 已经不再区分纯语言和 VLM，实现了真正的“原生多模态”——一个模型同时具备语言和视觉能力。

3.3 本章小结

“原生多模态”代表了从“拼接”到“融合”的架构演进。K2.5 不再区分纯语言和 VLM 模型，是这一趋势的体现。

4 VLM 的一般性架构

4.1 三大组件

标准的 VLM 架构包含三个核心组件：

1. **视觉编码器**（Vision Encoder）：将图像/视频编码为视觉 token。常用 ViT（Vision Transformer）
2. **投影/对齐模块**（Projector/Adapter）：将视觉 token 映射到语言模型的 embedding 空间
3. **语言模型骨干**（LLM Backbone）：处理混合的文本 + 视觉 token 序列

4.2 动态分辨率处理

现代 VLM 普遍支持动态分辨率输入，不再将所有图像调整到固定大小：

- 将图像分割成多个 patch
- 每个 patch 编码为若干视觉 token
- 更高分辨率 → 更多视觉 token → 更长的序列

4.3 本章小结

VLM = 视觉编码器 + 投影模块 + 语言模型。动态分辨率处理是当前的标准做法，使模型能够处理不同大小的图像。

5 总结与延伸

1. 模态间存在天然鸿沟，需要对齐映射到统一空间
2. “原生多模态”是架构趋势：从拼接到融合
3. 当前 VLM 主要处理文本 + 图像 + 视频帧，音频仍是短板
4. K2.5 不再区分纯语言和 VLM，实现了原生多模态
5. 下一期将完整串讲 K2.5 论文

5.1 拓展阅读

- Qwen3-VL 技术报告
- KiMi K2.5: Visual Agency Intelligence
- Gemini 技术报告
- KiMi VL (K2.5 的前身)