

课程笔记

SAM3 与 VLM: Visual Prompting 与 Grounding

基于公开课程资料整理

2025

SAM3/VLM
检测/识别/分割
Visual Prompting
Visual Grounding
Gemini 原生分割能力

视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 17 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：多模态的新世界	2
2 Visual Prompting：视觉提示的新范式	2
2.1 什么是 Visual Prompting	2
2.2 Visual Prompting 与 Visual Grounding	2
2.3 本章小结	3
3 SAM3：Segment Anything Model 3	3
3.1 SAM3 相比 SAM1/SAM2 的进化	3
3.2 SAM3 的使用流程	3
3.3 SAM3 实例级分割示例	4
3.4 本章小结	4
4 SAM3 Agent：VLM + SAM3 的协作架构	4
4.1 架构设计：大脑与眼睛/手	4
4.2 工具定义与 System Prompt	4
4.3 Visual Grounding 的完整交互流程	5
4.4 实现细节	5
4.5 本章小结	5
5 Gemini 2.5 Flash：原生多模态视觉能力	5
5.1 对话式的检测分割识别	5
5.2 使用方式	6
5.3 分割效果评估	6
5.4 本章小结	6
6 三种方案对比	7
7 总结与延伸	7

1 引言：多模态的新世界

本期是 Modern Agents 系列中第一次正式介绍 VLM (Vision-Language Model, 视觉语言模型)。课程围绕三大主题展开：

1. **SAM3**: Meta 发布的 Segment Anything Model 3, 用于经典 CV 任务——检测、分割、识别；
2. **SAM3 Agent**: 将 VLM 与 SAM3 结合, 实现视觉问答 (VQA) 与 Visual Grounding；
3. **Gemini 2.5 Flash 原生多模态**: 端到端的对话式检测分割识别。

从数字世界到物理世界

多模态视觉能力让语言模型“插上眼睛”，打开了通往物理世界的大门。Embodied AI、Robotics 等更广阔的应用场景，都依赖于模型对图像中物体的检测、分割与识别能力。

2 Visual Prompting：视觉提示的新范式

2.1 什么是 Visual Prompting

Visual Prompting 的核心理念是：与其用文字告诉 AI 找什么，不如直接在图片里标注。具体的视觉线索 (Visual Cues) 包括：

- **点标注** (Point Prompt): 在图片上指定一个点
- **框标注** (Bounding Box Prompt): 画一个矩形框
- **涂鸦标注** (Scribble): 自由涂画区域
- **文本标注**: 在图片上写文字说明

这些视觉线索引导模型完成特定的视觉任务，如 VQA、图像分割、目标检测等。在图像生成领域，用户也可以通过在图片中框选区域并写上文字，来指导视觉生成模型做更精确的编辑。

Visual Prompting 的本质

Visual Prompting 是一种将人类的视觉意图直接编码到图像中的交互方式。它弥补了纯文本 Prompt 在空间定位上的不足——某些视觉任务（如“最左边的那个蓝色物体”）用文字描述既冗长又容易歧义，而直接在图上标注则直观明了。

2.2 Visual Prompting 与 Visual Grounding

Visual Grounding 是 Visual Prompting 的逆过程：

- **Visual Prompting**: 人在图上标注 → 引导模型理解
- **Visual Grounding**: 模型理解文本 → 在图上定位（框出/分割出目标）

两者结合形成了完整的“视觉对话”闭环。

2.3 本章小结

Visual Prompting 将传统的文本提示扩展到视觉维度，为 CV 任务提供了更自然、更精确的人机交互方式。它是理解 SAM3 与 VLM 协作的基础概念。

3 SAM3: Segment Anything Model 3

3.1 SAM3 相比 SAM1/SAM2 的进化

SAM (Segment Anything Model) 系列是 Meta 推出的通用分割模型。SAM3 相比前两代的关键进化在于支持了文本 Prompt 输入：

能力	SAM1	SAM2	SAM3
点/框 Prompt 分割	✓	✓	✓
视频分割	×	✓	✓
文本 Prompt 分割	×	×	✓
识别（输出 Label）	×	×	✓

表 1: SAM 系列能力对比

SAM3 不是 VLM

SAM3 虽然支持文本输入，但它只接受**简单的名词短语**（如“cat”、“person”、“shoe”），而非自然语言句子。它不支持列表输入（如“cat, remote”），也不支持复杂的修饰语。需要一次识别多类物体时，必须逐个遍历类别名称。

3.2 SAM3 的使用流程

SAM3 的基本使用非常简洁：

1. 通过 `build_model` 加载 SAM3 模型（约 3.3GB，自动下载到 HuggingFace Hub 目录）
2. 将模型放到 CUDA 设备上
3. 构建 Processor，传入图像和文本 Prompt
4. 获取输出：Mask（分割掩码）、Bounding Box、置信度分数

```
1 # 构建模型
2 model = build_sam3_model()
3 model.to("cuda")
4
5 # 构建 Processor
6 processor = SAM3Processor(model)
7
8 # 读取图片并推理
9 image = load_image(url)
10 with torch.inference_mode():
```

```
11 outputs = processor(image, text_prompt="remote")
12 # outputs 包含: masks, bounding_boxes, confidence_scores
```

Listing 1: SAM3 基本使用示例（伪代码）

3.3 SAM3 实例级分割示例

以 COCO 数据集中的经典图像（两只猫、两个遥控器）为例：

- 输入 "remote"：准确识别两个遥控器，各自有独立的 Mask 和编号（Instance 0、Instance 1），置信度约 0.96
- 输入 "cat"：准确识别两只猫，置信度同样很高
- 多类检测：通过遍历类别列表 ["remote", "cat"]，融合结果得到全部四个实例

对于更复杂的场景（如多个孩子、鞋子、门等），SAM3 也能实现实例级别的分割，但在复杂目标（如半遮挡的门）上置信度会有所下降。

3.4 本章小结

SAM3 通过引入文本 Prompt，在保持高质量分割能力的同时实现了识别功能，但其文本理解能力仅限于简单名词短语。对于需要空间推理或语义理解的复杂查询，需要结合 VLM 来弥补。

4 SAM3 Agent：VLM + SAM3 的协作架构

4.1 架构设计：大脑与眼睛/手

SAM3 官方代码库提供了一个 Agent 示例，其核心思想是将 VLM 与 SAM3 分工协作：

SAM3 Agent 的分工模式

- **VLM（大脑）**：负责高层语义推理、理解用户的自然语言意图、规划执行步骤
- **SAM3（眼睛/手）**：负责底层视觉操作、生成精确的 Mask 分割

VLM 不直接画 Mask，而是指挥 SAM3 去画 Mask。

4.2 工具定义与 System Prompt

SAM3 Agent 定义了四个工具（Tools），其中最核心的是 `segment_phrase`：

- 输入：一个简单的名词短语（如 "child"、"blue vest"）
- 输出：全图中所有匹配物体的 Mask 图像（带编号标签）

System Prompt 中明确规定了关键约束：

- **禁止使用方位词**：不能输入 "left child"
- **禁止使用数量词**：不能输入 "three cats"
- **强制通用名词**：只能用 "child"、"person" 等通用短语

4.3 Visual Grounding 的完整交互流程

以”找出最左侧穿蓝色马甲的孩子”为例：

第 1 轮——分割阶段：

1. GPT-4o 接收原始图像和用户 Query
2. 因为 SAM3 不擅长方位推理（在 Tool 描述中已说明），GPT-4o 规划策略：先分割出所有穿蓝色马甲的孩子
3. 调用 `segment_phrase("child in blue vest")`
4. SAM3 返回带编号 Mask 的结构图（检测到 3 个匹配实例）

第 2 轮——推理阶段：

1. GPT-4o 接收带 Mask 标注的结构图（这就是 Visual Prompting!）
2. 进行视觉验证和空间推理，确定哪个 Mask ID 对应”最左侧”的孩子
3. 输出最终答案

VLM 的空间推理仍有缺陷

在实际测试中，GPT-4o 将 Mask ID 1 判断为最左侧，但正确答案应是 Mask ID 2——模型把左右搞混了。这说明即使是最先进的 VLM，在空间位置推理上仍然存在不稳定性。

4.4 实现细节

SAM3 Agent 的官方实现并未使用 LangChain/LangGraph 等现代 Agent 框架，而是采用了较为朴素的方式：

- 支持文本和图像的混合输入
- Tool 定义直接写在 System Prompt 中
- 官方示例基于 LLaMA 3 Vision 8B；讲者改用 GPT-4o（支持 Tool + 多模态输入）

4.5 本章小结

SAM3 Agent 展示了一种经典的”VLM + 专业视觉模型”协作范式：VLM 负责推理与规划，SAM3 负责精准的视觉操作。通过 Tool Call 机制，不具备分割能力的 VLM 获得了像素级别的分割能力，实现了 Visual Grounding。

5 Gemini 2.5 Flash：原生多模态视觉能力

5.1 对话式的检测分割识别

Gemini 2.5 Flash 代表了一种更”端到端”的路线：无需外挂 SAM3 等专业模型，模型本身就具备检测、分割和识别的能力。

Gemini 2.5 Flash 的原生视觉能力

截至 2025 年 12 月，支持原生 Mask 分割输出的 VLM 仅有 Gemini 2.5 Flash。其关键特点：

- 对话式交互：用自然语言 Query 触发分割
- 输出格式：List of Dict，每个 Dict 包含 `box_2d`（边界框）、`mask`（分割掩码图片）、`label`（描述性标签）
- BBox 坐标在 1000×1000 范围内归一化，叠加到原图时需要转换

5.2 使用方式

调用 Gemini 2.5 Flash 进行分割的关键配置：

- 使用 `gemini-2.5-flash` 模型
- 设置 `temperature=0`（确保确定性输出）
- 传入图文 Prompt，使用官方推荐的分割 Prompt 模板

5.3 分割效果评估

以多个孩子跑步的测试图为例：

- 六个孩子中，五个的检测分割非常准确
- 第三个孩子的框略有偏差
- 整体准确率很高，Mask 质量是 0/1 矩阵的像素级分割

Gemini 2.5 Flash Preview 与 Pro 的区别

- **Gemini 2.5 Flash**：支持完整的 Mask 输出，是目前唯一支持原生对话式分割的 VLM
- **Gemini 2.5 Flash Preview**（新发布）：暂不支持 Mask 输出
- **Gemini 2.5 Flash 3 Pro**：可能只输出描点而非完整 Mask

5.4 本章小结

Gemini 2.5 Flash 展示了 VLM 发展的一个重要方向——将检测、分割、识别能力原生内化到一个统一模型中，实现真正的“对话式视觉理解”。虽然 SAM3 + VLM 的组合方案更灵活，但端到端方案代表了未来的趋势。

6 三种方案对比

维度	SAM3 单独	SAM3 + VLM	Gemini 原生
文本理解	简单名词短语	任意自然语言	任意自然语言
分割精度	高	高 (SAM3 执行)	高
空间推理	不支持	VLM 负责 (有局限)	模型内置
交互方式	API 调用	多轮 Tool Call	对话式
部署复杂度	需要 GPU (3.3GB)	需要 GPU + API	云 API
可扩展性	需遍历类别	Agent 自动规划	单次请求

表 2: 三种视觉分割方案对比

7 总结与延伸

本期课程完成了从传统 CV 工具到现代多模态 Agent 的完整过渡：

1. **SAM3** 通过引入文本 Prompt，将”万物分割”升级为”万物检测分割识别”
2. **SAM3 Agent** 展示了如何用 VLM 作为推理大脑、SAM3 作为视觉执行器，通过 Tool Call 实现 Visual Grounding
3. **Gemini 2.5 Flash** 代表了端到端原生多模态的方向，将检测分割识别统一在一个对话式模型中

拓展思考

- **Embodied AI**: 视觉分割是机器人操作的基础——识别物体、理解场景、规划抓取
- **Visual Prompting 的未来**: 随着模型能力提升，人类提供的视觉线索将从”显式标注”演变为”模型自主生成视觉草图”（如 Gemini 的 Agentic Vision）
- **开放词汇分割**: SAM3 + VLM 的组合实现了 Open-Vocabulary Segmentation，不再受限于预定义的类别列表