

课程笔记

多模态 Visual Prompting: SAM 1/2/3 与 Grounding DINO

基于公开课程资料整理

2025

Visual Prompting SAM 1/2/3 Grounding SAM2 Robotics 初步

视频作者/频道: 五道口纳什

发布日期: 2025

视频时长: 约 19 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1 Visual Prompting: 概念与动机	2
1.1 什么是 Visual Prompting	2
1.2 回归问题变分类问题	2
1.3 本章小结	2
2 SAM 系列: 从实例分割到语义分割	3
2.1 SAM 1 与 SAM 2: 实例级分割	3
2.2 SAM 3: 语义级可提示分割	3
2.3 VLM + SAM 3 Agent 组合	3
2.4 本章小结	4
3 Grounding DINO 与检测-分割 Pipeline	4
3.1 Grounding DINO: 开放词汇目标检测	4
3.2 Grounding SAM 2: 视频级物体追踪	4
3.3 本章小结	5
4 Set-of-Mark: 全图编号辅助定位	5
4.1 方法原理	5
4.2 优势分析	5
4.3 本章小结	5
5 FreeGrasp: 机器人抓取中的 Visual Prompting	6
5.1 问题设定	6
5.2 Pipeline 设计	6
5.3 本章小结	6
6 Pivot: 机器人导航中的迭代式 Visual Prompting	6
6.1 问题设定与方法	6
6.2 Visual Prompting 在导航中的价值	7
6.3 本章小结	7
7 总结与延伸	8
7.1 Visual Prompting 的统一范式	8
7.2 技术演化方向	8
7.3 拓展阅读	8

1 Visual Prompting: 概念与动机

1.1 什么是 Visual Prompting

Visual Prompting (视觉提示) 是一种在多模态视觉-语言模型 (VLM) 交互中, 通过在原始图片上叠加视觉标记 (如编号、箭头、掩码区域、边界框等), 来辅助模型更好地进行视觉推理与定位的技巧。

Visual Prompting 的核心思想

Visual Prompting 的本质是: 在送给 VLM 之前, 先用 CV 模块对原始图片做预处理 (分割、检测、标注编号), 再将增强后的图片送给 VLM 做推理。这样做将”直接生成坐标”的回归问题, 转化为”选择编号”的分类问题, 大幅降低了模型推理难度。

以 Set-of-Mark (SoM) 为例: 给定一张原始图片和一个文本问题, SoM 首先用分割模型对图片做全图实例分割, 然后为每个分割区域在其中心位置打上数字编号标签, 最终将这张带编号的新图片连同文本问题一起交给 VLM 进行问答。

为什么 Visual Prompting 有效

GPT-4V 等 VLM 在预训练阶段包含了大量带有标注的图表 (labelled figures)、教科书插图 (charts, textbooks) 等图文对数据。这些训练数据中的图片本身就包含箭头、编号、分割区域等视觉标记。因此, 当我们人为地在图片上添加类似标记时, 能很自然地激活模型内部对这类标注的注意力机制, 从而提升推理准确率。类似于数学几何题中的标注——编号、箭头、方向标记, 都能帮助模型聚焦关键信息。

1.2 回归问题变分类问题

Visual Prompting 最关键的优势在于降低推理难度:

- **常规方式:** VLM 需要直接输出目标物体的精确坐标 (x, y) 或边界框 (x_1, y_1, x_2, y_2) , 这是一个回归问题
- **Visual Prompting 方式:** 图片已经被分割并打上编号, VLM 只需选择正确的编号即可, 这变成了一个分类/选择问题

Visual Prompting 并非万能

随着现代 VLM (如 GPT-4o、Gemini 2.5 等) 的视觉能力越来越强, 部分场景下模型已经能直接准确输出坐标。但在复杂场景 (多物体、遮挡、方位描述等) 中, Visual Prompting 仍然是非常实用的辅助技巧。它通过帮助模型聚焦注意力并稳定推理过程, 显著提升定位准确率。

1.3 本章小结

Visual Prompting 是一种在原始图片上叠加 CV 预处理结果 (分割掩码、数字编号、边界框等) 的技巧, 能将物体定位的回归问题转化为选择问题, 降低 VLM 推理难度, 提升准确率。其有效性源于 VLM 训练数据中天然包含大量带标注图片。

2 SAM 系列：从实例分割到语义分割

2.1 SAM 1 与 SAM 2：实例级分割

SAM (Segment Anything Model) 是 Meta 推出的通用分割模型系列。SAM 1 和 SAM 2 都支持实例级别的分割，主要输入方式包括：

- **Point Prompt**：在图片中指定一个点，分割该点所在的主体（如鲸鱼身体中心的点，分割出整条鲸鱼）
- **Bounding Box Prompt**：给定一个边界框，分割框内的主体
- **Automatic Mask Generation**：不需要任何输入提示，自动对整张图片进行全图实例分割

SAM 的 Point/Box 输入本身就是 Visual Prompting

从广义上看，SAM 接受的 Point 和 Bounding Box 输入，本身就是一种 Visual Prompting——在原始图片中指定具体的视觉位置信息，引导模型进行分割。这种设计使得 SAM 可以灵活地与其他模型组合使用。

SAM 1 和 SAM 2 的自动分割功能 (Automatic Segmentation) 不需要任何人工输入，只接收原始图片，就能对全图所有实例进行分割。这一功能是 Set-of-Mark 等 Visual Prompting 方法的基础组件。

2.2 SAM 3：语义级可提示分割

SAM 3 相比前代有了质的飞跃，支持语义级别的分割，且是 promptable（可提示）的：

SAM 3 的多模态输入

SAM 3 支持以下多种输入方式：

- **文本输入**：输入一个简单的名词短语（如“cat”），分割出图中所有的猫
- **Point/Box 输入**：继承自 SAM 1/2 的经典交互方式
- **示例图输入**：提供正样本和负样本图片，向正样本靠近、远离负样本

SAM 3 的文本输入限制

SAM 3 的文本输入只支持简单的名词短语 (noun phrase)，**不支持方位词**（如“左边的猫”、“最上面的杯子”等包含空间关系的描述）。如果需要处理包含方位描述的复杂查询，需要借助 VLM 先将复杂描述简化为名词短语，再交给 SAM 3。

2.3 VLM + SAM 3 Agent 组合

由于 SAM 3 不支持方位词，可以构建一个 VLM + SAM 3 的 Agent Pipeline 来处理复杂的物体定位任务：

1. **用户输入复杂查询**：如“穿蓝色马甲的最左侧的孩子”

2. **VLM 简化查询**：将复杂描述转化为简单名词短语——“child in blue vest”
3. **SAM 3 分割**：基于简化后的文本，分割出所有穿蓝色马甲的孩子
4. **打上编号**：对分割结果打上数字编号
5. **VLM 二次推理**：基于带编号的分割图，VLM 可以准确定位”最左侧的”那个孩子

这种 Pipeline 的核心思想是：VLM 负责语言理解和推理，SAM 3 负责视觉分割，两者各司其职，协同完成单一模型难以完成的复杂定位任务。

2.4 本章小结

SAM 系列从 SAM 1/2 的实例分割，演进到 SAM 3 的语义级可提示分割。SAM 3 支持文本、点、框、示例图等多模态输入，但文本仅限简单名词短语。通过 VLM + SAM 3 的 Agent 组合，可以处理包含方位词的复杂定位任务。

3 Grounding DINO 与检测-分割 Pipeline

3.1 Grounding DINO：开放词汇目标检测

Grounding DINO 是一个开放词汇（open-vocabulary）的目标检测模型，能根据自然语言描述在图片中定位目标物体，输出边界框（bounding box）。

检测 → 分割的标准 Pipeline

在实际应用中，通常将检测与分割组合使用：

1. 用 Grounding DINO 根据文本描述检测目标，得到边界框
2. 计算边界框的中心点
3. 将边界框或中心点作为 Prompt 输入给 SAM，对目标物体做像素级分割

这样就从粗粒度的框定位，精细化到像素级的不规则多边形分割区域。

以自动驾驶场景为例：用户描述”红色跑车”，Grounding DINO 先在图中框出红色跑车的边界框，然后 SAM 基于这个框做精确的像素级分割，得到不规则多边形区域。

3.2 Grounding SAM 2：视频级物体追踪

Grounding SAM 2 将 Grounding DINO 与 SAM 2 的视频追踪能力相结合，用于视频级别的物体追踪（tracking）：

1. **选取关键帧**：从视频中取出一个典型帧
2. **检测目标**：用 Grounding DINO 检测目标物体（如”little girl”），得到边界框
3. **初始分割**：将边界框作为 Box Prompt 输入 SAM 2，分割出目标
4. **视频追踪**：用 SAM 2 的 Tracking 模块，在整个视频的所有帧中持续追踪并分割该目标

追踪阶段可以使用多种提示信息：

- 原始的边界框
- 分割区域中采样的点 (Point Prompt)
- 分割得到的 Mask 区域

3.3 本章小结

Grounding DINO 提供开放词汇检测能力，与 SAM 系列结合形成检测 → 分割的标准 Pipeline。Grounding SAM 2 进一步将其扩展到视频追踪场景，实现单帧检测 + 全视频追踪的端到端流程。

4 Set-of-Mark：全图编号辅助定位

4.1 方法原理

Set-of-Mark (SoM) 是 Visual Prompting 的代表性工作，方法极其简单但非常有效：

1. 对原始图片做全图实例分割（使用 SAM 的自动分割功能）
2. 在每个分割区域的中心点打上数字编号
3. 将带编号的新图片连同文本问题一起输入 VLM
4. VLM 通过选择编号来回答定位问题

SoM 的设计假设

SoM 的有效性基于一个关键假设：VLM 在预训练阶段已经接触了大量带标注的 labelled figures、charts 和 textbooks。这些数据中天然包含编号、箭头等标记，因此 VLM 对这类视觉标记有很强的理解能力。SoM 利用这种能力，将图像分割为语义区域，赋予每个区域可读的 ID，让 VLM 能够“看图说话”。

4.2 优势分析

SoM 的两大核心优势：

1. **降低推理难度**：将直接生成坐标的回归问题变为选编号的分类问题
2. **辅助注意力聚焦**：分割后的编号标记帮助模型聚焦到具体区域，稳定推理过程中的注意力

4.3 本章小结

SoM 通过全图分割 + 编号标注的简单策略，将物体定位问题转化为选择题，显著降低 VLM 的推理难度，是 Visual Prompting 的经典范例。

5 FreeGrasp: 机器人抓取中的 Visual Prompting

5.1 问题设定

FreeGrasp 解决的是机器人自由形式抓取 (free-form grasping) 问题: 用户用自然语言给出模糊的抓取指令 (如”抓底部的红色玩具车”), 机器人需要理解指令、定位目标物体、处理遮挡, 最终完成抓取。

遮挡处理是关键挑战

在真实抓取场景中, 目标物体常被其他物体遮挡。FreeGrasp 设计了一个完整的 Pipeline 来处理遮挡: 先识别目标 → 判断是否被遮挡 → 移开遮挡物 → 再抓取目标。这个过程需要 VLM 具备多步推理能力。

5.2 Pipeline 设计

FreeGrasp 的处理流程:

1. **输入:** RGBD 图像 (RGB 用于视觉推理, Depth 用于机械臂执行) + 自然语言指令
2. **全图检测:** 用预训练的 CV 模型检测全图所有物体, 获取每个物体的中心点
3. **Visual Marking:** 在中心点位置标注数字编号
4. **VLM 推理:** 使用结构化 Prompt, 让 VLM 基于带编号的图片进行多步推理:
 - 识别目标物体 (哪个编号是目标?)
 - 判断是否被遮挡 (哪些物体遮挡了目标?)
 - 规划移除遮挡物的顺序
5. **分割与抓取:** 对目标物体做分割, 传统算法估计抓取姿态, 机械臂执行

Free-form 的含义

FreeGrasp 中”Free” 指的是用户输入的自由度——可以用任意自然语言描述抓取目标, 无需结构化的指令格式。这得益于 VLM 强大的自然语言理解能力。

5.3 本章小结

FreeGrasp 将 Visual Prompting 技术应用于机器人抓取领域, 通过检测 → 编号 → VLM 推理 → 分割 → 执行的 Pipeline, 实现了基于自由形式自然语言指令的物体抓取, 其中遮挡检测与处理是核心创新。

6 Pivot: 机器人导航中的迭代式 Visual Prompting

6.1 问题设定与方法

Pivot 解决的是机器人视觉导航问题: 机器人需要根据指令 (如”找到木质长凳”) 在环境中导航移动。

Pivot 的迭代式优化

Pivot 采用迭代式的 Visual Prompting 策略：

1. 从动作空间中采样一组候选方向
2. 将候选动作映射到图片空间（在图片上标记方向箭头/编号）
3. 让 VLM 基于带标记的图片推理最佳的几个候选方向
4. 在选出的子空间中重新采样，重复以上过程
5. 迭代若干轮后输出最终动作

算法的核心输入：

- 原始 RGB 图片
- 导航指令
- 动作空间定义
- 最大迭代次数 T
- 每轮采样数量 K

在每次迭代中，从概率化的动作策略 π 中采样 K 个动作，映射到图像空间后让 VLM 选择最优的几个候选，然后拟合新的动作分布，循环直到达到最大迭代次数。这本质上是一种采样-选择-细化的优化过程。

6.2 Visual Prompting 在导航中的价值

在导航任务中，Visual Prompting 的价值在于：将抽象的动作选择（前进、左转 30 度、右转 15 度等）转化为直观的视觉选择——在图片上标出候选方向的编号，让 VLM 基于视觉信息选择最合理的方向。

导航场景的特殊性

与物体定位不同，导航需要的不是“图中哪个物体”的选择，而是“往哪个方向移动”的决策。Visual Prompting 在这里的作用是将连续的方向空间离散化为有限的标记选项，降低 VLM 的决策难度。

6.3 本章小结

Pivot 展示了 Visual Prompting 在机器人导航中的应用，通过迭代式的采样 → 标记 → VLM 推理 → 细化流程，实现了基于视觉的导航决策，是 Visual Prompting 从静态定位扩展到动态决策的代表性工作。

7 总结与延伸

7.1 Visual Prompting 的统一范式

本期介绍的所有工作——SoM、FreeGrasp、Pivot、VLM+SAM Agent——都遵循一个统一的范式：

Visual Prompting 统一范式

1. 使用经典 CV 模块（分割、检测、采样等）对原始图片做预处理
2. 在预处理结果上叠加视觉标记（编号、箭头、掩码等）
3. 将增强后的图片交给 VLM 做高层推理与决策

这种“CV 预处理 + VLM 推理”的组合，充分利用了两者的互补优势。

7.2 技术演化方向

- **模型能力增强**：随着 VLM 视觉理解能力的提升，部分 Visual Prompting 场景可能不再必要，但在复杂场景中仍有价值
- **端到端整合**：未来可能出现将 CV 预处理与 VLM 推理端到端整合的统一模型
- **更多应用场景**：从物体定位、机器人抓取、导航，到自动驾驶、医学影像等更多领域
- **动态视频处理**：结合 SAM 2 的视频追踪能力，Visual Prompting 可以扩展到视频理解与交互

7.3 拓展阅读

- Set-of-Mark Visual Prompting for GPT-4V (SoM 原论文)
- Segment Anything Model (SAM 1/2/3) 系列论文
- Grounding DINO：开放词汇目标检测
- FreeGrasp：机器人自由形式抓取
- Pivot：迭代式 Visual Prompting 导航