

演讲笔记

张钹院士：迈向通用人工智能

基于公开课程资料整理

2025



视频作者/频道: AITIME 论道

发布日期: 2025

视频时长: 约 20 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：大语言模型究竟掌握了什么？	2
2 分布式语义：大模型的理论基础	2
2.1 从稀疏到稠密	2
2.2 可证明的极限性质	2
2.3 本章小结	2
3 模型近似的五大缺陷	2
3.1 语义定义的根本困境	2
3.2 五大缺陷	3
4 AGI 的可操作定义：五项关键能力	3
4.1 为什么需要新定义	3
4.2 五项关键能力	3
5 从 LLM 到 Agent：实现路径	4
5.1 当前的六大技术方向	4
5.2 本章小结	4
6 AI 主体性的三个层次	4
7 对齐与治理：治理的对象是人，不是机器	5
7.1 对齐的悖论	5
7.2 治理研究者与使用者	5
8 AI 时代企业家的新使命	5
9 总结与延伸	6

1 引言：大语言模型究竟掌握了什么？

张钹院士（清华大学人工智能研究院名誉院长，中国科学院院士）从语言学和哲学的高度，系统分析了大语言模型的原理、局限，以及迈向通用人工智能（AGI）的真正挑战。

他从一个根本性的问题出发：机器能不能像人类一样理解语言？

大语言模型的成就与局限

在外部提示下，机器已经能够在开放领域生成多样性的、语义上连贯的、类似人类的语言。这算不算掌握了人类语言？答案是：算，但**还不够彻底**。它在很多地方与人类语言仍有本质差异。

2 分布式语义：大模型的理论基础

2.1 从稀疏到稠密

大语言模型的核心原理是**分布式语义**——用一个词周围的上下文来定义这个词的意义（Firth 的经典观点）。

关键技术突破

将语言从高维空间中的**稀疏表示**转化为**稠密的向量空间几何结构**，这是一个重大进步。它使得语言处理问题完全变成了**数学计算问题**——原来稀疏的共现空间不可计算，变成稠密向量空间后就可以用数学工具处理。

2.2 可证明的极限性质

可以证明：只要数据量足够多、上下文足够长，这个向量空间就会趋近于**语义关系空间**。这解释了为什么当前研究都在追求更长的上下文和更多的数据。

语义趋近的含义

一旦向量空间趋近了语言的语义关系，在一定意义下就可以做到“理解”，甚至可以做到**自反性**——对自己的思考进行思考。这在大语言模型中已经被观察到了。

2.3 本章小结

大语言模型基于分布式语义原理，通过稀疏到稠密的向量空间转换，实现了语言的可计算化。但这种语义定义本身是近似的。

3 模型近似的五大缺陷

3.1 语义定义的根本困境

张钹院士提出了一个深刻的观点：当前大语言模型中出现的很多怪现象，**不能简单归结于数据问题**。

被广泛误解的归因

“很多人发现机器里出现很多怪现象，都归结于数据问题。这是完全错误的。现在很多东西是由于**模型近似**引起的。”世界上有七八种不同哲学学派对“语义”的定义，没有任何一种是科学上完备的。分布式语义只是其中一种近似。

3.2 五大缺陷

由于语义定义的不完备性，大语言模型必然存在以下五个缺陷：

大语言模型的五大固有缺陷

1. **指称缺陷**：模型不能真正指向现实世界中的实体
2. **真实和因果缺陷**：模型缺乏因果推理能力，只能捕捉统计相关性
3. **语用缺陷**：模型无法真正理解语言在特定社会情境中的使用规则
4. **多义和动态缺陷**：词义的多样性和动态变化超出了静态向量表示的能力
5. **语境和闭环行为缺陷**：模型缺乏与物理环境的闭环交互能力

张钹院士强调：这五个缺陷是**固有的、必然存在的**——不是通过更多数据或更大模型就能消除的，因为问题的根源在于语义定义本身的不完备。

4 AGI 的可操作定义：五项关键能力

4.1 为什么需要新定义

张钹院士指出，当前对 AGI 的定义（如马斯克的“能完成人类 70% 以上任务”）**完全不可执行、不可检验**，必然引起争议。

模糊定义的危害

以模式识别为例：识别率超过人类就算“达到人类水平”吗？有人说算，有人说从鲁棒性来看差得远。模糊的定义让 AGI 的讨论陷入无休止的口水战。

4.2 五项关键能力

张钹院士提出了一个**可执行、可检验**的 AGI 定义，即必须达到以下五项关键能力（特别注意每项的**限定形容词**）：

AGI 的五项关键能力

1. **时空一致**的多模态理解——关键在“时空一致性”：不同模态的时间节奏不同步（视频逐帧、文本千年一句），对齐极其困难
2. **在线**的学习和适应——区别于离线学习；核心挑战是**可控性**，强化学习过程能否收敛到目标
3. **可检验**的推理和**长期**的规划——推理结果必须可验证；规划必须具备长期性
4. **可检验**的反思和元认知——当前反思都是“感觉性”的，缺乏可回溯、可验证的信号
5. **跨任务**的泛化——不仅是跨领域泛化（大模型已做得较好），还必须是分布外、结构不同、长尾场景下的跨任务泛化

形容词为什么重要

张钹院士反复强调“形容词非常重要”。例如：“多模态理解”很多团队都在做，但加上“时空一致”后难度骤增；“推理”很多模型都有，但“可检验的”推理则是完全不同的要求。这些限定词划定了真正的技术前沿。

5 从 LLM 到 Agent：实现路径

5.1 当前的六大技术方向

张钹院士认为，当前业界正在做的六件事都是冲着上述五个目标来的：

1. 多模态融合与具身交互
2. 检索增强（RAG）
3. 结构化知识对齐
4. 工具与执行的绑定
5. 对齐与约束
6. 在线学习与适应

5.2 本章小结

从 LLM 到能执行复杂任务的 Agent，需要在五个维度上取得突破。当前六大技术方向各有对应，但每个方向都面临着从“有”到“好”的关键形容词挑战。

6 AI 主体性的三个层次

张钹院士提出了人工智能作为“主体”的三个发展层次：

三个主体层次

1. **行为主体** (Agent of Action): 机器作为工具执行人类指令——**已经达到**, 我们很希望它达到, 因为它帮助我们
2. **规范和责任主体** (Agent of Norm): 机器能够承担责任——**尚未达到**, 技术难度较高, 但是可追求的目标
3. **体验和意识主体** (Agent of Consciousness): 机器拥有意识——这是最令人担忧的层次

对于实际从业者, 张钹院士建议关注前两个层次, 不必过早考虑第三个层次。

7 对齐与治理: 治理的对象是人, 不是机器

7.1 对齐的悖论

对齐到底对齐什么?

机器一定要和人类对齐吗? 人类自身存在贪婪、欺骗等缺陷——而这些恰恰是机器原本没有的。人类道德并非最高标准。那么“对齐”到底该对齐什么? 这值得深入讨论。

7.2 治理研究者与使用者

张钹院士明确指出: **最重要的治理对象不是机器, 而是人类**——特别是研究者和使用者。AI 时代的企业家必须承担更大的社会责任。

8 AI 时代企业家的新使命

张钹院士过去不赞成学生创业, 但大模型出现后改变了看法——**最优秀的学生应该去做企业**, 因为人工智能重新定义了企业家的角色。

六项新职责

AI 时代的企业家不再是简单地赚钱, 而应:

1. **重新定义价值创造**: 不是简单提供产品和服务, 而是将知识和推理变为可复用的工具
2. 将 AI 作为像水和电一样的通用技术交给人类
3. 承担社会责任与治理职责
4. 实现普惠的可持续增长
5. 参与 AI 安全与伦理建设
6. 推动教育与人才培养

9 总结与延伸

张钹院士的演讲从哲学和科学的根基出发，为我们理解 AGI 的路径提供了深刻的框架：

1. **理论基础**：分布式语义使语言可计算化，但语义定义本身是近似的
2. **五大固有缺陷**：指称、因果、语用、多义/动态、闭环行为——源于模型近似而非数据不足
3. **AGI 的可操作定义**：五项关键能力，每项的限定形容词划定了真正的技术前沿
4. **从 LLM 到 Agent**：六大技术方向对应五个目标
5. **主体性三层次**：行为主体 → 规范主体 → 意识主体
6. **治理的核心**：治理人（研究者和使用者），而非机器
7. **企业家新使命**：从赚钱到造福人类，AI 重新定义了企业家角色

拓展阅读

- Firth (1957): “A Synopsis of Linguistic Theory”——分布式语义的哲学根基
- 语义学七大流派（指称论、真值条件论、语用学、认知语义学等）
- AGI 等级定义：OpenAI 的 L1-L5 框架与 Google DeepMind 的 AGI 分类
- 可检验推理（Verifiable Reasoning）的最新研究进展
- 张钹院士此前关于“第三代人工智能”的系列论述