

课程笔记

[LLM Agents F24] Course Introduction

—Dawn Song & Xinyun Chen

基于公开课程资料整理

2024 年 9 月 9 日

UC Berkeley Center for Responsible,
Decentralized Intelligence

**LARGE LANGUAGE MODEL AGENTS
MOOC**

**TOWARDS BUILDING
SAFE & TRUSTWORTHY
AI AGENTS AND A PATH
FOR SCIENCE- AND
EVIDENCE-BASED AI
POLICY**

December 2, 2024



DAWN SONG
PROFESSOR, BERKELEY RDI
CO-DIRECTOR

UC Berkeley

视频作者/频道: Berkeley RDI

发布日期: 2024 年 9 月 9 日

视频时长: 约 60 分钟

视频链接: <https://rdi.berkeley.edu/llm-agents/f24>

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 课程导论：这门课在讲什么	2
1.1 大模型为什么自然走向 Agent	2
1.2 本章小结	3
2 什么是 LLM Agent	3
2.1 Agent 的系统组成	3
2.2 Agent 活跃的环境类型	4
2.3 本章小结	4
3 为什么要研究 Agent Framework	5
3.1 从单 Agent 到多 Agent 协作	5
3.2 应用机会与评测压力	6
3.3 本章小结	7
4 课程结构、作业与项目	7
4.1 课程内容分层	7
4.2 考核与项目组织	8
4.3 本章小结	8
5 总结与延伸	8
5.1 拓展阅读	8

1 课程导论：这门课在讲什么

这节课是 Berkeley “Large Language Model Agents” 的开场导论，由 Dawn Song 介绍课程定位、教学团队和学习目标。她把 Agent 放在 LLM 快速进化的大背景下讨论：语言模型已经足够强，但若想解决真实任务，就必须让模型与环境、工具、记忆和反馈形成闭环。

Teaching Staff

- **Instructor: Prof. Dawn Song**
- **(guest) Co-instructor: Dr. Xinyun Chen**
- **GSIs: Alex Pan & Sehoon Kim**
- **Readers: Tara Pande & Ashwin Dara**

图 1: 课程教学团队与协作角色。导论首先明确师资、助教和课程支持资源。

这门课的出发点

课程并不把 Agent 视为单次 prompt 的技巧集合，而是把它定义为一个完整系统：LLM 负责推理与规划，外部模块负责工具使用、记忆、检索和环境交互。只有把这些能力串起来，LLM 才能从“回答问题”转向“完成任务”。

1.1 大模型为什么自然走向 Agent

导论指出，近两年 LLM 的能力提升极快，但纯文本输入到纯文本输出的模式很快触到了上限。真实世界任务通常不是一次性问答，而是需要：

- 与环境交互，读取页面、文件、数据库或设备状态；
- 保留任务上下文和长期记忆；
- 在失败后重试、调整计划，并从反馈中修正行为；
- 调用外部工具弥补模型在计算、检索和执行上的短板。

从 LLM 到 Agent 的关键跳变

一旦模型拥有了记忆、工具使用、检索和反馈回路，它的行为单位就不再是“回答一句话”，而是“在多步交互中推进任务”。这也是 Agent 研究和普通 chatbot 应用的根本分界线。

1.2 本章小结

课程导论先把问题讲清楚了：Agent 不是给 LLM 再包一层 UI，而是把模型放进一个能持续观察、规划、行动和修正的执行框架中。

2 什么是 LLM Agent

2.1 Agent 的系统组成

LLM agents: enabling LLMs to interact with the environment




图 2: 课程用 Memory、Tool Use、Retrieval、Reasoning/Planning 和 Environment Feedback 概括 Agent 的标准组件。

课程给出的图景很清晰：Agent 的中心仍是 LLM，但 LLM 不再孤立运行，而是通过多个接口与外部系统耦合。


- **Memory**：保存任务上下文、用户偏好、历史轨迹，避免每轮对话都从零开始。
- **Tool use**：让模型调用搜索、代码执行、API、数据库或浏览器操作。
- **Retrieval**：从文档和知识库中拉取外部证据，避免全靠参数记忆硬答。
- **Reasoning & Planning**：把复杂目标拆成若干步骤，而不是直接给出单轮输出。
- **Feedback / Environment**：让 Agent 根据执行结果回看自己，形成 trial-and-error 的闭环。

为什么要保留这些模块边界

如果把记忆、检索、工具调用和规划全都塞回一个超长 prompt，系统将很难观测、调试和优化。Agent 框架的重要价值就在于把这些能力显式拆开，使每个组件都可以被替换、约束和评估。

2.2 Agent 活跃的环境类型

LLM Agents in Diverse Environments



<https://yusu.substack.com/p/language-agents>

图 3: LLM Agent 不只存在于聊天界面，还可以进入网页、软件开发、企业工作流和机器人等多种环境。

课程特别强调 Agent 的环境多样性。它既可以工作在数字环境中，例如 IDE、浏览器、工作流平台，也可以延伸到具身环境，如机器人和多模态感知任务。环境越开放，Agent 越需要：

- 在不完整信息下做局部决策；
- 从失败中恢复，而不是一次错误直接终止；
- 同时协调符号操作、自然语言交互和外部动作。

2.3 本章小结

LLM Agent 的定义不是“会调用工具的 LLM”这么简单，而是一个由模型、外部能力和反馈回路构成的任务执行系统。

3 为什么要研究 Agent Framework

3.1 从单 Agent 到多 Agent 协作

Multi-agent collaboration: division of labor for complex tasks




图 4: 导论把多 Agent 协作描述为复杂任务中的“分工机制”，不同模块负责不同子任务。

当任务跨度足够长、子任务差异足够大时，单个 Agent 往往会在上下文拥挤、职责混杂和推理漂移中失效。课程因此把多 Agent 协作列为核心主题之一：

- 专门的 planner 负责任务拆解；
- specialized executor 负责代码、检索、表格分析等局部操作；
- verifier / reviewer 负责检查事实性、一致性和安全性。

Framework 的真正价值

Agent framework 的价值不在于多套 API，而在于它为复杂任务提供了稳定的组织方式：如何拆分模块、如何传递上下文、如何让多个角色协作、如何把失败恢复写进执行流程。

3.2 应用机会与评测压力

LLM agents transformed various applications




图 5: 课程把代码生成、工作流自动化、个人助手和机器人并列展示, 说明 Agent 的应用边界正在快速扩张。

LLM agents are improving




图 6: GAIA、WebArena、SWE-Bench 等基准构成了 Agent 研究的早期评测坐标。

课程一开始就把应用和 benchmark 放在一起, 是因为 Agent 系统很容易做出 demo, 却很难稳定上线。导论中列出的挑战包括:

- 复杂任务中的推理和规划不稳;
- 长时程任务中对环境反馈的利用效率不高;
- 多模态理解和 world model 仍不成熟;

- 多 Agent 协作、理论解释和安全隐私尚未形成稳固框架。

导论里最重要的风险提醒

Agent 系统的失败通常不是“答错一道题”，而是长期任务中的累积偏差：错误计划、错误调用工具、错误读写外部环境，最后把小问题放大成系统性故障。也因此，部署 Agent 比部署普通 LLM 应用更强调可观测性和评测。

3.3 本章小结

研究 Agent framework 的原因很实际：它既决定系统能否处理真实任务，也决定这些系统能否被稳定评估、调试和部署。

4 课程结构、作业与项目

4.1 课程内容分层

Topics covered in this course

- Model core capabilities
 - Reasoning
 - Planning
 - Multimodal understanding
- LLM agent frameworks
 - Workflow design
 - Tool use
 - Retrieval-augmented generation
 - Multi-agent systems
- Applications
 - Software development
 - Workflow automation
 - Multimodal applications
 - Enterprise applications
- Safety and ethics

图 7: 本课程把内容分成模型能力、Agent framework、应用和安全伦理四条主线。

课程结构分为四层：

1. **Model core capabilities**: 推理、规划、多模态理解。
2. **LLM agent frameworks**: workflow、tool use、RAG、多 Agent。
3. **Applications**: 软件开发、工作流自动化、多模态和企业应用。
4. **Safety & ethics**: 部署风险、人机交互、隐私和控制问题。

项目方向的设计意图

课程项目不是让学生重复做一个聊天机器人，而是鼓励围绕五类主题展开：应用、基准、基础能力、安全、多 Agent / 去中心化系统。这个设计本身就在提示学生，Agent 研究并不是单一方向，而是一个由能力、系统和治理共同组成的研究空间。

4.2 考核与项目组织

导论中也给出了清晰的课程交付方式：

- 每周阅读任务，用于建立跨讲次的共识背景；
- 一次 hands-on lab，把框架和工具真正跑起来；
- semester-long project，鼓励五人组队并围绕完整问题展开。

从质量要求上看，课程把 1-4 unit 分别对应到不同强度的实现深度，说明它更重视“把 Agent 系统做成一个可说明、可展示、可验证的工程实体”，而不只是阅读论文或写概念综述。

4.3 本章小结

这门课的组织方式与它的主题高度一致：课程本身就是一个从阅读、实验到项目落地的 Agent 系统训练场。

5 总结与延伸

这节导论课完成了三件事：定义 LLM Agent 的系统结构、说明为什么 Agent framework 值得单独研究、以及给出整门课的能力地图与项目路线。它的核心信息非常直接：大模型能力已经足够强，但若想进入真实世界任务，关键瓶颈会从“模型会不会说”转向“系统会不会做”。

5.1 拓展阅读

- Mialon et al., “GAIA: a benchmark for General AI Assistants,” 2023–2024.
- Zhou et al., “WebArena: A Realistic Web Environment for Building Autonomous Agents,” 2024.
- Jimenez et al., “SWE-Bench: Can Language Models Resolve Real-World GitHub Issues?,” 2024.
- Yao et al., “ReAct: Synergizing Reasoning and Acting in Language Models,” ICLR 2023.