

课程笔记

[LLM Agents F24] Measuring Agent Capabilities & RSP —Ben Mann

基于公开课程资料整理

Fall 2024



BEN MANN
CO-FOUNDER

ANTHROPIC

视频作者/频道: Berkeley RDI

发布日期: Fall 2024

视频时长: 约 60 分钟

视频链接: https://www.youtube.com/playlist?list=PLoROMvodv4r0Y23Y0BoGoBGgQ1zmU_MT_

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言: Anthropic 与 AI 安全	2
1.1 本章小结	2
2 Agent 能力的评估	2
2.1 为什么需要评估 Agent 能力	2
2.2 评估的维度	2
2.3 评估方法论	2
2.4 本章小结	3
3 Responsible Scaling Policy (RSP)	3
3.1 RSP 的核心框架	3
3.2 RSP 的运作机制	3
3.3 RSP 的意义	3
3.4 本章小结	3
4 Long-term Benefit Trust	3
5 总结与延伸	4
5.1 核心要点	4
5.2 拓展阅读	4

1 引言：Anthropic 与 AI 安全

Ben Mann 是 Anthropic 的联合创始人之一，曾是 GPT-3 论文的首批作者。Anthropic 成立于 2021 年，致力于构建安全的 AI 系统。本次讲座聚焦于两个核心问题：如何**衡量** AI Agent 的能力？如何基于能力评估制定**负责的扩展政策**？

Anthropic 的研究谱系

Anthropic 的研究覆盖：Transformer 电路可解释性（理解模型内部机制）、Constitutional AI（让 AI 根据原则自我修正）、Claude 系列模型的开发与部署、Responsible Scaling Policy 的制定。

1.1 本章小结

Anthropic 的核心理念是：AI 能力越强，安全措施必须越严格。衡量能力是制定安全措施的前提。

2 Agent 能力的评估

2.1 为什么需要评估 Agent 能力

评估的双重目的

1. **了解进展**：量化 Agent 在各类任务上的能力水平
2. **预判风险**：识别接近危险阈值的能力维度，提前部署安全措施

2.2 评估的维度

- **自主性** (Autonomy)：Agent 能否在无人监督下完成长周期任务？
- **工具使用** (Tool Use)：Agent 能多有效地使用外部工具（代码执行、搜索、API）？
- **说服力** (Persuasion)：Agent 能否影响人类决策？这涉及潜在的操纵风险。
- **CBRN 知识**：Agent 是否具备化学、生物、放射性和核领域的专业知识？
- **网络安全**：Agent 能否发现和利用软件漏洞？

2.3 评估方法论

- 设计真实世界任务（非合成基准），观察 Agent 的端到端表现
- 人类基线对照：让领域专家完成同样任务，比较 Agent 表现
- 关注“尾部能力”：关注模型在极端情况下可能展现的能力

评估的根本困难

评估是对称的——如果我们能评估一个能力，说明我们已经理解了这个能力。但最危险的可能是恰恰是我们尚未识别的能力（unknown unknowns）。

2.4 本章小结

Agent 能力评估需要覆盖自主性、工具使用、社会影响和专业知识等多个维度，且需要超越标准基准测试，关注真实世界表现和尾部风险。

3 Responsible Scaling Policy (RSP)

3.1 RSP 的核心框架

ASL (AI Safety Level) 分级

Anthropic 提出 AI Safety Level 分级系统（类似生物安全等级 BSL）：

- **ASL-1**：无显著风险的 AI 系统
- **ASL-2**：当前大模型水平，需要标准安全措施
- **ASL-3**：具备显著自主能力或专业知识，需要强化安全措施
- **ASL-4+**：接近超人能力，需要极端安全措施

每个级别对应不同的安全要求——部署条件、监控强度、使用限制。

3.2 RSP 的运作机制

1. **定期评估**：每次训练新模型或显著更新时，评估其能力是否跨越 ASL 边界
2. **触发机制**：如果评估显示模型接近下一级能力，暂停部署直到相应安全措施就位
3. **安全投入**：将安全研发预算与模型能力增长挂钩
4. **透明度**：定期发布能力评估报告

3.3 RSP 的意义

为什么 RSP 重要

RSP 的核心贡献是将“模型能力”与“安全措施”显式绑定——不是“先发布再补救”，而是“先确保安全再推进”。这为整个行业提供了一个可操作的安全框架模板。

3.4 本章小结

RSP 通过 ASL 分级和触发机制，实现了“能力驱动的安全升级”。这是目前最具操作性的 AI 安全框架之一。

4 Long-term Benefit Trust

Anthropic 创新性地设立了 Long-term Benefit Trust：随着 AI 变得越来越强大，公司的控制权将逐步移交给没有经济利益、只关注安全和公共利益的独立董事。这是 AI 行业的首个此类治理结构。

治理创新

在 AI 可能成为史上最强大技术之一的背景下，确保控制者的激励机制与公共利益对齐，是长期安全的制度保障。

5 总结与延伸

5.1 核心要点

1. Agent 能力评估需要覆盖多维度，且关注尾部风险和 unknown unknowns
2. RSP 将“能力”与“安全措施”显式绑定，提供可操作的安全升级路径
3. ASL 分级系统为行业提供了安全基准参照
4. 治理结构创新（如 Long-term Benefit Trust）是技术安全之外的制度补充

5.2 拓展阅读

- Anthropic, “Anthropic’s Responsible Scaling Policy,” 2023.
- Anthropic, “The Claude Model Card and Evaluations,” 2024.
- Shevlane et al., “Model Evaluation for Extreme Risks,” 2023.