


课程笔记

# [LLM Agents F24] Open Source & Science in Foundation Models —Percy Liang

五道口纳什 & Codex

2026 年 3 月 28 日



PERCY LIANG



视频作者/频道: Berkeley RDI

发布日期: Fall 2024

视频时长: 约 70 分钟

视 频 链 接: [https://www.youtube.com/playlist?list=PLoROMvodv4r0Y23Y0BoGoBGgQ1zmU\\_MT\\_](https://www.youtube.com/playlist?list=PLoROMvodv4r0Y23Y0BoGoBGgQ1zmU_MT_)

# 目录

|                              |          |
|------------------------------|----------|
| <b>1 引言：开放性为何重要</b>          | <b>2</b> |
| 1.1 本章小结 . . . . .           | 2        |
| <b>2 开源基础模型的价值</b>           | <b>2</b> |
| 2.1 科学研究的必要条件 . . . . .      | 2        |
| 2.2 创新生态 . . . . .           | 2        |
| 2.3 本章小结 . . . . .           | 2        |
| <b>3 Together AI 与去中心化计算</b> | <b>3</b> |
| 3.1 本章小结 . . . . .           | 3        |
| <b>4 AI Agent 中的开源挑战</b>     | <b>3</b> |
| 4.1 本章小结 . . . . .           | 3        |
| <b>5 总结与延伸</b>               | <b>3</b> |
| 5.1 核心要点 . . . . .           | 3        |
| 5.2 拓展阅读 . . . . .           | 3        |

# 1 引言：开放性为何重要

Percy Liang 是 Stanford 计算机科学教授，HELM 基准和 Together AI 的创始人。他从一个尖锐的观察切入：基础模型的能力飞速提升，但**开放性和可访问性却在对称地下降**——从完整的论文、代码、数据、权重，退化为仅有 API 接口。

## 访问塑造研究

我们拥有什么样的访问权限，决定了我们能做什么样的研究。当只有 API 时，我们只能做 prompting 研究；当有完整权重时，我们可以做 fine-tuning、机制解释性、安全审计等深层研究。

## 1.1 本章小结

开放性不仅是价值观问题，更直接影响 AI 研究的深度和方向。封闭 API 限制了科学理解和安全研究的可能性。

# 2 开源基础模型的价值

## 2.1 科学研究的必要条件

- **可复现性**：科学研究的基石是可复现性，封闭模型无法满足
- **可解释性研究**：理解 Transformer 内部机制需要完整的模型权重
- **安全研究**：Red teaming、对齐研究都需要深度模型访问
- **公平评估**：统一评估（如 HELM）需要在标准化条件下运行模型

## HELM：统一的基础模型评估

Holistic Evaluation of Language Models (HELM) 是 Percy Liang 团队构建的大规模评估平台，旨在在统一条件下比较不同模型的能力。这需要深度模型访问才能实现公平、全面的评估。

## 2.2 创新生态

- 开源模型催生了繁荣的微调和应用生态（Llama 系列的社区贡献）
- 小规模研究者和创业公司可以在开源模型基础上创新
- 去中心化的计算资源池化可以实现超出个体能力的研究

## 2.3 本章小结

开源基础模型是科学研究、安全审计、公平评估和创新生态的必要条件。

## 3 Together AI 与去中心化计算

Percy Liang 联合创立的 Together AI 致力于降低 AI 研究和部署的门槛：

- 提供开源模型的高效推理和微调服务
- 探索去中心化计算——让多方贡献算力，协同完成大规模训练
- 在小规模实验中保持 “scale mindset”——虽然资源有限，但设计时考虑可扩展性

### 3.1 本章小结

去中心化计算和高效推理是让更多人参与 AI 研究的关键基础设施。

## 4 AI Agent 中的开源挑战

### Agent 系统的额外复杂性

Agent 系统不仅涉及模型本身，还涉及工具、环境、编排框架。即使模型开源，如果工具接口、评估环境或编排逻辑不开放，研究者仍然无法复现和改进 Agent 系统。

- Agent 评估需要标准化的环境和基准
- 多模型组合系统的开源需要新的方法论
- 算力挑战在 Agent 系统中更加突出（长周期、多轮交互）

### 4.1 本章小结

Agent 系统的开源不仅需要开放模型权重，还需要开放工具、环境和评估基础设施。

## 5 总结与延伸

### 5.1 核心要点

1. 基础模型的开放性正在下降，这限制了科学研究和安全审计
2. 开源模型是可复现性、可解释性研究和公平评估的必要条件
3. 去中心化计算可以让更多人参与大规模 AI 研究
4. Agent 系统的开源需要覆盖模型、工具、环境和评估全栈

### 5.2 拓展阅读

- Liang et al., “Holistic Evaluation of Language Models,” 2022.
- Bommasani et al., “On the Opportunities and Risks of Foundation Models,” 2021.