

课程笔记

[LLM Agents F24] Agents for Software Development —Graham Neubig

基于公开课程资料整理

Fall 2024



GRAHAM
NEUBIG

Carnegie
Mellon
University

视频作者/频道: Berkeley RDI

发布日期: Fall 2024

视频时长: 约 70 分钟

视频链接: https://www.youtube.com/playlist?list=PLoROMvodv4r0Y23Y0BoGoBGgQ1zmU_MT_

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言：软件开发 Agent	2
1.1	本章小结	2
2	软件开发 Agent 的架构	2
2.1	核心组件	2
2.2	OpenHands 架构	2
2.3	本章小结	2
3	SWE-bench：软件工程基准	3
3.1	任务定义	3
3.2	当前表现	3
3.3	本章小结	3
4	关键技术挑战	3
4.1	代码库导航	3
4.2	长 Horizon 规划	3
4.3	测试生成	3
4.4	本章小结	4
5	总结与延伸	4
5.1	核心要点	4
5.2	拓展阅读	4

1 引言：软件开发 Agent

Graham Neubig 是 CMU 教授，同时是 All Hands AI 的首席科学家，维护着开源编程 Agent 框架 **OpenHands** (原 OpenDevin)。本讲系统介绍了 AI Agent 在软件开发中的应用。

为什么软件开发是 Agent 的理想应用场景

软件开发天然具备 Agent 成功所需的条件：明确的反馈信号（测试通过/失败）、丰富的工具生态（编辑器、终端、浏览器、版本控制）、大量公开训练数据（GitHub）、以及明确的成功标准。

1.1 本章小结

软件开发 Agent 是 LLM Agent 最成熟的应用方向之一，因为它具备完善的反馈机制和工具生态。

2 软件开发 Agent 的架构

2.1 核心组件

软件开发 Agent 的四大能力

1. **代码理解**：浏览和理解大型代码库（数千文件）
2. **代码生成**：编写新代码或修改现有代码
3. **测试与调试**：运行测试、分析错误、迭代修复
4. **环境交互**：使用终端、浏览器、文件系统等开发工具

2.2 OpenHands 架构

OpenHands 提供完整的软件开发 Agent 平台：

- 沙箱化的开发环境（Docker 容器）
- Agent 可以访问终端、代码编辑器、浏览器
- 支持多种 LLM 后端
- 支持 ReAct 风格的推理-行动循环

2.3 本章小结

软件开发 Agent 需要综合代码理解、生成、测试和环境交互四大能力，OpenHands 提供了统一的平台。

3 SWE-bench: 软件工程基准

3.1 任务定义

- 给定一个 GitHub 仓库和一个 issue (bug report 或 feature request)
- Agent 需要理解代码库、定位相关文件、编写修复补丁
- 通过仓库中的测试用例验证补丁正确性

3.2 当前表现

- SWE-bench Lite (300 个较简单的问题): 最好的 Agent 约 40-50% 解决率
- SWE-bench Full (2,294 个问题): 解决率更低
- 人类软件工程师作为对照组的表现也不是 100%

SWE-bench 的局限

SWE-bench 只覆盖了 bug fix 和 feature implementation, 不涉及软件设计、需求分析、代码审查、部署运维等软件工程的其他环节。完整的软件开发自动化还有很长的路要走。

3.3 本章小结

SWE-bench 是当前最重要的软件开发 Agent 基准, 但只覆盖了软件工程的一小部分。

4 关键技术挑战

4.1 代码库导航

- 真实项目有数千个文件, Agent 需要高效定位相关代码
- 搜索策略: 关键词搜索、语义搜索、调用图分析
- 上下文窗口限制: 无法将整个代码库放入 LLM

4.2 长 Horizon 规划

- 复杂修复可能需要数十步操作
- 错误会累积, 需要及时发现和纠正
- 需要在探索和利用之间平衡

4.3 测试生成

- Agent 不仅要写代码, 还要写测试来验证自己的修改
- 高质量的测试生成仍然是开放问题

4.4 本章小结

代码库导航、长 horizon 规划和测试生成是当前软件开发 Agent 的三大技术瓶颈。

5 总结与延伸

5.1 核心要点

1. 软件开发是 LLM Agent 最成熟的应用方向之一
2. OpenHands 提供了完整的开源软件开发 Agent 平台
3. SWE-bench 是标准评测基准，当前最佳约 40-50% 解决率
4. 代码库导航、长 horizon 规划和测试生成是核心挑战
5. 完整的软件开发自动化还需要覆盖设计、审查、部署等环节

5.2 拓展阅读

- Jimenez et al., “SWE-bench: Can Language Models Resolve Real-World GitHub Issues?” ICLR 2024.
- Wang et al., “OpenHands: An Open Platform for AI Software Developers as Generalist Agents,” 2024.