


课程笔记

[LLM Agents F24] Enterprise GenAI Trends & AI Agents —Burak Gokturk

基于公开课程资料整理

Fall 2024



BURAK GOKTURK
VP, ML, SYSTEMS, AND
CLOUD AI RESEARCH



视频作者/频道: Berkeley RDI

发布日期: Fall 2024

视频时长: 约 70 分钟

视频链接: https://www.youtube.com/playlist?list=PLoROMvodv4r0Y23Y0BoGoBGgQ1zmU_MT_

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：企业视角下的 GenAI 趋势	2
1.1 本章小结	2
2 企业 GenAI 的关键趋势	2
2.1 AI 民主化	2
2.2 数据需求降低	2
2.3 模型快速迭代	2
2.4 多模态融合	2
2.5 成本与延迟持续下降	3
2.6 本章小结	3
3 搜索 + LLM：企业的杀手级应用	3
3.1 本章小结	3
4 构建 AI Agent 的关键模块	3
4.1 Vertex AI 平台架构	3
4.2 Gemini 的差异化	3
4.3 本章小结	4
5 对学生和创业者的建议	4
6 总结与延伸	4
6.1 核心要点	4
6.2 拓展阅读	4

1 引言：企业视角下的 GenAI 趋势

Burak Gokturk 是 Google 的工程副总裁。本讲不深入算法细节，而是从**企业市场**的宏观视角审视 GenAI 的发展趋势，为学生和创业者提供实用的方向指引。

从 PhD 到产业的视角转变

Burak Gokturk 以自己的 PhD 经历开场：当年神经网络被认为“不如 SVM”，训练 50 个病人的 CT 数据需要 42 秒就觉得太慢。如今大模型训练动辄数周。一个有趣的担忧是：训练周期过长导致研究者获取直觉的速度变慢了。

1.1 本章小结

AI 的发展速度远超预期，从学术界到企业界都在经历范式转变。

2 企业 GenAI 的关键趋势

2.1 AI 民主化

开发者取代 AI 专家

过去构建 AI 应用需要数据科学家和 ML 专家；如今任何开发者——甚至中学生——都可以用 LLM API 构建 AI 应用。这将 AI 开发者群体扩大了 100 倍以上，是 AI 应用爆发式增长的根本原因。

2.2 数据需求降低

- 过去企业需要花费数月甚至数年收集标注数据
- 大模型已经包含海量预训练知识，fine-tuning 所需数据量大幅减少
- 企业可以在数天内启动 AI 项目，而非数年

2.3 模型快速迭代

- 每隔几周就有新模型发布，排行榜不断变化
- 企业关注**平台**而非单个模型——需要能灵活切换模型的基础设施
- 18 个月前只有一个顶级模型（GPT-4），如今有多个旗鼓相当的选择

2.4 多模态融合

- 单模态模型正在被多模态模型取代（Gemini 原生支持文本、图像、音频、视频）
- 企业对多模态输入（文档中的图表、视频内容分析）需求日增

2.5 成本与延迟持续下降

- API 调用成本已下降约 1.5 个数量级
- 延迟下降使更多实时应用成为可能
- 稀疏 MoE 模型（只激活部分参数）进一步降低推理成本
- 有趣发现：运行某些 API 模型比运行等效开源模型更便宜（因省去运维成本）

2.6 本章小结

企业 GenAI 的核心趋势：AI 民主化、数据门槛降低、模型快速迭代、多模态融合、成本持续下降。

3 搜索 + LLM：企业的杀手级应用

Grounding with Search

几乎每个企业用例都在结合 LLM 和搜索：

- LLM 的知识有时效性限制——需要搜索获取最新信息
- LLM 会产生幻觉——需要搜索做事实验证
- LLM 擅长推理但缺乏引用——搜索提供精确的来源引用

这使得 RAG（检索增强生成）成为企业 AI 应用的标配架构。

3.1 本章小结

搜索 + LLM 是企业最普遍的 GenAI 应用模式，解决了时效性、幻觉和引用三大痛点。

4 构建 AI Agent 的关键模块

4.1 Vertex AI 平台架构

Google Vertex AI 的设计体现了企业 AI 平台的共性需求：

- **芯片层**：GPU/TPU 选择灵活性（当前全球芯片严重短缺）
- **模型层**：第一方 + 第三方 + 开源模型的统一接口
- **工具层**：Model Builder 和 Agent Builder 提供定制和编排能力
- **应用层**：搜索、对话、数据分析等垂直应用

4.2 Gemini 的差异化

- 原生多模态（从训练开始就混合多种模态）
- 超大上下文窗口（实验中已达 1000 万 token）
- Needle-in-a-haystack 测试：在超长上下文中精确检索信息

4.3 本章小结

企业 AI 平台需要在芯片、模型、工具和应用各层提供选择灵活性。

5 对学生和创业者的建议

- 研究方向：如何为特定用例定制大模型？如何用长上下文替代传统搜索？
- AI 领域最需要**创造力**——不仅是技术能力，还需要跨学科思维
- 建议在 AI 之外学习人文、艺术或其他科学，培养创造性思维

6 总结与延伸

6.1 核心要点

1. AI 民主化使开发者群体扩大 100 倍，驱动应用爆发
2. 企业关注平台而非单一模型，需要灵活切换能力
3. 搜索 + LLM 是企业最普遍的应用模式
4. API 成本持续下降，多模态和稀疏模型是关键趋势
5. 创造力和跨学科思维对 AI 从业者越来越重要

6.2 拓展阅读

- Google, “Gemini: A Family of Highly Capable Multimodal Models,” 2023.
- Kamradt, “Needle in a Haystack - Pressure Testing LLMs,” 2023.