

课程笔记

[LLM Agents F25] Agentic AI Safety Security —Dawn Song

五道口纳什 & Codex

2026 年 3 月 28 日



UC Berkeley Center for Responsible,
Decentralized Intelligence

AGENTIC AI MOOC

AGENTIC AI SAFETY &
SECURITY

DECEMBER 8, 2025



Dawn Song
Professor; Berkeley RDI
Co-Director
UC Berkeley

视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

视频链接: 未填写

目录

1	引言	2
2	Agentic AI 的安全威胁全景	2
3	攻击面分析	2
4	防御原则与机制	2
5	总结与延伸	2
5.1	拓展阅读	2

1 引言

本讲由 UC Berkeley 教授 Dawn Song 主讲，作为 Fall 2025 Agentic AI 系列的开篇，讨论 Agentic AI 的安全与安保问题。

2 Agentic AI 的安全威胁全景

Agent 安全的独特挑战

Agent 不仅处理输入输出，还**采取行动**影响外部世界。这使得安全问题从“输出有害内容”升级为“执行有害操作”。

3 攻击面分析

包括 Prompt 注入（直接/间接）、供应链攻击、数据投毒、工具滥用等。Agent 的多步交互大幅增加了攻击面。

4 防御原则与机制

纵深防御、最小权限、安全设计。具体机制：模型加固、输入清洗、动作策略执行、输出护栏、持续监控。

5 总结与延伸

Agentic AI 安全需要系统性的纵深防御策略，从模型层到系统层全方位保护。

5.1 拓展阅读

- DecodingTrust: LLM 可信度评估
- AgentExploit: 黑盒 Agent 红队测试