

课程笔记

[LLM Agents F25] Predictable Noise in LLM Benchmarks —Sida Wang

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqhq1025/ai-course-notes>

目录

1	引言	2
2	基准测试的噪声来源	2
3	改进评估的方法	2
4	总结与延伸	2

1 引言

本讲由 Sida Wang 主讲，深入分析 LLM 基准测试中的可预测噪声问题。

2 基准测试的噪声来源

LLM 基准中的噪声

- **数据污染**：测试数据出现在训练集中
- **评估方差**：采样、Prompt 格式、温度参数带来的随机性
- **过拟合**：针对特定基准优化而非真实能力提升
- **评分标准模糊**：开放式任务的评估主观性

3 改进评估的方法

更可靠的评估策略

- 持续更新基准以防泄露
- 统计严格的置信区间报告
- 多维度评估而非单一分数
- 人类评估作为锚点

4 总结与延伸

理解和量化基准测试中的噪声对于正确解读 LLM 进展至关重要。社区需要更严格的评估方法论。