

课程笔记

[LLM Agents F25] Post-Training Verifiable Agents —Jiantao Jiao

基于公开课程资料整理

2025



UC Berkeley Center for Responsible,
Decentralized Intelligence

AGENTIC AI MOOC
POST-TRAINING
VERIFIABLE AGENTS
SEPTEMBER 29, 2025


Jiantao Jiao
Director of Research & Distinguished Scientist


视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	可验证性的重要性	2
3	后训练中的验证方法	2
4	总结与延伸	2

1 引言

本讲由 UC Berkeley 的 Jiantao Jiao 教授主讲，讨论如何通过后训练方法构建可验证的 Agent。

2 可验证性的重要性

为什么 Agent 需要可验证

Agent 采取真实行动，错误可能造成不可逆后果。可验证性提供了一种确保 Agent 行为正确的机制。

3 后训练中的验证方法

- **形式化验证**：数学证明 Agent 行为满足特定属性
- **运行时验证**：在执行过程中检查约束条件
- **基于奖励的验证**：利用可验证的奖励信号进行 RL 训练

验证的可扩展性挑战

形式化验证在简单系统上可行，但对复杂的 LLM Agent 系统，完整的形式化验证仍然极具挑战。需要在严格性和可扩展性之间找到平衡。

4 总结与延伸

可验证的 Agent 是实现可信 AI 的关键。后训练方法通过将验证信号融入训练过程，提供了一条务实的路径。