

课程笔记

[LLM Agents F25] LLM Agents Overview —Yann Dubois

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言	2
2	LLM Agent 的发展脉络	2
3	Agent 的核心组件	2
4	开放挑战	2
5	总结与延伸	2
5.1	拓展阅读	2

1 引言

本讲由 Yann Dubois 主讲，作为 Fall 2025 系列的总结，全面综述 LLM Agent 的现状与未来。

2 LLM Agent 的发展脉络

Agent 发展时间线

- 2023: ReAct、AutoGPT、BabyAGI 等早期框架
- 2024: 工具使用标准化、Agent 评估基准成熟
- 2025: 推理模型 + Agent、多模态 Agent 产品化

3 Agent 的核心组件

Agent 技术栈

- **基础模型**: 推理能力、指令跟随、工具使用
- **记忆系统**: 短期/长期记忆、RAG
- **工具接口**: API 调用、代码执行、浏览器控制
- **规划与搜索**: 分层规划、树搜索、反思
- **评估框架**: SWE-Bench、WebArena、OS-World 等

4 开放挑战

当前的关键瓶颈

1. 长时间跨度任务的可靠性
2. Agent 的安全性和可控性
3. 训练数据的稀缺
4. 评估的标准化和可复现性
5. 成本效益的优化

5 总结与延伸

LLM Agent 正处于从研究原型到实际产品的关键转折点。推理能力的提升、多模态支持的完善和安全机制的建立将决定其发展速度。

5.1 拓展阅读

- 本系列所有讲座的参考文献

- Agent 综述论文（多篇）
- Berkeley RDI LLM Agents 课程主页