

课程笔记

[LLM Agents SP25] Abstraction & Discovery with LLM Agents —Swarat Chaudhuri

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1 引言：LLM 作为科学与数学发现的工具	2
1.1 LLM Agent 在发现中的三大优势	2
2 AI for Math：形式化推理与 LLM Agent	2
2.1 纯神经方法的局限	2
2.2 形式化表示：替代方案	2
2.2.1 Lean 证明助手工作原理	2
2.3 Copra：基于 LLM Agent 的定理证明	3
2.4 层次化证明：抽象的力量	3
2.5 应用：编译器形式化验证	4
2.6 本章小结	4
3 AI for Science：LLM 引导的科学发现	4
3.1 从符号回归到 LLM 引导进化	4
3.2 LaSR：概念引导的符号回归	5
3.3 实验结果	5
3.4 新发现：LLM 缩放定律	5
3.5 本章小结	6
4 总结与延伸	6
4.1 核心信息	6
4.2 拓展阅读	6

1 引言：LLM 作为科学与数学发现的工具

本讲由 UT Austin 教授 Swarat Chaudhuri 主讲，重点介绍 LLM 在数学发现和科学发现中的应用，特别强调 LLM 的**抽象能力**如何加速发现过程。

数学发现与科学发现的流程

数学发现：建模 → 猜想 → 严格推理（证明）→ 反例/新猜想 → 迭代循环。

科学发现：理论构建 → 假设提出 → 实验设计 → 实验验证 → 新数据 → 新理论。

AI for Math 旨在自动化证明过程；AI for Science 旨在自动化假设生成和实验设计。

1.1 LLM Agent 在发现中的三大优势

1. **搜索引导**：LLM 内部蕴含大量先验知识，可引导在巨大假设空间中的搜索方向
2. **经验学习**：LLM Agent 可与环境交互，从经验中学习（放入 Prompt 或通过 RL 调整权重）
3. **抽象能力**：LLM 可以发现和构造新概念与新工具——这是一个全新但极具潜力的方向

2 AI for Math：形式化推理与 LLM Agent

2.1 纯神经方法的局限

近年来 LLM 在数学竞赛中表现出色（如 O1 在 AMC 2024 中的显著提升、AlphaProof 在 IMO 中获得银牌级表现），但纯神经方法存在根本性弱点：

纯语言模型做数学的两个根本问题

1. **数据稀缺**：严格数学推理需要大量高质量推理轨迹或高质量奖励函数，超出竞赛/高中水平后难以仅靠人类数据获取
2. **自然语言推理难以验证**：语言推理的正确性无法被形式化检验，在边界情况关键的实际系统中尤为危险

2.2 形式化表示：替代方案

形式化方法的核心思路

1. **自动形式化**（Autoformalization）：将非形式化的数学陈述转换为 Lean、Coq、Isabelle 等形式化语言
2. **神经证明器**（Neural Prover）：在形式化环境中搜索证明策略（tactics）序列
3. **验证**：形式化证明可被证明助手自动检验——这解决了验证难题
4. **合成数据**：可大量生成候选证明并立即获得正确性反馈，将证明问题转化为类游戏任务

2.2.1 Lean 证明助手工作原理

Lean 是一个状态机：

- **状态 (State)**: 当前需要证明的目标 (goals) 和上下文假设
- **动作 (Tactic)**: 简化规则, 应用后改变证明状态
- **目标**: 找到一系列 tactics, 使所有 goals 被消解, 到达 QED 状态

例如证明“若 x 为偶数, 则 x^2 为偶数”: 初始状态包含目标 $x^2 \bmod 2 = 0$, 通过 `intro`、`rw` 等 tactics 逐步简化, 最终达到 $0 = 0$ 即 QED。

2.3 Copra: 基于 LLM Agent 的定理证明

Copra 系统架构

Copra 是一种基于上下文学习 (In-Context Learning) 的定理证明 Agent:

1. 使用前沿 LLM (如 GPT-4) 预测下一步 tactic
2. 将证明状态和搜索历史作为 Prompt 提供给 LLM
3. 执行预测的 tactic, 获取新状态或错误反馈
4. 将错误信息反馈到 Prompt 中, 让 LLM 修正策略
5. 外层使用深度优先搜索 (DFS) 组织整个证明过程

Copra 的核心优势:

- **无需额外训练**: 直接利用预训练 LLM 的能力
- **即时受益于 LLM 进步**: 从 GPT-4 到 O1/O3 的升级直接提升性能
- **融合自然语言与形式语言推理**
- **无需训练语料**: 适用于全新的研究问题
- **证明助手反馈提供接地 (grounding)**: 防止幻觉

2.4 层次化证明: 抽象的力量

LLM 驱动的层次化证明分解

对于复杂定理 (如 IMO 问题), Copra 可扩展为层次化求解:

1. 让 LLM 生成非形式化的证明计划 (informal proof plan)
2. 基于计划将定理分解为多个子目标 (sub-goals) 的形式化表述
3. 用 Copra 逐个证明子目标
4. 将已证明的子目标放入上下文, 证明完整定理

关键洞察: LLM 不仅可以预测低级证明步骤, 还可以进行**高级抽象推理**——这一切通过 Prompt 工程即可实现, 无需额外训练。

以 IMO 题目“证明 $\frac{21n+4}{14n+3}$ 对所有自然数 n 不可约”为例: O3 将问题分解为关于 GCD 的三个子引理, Copra 分别证明后, 再组合证明完整定理。

2.5 应用：编译器形式化验证

形式化验证的实际价值

形式化验证可以数学地证明系统的正确性、安全性和性能。美国国防部曾使用形式化验证的 Linux 内核 (seL4) 部署在无人机上，红队 6 周内无法攻破。

历史上形式化验证极其昂贵，但 AI for Math 的兴起正在**根本性改变成本-收益方程**。

讲座演示了一个简单的算术表达式编译器验证案例 (Coq 语言)：

- 源语言：递归定义的算术表达式（加法、乘法）
- 目标语言：基于栈机的指令列表
- 编译器正确性定理：编译后执行结果 = 源语言求值结果
- Copra 无法一次性证明，但通过 LLM 发明辅助引理（单条指令编译正确性），再组合完成完整证明

2.6 本章小结

- LLM Agent 用于数学发现极具前景，上下文学习方法已展现强大能力
- 证明助手的反馈对于接地 (grounding) 至关重要
- 高级 Agent 设计可组合形式化、层次化规划和低级证明生成
- 目前仍需 Agent 架构，纯训练方法尚未达到足够水平

3 AI for Science: LLM 引导的科学发现

3.1 从符号回归到 LLM 引导进化

符号回归问题

符号回归 (Symbolic Regression) 是根据经验观测数据发现方程的任务。例如，给定火星运动的测量数据，发现开普勒第三定律。

传统方法（如遗传编程 PySR）维护候选表达式种群，通过变异和交叉进化。LLM 可通过提供先验科学知识来增强这一过程。

3.2 LaSR: 概念引导的符号回归

LaSR (Language-guided Symbolic Regression) 框架

LaSR 联合推断程序假设和高级概念:

$$P(\pi, C \mid D) \propto P(D \mid \pi) \cdot P(\pi \mid C) \cdot P(C)$$

其中:

- $P(D \mid \pi)$: 程序 π 对数据 D 的似然 (通过执行程序计算)
- $P(\pi \mid C)$: 给定概念 C 下程序的概率 (LLM 的背景知识)
- $P(C)$: 概念的先验分布 (LLM 的科学知识)

LaSR 的工作流程:

1. 维护候选程序 (方程) 种群
2. **假设进化**: 经典符号变异 + LLM 引导变异 (基于概念库)
3. **适应度评估**: 程序对数据的拟合程度
4. **概念抽象**: LLM 将程序池抽象为自然语言高级描述 (如 "指数增长/衰减"、"幂律")
5. **概念进化**: LLM 组合现有概念生成新概念 (如 "指数增长" + "温度依赖" $\rightarrow$ "Boltzmann 分布")
6. 概念库反馈到假设进化, 形成闭环

3.3 实验结果

- 在费曼方程发现任务上, LaSR 优于纯遗传编程和无概念学习的版本
- 即使使用本地语言模型 (非前沿模型), 也能超过纯遗传编程
- 用户提示 (hints) 可提供额外收益
- LaSR 发现的库仑定律表达式仅需 4 步化简即可得到标准形式, 而 PySR 得到的等价表达式需要大量化简

3.4 新发现: LLM 缩放定律

为验证方法不只是 "记忆已知公式", 团队用 LaSR 发现了新的 LLM 缩放定律, 纳入了 **few-shot 样本数** 参数:

有趣发现

大量 few-shot 样本对低能力模型反而有害, 但一旦模型能力超过阈值, 更多 shots 带来更好表现。将此发现与 Chinchilla 定律结合, 得到了更准确的缩放定律。

3.5 本章小结

- LLM 引导的进化是经验科学的强大工具
- LLM 的抽象能力（概念发现）可进一步增强发现过程
- 可扩展到视觉高维输入（使用 VLM）
- 开放挑战：假设验证、超越自然语言的概念表示、更大搜索空间的扩展

4 总结与延伸

4.1 核心信息

LLM Agent 在数学发现和科学发现中具有巨大潜力，其优势不仅在于强大的搜索能力和先验知识，更在于**抽象能力**——发现新概念、构建层次化解决方案。关键设计模式包括：

1. **LLM + 形式化验证**：LLM 生成证明步骤，证明助手提供接地反馈
2. **层次化分解**：LLM 进行高级规划和子问题分解
3. **概念引导进化**：LLM 抽象和组合高级概念，引导搜索方向
4. **Prompt 工程的灵活性**：无需额外训练即可实现质变的能力提升

4.2 拓展阅读

- Copra: LLM Agent 定理证明 (Conference on Language Models, 2024)
- LaSR: 概念引导的符号回归 (NeurIPS 2024)
- FunSearch (DeepMind): LLM 引导的进化搜索
- AlphaProof: RL + 形式化数学
- “AI for Math” 综述论文 (Dawn Song 等参与)