

课程笔记

[LLM Agents SP25] Multimodal Agents: Perception to Action —Caiming Xiong

基于公开课程资料整理

2025



视频作者/频道: Berkeley RDI

发布日期: 2025

视频时长: 约 60 分钟

项目主页: <https://github.com/hqh1025/ai-course-notes>

目录

1	引言：多模态 AI Agent 的时代	2
2	环境与基准测试	2
2.1	OS-World: 真实计算机环境	2
2.2	评估方法	2
3	数据获取	2
3.1	Agent 数据的稀缺性	2
3.2	合成数据与自动化	2
4	模型架构	3
4.1	视觉-语言-动作模型	3
4.2	本章小结	3
5	总结与延伸	3
5.1	核心信息	3
5.2	拓展阅读	3

1 引言：多模态 AI Agent 的时代

本讲由 Salesforce 的 Caiming Xiong 主讲，介绍多模态 Agent 从感知到行动的全链路，重点讨论环境基准、数据获取和模型构建。

为什么需要多模态 Agent

我们希望 Agent 不仅能阅读文本，还能看、听、说、感知。大多数计算机任务涉及多个应用和界面，需要视觉-语言-动作模型（VLA）来自动化数字交互。

2 环境与基准测试

2.1 OS-World：真实计算机环境

OS-World 的核心特性

- 首个可扩展的真实计算机环境，用于多模态 Agent 开发与基准测试
- 基于虚拟机的安全隔离环境，支持自由的键鼠控制
- 可配置的任务设置：初始状态、后处理、评估脚本
- 支持开放式计算机任务，覆盖多种应用
- 369 个真实世界任务（含跨应用 workflows、不可能任务等）

Agent 与环境的交互循环：

1. 接收用户指令和环境观察（截图、可访问性树、终端输出等）
2. 生成可执行动作（点击、输入、滚动等，以代码字符串表示）
3. 虚拟机执行动作，返回新观察
4. 重复直到任务完成或达到最大步数

2.2 评估方法

采用**基于执行的奖励函数**：每个任务有自定义评估脚本，支持部分完成评分，适应多样化的开放式任务。

3 数据获取

3.1 Agent 数据的稀缺性

传统方法（人工标注）成本高、耗时长。需要探索更高效的数据获取策略。

3.2 合成数据与自动化

通过环境交互自动收集轨迹数据，结合人工审核确保质量。

4 模型架构

4.1 视觉-语言-动作模型

将视觉编码器与语言模型结合，使 Agent 能基于截图和文本理解生成精确的界面操作。

当前 Agent 的局限

即使是最先进的多模态模型（GPT-4V 等），在 OS-World 基准上的成功率仍然很低（个位数百分比），距离实用还有很大距离。

4.2 本章小结

多模态 Agent 需要三大支柱：可交互的真实环境、高质量的训练数据、强大的视觉-语言-动作模型。OS-World 提供了统一的开发和评估平台。

5 总结与延伸

5.1 核心信息

多模态 Agent 是下一代 AI 应用的核心方向。构建可靠的 Agent 需要真实、可交互的评估环境，而非静态基准。当前技术距离自动化日常计算机操作仍有显著差距。

5.2 拓展阅读

- OS-World：真实计算机环境基准
- WebArena / VisualWebArena：Web Agent 评估
- SWE-Bench：软件工程 Agent 评估